



23^a Conferencia Internacional sobre Información e Ingeniería Inteligentes y Basadas en el Conocimiento
23^a Conferencia Internacional sobre Información e Ingeniería Inteligentes y Basadas en el Conocimiento
Sistemas

S PRAR: una nueva clasificación de minería de reglas de asociación relacional S PRAR: Un nuevo modelo de clasificación de minería de reglas de asociación relacional aplicado para la predicción del rendimiento académico modelo aplicado para la predicción del rendimiento académico

Gabriela Czibulaa, Andrei Mihaia, Liana Maria Criveia,
Gabriela Czibulaa, Andrei Mihaia, Liana Maria Criveia,

aDepartamento de Ciencias de la Computación, Universidad Babes,-
Bolyai, Cluj-Napoca, Romania
Rumania 1, M. Kogalniceanu Street, 400084, Cluj-Napoca, Rumania

Resumen Resumen

Este artículo analiza el problema de la predicción del rendimiento académico de los estudiantes, un tema cada vez más investigado dentro de la literatura de Minería de datos educativos. Para una mejor comprensión de los fenómenos relacionados con la educación, existe un interés continuo en la literatura sobre minería de datos educativos. Para una mejor comprensión de los fenómenos relacionados con la educación, existe un interés continuo en aplicar métodos de aprendizaje supervisados y no supervisados para obtener información adicional sobre el proceso de aprendizaje de los estudiantes. En la aplicación de métodos de aprendizaje supervisados y no supervisados para obtener información adicional sobre el proceso de aprendizaje de los estudiantes.

El problema de predecir si un estudiante aprobará o reprobará cierta disciplina académica con base en las calificaciones que recibió el estudiante El problema de predecir si un estudiante aprobará o reprobará cierta disciplina académica con base en las calificaciones que recibió durante el semestre es uno difícil, altamente dependiente de varias condiciones como el curso, la cantidad de exámenes durante el semestre es difícil, altamente dependiente de varias condiciones como el curso, la cantidad de exámenes durante el semestre, los profesores y sus exigencias. Proponemos un nuevo modelo de clasificación, S PRAR (Desempeño de los Estudiantes usando Reglas de Asociación Relacional) para predecir el resultado final de un estudiante en una determinada disciplina académica usando predicción usando Reglas de Asociación Relacional (RAR) para predecir el resultado final de un estudiante en una determinada disciplina académica usando reglas de asociación relacional (RAR). Los RAR amplían las reglas de asociación clásicas para expresar varias relaciones entre los atributos de datos. Los experimentos se realizan en tres conjuntos de datos académicos reales recopilados de la Universidad Babes,-Bolyai de Rumania. Los resultados de los experimentos se comparan con el trabajo relacionado existente, siendo superior al desempeño de los predictores de desempeño de los estudiantes propuestos previamente, predictores de rendimiento de los estudiantes propuestos previamente.

© 2019 El (los) autor(es). Publicado por Elsevier B.V. Los
Publicado por Elsevier B.V.

Este es un artículo de acceso abierto bajo la licencia CC BY-NC-ND (<https://creativecommons.org/licenses/by-nc-nd/4.0/>)
Este es un artículo de acceso abierto bajo la licencia CC BY-NC-ND (<https://creativecommons.org/licenses/by-nc-nd/4.0/>)
Revisión por pares bajo la responsabilidad de KES International.

Revisión por pares bajo la responsabilidad de KES International.

Keywords: Minería de datos educativos; predicción del rendimiento de los estudiantes; Aprendizaje supervisado; Reglas de asociación relacional
Palabras clave: Minería de datos educativos; predicción del rendimiento de los estudiantes; Aprendizaje supervisado; Reglas de asociación relacional

1. Introducción 1. Introducción

La minería de datos educativos (EDM) es un dominio de investigación atractivo que lleva la perspectiva de la minería de datos a los entornos educativos. El objetivo principal de los temas de EDM es ofrecer una mejor comprensión de los entornos educativos relacionados con la educación. El objetivo principal de los temas de EDM es ofrecer una mejor comprensión de los fenómenos relacionados con la educación al descubrir patrones ocultos relevantes de conjuntos de datos educativos. Dentro del campo EDM, un fenómeno problemático al descubrir patrones ocultos relevantes de conjuntos de datos educativos. Dentro del campo de EDM, un problema intensamente investigado es el de la predicción del rendimiento de los estudiantes. Intensamente investigado es el de la predicción del desempeño de los estudiantes.

* Autor correspondiente. Tel.: +4-264-405-327; fax: +4-264-591-906.

* Autor correspondiente. Tel.: +4-264-405-327; fax: +4-264-591-906.

* Autor correspondiente. Tel.: +4-264-405-327; fax: +4-264-591-906.

Dirección de correo electrónico:

liana.crivei@cs.ubbcluj.ro Dirección de correo

electrónico: liana.crivei@cs.ubbcluj.ro 1877-0509 © 2019 El (los) autor(es). Publicado por Elsevier B.V.

Publicado por Elsevier B.V. 1877-0509 © 2019 El (los) autor(es). Publicado por Elsevier B.V.
Este es un artículo de acceso abierto bajo la licencia CC BY-NC-ND (<https://creativecommons.org/licenses/by-nc-nd/4.0/>) 1877-0509 ©

Este es un artículo de acceso abierto bajo la licencia CC BY-NC-ND (<https://creativecommons.org/licenses/by-nc-nd/4.0/>)

Revisión por pares bajo la responsabilidad de KES International. (<https://creativecommons.org/licenses/by-nc-nd/4.0/>)

Revisión por pares bajo la responsabilidad de KES International.

10.1016/j.procs.2019.09.156

Detectar patrones significativos de los procesos educativos es de gran interés en entornos académicos, ya que sería útil para comprender las actividades de aprendizaje de los estudiantes, así como para mejorar los resultados de aprendizaje.

Existe una atención considerable por parte de la comunidad de investigación para EDM, ya que extraer conocimiento de los datos educativos es una preocupación importante para las instituciones académicas y también es útil para mejorar sus metodologías y principios didácticos [17].

Las reglas de asociación relacional (RAR) [21] se introdujeron en la literatura de minería de datos como una extensión de las reglas de asociación clásicas con el objetivo de capturar diferentes tipos de relaciones entre los atributos que caracterizan un conjunto de datos. Tanto la minería de reglas de asociación ordinal como relacional se han aplicado con éxito para abordar problemas que van desde tareas de minería de datos (p. ej., detección de defectos de diseño de software [10] o limpieza de datos [5]) hasta clasificación supervisada (p. ej., predicción de defectos de software [16]).

Este artículo aborda el problema de predecir si un estudiante aprobará o reprobará una determinada disciplina académica en función de las calificaciones obtenidas por los estudiantes durante el semestre. El problema tiene una gran relevancia práctica en entornos educativos, ya que podría proporcionar una retroalimentación relevante a los estudiantes que probablemente reprobarán un determinado curso académico. Teniendo tal asesoría durante el semestre, los estudiantes tendrán la posibilidad de prevenir un posible fracaso académico. A pesar de su evidente importancia pragmática, el problema es complejo y difícil, y depende en gran medida de diversas condiciones, como el curso, el número de exámenes durante el semestre, los profesores y sus exigencias. Proponemos un nuevo modelo de clasificación, S PRAR (Predicción del rendimiento de los estudiantes usando reglas de asociación relacional) para predecir el resultado final de un estudiante en una determinada disciplina académica usando reglas de asociación relacional (RAR). Cabe señalar la generalidad del clasificador S PRAR, que no es específico de la tarea de predicción del rendimiento de los alumnos. SPRAR se puede adaptar fácilmente a otros problemas de clasificación.

El modelo de clasificación presentado en el documento es binario (es decir, solo hay dos clases para predecir: pasa o falla), pero el modelo propuesto es general, puede extenderse para un problema de clasificación de múltiples clases (es decir, para predecir la nota final del alumno). Desde una perspectiva de aprendizaje supervisado, el problema de predecir la finalización exitosa de un curso durante un semestre académico es un problema difícil, particularmente debido a la naturaleza desequilibrada de los datos de capacitación (es decir, el número de estudiantes que aprobaron el examen es generalmente mucho mayor que el número de estudiantes que reprobaron el examen). Los experimentos realizados en tres conjuntos de datos reales de la Universidad Babes-Bolyai, Rumanía, destacan la eficacia de la clasificación utilizando SPRAR. La literatura sobre la predicción del rendimiento de los estudiantes revela que el uso de RAR para predecir el rendimiento académico de los estudiantes es un enfoque novedoso.

En resumen, el objetivo de la investigación realizada en el artículo es proponer un modelo de clasificación S PARAR basado en minería RAR para la predicción del rendimiento académico de los estudiantes, como prueba de concepto. Con este objetivo, la prueba de concepto considera solo tres conjuntos de datos de tamaño mediano para resaltar que SPRAR es adecuado para el problema planteado. Si esto se mantiene, el estudio de la aplicación de SPRAR para la predicción del rendimiento de los estudiantes puede extenderse a mayor escala.

El resto del documento está organizado de la siguiente manera. La sección 2 presenta una revisión de la literatura sobre el uso de métodos de aprendizaje supervisado para predecir el rendimiento académico de los estudiantes. Los principales conceptos de fondo sobre la minería RAR se presentan en la Sección 3. La metodología que proponemos para construir el clasificador S PRAR se presenta en la Sección 4, mientras que los resultados experimentales y la comparación con el trabajo relacionado se proporcionan en la Sección 5. Las conclusiones de nuestro documento y las instrucciones para mejorar aún más nuestro trabajo se describen en la Sección 6.

2. Revisión de la literatura

Para evaluar el desempeño de los estudiantes en entornos educativos, describimos a continuación, varias máquinas recientes estudios de investigación del aprendizaje.

AK Pal y S. Pal [18] intentan identificar el clasificador de mayor rendimiento para predecir los logros de los estudiantes en un examen final de aplicación informática. Los autores utilizan tres algoritmos de minería de datos conocidos en su estudio: ID3 (Ditomizador iterativo 3), C4.5 y agregación Bootstrap. Los resultados son efectivos para establecer qué alumnos requieren un asesoramiento especial para mejorar su resultado final en la evaluación. Hajizadeh y Ahmadzadeh [13] intentan identificar los factores que afectan el logro o el fracaso de los estudiantes y que además determinan que los estudiantes no vuelvan a registrarse en un curso en particular. Las técnicas de minería de datos utilizadas en [13] son el descubrimiento y clasificación de reglas de asociación.

Jishan et al. [14] tiene como objetivo aumentar la precisión de la predicción de la calificación final mediante la aplicación de varios modelos de clasificación que incluyen redes neuronales, árboles de decisión y Naive Bayes. Con el fin de lograr un mejor rendimiento para predecir la calificación final de los estudiantes en un curso en particular, se realiza el agrupamiento de ancho igual óptimo para el preprocesamiento de datos y

Se aplica el método de sobremuestreo de minorías sintéticas (SMOTE). Shahiri et al. [22] analizan el desempeño de los Modelos ML anteriormente especificados, así como máquina de vectores de soporte y vecino K-Nearest. Un estudio comparativo es alcanzado con el fin de identificar los atributos que son significativos para la predicción del rendimiento de los estudiantes. Ahmed et al. [1] evaluar varios clasificadores como J48 Decision Tree, Multilayer Perceptron, Naive Bayes y Sequential Minimal Optimización al intentar identificar el algoritmo de mayor rendimiento. Analizan los factores que inciden logro o fracaso académico de los estudiantes con el objetivo de mejorar la calidad del sistema educativo.

Tran et al. [24] intentan predecir el rendimiento de los estudiantes en entornos académicos analizando y comparando un enfoque basado en la regresión y un enfoque basado en el sistema de recomendaciones. Con el fin de mejorar el rendimiento en el escenario de regresión se agregan varias habilidades relacionadas con el curso. Con el objetivo de mejorar el rendimiento general de la predicción, los autores también introducen un método híbrido: una combinación lineal de los dos métodos especificados anteriormente Beaulac y Rosenthal [2] aplicaron bosques aleatorios (RF) para predecir qué estudiantes podrían obtener un Licenciatura basada en los cursos asistidos y completados en los primeros 2 semestres de un año académico. El El conjunto de datos contiene información sobre varios cursos tomados por estudiantes de pregrado en una universidad de Canadá.

Verma et. al presente [23] una técnica de inferencia difusa que se utiliza como herramienta de minería de datos para evaluar y predecir rendimiento de los estudiantes al final de un semestre. Para la predicción del rendimiento en el examen final varios atributos Se consideran: Notas de Semestre Previo (PSM), Expediente Académico Previo (PAR), Asistencia (ATT) y Fin de Notas Semestrales (ESM), considerándose ESM una variable de salida, mientras que las otras tres son variables de entrada. Estudiantes los puntajes se clasifican según su nivel de logro para reducir la tasa de reprobación y mejorar las decisiones académicas. El método de investigación emplea la minería de reglas de asociación difusa que se divide en varias etapas: definición de los conjuntos difusos, la construcción del conjunto de datos de minería a partir de los datos originales se denominó transformación de datos en dominio difuso, normalización difusa y, finalmente, la generación de conjuntos de elementos frecuentes utilizando un algoritmo tipo Apriori. La Tabla 1 resume varios resultados de investigación obtenidos en la literatura EDM para predecir el rendimiento de los estudiantes.

Enfoque	Modelo	Medida	Desempeño		
Hajizadeh y Ahmadzadeh [13]	DT	F-score	0.774		
Amigo y Amigo [18]	0.8	DT	F-score	Tran et	
al. [24]		SVM	RMSE		1.705
Ahmed et al. [1]	J48		Exactitud		0.848
Beaulac y Rosenthal [2]		Precisión	de radiofrecuencia		0.788

Tabla 1: Resultados existentes sobre la predicción del desempeño de los estudiantes.

3. Minería de reglas de asociación relacional

La minería de reglas de asociación (AR) representa una importante técnica de análisis y minería de datos útil en múltiples tareas de aprendizaje automático para descubrir patrones significativos basados en reglas en conjuntos de datos. Reglas de asociación ordinal (OAR) [6] fueron propuestos como una clase particular de AR que expresan relaciones ordinales entre los atributos que caracterizan un conjunto de datos Las reglas de asociación relacional (RAR) [5, 21] se han introducido como una extensión de los OAR y pueden expresar diferentes tipos de relaciones no ordinales entre atributos de datos.

Definimos el concepto de Reglas de Asociación Relacional (RAR) a continuación. Consideremos $D = \{s_1, s_2, \dots, s_q\}$ un conjunto de registros o instancias [8]. Para cada instancia del conjunto de datos, consideramos una secuencia de m atributos $A = (a_1, \dots, a_m)$ que describe el conjunto de datos D . Cada atributo a_i toma valores de un dominio no vacío \mathcal{Y}_i ni difuso \mathcal{Y}_i . Nulo Los valores (vacíos) también pueden incluirse en el dominio \mathcal{Y}_i . El valor del atributo a_i para una instancia s_j se expresa por $\tilde{y}(s_j, a_i)$.

El conjunto de todas las relaciones posibles que no son necesariamente ordinales y pueden definirse entre dos dominios \mathcal{Y}_i y \mathcal{Y}_j se denota por T .

Definición 1. Una regla de asociación relacional [21] es una expresión $(a_{i1} , a_{i2} , a_{i3} , \dots, a_{ih}) \tilde{y} (a_{i1}\tilde{y}_1 a_{i2}\tilde{y}_2 a_{i3} \dots \tilde{y}_h a_{ih})$, donde $\{a_{i1} , a_{i2} , a_{i3} , \dots, a_{ih} \} \tilde{y} A$, $a_{ik} a_{ij} , k, j = 1, \dots, h, k, j \tilde{y} \mathcal{Y}_k \tilde{y} T$ es una relación sobre $\mathcal{Y}_k \times \mathcal{Y}_{k+1}$, donde \mathcal{Y}_k se considera el dominio del atributo a_{ik} .

a) Si $a_{i1} , a_{i2} , \dots, a_{ih}$ no faltan en \tilde{y} instancias del conjunto de datos, llamamos $Supp = \frac{q}{q}$ el apoyo de la regla.

b) Si denotamos por D y D el conjunto de instancias donde $a_1, a_2, a_3, \dots, a_i$ no faltan y todas las relaciones $\bar{y}(s_j, a_1) \bar{y}_1 \bar{y}(s_j, a_2), \bar{y}(s_j, a_2) \bar{y}_2 \bar{y}(s_j, a_3), \dots, \bar{y}(s_j, a_i) \bar{y}_i \bar{y}(s_j, a_i)$ se mantiene para cada instancia s de D entonces llamamos Con $f = \frac{|D|}{q}$ la confianza de la regla.

Los RAR interesantes [21] se definieron como la representación de aquellas reglas que tienen tanto su confianza como su apoyo mayor que o igual a los umbrales mínimos especificados. Con el propósito de minar RARs interesantes un algoritmo tipo Apriori llamado DRAR (Discovery of Relational Association Rules) [9] fue propuesto como una extensión del algoritmo DOAR introducido [6] para descubrir los OAR [8].

El algoritmo DRAR [9] consiste en la generación de RAR a nivel de longitud, comenzando con las reglas de longitud 2. El conjunto de reglas de 2 longitudes se filtra para determinar las reglas interesantes (es decir, aquellas reglas que verifican el soporte mínimo y requisitos de confianza). En un paso dado, para determinar los RAR de cierta longitud l , partimos del conjunto de RAR interesantes de longitud $l-1$ generados en el paso anterior. Este conjunto se utiliza para generar al unir nuevos posibles RAR interesantes, llamadas reglas candidatas que se filtrarán para conservar solo las reglas que son interesantes. Después de la Se genera un conjunto de RAR interesantes de longitud l , el proceso iterativo continúa con la generación de las reglas de longitud $l+1$. El proceso se detiene cuando no se descubren nuevos RAR interesantes [8].

3.1. Ejemplo

Para ejemplificar el concepto de RAR, utilizamos un conjunto de datos generados sintéticamente con cinco instancias y tres atributos denotados por a_1, a_2 y a_3 . El conjunto de datos de muestra y los RAR máximos interesantes descubiertos se dan en Figura 1. Para extraer los RAR interesantes del conjunto de datos, se aplicó el algoritmo DRAR con un soporte mínimo umbral en $\text{Suppmin} = 1$ y el umbral mínimo de confianza en $\text{Con fmin} = 0.4$. Dado que todos los atributos en nuestro experimento tienen valores enteros, se utilizaron dos posibles relaciones binarias entre atributos con valores enteros: \bar{y} y $<$.

No.	a_1	a_2	a_3
1.	7,30	5,00	6,50
2.	10,00	9,90	9,00
3.	7,95	8,30	7,00
4.	8,50	10,00	9,20
5.	10,00	9,50	9,00

Longitud	Regla	Confianza
2	$a_1 \bar{y} a_3$	0.8
3	$a_1 < a_2 \bar{y} a_3$	0.4
3	$a_2 \bar{y} a_3$	0.4

Fig. 1: Conjunto de datos de muestra (izquierda) y RAR máximos interesantes extraídos para $\text{Suppmin} = 1$ y $\text{Con fmin} = 0.4$.

Cada línea de la Tabla 1 describe un RAR de cierta longitud (representado en la primera columna), que tiene la confianza ilustrado en la tercera columna. Por ejemplo, la primera línea de la Tabla 1 se refiere al RAR $a_1 \bar{y} a_3$ de longitud 2 (es decir, la regla contiene dos atributos) con una confianza de **0.8**. Esta regla tiene la siguiente interpretación: el valor del atributo a_1 es mayor o igual que el valor del atributo a_3 en el 80% de las instancias de los datos analizados, es decir, en 4 de 5 instancias.

4. Metodología

El problema de clasificación que estamos abordando en este artículo es un problema de clasificación binaria. Hay dos clases posibles, indicadas a continuación por "+" y "-". Con "+" denotamos la clase correspondiente a los estudiantes que aprobar un determinado curso y las instancias pertenecientes a la clase "+" se denominarán instancias positivas. Por "-" nosotros denota la clase correspondiente a los estudiantes que reprobaron un curso en particular y las instancias que pertenecen a la clase "-" se denominarán instancias negativas.

En un escenario de aprendizaje supervisado para predecir si los estudiantes aprobarán o reprobarán un determinado curso, un conjunto de datos de entrenamiento D está provisto. Se considerará el siguiente modelo teórico. El conjunto de datos de entrenamiento D consta de un conjunto de instancias (estudiantes), $D = \{s_1, s_2, \dots, s_q\}$ y cada instancia s_i describe el desempeño de un estudiante, durante el curso académico semestre, en un curso dado. En consecuencia, cada instancia s_i se caracteriza por un conjunto de atributos $A = \{a_1, a_2, \dots, a_m\}$ representando las calificaciones obtenidas por el estudiante durante las evaluaciones semestrales. Así, cada s_i se visualiza como un vector m -dimensional $s_i = (s_{i1}, s_{i2}, \dots, s_{im})$, si j que representa la nota recibida por el estudiante s_i en el j -ésimo semestre evaluación.

En la Figura 2 se muestra un diagrama de flujo del enfoque S PRAR.

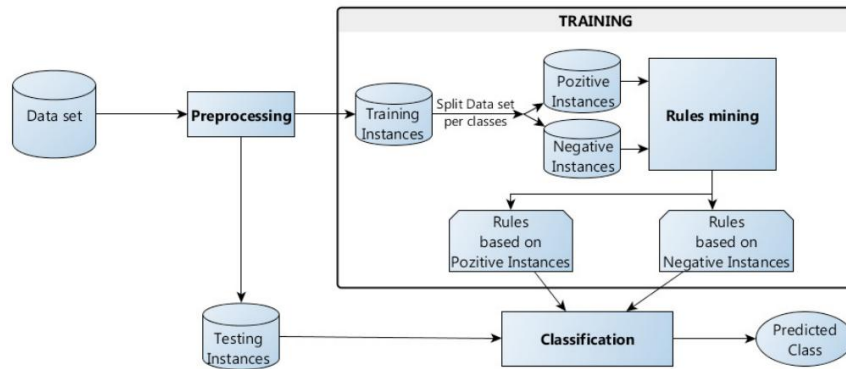


Fig. 2: Diagrama de flujo del enfoque SPRAR.

La idea subyacente detrás de nuestro enfoque se describe brevemente a continuación. El conjunto de datos de entrenamiento D se divide en un subconjunto de instancias positivas, denotado por D^+ y un subconjunto de instancias negativas denotado por D^- . Estos conjuntos se utilizarán para entrenar el clasificador SPRAR. Durante el entrenamiento, los RAR interesantes de los conjuntos D^+ y D^- se descubren utilizando el algoritmo DRAR [9]. Detectamos en los conjuntos de datos de entrenamiento todos los RAR interesantes, con respecto al soporte proporcionado por el usuario y los umbrales de confianza: RAR^+ el conjunto de RAR interesantes descubiertos en D^+ y RAR^- el conjunto de RAR interesantes descubiertos en D^- . Después de completar el entrenamiento, cuando un nuevo estudiante (instancia) s tiene que ser clasificado (como “+” o “-”), dos probabilidades p^+ y p^- (que expresan las probabilidades de que la instancia de consulta pertenezca a las clases positiva y negativa, respectivamente) será computado.

Para clasificar mediante SPRAR una instancia como perteneciente a la clase positiva o negativa, se seguirán los siguientes pasos.

En primer lugar, se aplica un paso de **preprocesamiento de datos**. El paso de preprocesamiento depende en gran medida de los datos y del problema de clasificación abordado. Para el problema abordado en este artículo, con el objetivo de ampliar el conjunto de RAR potenciales que pueden descubrirse en los datos de entrenamiento, el conjunto de atributos A se amplía con cuatro atributos adicionales: $am+1 = 5$, $am+2 = 6$, $am+3 = 7$ y $am+4 = 8$. Dado que el algoritmo DRAR considera solo relaciones binarias entre valores de atributos, los atributos recién agregados ($am+1, \dots, am+4$) permitirán el descubrimiento de relaciones unarias entre atributos valores, también. De esta manera, se identificarán RAR más expresivos y significativos. El segundo paso consiste en **entrenar** el clasificador SPRAR. El paso de entrenamiento consiste en extraer del conjunto de datos de entrenamiento D dos conjuntos de RAR interesantes: RAR^+ y RAR^- . RAR^+ consta de los RAR interesantes descubiertos del subconjunto de D que representan a los estudiantes que aprueban el curso y RAR^- consta de los RAR interesantes descubiertos del subconjunto de D que representan a los estudiantes que no aprueban el curso. Después de que se haya construido el modelo SPRAR durante el paso de entrenamiento, se probará para evaluar su desempeño predictivo. La metodología de clasificación de SPRAR se presentará en la Sección 4.1.

4.1. Clasificación usando SPRAR

En la etapa de clasificación, cuando se debe clasificar una nueva instancia de consulta s , calculamos las probabilidades $p^+(s)$ y $p^-(s)$ de que la instancia de consulta pertenezca a las clases positiva y negativa, respectivamente. Nuestra intuición detrás de la definición de estas probabilidades fue que es muy probable que la similitud de una instancia s con una clase c en particular esté influenciada por las confianzas de las reglas de RAR_c que se verifican en la instancia s , pero también por las reglas de $RAR_{\neg c}$ que no se verifican en la instancia s . Por $\neg c$ denotamos una clase que es lo opuesto a c . Partiendo de esta intuición, $p_c(s)$ medirá no sólo qué tan “cerca” está la instancia s de la clase c , sino también qué tan “lejos” está de la clase opuesta $\neg c$.

Denotemos por n^+ la suma de confianzas de los RARs de RAR^+ y por n^- la suma de confianzas de los RARs de RAR^- . Para la instancia de consulta s y cada regla r (de RAR^+ y RAR^-) nuestro objetivo es calcular el grado en que r se verifica en la instancia s . Así, expresamos por $v^+(s)$ la suma de confianzas de las reglas de RAR^+ que se verifican en s y por $v^-(s)$ la suma de confianzas de las reglas de RAR^- que se verifican en s . Intuitivamente, si todas las reglas de RAR^+ se verifican en s , entonces $v^+(s) = n^+$. De manera similar, por $nv^+(s)$ denotamos la suma de confianzas de las reglas de RAR^+ que no se verifican en s y por $nv^-(s)$ la suma de confianzas de las reglas de RAR^- que no se verifican.

verificado en el s. Obviamente, $nv+(s) = n+ \ddot{y} v+(s)$ y $nv\ddot{y}(s) = n\ddot{y} \ddot{y} v\ddot{y}(s)$. Al calcular la similitud de la instancia s con una clase en particular (por ejemplo, "+"), consideramos no solo la "similitud" de s con la clase, sino también la "disimilitud" de s con la clase opuesta ("- en nuestro ejemplo). $p+(s)$ y $p\ddot{y}(s)$ se calculan como se describe en las fórmulas (1). se puede observar que $p+(s)$ y $p\ddot{y}(s)$ son probabilidades, es decir, $0 \leq p+(s)$, $p\ddot{y}(s) \leq 1$ y $p+(s) + p\ddot{y}(s) = 1$.

$$p+(s) = \frac{v+(s) + nv\ddot{y}(s)}{n+ + n\ddot{y}}, \quad p\ddot{y}(s) = \frac{v\ddot{y}(s) + nv+(s)}{n+ + n\ddot{y}} \quad (1)$$

Cuando la instancia s tiene que ser clasificada, si $p+ \geq 0.5$ entonces la instancia s será clasificada como positiva, de lo contrario será clasificada como negativo.

4.2. Medidas de evaluación

Para evaluar el desempeño del modelo SPRAR en un conjunto de datos de prueba, la matriz de confusión para los dos posibles clases (aprobado y suspenso) se computarán en un conjunto de pruebas, considerando que la clase de aprobado es la positiva y la la clase fail es la negativa. La matriz de confusión consta de los siguientes valores: TP (verdaderos positivos), FP (falsos positivos), TN (verdaderos negativos) y FN (falsos negativos). Usando los valores de la matriz de confusión, evaluación Se determinan las medidas que normalmente se utilizan para la clasificación binaria [12]: precisión (para la clase positiva, $Prec = \frac{TP}{TP+FP}$), sensibilidad (o $\frac{TP}{TP+FN}$), valor predictivo negativo ($\frac{TN}{TN+FP}$), especificidad (o tasa negativa verdadera, $S_{pec} = \frac{TN}{TN+FP}$), F-score+ (F-score para la clase positiva, F) y Área bajo la curva ROC (AUC). Todas estas medidas van de 0 a 1 y los valores más grandes indican mejores clasificadores.

El puntaje F se usa en la literatura para medir el desempeño en el caso de conjuntos de datos desequilibrados, aún así es altamente depende del etiquetado de las clases (es decir, clase positiva o negativa). Así, en el caso de datos desbalanceados, la medida de evaluación que se recomienda como relevante para representar el desempeño de los clasificadores es el Área Bajo la medida de la curva ROC (AUC). La curva ROC (Receiver Operating Characteristics) representa una curva bidimensional gráfica de (1-especificidad, sensibilidad). Para los clasificadores que devuelven directamente la clase, el punto (1- S_{pec} , S_{ens}) está vinculado a los puntos en (0,0) y (1,1), y el área bajo la curva ROC resultante (AUC) se calculará como $\frac{(S_{pec}+S_{ente})}{2}$.

Notamos que para el problema de predecir si un estudiante aprobará o reprobará, el enfoque principal es aumentar la tasa negativa verdadera (especificidad) (es decir, maximizar el número de estudiantes que fueron correctamente clasificados como reprobados), o, de manera equivalente para disminuir la tasa de falsos positivos. Para nuestro problema, tener falsos positivos es un problema más serio que tener falsos negativos, ya que predecir un falso éxito (etiqueta de aprobación) para un estudiante sería un error más grave que predecir un falla falsa (falla de clase).

5. Resultados y discusión

Esta sección presenta los resultados experimentales obtenidos al evaluar el desempeño del clasificador SPRAR, así como como una discusión sobre los resultados y una comparación con trabajos relacionados.

5.1. Conjuntos de datos

En nuestros experimentos se utilizan tres conjuntos de datos reales recopilados de la Universidad Babes, -Bolyai, Rumania. los conjuntos de datos contienen las calificaciones obtenidas por los estudiantes en los cursos de pregrado de CS ofrecidos en el primer, segundo y tercer semestre en Universidad Babes, -Bolyai. Mostramos en la Tabla 2 la descripción de los conjuntos de datos utilizados en nuestros estudios de caso. El completo conjuntos de datos están disponibles en [7]. Para cada conjunto de datos, se ilustra el número de instancias positivas y negativas y el se calcula la dificultad del conjunto de datos. Para medir la dificultad de la tarea de clasificación, la dificultad para un dato se proporciona el conjunto. La dificultad fue introducida por Boetticher [3] y se calcula como el porcentaje de instancias para que el vecino más cercano (ignorando la etiqueta de clase de las instancias) tiene una etiqueta de clase diferente. Al calcular el dificultad de nuestros conjuntos de datos, consideramos solo el porcentaje de entidades de la clase minoritaria (negativa) para las cuales el vecino más cercano es de la clase mayoritaria (positivo).

Datos colocar	# de instancias negativas	# de positivo instancias	Dificultad
D1	49 (12,76%)	335 (87,24%)	51,02%
D2	152 (17,61%)	711 (82,39%)	61,84%
D3	310 (26,86%)	844 (73,14 %)	32,58%

Tabla 2: Descripción de los conjuntos de datos utilizados.

Datos colocar	# de instancias de		# de pruebas instancias	
	entrenamiento	negativo positivo	negativo	positivo
D1	34	260	15	75
D2	112	571	40	140
D3	240	528	70	316

Tabla 3: Descripción de los conjuntos de entrenamiento y prueba.

a1	a2	a3	a4	Nota final	Clase
9.625	10	10	9.25	9	"+"
10	10	10	10	10	
5,5	8,69	10	1	7	
9,625	8,63	9,25	10	6	
2,50	6	5,70	5	5	
2,50	9,50	10	10	4	"-"
2,50	5,71	10	5	4	
2,50	9,64	7	9	4	
5,00	7,96	9,10	8,50	4	
7,3	4,8	4,6	10	4	

Regla	Confianza
a2 y a4	0.8
a2 y 8	0.8
a3 y a4	0.8
a3 y 8	0.8
a1 y 5	0.8
a2 y 5	1
a2 y 6	1
a2 y 7	0.8
a3 y 5	1
a3 y 6	0.8
a3 y 7	0.8
a4 y 5	0.8

Regla	Confianza
a1 < 8	1
a1 < 6	0.8
a1 < 7	0.8
a1 < a4 y 8 a1	0.8
< a2 y 5 a1 <	0.8
a3 y 5 a1 < a3	0.8
y 6 a1 < a3 y	0.8
7 a1 < a4 y 5	0.8
a1 < a4 y 6 a1	1.0
< a4 y 7	0.8
	0.8

Fig. 3: Datos de muestra (izquierda), los conjuntos RAR+ (centro) y RAR- (derecha) extraídos para un umbral mínimo de confianza de 0,8.

Instancia de prueba	Real clase	v+	v̄	nv+	Novado-	n+	n-	p+	pag	Predicho clase
(a1 = 9,53, a2 = 6,07, a3 = 10, a4 = 9,05) (a1 = 5,0,	"+"	7,8	2,4	2,4	6,8	10,2	9,2	0,75	0,25	"+"
a2 = 1,0, a3 = 10,0, a4 = 7,0)	"-"	5,8	7,6	4,4	1,6	10,2	9,2	0,38	0,62	"-"

Tabla 4: La clasificación de SPRAR entrenada en el conjunto de datos de la Figura 3.

En la Tabla 2 se puede observar que todos los conjuntos de datos están desequilibrados, con todos los números de estudiantes reprobados más pequeños que el número de alumnos aprobados. El conjunto de datos más desequilibrado es D1, seguido de D2 y D3. Además, observamos la dificultad de la tarea de predicción representada en la última columna de la Tabla 2. Desde el punto de vista de la clasificación, la mayoría el conjunto de datos difícil parece ser D2, luego D1 y D3.

5.2. Ejemplo de clasificación utilizando S PRAR

Se considera más adelante un ejemplo que ilustra cómo funciona el clasificador S PRAR. La mesa del lado izquierdo de la Figura 3 contiene un conjunto de datos de muestra (extraído del conjunto de datos D2) en el que cada instancia se caracteriza por cuatro atributos. Para cada instancia, también se proporciona la calificación del examen final y la clase ("+" o "-"). El medio y más a la derecha las tablas de la Figura 3 ilustran los conjuntos de RAR extraídos de las instancias positivas y negativas de los datos de muestra para un umbral mínimo de confianza de 0,8. La Tabla 4 muestra el proceso de clasificación de S PRAR para dos instancias de prueba, junto con sus clases reales y las clases predichas por SPRAR utilizando las probabilidades calculadas.

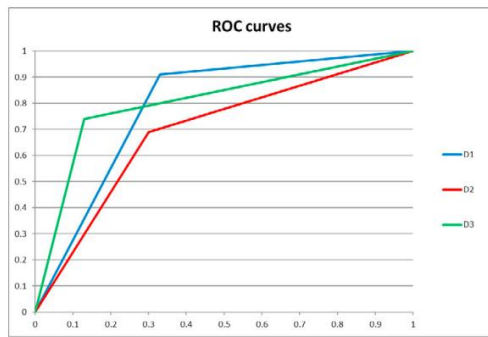
5.3. Resultados y discusión

Antes de construir el clasificador S PRAR, seleccionamos aleatoriamente un subconjunto de entrenamiento de cada conjunto de datos. El conjunto de instancias que no fueron seleccionadas para el entrenamiento, se utilizará posteriormente para la prueba. La Tabla 3 describe la estructura de los subconjuntos de entrenamiento/prueba de los conjuntos de datos D1, D2 y D3. Para entrenar el clasificador S PRAR y generar los conjuntos RAR+ y RAR- se utilizaron los siguientes parámetros: 1 para el umbral mínimo de soporte, 0,6 para el mínimo de confianza umbral y dos posibles relaciones binarias entre los atributos (< y y). Después de construir el clasificador S PRAR utilizando la metodología presentada en la Sección 4, se aplica sobre los estudios de caso descritos en la Sección 5.1 para evaluar su desempeño. Las medidas de evaluación descritas en la Sección 4.2 se computan tanto en el entrenamiento como en las pruebas. subconjuntos y las matrices de confusión obtenidas se presentan en la Tabla 5. Como indicador de desempeño para S PRAR, el último La columna de la Tabla 5 contiene el valor AUC con un intervalo de confianza (IC) del 95 % [4]. Los valores para toda evaluación. las medidas se dan en la Tabla 6. Los resultados de la Tabla 5 no indican una tendencia de sobreajuste del clasificador S PRAR, para ninguno de los conjuntos de datos.


Conjunto de datos	TP		Tennesse		FP		FN		ABC	
	entrenamiento	pruebas	entrenamiento	pruebas	entrenamiento	pruebas	entrenamiento	pruebas	capacitación	pruebas
D1	228	68	24	10	10	5	32	7	$0,79 \pm 0,05$	$0,79 \pm 0,08$
D2	451	97	76	28	36	12	120	43	$0,73 \pm 0,03$	$0,70 \pm 0,07$
D3	351	234	190	61	50	9	177	82	$0,73 \pm 0,03$	$0,81 \pm 0,04$

Tabla 5: Desempeño del clasificador S PRAR en los casos de estudio considerados. Se utilizan IC del 95 % para los resultados.

La Figura 4 ilustra las curvas ROC (imagen del lado izquierdo) y un gráfico para el valor predictivo positivo (precisión) vs. verdadera tasa negativa (especificidad) (imagen del lado derecho) para el clasificador S PRAR en los estudios de casos considerados (conjuntos de datos D1, D2 y D3). De la Tabla 6 y la Figura 4 observamos, para todos los conjuntos de datos, una precisión superior a 0,89, una especificidad superior a 0,67 y valores de AUC que oscilan entre 0,7 y 0,81. Todos estos valores expresan un muy buen desempeño predictivo de SPRAR clasificador, tanto para la clase positiva como para la negativa, considerando la naturaleza desequilibrada de los conjuntos de datos.



(a)



(B)

Fig. 4: Resultados experimentales: curvas ROC (izquierda) y valor predictivo positivo frente a tasa negativa verdadera (derecha) obtenida por SPRAR en todos los conjuntos de datos.

Observamos en la Tabla 5 que existe una correlación perfecta entre la dificultad de los conjuntos de datos (Tabla 2) basada en los valores de AUC. Un análisis de los resultados obtenidos también revela que el problema que presentó mayor dificultad para el clasificador S PRAR diferenciaba a los alumnos con calificaciones entre 4 y 5. Mientras que, en promedio, los alumnos que aprueban se ajustarán a más reglas de RAR+ y los estudiantes que reprobarán se ajustarán a más reglas de RAR-, los estudiantes con grado 5 encajarán número similar de reglas de ambos conjuntos, e incluso se ajustaría a más reglas RAR que los estudiantes con grado 4. Curiosamente, esto no se debe simplemente a que el clasificador tenga problemas con las instancias en el límite. Al elevar el umbral de la clase positiva de 5 a 6, el rendimiento aumenta significativamente. Para el conjunto de datos D2, el AUC aumentó de **0,70** a **0,81** y para el conjunto de datos D3 aumentó de **0,81** a **0,92**. Para los datos D1, establezca una ligera disminución en AUC (de **0,79** a **0,70**) se ha observado, pero esto se debe a la pequeña cantidad de instancias (solo siete instancias con la calificación final 5 se encontraron en todo el conjunto de datos). La dificultad de clasificar las instancias con la calificación final 5 no es necesariamente una limitación de S PRAR, pero es una especificidad de los conjuntos de datos académicos, como otros clasificadores bien conocidos como ANN, DT, Las SVM encuentran el mismo problema (Tabla 6). Una posible explicación a la complejidad para discriminar a los estudiantes con la calificación final 4 y 5 puede ser el hecho de que decidir qué estudiantes aprueban o reproban es un límite de la vida real que puede ser más susceptibles de verse afectados por eventos externos (por ejemplo, la voluntad del instructor de dar artificialmente un pase calificación a los estudiantes que estaban muy cerca de aprobar).

La Tabla 6 compara el desempeño de nuestro clasificador S PRAR con el desempeño de varios enfoques relacionados existentes en la literatura. Para una comparación precisa, aplicamos las técnicas del trabajo relacionado (DTs [13], ANN [19] y SVM [24]) en nuestros conjuntos de datos D1, D2 y D3, empleando en los experimentos los mismos conjuntos de datos y metodología experimental como se describe en la Sección 4. A modo de comparación, las medidas de evaluación descritas en la Sección 4.2 se utilizan. Se destacan los mejores y los segundos mejores clasificadores teniendo en cuenta las medidas AUC y Spec.

Para ANN, usamos la implementación de la API de aprendizaje profundo de Keras [15] usando el Tensorflow neural framework de redes, y para DT y SVM usamos la implementación del aprendizaje automático scikit-learn [20] marco de referencia. Para la ANN usamos la siguiente configuración de parámetros [19]: 2 capas ocultas con 17 y 35 neuronas,

respectivamente, usando la función de activación Sigmoide; una neurona de salida con la función de activación lineal, por lo tanto, la salida es la calificación prevista del estudiante; la pérdida de error cuadrático medio y el optimizador adadelta predefinido; nosotros entrenó la red durante 30 épocas usando un lote de 1 instancia. Para los clasificadores SVM y DT usamos el predefinido ajustes. Para todos los clasificadores establecemos pesos para las clases, con el fin de combatir el desequilibrio de clases; usamos un 4:1 relación de peso a favor de la clase negativa.

Conjunto de datos	Modelo	Prec S	ens F-score	+ NPV S	pec F-score	y AUC		
D1	Our S PRAR 0.93	0.91	0.92	0.95	0.92	0.59 0.67 0.63 0.79 ± 0.08		
	DT [13]	0.87	1.0	0.92	0.93	0.69 0.60 0.64 0.77 ± 0.09		
	ana [19]	0.97			0.93	1.0 0.27 0.42 0.63 ± 0.10		
	MVS [24]				0.95	0.82 0.60 0.69 0.78 ± 0.08		
D2	Our S PRAR 0.89	0.69	0.83	0.80	0.78	0.39 0.70 0.37	0.50	0.70 ± 0.07
	DT [13]	0.86	0.81	0.85	0.81	0.43 0.45 0.53	0.40	0.61 ± 0.07
	ana [19]	0.75			0.84	0.55	0.48	0.67 ± 0.07
	MVS [24]				0.80		0.45	0.65 ± 0.07
D3	Our S PRAR 0.96	0.74	0.87	0.82	0.84	0.43 0.87 0.35	0.57	0.81 ± 0.04
	DT [13]	0.97	0.87		0.84	0.43 0.59 0.87	0.38	0.63 ± 0.05
	ana [19]				0.91	0.39	0.71	0.87 ± 0.03
	MVS [24]	0.82	0.61		0.70		0.24	0.5 ± 0.05

Tabla 6: Comparación con trabajos relacionados ([13], [19] y [24]). Los valores de AUC se proporcionan con IC del 95 %

De la Tabla 6 observamos que de 63 comparaciones, S PRAR **gana** (es decir, proporciona un valor mayor o igual) en 38 casos, **pierde** (es decir, aporta un valor menor) en 25 casos. Esto revela que en el 60% de las comparaciones, S PRAR supera el trabajo relacionado. Se obtiene un muy buen rendimiento general de SPRAR, ya que tanto el AUC como el S pec Los valores superan el trabajo relacionado en el 89% de los casos (8 de 9). Observamos que para los conjuntos de datos D1 y D2, que son los más difíciles y desequilibrados (ver Tabla 2) S PRAR supera a los clasificadores DT, ANN y SVM, confirmando el potencial del SPRAR para manejar conjuntos de datos desequilibrados.

Analizando los resultados experimentales de la Tabla 5 y la comparación con los enfoques existentes (Tabla 6) podemos concluir que los RAR descubiertos en las calificaciones recibidas por los estudiantes durante el semestre son efectivos para predecir si aprobarán o reprobarán un determinado curso y otras mejoras pueden aumentar el rendimiento predictivo. Un posible La explicación de un rendimiento más bajo de S PRAR (particularmente para los conjuntos de datos D1 y D2) es la pequeña cantidad de instancias y atributos que caracterizan las instancias (conjunto de datos D1) lo que aumenta la dificultad del proceso de predicción. Como Como conclusión, para una predicción más precisa, el número de evaluaciones de los estudiantes durante el semestre (atributos en el modelo de aprendizaje) tiene que ser incrementado. Además, hay algunos factores externos que es muy probable que hagan que la predicción difícil, tales como: (1) el proceso de aprendizaje de los estudiantes no es continuo durante el semestre académico; (2) es muy probable que los instructores de las actividades de laboratorio y seminarios no tengan los mismos estándares de evaluación.

6. Conclusiones y trabajos futuros

Como prueba de concepto, este artículo introdujo un modelo de clasificación novedoso SPRAR basado en el descubrimiento de reglas de asociación relacional para predecir la finalización exitosa de un curso académico, basado en las calificaciones recibidas por estudiantes durante el semestre académico. Experimentos realizados en tres conjuntos de datos reales recopilados de Babes-Bolyai La Universidad de Rumania ha mostrado un buen desempeño del clasificador SPRAR. Los resultados experimentales obtenidos destacó que nuestro clasificador es mejor que, o comparable a, los clasificadores supervisados ya aplicados en el EDM literatura para la predicción del rendimiento de los estudiantes.

Una ventaja del clasificador S PRAR presentado en este artículo es su generalidad, ya que no es específico para los estudiantes. tarea de predicción de rendimiento. S PRAR es un modelo de clasificación genérico que se puede aplicar a problemas de clasificación en el que las instancias del conjunto de datos de entrenamiento se caracterizan por un conjunto de características. Cualquier tipo de característica puede ser utilizados en el modelo propuesto, así como cualquier relación binaria entre las características. Además, S PRAR puede ser fácilmente adaptado a problemas de clasificación binaria o multiclase, distintos de la tarea de desempeño de los estudiantes, como el software

predicción de defectos [16]. Las limitaciones de SPRAR son que no es aplicable a problemas de regresión y que actualmente solo manejan relaciones binarias entre los valores de las características.

El trabajo futuro se llevará a cabo con el fin de extender la evaluación experimental de SPRAR en otros casos de estudio. Además, nuestro objetivo es generalizar el clasificador binario SPRAR a un clasificador multiclase para predecir la calificación del examen final de los estudiantes en un determinado curso académico. Con respecto al proceso de descubrimiento de reglas de asociación relacional, planeamos extender nuestro modelo considerando reglas de asociación relacional graduales [11]. Se seguirán investigando medidas alternativas para definir las probabilidades p_+ y p_- , así como la idea de utilizar un conjunto de clasificadores SPRAR para mejorar el rendimiento predictivo. SPRAR también puede extenderse para manejar relaciones n-arias entre los valores de los atributos.

Referencias

- [1] Ahmed, AM, Rizaner, A., Ulusoy, AH, 2016. Uso de la minería de datos para predecir el desempeño del instructor. *Procedia Informática* 102, 137 – 142.
- [2] Beaulac, C., Rosenthal, JS, 2019. Predicción del éxito académico y la especialización de los estudiantes universitarios mediante bosques aleatorios. *Investigación en la Educación Superior*, 1–25.
- [3] Boetticher, GD, 2007. Avances en aplicaciones de aprendizaje automático en ingeniería de software. IGI Global. capítulo Mejorar la credibilidad de modelos de aprendizaje automático en ingeniería de software.
- [4] Brown, L., Cat, T., DasGupta, A., 2001. Estimación de intervalos para una proporción. *Ciencia estadística* 16, 101–133.
- [5] Campan, A., Serban, G., Marcus, A., 2006. Reglas de asociación relacional y detección de errores. *Universidad de Estudios Babes-Bolyai Informatica LI*, 31–36.
- [6] Campan, A., Serban, G., Truta, TM, Marcus, A., 2006. Un algoritmo para el descubrimiento de reglas de asociación ordinal de longitud arbitraria, en: *Actas de la Conferencia Internacional sobre Minería de Datos de 2006*, págs. 107–113.
- [7] Crivei, L., 2018a. Conjunto de datos académicos. <http://www.cs.ubbcluj.ro/yliana.crivei/AcademicDataSets/SPRAR/>.
- [8] Crivei, LM, 2018b. Minería de reglas de asociación relacional incremental de conjuntos de datos educativos. *Studia Universitatis Babes-Bolyai Serie Informatica* 63, 102–117.
- [9] Czibula, G., Bocicor, MI, Czibula, IG, 2012. Predicción de secuencias promotoras utilizando minería de reglas de asociación relacional. *Bioinformatica* 8, 181–196.
- [10] Czibula, G., Marian, Z., Czibula, IG, 2015. Detección de defectos de diseño de software mediante minería de reglas de asociación relacional. *Conocimiento y Sistemas de información* 42, 545–577.
- [11] Czibula, IG, Czibula, G., Miholca, DL, 2018. Mejora de las reglas de asociación relacional con gradualidad. *Revista Internacional de Innovación Informática, Información y Control* 13, 289–305.
- [12] Gu, Q., Zhu, L., Cai, Z., 2009. Medidas de evaluación del rendimiento de clasificación de conjuntos de datos desequilibrados, en: *Simposio internacional sobre Computación y aplicaciones de inteligencia (ISICA)*, Springer Berlin Heidelberg, Berlín, Heidelberg. págs. 461–471.
- [13] Hajizadeh, N., Ahmadzadeh, M., 2014. Análisis de los factores que afectan el rendimiento académico de los estudiantes: enfoque de minería de datos. *Internacional Revista de estudios avanzados en Informática e Ingeniería IJASCSE* 3, 1–4.
- [14] Jishan, ST, Rashu, RI, Haque, N., Rahman, RM, 2015. Mejora de la precisión del modelo de predicción de calificaciones finales de los estudiantes mediante la técnica de sobremuestreo de minorías sintéticas y agrupamiento de ancho igual óptimo. *Análisis de decisiones* 2, 1–10.
- [15] Keras, 2018. La biblioteca de aprendizaje profundo de Python. <https://keras.io/>.
- [16] Miholca, D., Czibula, G., Czibula, IG, 2018. Un enfoque novedoso para la predicción de defectos de software mediante la hibridación de reglas de asociación relacional gradual con redes neuronales artificiales. *información ciencia* 441, 152–170.
- [17] Mohamad, SK, Tasir, Z., 2013. Minería de datos educativos: una revisión. *Procedia - Ciencias Sociales y del Comportamiento* 97, 320 – 324.
- [18] Pal, AK, Pal, S., 2013. Análisis y minería de datos educativos para predecir el rendimiento de los estudiantes. *Revista internacional de electrónica, comunicación e ingeniería informática* 4, 2278–4209.
- [19] Pauziah Mohd Arsad, NB, Iail Ab Manan, J., 2013. Un modelo de predicción de rendimiento de estudiantes de redes neuronales (NNSPPM), en: *Proc. de la Conferencia Internacional IEEE sobre Instrumentación, Medida y Aplicaciones Inteligentes (ICSIMA)*, IEEE Computer Society. págs. 1 a 5.
- [20] Scikit-learn, 2018. Aprendizaje automático en Python. <http://scikit-learn.org/stable/>.
- [21] Serban, G., Campan, A., Czibula, IG, 2006. Una interfaz de programación para encontrar reglas de asociación relacional. *Revista Internacional de Informática, Comunicaciones y Control* 1, 439–444.
- [22] Shahiri, AM, Husain, W., Rashid, NA, 2015. Una revisión sobre la predicción del desempeño de los estudiantes mediante técnicas de minería de datos. *computadora Ciencia* 72, 414 – 422.
- [23] Sushil Kumar Verma, RT, Jaloree, S., 2017. Modelo basado en minería de reglas de asociación difusa para predecir el rendimiento de los estudiantes. *revista internacional de Ingeniería Eléctrica e Informática* 7, 2223–2231.
- [24] Tran, TO, Dang, HT, Dinh, VT, Truong, TMN, Vuong, TPT, Phan, XH, 2017. Predicción del desempeño para estudiantes: un enfoque de múltiples estrategias. *Cibernética y Tecnologías de la Información* 17, 164 – 182.