$Vea\ discusiones,\ estad{\'e} stads ticas\ y\ per files\ de\ autor\ para\ esta\ publicaci{\'e} on:\ https://www.researchgate.net/publication/329870230$

Utilizar el compromiso temprano y el aprendizaje automático para predecir los resultados de los estudiantes

Artículo en	Artículo en Computers & Education - Diciembre 2018			
DOI: 10.1016	/j.compedu.2018.12.006			
CITAS		LEE		
70		602		
2 autores, incluyendo:				
Re	cameron gris			
	Universidad de Bangor			
	12 PUBLICACIONES 99 CITAS			
	VER EL PERFIL			

Utilizando Early Engagement y Machine Learning para

Predecir los resultados de los estudiantes

Cameron C. Graya, ÿ, Dave Perkinsa

aEscuela de Ciencias de la Computación, Universidad de Bangor, Gwynedd, Reino Unido

Abstracto

Encontrar una solución al problema de la retención de los estudiantes es una tarea requerida a menudo.

a través de la Educación Superior. La mayoría de las veces, tanto los gerentes como los académicos confían en

intuición y experiencia para identificar los posibles factores y estudiantes de riesgo.

Este documento examina la literatura sobre los métodos y medidas actuales.

en uso en Learning Analytics. Encontramos que mientras las herramientas están disponibles,

no se centre en la identificación más temprana posible de los estudiantes con dificultades. Nuestra

trabajo define una nueva estadística descriptiva para la asistencia de los estudiantes y aplica

herramientas y técnicas modernas de aprendizaje automático para crear un modelo predictivo.

Demostramos cómo se puede identificar a los estudiantes ya en la semana 3 (del semestre de otoño)

con aproximadamente un 97 % de precisión. Nosotros, además, situamos este

resultado dentro de un contexto pedagógico apropiado para apoyar su uso como parte de un

mecanismo de apoyo a los estudiantes más completo.

Palabras clave: Machine Learning, Learning Analytics, Retención de estudiantes.

2010 MSC: 68-U35, 68-T10, 97-B40

1. Introducción

La retención de estudiantes, la práctica de evitar situaciones en las que la Educación Superior

(HE) los estudiantes no continúan sus estudios con un resultado exitoso, es un área de investigación y

estudio activo [1, 2]. Métodos y respuestas a la retención, y

ÿAutor para la

correspondencia Direcciones de correo electrónico: c.gray@bangor.ac.uk (Cameron C. Gray),

d.perkins@bangor.ac.uk (Dave Perkins)

Preprint enviado a Computers & Education

2 de julio de 2018

El compromiso de 5 estudiantes en general ha sido variado [3, 4]. La mayoría encaja en dos amplias categorías; reactivo - donde los tutores y el personal de apoyo responden a casos específicos y causas, o preventivo - acción diseñada para grupos más grandes de estudiantes para resaltar los éxitos y beneficios que todos disfrutan. Las acciones generales suelen tienen como objetivo aumentar la satisfacción general de los estudiantes, contrarrestando cualquier descontento local 10 (tanto organizacionalmente - dentro de un departamento o curso, como temporalmente - un momento particular en el tiempo).

Durante mucho tiempo se ha sostenido que el rendimiento académico no es necesariamente el único factor implicado en los problemas de retención [5]. Las razones pueden incluir un complejo interacción psicosocial de factores que conducen a respuestas intuitivas de los educadores

15 en lugar de decisiones basadas en datos [6]. Por lo tanto, los resultados de estas respuestas son variados. Aquellos educadores con experiencia en el manejo de problemas tanto académicos como los temas pastorales, sin duda, superarán a sus colegas menos experimentados.

Para cumplir con las metas de retención (y otras, como el cuidado pastoral), los educadores requieren el desarrollo de modelos de decisión rápida, procesos y apoyo para identificar

20 y mediar cuestiones descubiertas. Los productos y herramientas de Learning Analytics están progresando para ayudar en este esfuerzo. Sin embargo, estos productos no se centran en los primeros identificación posible o requieren interpretación humana significativa en cuanto a la mejor Curso de acción.

Nuestra investigación se ha centrado en proporcionar la identificación más temprana posible

25 de estudiantes que se beneficiarían de la intervención del tutor. Hipotetizamos que por aplicar técnicas de aprendizaje automático a los datos ya recopilados sobre la sesión asistencia, podríamos hacer tal identificación.

Dentro de este artículo presentamos cuatro contribuciones;

30

- evaluación de varios métodos candidatos de aprendizaje automático utilizando derivados métrica que mide la asistencia/participación de los estudiantes para producir predicciones del resultado del estudiante.
- un estudio de caso usando un año académico completo y el modelo entrenado en Bangor Universidad, Reino Unido.
- 3. discusión de temas relacionados, incluida la motivación y el potencial de los estudiantes

intervenciones que los tutores deseen realizar.

2. Trabajo relacionado

Se ha encontrado que la asistencia a sesiones programadas es un predictor consistente de probable retención de estudiantes [7]. El mismo estudio también correlacionó la asistencia y el resultado de los cursos de "desarrollo", que generalmente ocurren en el primer año 40 de un programa de grado. Si bien el debate sobre un modelo cohesivo que incluya a todos causas plausibles de la rabia de salida de los estudiantes; ha habido un amplio acuerdo que el compromiso con un curso generalmente conduce a un mayor rendimiento [8, 9, 10].

Estudios previos [11, 12, 13] han demostrado que una de las estrategias más exitosas para retener a los estudiantes es una intervención temprana (con diferentes definiciones

- 45 de 'temprano'). Robbins, Oh, Le y Button examinaron el vínculo entre los tipos de intervención que muestra un posible aumento del 13% en la retención cuando se vincula a un habilidad académica o asistencia [14]. Las herramientas de Learning Analytics incluyen métodos que pueden usarse para apoyar intervenciones tempranas, pero no están diseñadas para ese propósito (Consulte la Sección 2 para obtener más evaluaciones).
- Oeste et al. llevó a cabo un estudio que vincula el análisis de aprendizaje específicamente con indicadores y esfuerzos de retención [15]. Sus hallazgos muestran que los estudiantes informan problemas es la fuente de datos más común cuando se proporciona con categorías fijas.

 Sin embargo, cuando se les da un campo de respuesta de formato libre, la mayoría de los comentarios se refieren a destaca la 'asistencia a clase' como la respuesta más ofrecida. Este resultado también fue informado
- 55 de Anderson, Whittington y Li [16] que confirman que la asistencia se puede utilizar como un fuerte indicador de la calificación final de un estudiante.

60 Entornos (VLE), bibliotecas y otros servicios de soporte [17, 18, 19]. Uso

Existen varios modelos predictivos de Learning Analytic tanto en la literatura como uso comercial. Una clase intenta predecir si los estudiantes aprobarán o reprobando en función de su uso de recursos educativos, como el aprendizaje virtual

los patrones pueden variar drásticamente, lo que significa que estos sistemas requieren tiempo para construirse un perfil de cada nueva clase. Suele haber una correlación entre la reducción compromiso con el apoyo y los recursos de enseñanza, pero el análisis solo puede

marcar un problema potencial con cualquier estudiante dado. Una correlación débil significa que 65 el 'uso' es solo un factor en el modelo, y el uso solo no puede usarse para hacer una predicción definitiva debido a las varianzas observadas.

La segunda clase de productos/herramientas y la investigación que los acompaña utiliza marcas/calificaciones para predecir la probabilidad de un mal resultado o problemas de retención [20, 21]. Estos

Los modelos tienen una alta tasa de éxito en señalar malos resultados, ya que son directamente

70 descendió de los componentes constitutivos de ese resultado. Hay uno

inconveniente de usar calificaciones como variables predictoras; en el punto las calificaciones son otorgado, el estudiante no puede hacer nada para influir en ellos. Esta deficiencia puede ser aceptable cuando hay evaluaciones múltiples o formativas pero falla en cursos con evaluaciones sumativas únicas y/o principales.

Durante finales de la década de 2000 y principios de la de 2010, se hizo popular una tercera metaclase donde los dos estilos anteriores de análisis se combinaron con entrevistas en persona o declaraciones orales/escritas [22, 23]. Los resultados de este trabajo muestran que ambos profesores y estudiantes están buscando más información sobre por qué cualquier evento marcado fue significativo, en lugar de un mero informe de estadísticas y listas.

80 Dentro de Learning Analytics esto se conoce como pasar de análisis descriptivos al análisis de información [24].

Hay varios modelos predictivos desarrollados y presentados en la literatura.

Estos trabajos caen en términos generales en uno de dos grupos: identificación de grupos o subpoblaciones; y exploración de la eficacia de incluir otros conjuntos de datos.

85 La mayor parte del trabajo sobre análisis de aprendizaje se ocupa de los EE. UU. o Australia.

aunque también examinamos casos de instituciones de educación superior del Reino Unido, ya que son particularmente relevante.

Ha habido varios estudios sobre el valor estadístico de 'desempeño indicadores' y 'métricas' para describir a los estudiantes [25, 26, 27]. Si bien las 90 conclusiones relativas al mérito difieren ligeramente, los tres estudios respaldan la idea de que

las métricas deben ser individualizadas. El nivel de resolución puede variar, de métricas específicas para la institución basadas en la lógica de implementación de análisis a diferentes factores que se están considerando para cada estudiante. Esta vista es compatible por Gaÿsevi´c et al. advirtiendo contra un enfoque de análisis único para todos [28].

- panadero et al. estudia qué factores son más reveladores del éxito en línea cursos y qué tan pronto se pueden usar [29]. Como los cursos son enteramente informatizados, los factores se basan enteramente en la actividad como un sustituto de compromiso/atención. Informan un 65% 70% de precisión según las métricas obtenidos en la primera semana del curso. Este nivel de precisión no es suficiente.
- 100 para ser considerado predictivo, lo que admite el estudio, pero los autores se sienten esto es lo suficientemente fuerte como para apoyar la intervención con un estudiante. Ye y Biswas llevó a cabo un estudio similar sobre los datos de Massive Online Open Course (MOOC) [30].
 Su estudio encontró que se encontraron mejores tasas de predicción cuando se usaban datos, en este caso un comportamiento, dentro de la semana anterior.
- JISC, una organización de apoyo técnico y de políticas sin fines de lucro del Reino Unido para educación postobligatoria, ha realizado una revisión exhaustiva del estado de analítica de aprendizaje en ES [31]. Como parte de este informe, los autores presentan 11 casos estudios. Cada uno se enfoca en un aspecto diferente del análisis de aprendizaje. Éstas incluyen 'Early Alert' en la Universidad de Nueva Inglaterra, donde se desarrolló el sistema 110 la misma misión que nuestro trabajo. Su enfoque, sin embargo, correlacionó el emoticón
 - y la entrada de texto a un 'estado de bienestar'. Donde esto cayó o permaneció bajo, a los estudiantes se les ofrece gradualmente más y más apoyo. Este proyecto provocó un disminución en la tasa de deserción/abandono del 18% al 12% [32].
- La Universidad de Nottingham Trent creó el 'Tablero de estudiantes de NTU' como un 115 proyecto piloto en el despliegue de análisis de aprendizaje. El sistema se considera predictivo. ya que correlaciona el bajo compromiso con el alto riesgo de un mal resultado. El modelo deriva una métrica de compromiso de múltiples fuentes, incluida la interacción VLE, uso de la biblioteca, controles de asistencia y presentación de evaluaciones. Curiosamente, la retención no es una preocupación particular en esta institución, pero reconocen
- 120 que el tablero ayudará en este sentido. El objetivo principal es fomentar y mejorar la relación entre el estudiante, la institución y su tutor.
 - Por lo tanto, el sistema se enfoca en una métrica de participación positiva, en lugar de la factor de riesgo negativo para la abstinencia. Este proyecto encontró que el 27% de los estudiantes de primer año los estudiantes habían cambiado su comportamiento en base a la información presentada.
- El análisis de aprendizaje no debe verse como una 'bala de plata'. Si bien puede ayudar

educadores, la mayoría de los sistemas no pueden proporcionar todas las respuestas. el es el mismo conclusión a la que llegó Pardo y un equipo internacional. Su estudio parecía en la utilidad de los modelos predictivos para ayudar a los educadores. Encontraron que la provisión de una plataforma de análisis de aprendizaje no es el catalizador que algunos creían Serian 130. Los educadores requirieron más apoyo para identificar los grupos o grupos dentro de sus cohortes para diseñar intervenciones apropiadas [33].

La evaluación de estos esfuerzos, en términos del mundo real, es difícil. por el mismo naturaleza de la implementación de análisis e intervenciones educativas, el conjunto de datos resultante está alterado. Esto significa que producir un grupo objetivo o de control se convierte en un 135 dilema ético para los educadores e investigadores [34]. El rigor científico exige una evaluación imparcial. Sin embargo, esto significaría a sabiendas y deliberadamente retener la intervención de algunos estudiantes que pueden estar en extrema necesidad de ella. Gaÿsevi´c et al. nos recuerdan que si bien la tecnología y la ciencia son una necesidad fundamental, todo el esfuerzo se relaciona con mejorar las experiencias de aprendizaje [35].

140 3. Aplicar el aprendizaje automático al compromiso

El objetivo principal de este trabajo es hacer una identificación temprana de los estudiantes que se beneficiaría de la intervención posible. Por lo tanto, llevamos a cabo un conjunto de experimentos de selección de características para determinar en qué punto la asistencia se vuelve un predictor confiable de las posiciones académicas de los estudiantes al final de un año académico 145 año. Estos experimentos se realizaron utilizando el banco de trabajo WEKA [36], clasificadores y herramientas.

3.1. Recopilación y estructura de datos

Bangor, al igual que con otras instituciones de educación superior del Reino Unido, establece un Monitoreo de Compromiso política. Bajo esta política, la asistencia de todos los estudiantes será monitoreada a través de 150 verificaciones de su identificación de estudiante en la mayoría, si no en todas, las sesiones. El personal está equipado con lectores de código de barras que registran el número único de cada tarjeta de identificación junto con una marca de tiempo. Al final de cada sesión monitoreada, este registro se carga a una base de datos central. Cada sello de tiempo se compara con el calendario

sesión en la que se tomó. La base de datos también permite reuniones con sus 155 tutores asignados para ser grabados, junto con otros eventos personalizados.

Dentro de la base de datos, en cualquier momento, habría k observaciones para cada estudiante. Cada observación se codifica como una para una asistencia y cero en caso contrario. Estas observaciones se registran en el conjunto z = hz1, z2, ..., zki.

Inicialmente, se consideró una proporción de sesiones a las que se asistió, denominada tasa de compromiso.

160 o ER - definido matemáticamente como Ecuación (1).

$$ERk = 1 / k X \qquad zj$$

$$j=1$$
(1)

En última instancia, esto resultó ser menos efectivo para la predicción del resultado de los estudiantes.

Consulte la Sección 3.6 para obtener detalles del experimento que condujo al abandono de esta métrica.

La segunda métrica, denominada Bangor Engagement Metric (BEM), combinada tanto la asistencia como la no asistencia en una sola lectura. En ausencia de

165 orientación definitiva del trabajo anterior, elaboramos la métrica de forma independiente y basado en una visión idealizada de la asistencia. Se forma, para cualquier punto en el tiempo, como el número de sesiones a las que asistió menos el número de sesiones perdidas. Utilizando el mismo conjunto de k observaciones en el conjunto z, la métrica se define formalmente como la Ecuación (2).

BEMk =
$$X$$
 (ÿ1)(1ÿzj)
_{j=1} (2)

Dado que la estructura y el calendario de cada variante del programa son diferentes, es

170 no es posible comparar el conjunto bruto z. Para proporcionar un número común de resultados,
y marco de referencia, los elementos del conjunto se suman por semana académica.

Cada estudiante ahora tiene 12 valores ER y BEM consistentes para cada
semestre. La asistencia a los exámenes también se controla mediante el mismo proceso,
añadiendo seis lecturas adicionales durante un año. Esto totaliza 30 lecturas BEM para un

175 curso académico completo.

El conjunto de datos incluye tres variables biográficas; los códigos numéricos para el programa del estudiante, la escuela y el año de estudio. estos elementos son manejados como datos categóricos en el conjunto de datos forzando un conjunto de valores. Además, a cada estudiante se le asigna uno de los cinco códigos de Situación Académica que significan el

- 180 estado de finalización de ese año/nivel académico. El código de clasificación académica es la etiqueta de clase que el modelo de aprendizaje automático necesita hacer coincidir/predecir. Estos los códigos son;
 - PA pase.
 - FN: error (no se puede progresar).
- FC suspenso condicional (requiere evaluación complementaria).
 - RY repite el año/nivel.
 - RS repetir un solo semestre.
 - 3.2. Fuentes de efectos externos (potenciales)

Si bien la asistencia es a menudo una elección del estudiante, hay varios factores que son

190 más allá de su control. Estos van desde lo básico y algo esperado, como

como enfermedad, a compromisos laborales y familiares más impactantes. También puede haber ser consideraciones demográficas, como eventos religiosos, que también pueden influir la asistencia del alumno.

El metaestudio de Micere sobre los ingresantes a la universidad de EE. UU., sus características y datos demográficos 195 [37] muestra un cambio demográfico significativo en las tasas de finalización. sin embargo, el los datos sin procesar sobre el compromiso muestran que solo los hombres negros tienen una caída significativa en compromiso tradicional con sus estudios. Un metanálisis de más de 21 000 EE. UU. estudiantes universitarios [38], ha mostrado una relación débil entre las características de los estudiantes

y su asistencia. En este caso, características significa rasgos de personalidad o

200 cualidades como la diligencia más que cualquier división demográfica o social. El

La población estudiantil también se puede dividir por modalidad de estudio, tiempo completo o tiempo parcial.

El estudio de Micere examinó este factor y el impacto del empleo a tiempo parcial y fue rechazado como un factor significativo.

Cuando un estudiante está completando sus estudios a tiempo parcial, su asistencia general 205 valor será menor en proporción a la cantidad de créditos que están completando.

Se espera que su valor BEM resultante sea menor en la misma proporción, teniendo en cuenta las diferencias de horario de clases. Como resultado de estos hallazgos, este estudio

ha optado por no colocar correcciones o sesgos específicos en la construcción de la métrica de compromiso de Bangor. Si esta información se incluyera en el 210, puede ser un sesgo que cause un sobreajuste específico a los datos, por no incluyendo estos detalles, los algoritmos (y el modelo resultante) deben generalizar los patrones de asistencia para todas las circunstancias.

3.3. Exploración inicial de datos

Nuestro conjunto de datos inicial contenía los valores semanales de todos los estudiantes de pregrado.

215 BEM, programa y año de estudio para el año académico 2016/17 en Bangor

Universidad. Estos fueron los resultados históricos y completos más recientes. Como un resultado, podemos hacer coincidir los resultados predichos con la verdad básica para cada estudiante.

Este conjunto tiene; N = 4970 instancias, n = 32 funciones y C = 5 clases.

220 cada conjunto semanal de métricas cambió marginalmente, siguió siendo una distribución normal.

La primera exploración de estos datos encontró que mientras que el sesgo y la media de

La Figura 1 muestra la población utilizando 20 contenedores calculados a partir del rango máximo de la Métrica de Compromiso. El mapa de calor también muestra que a medida que el año académico progresa, el rango de participación se amplía. Este resultado confirma los encontrados por otros estudios [39] y evidencia anecdótica de colegas.

Exploraciones posteriores examinaron parcelas de series de tiempo de estudiante individual datos. Estos se dividieron por año/nivel y departamento debido a la gran cantidad de sobre-trazar al visualizar el conjunto completo. Las observaciones realizadas se mantienen cierto para todas las divisiones en el conjunto de datos. La Figura 2 muestra los resultados de la cohorte de estudiantes de primer año (primer año) de 2016/17 para Ciencias de la Computación. La observación destacada

230 es el que permite una cierta cantidad de variación; los estudiantes tienden a permanecer en su trayectoria inicial a lo largo de un año académico. Algunos de estos estudiantes ya eran beneficiarios de la atención pastoral. Esta observación llamaría a Cuestionar la eficacia o la puntualidad de los esfuerzos del personal.

Esta figura también muestra claramente los valores atípicos inevitables en cualquier cohorte. Se podría suponer que la línea superior 235 (verde/sólida) es el estudiante más diligente que asiste a todas las sesiones y por lo tanto aprobará. El más bajo (nuevamente un codicioso/sólido en este ejemplo/trama) encajaría en el perfil de un talento natural

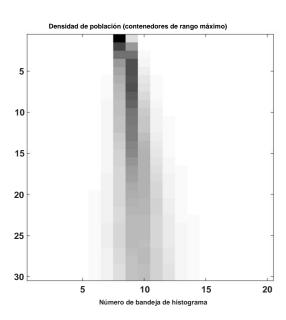


Figura 1: Mapa de calor que muestra la densidad de población relativa en cada semana académica. Cada semana tiene 20 contenedores calculados a partir del rango máximo de la métrica de compromiso de Bangor. el mas oscuro una celda cuantos más estudiantes ocupen esa posición.

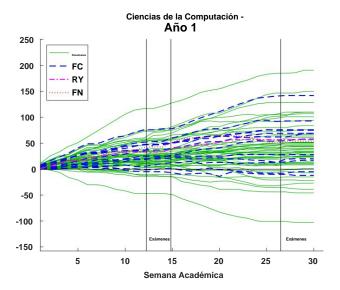


Figura 2: Gráfico de serie temporal que muestra la cohorte de primer año de 2016/17. Cada línea representa a un estudiante y está coloreada por su posición académica final al final del año. Las posiciones académicas en la leyenda son; PA/aprobado, FN/suspenso, FC/trabajo complementario requerido, RY/repetir año, y RS/repetir semestre.

estudiante que siente que no necesita asistir a las sesiones pero también se espera pasar.

240 3.4. Selección de características

Armado con hallazgos previos, se ideó un nuevo conjunto de experimentos. Ellos tenía como objetivo determinar cuándo estas trayectorias podrían separarse en el final posiciones académicas. Esta es una tarea de selección de características, un proceso donde las métricas se evalúan por su valor en un problema de clasificación. El proceso tiene como objetivo

245 mantenga las métricas que describen las diferencias con precisión y, por lo tanto, elimine esas que son irrelevantes o redundantes.

Ya se ha demostrado que los métodos de búsqueda flotante proporcionan resultados superiores en menos tiempo computacional. Por lo tanto, se eligió el método Sequential Forward Selection (SFS) [40,

41]. Este método funciona seleccionando las 250 características individuales más fuertes (normalmente definidas como las de mayor precisión) y luego emparejando esta

con todos los demás para encontrar el par más fuerte, y así sucesivamente.

Tabla 1: Resultados experimentales usando el clasificador 1-NN y los cuatro primeros algorítmicamente características seleccionadas. La última fila muestra el promedio ponderado, basado en el tamaño relativo de la clase, para todo el problema de clasificación. (TP = Verdadero Positivo, FP = Falso Positivo, Prec. = Precisión, AUC = Área bajo la curva ROC)

Clase	Tasa TP T	Tasa TP Tasa FP Prec. Recuperar F-Medida AUC					
Aprobar	0.914	0.764	0,878 0,914	0.896	0.628		
Suplementario	0.118	0.062	0.166 0.118	0.138	0.565		
Repetir año	0.051	0.013	0.058 0.051	0.054	0.632		
Fallar	0.161	0.022	0,198 0,161	0.178	0.668		
Repetir Semestre 0		0	0 0	0	0.699		

un enfoque seguido por Kudo y Sklansky [42]. Debido a la clase PA/pase superando drásticamente a otras etiquetas, la estadística F-Measure [43] se utiliza para 255 miden el rendimiento. Este experimento produce una lista clasificada de características que debería ser considerado. Se encontró que las cuatro características principales (en orden) eran Escuela, Semana 4 BEM, Semana 5 BEM y Semana 3 BEM. Una verificación de estos resultados fue

El experimento inicial utilizó SFS y el clasificador Nearest Neighbor (1-NN),

260 80,10% y un valor de medida F ponderado de 0,788. Sin embargo, estos resultados también

hecho, utilizando el clasificador 1-NN y las características seleccionadas. La tabla 1 muestra

los resultados de este experimento. El resultado principal es una precisión LOOCV de

muestran valores F-Measure muy bajos para las clases menos representadas.

Animado por este resultado, un nuevo intento aumentó la precisión, por usando un clasificador de árbol podado C4.5 [44] y el mismo protocolo y características, al 84,85%. Sin embargo, esta elección en realidad debilitó el poder predictivo para 265 estudiantes que necesitarían completar trabajo complementario, con esta clase F-Medida cayendo a 0.023.

que incluye todas las semanas del semestre de otoño. Esto no cumple con lo indicado

Como los resultados algorítmicos apuntaban hacia las primeras semanas del semestre de otoño, el siguiente conjunto de experimentos rastreó la precisión al agregar progresivamente datos semanales. Estos experimentos utilizaron la misma combinación C4.5/LOOCV; el 270 resultados se muestran en la Tabla 2. La mejor precisión general alcanzada fue 86.20%,

objetivo de la identificación temprana de los estudiantes. El segundo mejor resultado, 86,10%, o simplemente 0.10%/cinco estudiantes menos, exigía solo los valores de las tres primeras semanas sin el Se incluyen la escuela y el año de estudio. Usando este modelo, los tutores estarían en una 275 posición para potencialmente hacer intervenciones apropiadamente dirigidas desde académicos semana 4

Tabla 2: Resultados de la prueba de conjuntos de características de semanas sucesivas, utilizando árboles C4.5 con Leave One Fuera de Validación Cruzada. Las filas están ordenadas por precisión.

Madida E par alasa

			Medida F por clase		
Semanas Escuela/Año Inc. % de precisión		n	PA FC RY FN RS		
1-12 Y		86.20	0,935 0,202 0,068 0,190 0,000		
1-3	norte	86.10	0,926 0,049 0,000 0,231 0,000		
1-4	norte	86.04	0,929 0,040 0,065 0,149 0,000		
1-4	Υ	85.77	0,929 0,151 0,019 0,178 0,000		
1	norte	85.75	0,923 0,000 0,000 0,000 0,000		
1	Υ	85.75	0,923 0,000 0,000 0,000 0,000		
1, 2	Υ	85.75	0,923 0,000 0,000 0,000 0,000		
1-5	norte	85.73	0,927 0,058 0,065 0,245 0,000		
1-5	Υ	85.71	0,929 0,141 0,075 0,211 0,000		
1-6	Υ	85.69	0,930 0,135 0,038 0,200 0,000		
1-6	norte	85.69	0,927 0,075 0,041 0,216 0,000		
1-3	Υ	85.65	0,928 0,139 0,000 0,110 0,000		
1, 2	norte	85.59	0,924 0,000 0,000 0,056 0,000		
1-12	norte	84.35	0,923 0,103 0,017 0,183 0,000		

Estos experimentos proporcionaron evidencia suficiente de que existe suficiente capacidad predictiva potencia usando solo los valores BEM de las primeras tres semanas para proporcionar un adecuado modelo. También muestra que la inclusión de características discriminatorias, como año, escuela, 280 o el programa aumenta algunas medidas F. Se necesita un experimento más para determinar cuál de estos tres discriminadores es más poderoso. esto resultará en un conjunto de características seleccionadas de:

• Valor BEM de la semana 1

- Valor BEM de la semana 2
- Valor BEM de la semana 3
 - Escuela, programa o año
 - Posición Académica (Etiqueta de Clase)

3.5. Selección de clasificador

Hasta este punto, la métrica de éxito había sido la precisión general de la clasificación,

- 290 el número de estudiantes emparejados correctamente con sus resultados reales. Sin embargo, los autores rápidamente se dieron cuenta de que la clasificación precisa en las cinco clases, mientras que ideal, no es estrictamente necesario. La identificación de estudiantes potencialmente en riesgo no es depende del modo de falla que puedan lograr, solo que no se espera ser una pasada. Con esta restricción adicional, sería razonable reducir
- 295 el problema a un problema de clasificación de dos clases y recategorizar al estudiante resultados. Sin embargo, sigue siendo información útil para que los tutores entiendan el severidad del resultado potencial por modo.

Las Matrices de Confusión son la herramienta para reportar resultados resumidos en la clasificación tareas, una tabla simple que muestra etiquetas verdaderas/reales como filas y etiquetas pronosticadas como 300 columnas. Cada celda contiene un recuento de instancias/objetos que caen en ese intersección. El resultado perfecto sería un conteo correcto en la diagonal principal mostrando que las etiquetas verdaderas y predichas coinciden. Todo cuenta en otras partes del matriz indican un error de clasificación. Hay dos regiones separadas; sobre la diagonal que muestra falsos negativos, errores de tipo I, y debajo muestra falsos

305 positivos conocidos como errores Tipo II. La Tabla 3 muestra un ejemplo de matriz de confusión del experimento C4.5 Feature Selection.

Las celdas sombreadas en la tabla muestran los resultados de clasificación donde los estudiantes están identificados como teniendo un resultado positivo cuando en realidad lograrían un uno negativo Al replantear el entrenamiento de los clasificadores para minimizar el Tipo II

310 , estos errores inexactos y engañosos también se minimizarán. Esta se hizo un ajuste ya que es mejor intervenir con un estudiante que bien puede tener éxito por su cuenta que clasificar erróneamente a un estudiante débil como aprobado. En lugar de

315

Tabla 3: Matriz de confusión de un experimento de selección de funciones C4.5. Las celdas sombreadas representan clasificaciones "problemáticas" en las que se pasaría por alto un resultado deficiente.

ÿ Real / Pronosticado ÿ PA FC RY FN RS

Pase (AP)	4218 23		2	19	0
Resid1 (FC)	425 28		2	12	0
Año de repetición (RY)	68	3	0	7	0
Reprobado (FN)	117 10		3	31	0
Repetir Semestre (RS)	2	0	0	0	0

¹ Un estudiante que logra un FC/Resit, o más formalmente Fallo condicional, el estado debería emprender evaluaciones complementarias para aprobar sus asignaturas. En el sistema estadounidense, esto sería equivalente a Summer escuela/cursos.

de minimizar el conteo crudo de Tipo II, maximizando el puntaje de la Medida F de todos las clases tenderán hacia el clasificador 'perfecto'.

Un conjunto final de experimentos evaluó clasificadores adecuados en el conjunto de datos inicial. Cada experimento ejecutó una combinación de algoritmo clasificador, protocolo (Resustitución, o Leave-One-Out), y un discriminador de cohortes. Este discriminador era la Escuela Académica o Programa de Grado. El uso de la Escuela y el Año fue examinado en un experimento anterior, pero finalmente el Año no proporcionó ninguna 320 potencia predictiva adicional.

La selección de la combinación final se convirtió en un problema de optimización multivariante.

La medida F para todas las clases necesitaba ser maximizada, junto con la final tasa de precisión; minimizando al mismo tiempo la diferencia entre los diferentes protocolos.

Estos objetivos se establecen para crear el mejor clasificador, al mismo tiempo que resisten el ajuste excesivo en 325 el conjunto de datos. Los resultados de este benchmark se pueden encontrar en la Tabla A.4.

Todos los clasificadores evaluados tienen un buen desempeño con la mayoría clase (PA). Esto no es sorprendente ya que un resultado de aprobación se aplica al 85,75% de los instancias. Ninguno de los clasificadores es capaz de diferenciar las 2 instancias

para la clase RS (Repetir Semestre). Por lo tanto, los criterios de selección deben girar

330 en torno a la predicción precisa de los otros modos de falla. La medida F

proporciona un sustituto para la precisión individual, por lo tanto, la suma de la falla

El modo F-Measures se puede utilizar como una métrica comparativa, en el rango [0...5]. El

Los seis clasificadores principales (clasificados por esta métrica) logran entre el 36 % y el 47 % de los puntuación máxima (1.878/5 a 2.342/5).

Los tres clasificadores principales utilizan el programa de grado como discriminador de cohortes.

Estos tres también tienen mayores diferencias entre la resustitución y la

Protocolos LOO CV. Esto lleva a la conclusión de que el programa de grado es menos
apropiado al determinar los patrones dentro de una cohorte, y los de la
cohortes anteriores o sucesivas. Excluyendo combinaciones de programas, deje Aleatorio

340 Tree y Random Forest usando el discriminador School. la clasificación de los modos de falla están dentro del 1% uno del otro, mientras que Random Tree tiene un 11% borde con la clase de pase. Sobre esa base, el Árbol aleatorio con la escuela será utilizado como el clasificador de elección.

Creemos que los clasificadores con un elemento estocástico son capaces de superar

345 máximos/mínimos locales durante el entrenamiento. Esta habilidad le permite al clasificador
proporcionar un enfoque más completo para el conjunto de datos. Al examinar la clasificación
regiones y árboles producidos por otros algoritmos candidatos; las áreas y los números
de instancias que representan, se vuelven demasiado pequeños para evitar una clasificación errónea.

3.6. Experimento de Métrica Alternativa

Como se señaló anteriormente, utilizar un porcentaje de las sesiones a las que se asistió es una forma plausible alternativa al BEM. Utilizando el mismo clasificador y parámetros, realizamos un experimento complementario pero utilizando el conjunto de datos de proporción en su lugar. Los resultados se recopilaron utilizando los protocolos de resustitución y Leave-One-Out CV de las tres primeras semanas lectivas. Cuando se usa la resustitución, el clasificador

355 logra una precisión del 98,28% con solo tres estudiantes caracterizados erróneamente bajo el Métrica 'en misión'. Sin embargo, cuando se usa n-Fold Cross Validation, es justo un 12 % peor (85,90%) con 290 alumnos mal clasificados. Podemos concluir de estos resultados, que el clasificador es propenso a sobreajustarse cuando se usa la proporción. Eso

también logra un 7,66% menos en precisión general. Esto conduciría a más potencialmente

360 intervenciones estudiantiles innecesarias. Si bien esto es preferible a dejar que un pobre
el resultado continúa sin impedimentos, puede causar un estrés excesivo para los estudiantes que pasan
que no requirió intervención.

4. Resultados de estudios de casos no vistos

usando el conjunto 2015/16.

Hasta ahora, los resultados se han probado con el mismo conjunto de datos que los clasificadores.

365 han sido entrenados en. El modelo y las prácticas ideadas sobre experimentos anteriores.

se aplicaron a un nuevo conjunto de datos nunca antes visto. Este dato es del

Año académico 2015/16, anterior a cualquier trabajo sobre análisis de aprendizaje en la Universidad de

Bangor. Como resultado, estos datos no pueden verse influenciados por ningún factor, intencional o no.

Este conjunto de datos comprende N = 4877 instancias/estudiantes. utilizamos el

370 mismo n = 4 características (escuela y valores de semana 1-3 del BEM) con el mismo

C = 5 clases. El experimento entrenó el modelo usando datos del año académico 2016/17 y luego probó

La precisión exacta del modelo en los datos no vistos se redujo al 84,79 % (4135/4877 instancias), una diferencia de 8.77% del tren/prueba en el mismo conjunto. Esta 375 es comprensible ya que habrá efectos de cohorte, así como una clase que se gradúa introduciendo diferentes patrones que ya no estarán presentes. Estos efectos pueden también ser causada por cambios en la educación inferior, filtrándose a través de la sistema, para que la cohorte entrante de primer año no actúe de la misma manera que sus predecesores.

Sin embargo, cuando el modelo se evalúa frente a su objetivo principal, la correcta
la identificación de un posible mal resultado se eleva al 97,33%. Esto equivale a
130 estudiantes en toda la institución que no serían identificados, pero el modelo
también señala a 583 (11,95 %) estudiantes que habrían aprobado sin ayuda como potencialmente
que requiere intervención. Se consideró que esto presentaba un riesgo potencial demasiado alto para
385 estudiantes por lo demás capaces. Como resultado, buscamos un clasificador alternativo. Nuestra
evaluación del clasificador había descartado previamente el clasificador RandomForest como
demasiado inestable con datos cambiantes; sin embargo, ofrece un Tipo II significativamente más bajo

tasa de error, así como una mejora marginal en la precisión general.

Un nuevo modelo, usando el clasificador RandomForest pero manteniendo todos los demás parámetros 390 el mismo, fue creado a partir de los datos de 2016/17 y nuevamente probado en 2015/16 resultados Este modelo arrojó resultados significativamente mejores. La precisión general mejoró a 88.05% (+3.26%/159 instancias), mientras que la tasa de clasificación errónea para de lo contrario, los estudiantes que aprueban se redujeron al 8,65 % (-3,3 %/164 instancias). Crucialmente, el modelo solo marca a dos estudiantes adicionales como aprobados cuando lo harían 395 no, elevando el total a 132 no identificados. Esto constituye una caída de 0.041% en precisión efectiva.

5. Discusión

Nuestros resultados muestran que hemos sido capaces de producir un modelo para identificar objetivos potenciales para las intervenciones desde una coyuntura temprana. el modelo tiene 400 ha sido diseñado para minimizar el daño colateral, pero aún tergiversará algunos estudiantes. Nuestro principio rector puede verse como una nueva redacción de Blackstone Formulación (originalmente aplicable al derecho penal) [45]. "Es mejor intervenir con 10 alumnos que aprueban, que perder a uno solo que desaprueba". Como con todo modelos predictivos, es tan bueno como la información utilizada para entrenarlo. Ahí 405 serán alumnos mal caracterizados, por lo que es imperativo que los tutores utilicen

este modelo como una ayuda en lugar de un hecho consumado.

Hemos notado que dentro de nuestros resultados, incluido el conjunto de datos ocultos que las trayectorias de los estudiantes parecen fijas. Hay una pequeña cantidad de variación de la semana.

a la semana, pero sin cambios radicales en el comportamiento. Como este conjunto de datos proviene de dentro del 410 institución, podemos correlacionar fechas con otra información, como tutor visitas Esto implica que las intervenciones existentes simplemente previenen una situación empeorando, o fallan por completo en lograr el objetivo previsto.

Cuando se trata de los logros, el bienestar y la confianza de un estudiante, son consideraciones éticas serias. Las intervenciones, por bien intencionadas que sean,

415 afectan la mentalidad de un estudiante. ¿Qué tan grande es ese efecto, y si es positivo o negativo dependerá de la habilidad y el cuidado del educador involucrado. practicantes

tendrá que adoptar un nuevo enfoque al tratar con estudiantes identificados por cualquier analítica. Abogamos por adoptar un conjunto de principios similar al de la forma moderna del Juramento Hipocrático para médicos [46]. En la versión moderna,

420 médicos reconocen que no están tratando una enfermedad o conjunto de síntomas sino un ser humano enfermo. Esto es algo que los educadores pueden terminar perdiendo de vista. de, cuando los algoritmos hacen las identificaciones en lugar de su propia intuición.

Estos efectos no solo pueden ser provocados por una intervención, sino también de ser identificados como posibles beneficiarios de la asistencia. Algunos estudiantes 425 podría ver esto como un método oblicuo de evaluar su desempeño y convertirse en retirado [47]. Es con esto en mente que cualquier análisis debe usarse abiertamente. y de forma transparente. No recomendamos que los estudiantes sean 'mantenidos en la oscuridad' sobre cómo y por qué han sido seleccionados. Esta posición también es defendida por varias investigaciones éticas [48, 49]. Algunos incluso llegan a etiquetar los análisis

Se brinda muy poca orientación práctica a los educadores sobre cómo para reaccionar a los análisis que marcan a uno de sus estudiantes. La guía disponible los alienta a basar la intervención en términos pedagógicos sólidos [51, 52].

430 como 'nocivo' cuando no se usa de esta manera [50].

Una cosa está clara, que los educadores y los estudiantes deben discutir cualquier problema presente 435 con franqueza y honestidad si el estudiante es para desarrollar su potencial.

Estas intervenciones pueden ser tan simples como una conversación en el pasillo preguntando si el estudiante tiene problemas [53]. Para algunos estudiantes, saber que sus los tutores han notado que algo anda mal es suficiente para efectuar un cambio en el comportamiento [54]. En otros casos, generalmente donde las causas de la desvinculación son más variadas, 440 la intervención deberá ser más compleja e involucrar personal/servicios de apoyo.

así como los académicos. La investigación pedagógica actual sugiere que mientras

La mecánica de la intervención es importante, la relación entre estudiante

y su apoyo es de vital importancia [55].

Con el Reglamento General de Protección de Datos de la Unión Europea [56] a la vuelta de la esquina 445 grande en el horizonte, las instituciones (incluido Bangor) deberán revelar la forma en que se procesan los datos de los estudiantes. En Bangor, hemos tomado la ver que cualquier análisis que pueda ayudar al personal también debe ser visible para el estudiante

preocupado. También hemos desarrollado una posición sobre la búsqueda de permiso de estudiantes a que se incluyan sus datos. Buscamos permiso general para estudiante

450 datos para ser incluidos en nuestro modelo, pero permitir a los estudiantes optar por no tener el análisis resultantes utilizados. En este caso, no se muestra ni al estudiante ni al personal.

los resultados del análisis. Esto respeta los derechos de los estudiantes bajo la actual (y próxima) futuro) la legislación del Reino Unido y la UE, pero no compromete la disponibilidad de datos al modelo. Cada institución deberá trabajar con sus cuerpos estudiantiles.

455 y cualquier autoridad pertinente para formar sus propias políticas de implementación antes implementando su solución.

6. Conclusiones

Como parte de este trabajo, hemos definido una métrica descriptiva - el Bangor

Métrica de participación: que parece tener un poder predictivo significativo. Inicialmente

460, esta métrica se ha utilizado para mejorar el número de estudiantes existentes de la Universidad de Bangor.

sistemas de información. Ahora hemos demostrado cómo se puede llevar el aprendizaje automático

para abordar el problema de la retención de los estudiantes. A través de un conjunto de experimentos,

han seleccionado una combinación de clasificador y medidas para cumplir mejor con

misión de identificación temprana. Esta combinación ha logrado una precisión en

465 exceso del 97%. Minimiza tanto el número de alumnos intervenidos innecesariamente

con y el número de estudiantes incorrectamente predicho como teniendo un positivo

Salir.

Sin embargo, como ocurre con todas las aplicaciones de aprendizaje automático, el modelo no permanecerá estático. Diferentes cohortes de estudiantes progresarán a través de sus cursos, requiriendo 470 patrones diferentes para identificar. Esto significa que el entrenamiento de este modelo estar en curso, incluyendo datos nuevos y eliminando datos antiguos. También reconocemos que los modelos son tan buenos como su entrenamiento, lo que significa que mientras este modelo funciona para los estudiantes de Bangor no será idéntico en otras instituciones. Sin embargo; el el método, el clasificador y las características seleccionadas serían transferibles. Por lo tanto, hay 475 es necesario realizar un estudio longitudinal, tanto dentro de Bangor como comparando grupos similares en otras instituciones.

Referencias

- [1] S. McCoy, D. Byrne, Retención de estudiantes en la educación superior, en: Economía Insights on Higher Education Policy in Ireland, Springer, 2017, págs. 111–141.
- [2] SM Paige, AA Wall, JJ Marren, B. Dubenion, A. Rockwell,
 La experiencia de la comunidad de aprendizaje en la educación superior: alto impacto
 Práctica para la retención de estudiantes, Taylor & Francis, 2017.
 - [3] IW Li, D. Carroll, Factores que influyen en la satisfacción de los estudiantes universitarios, abandono escolar y rendimiento académico: una equidad en la educación superior australiana perspectiva, Centro Nacional para la Equidad Estudiantil en la Educación Superior, Universidad de Curtin, Perth, Australia Occidental, 2017.
 - [4] O. Webb, L. Wyness, D. Cotton, Mejora del acceso, retención, logro y progreso en la educación superior: una revisión de la literatura que muestra Impacto Demostrable., Academia de Educación Superior, 2017.
- [5] VA Lotkowski, SB Robbins, RJ Noeth, The role of academic and Factores no académicos para mejorar la retención universitaria, Informe de política de ACT.
 - [6] MS DeBerard, G. Spielmans, D. Julka, Predictors of academic logro y retención entre los estudiantes universitarios de primer año: un estudio longitudinal, Revista de estudiantes universitarios 38 (1) (2004) 66–80.
- [7] DS Fike, R. Fike, Predictores de retención de estudiantes de primer año en el colegio comunitario, revisión del colegio comunitario 36 (2) (2008) 68–88.
 - [8] A. Seidman, Retención de estudiantes universitarios: fórmula para el éxito estudiantil, Serie ACE/Praeger sobre educación superior, Praeger Publishers, 2005.
 URL https://books.google.co.uk/books?id=ckk5B_ADM_YC
- [9] V. Tinto, De la teoría a la acción: Explorando las condiciones institucionales para retención estudiantil, en: Educación superior: manual de teoría e investigación, Springer, 2010, págs. 51–89.

515

520

- [10] EN Shelton, Apoyo docente y retención de estudiantes, Journal of Nursing Educación 42 (2) (2003) 68–76.
- 505 [11] CP Veenstra, Una estrategia para mejorar la retención universitaria de primer año, The
 revista por la calidad y la participación 31 (4) (2009) 19.
 - [12] LA Price, Características de la deserción temprana de estudiantes en Allegany Colegio Comunitario y Recomendaciones para la Intervención Temprana, Allegany Colegio Comunitario, 1993.
- URL http://files.eric.ed.gov/fulltext/ED361051.pdf
 - [13] SA Martin, Programa de intervención temprana y asociaciones universitarias, ERIC Digerir.
 - [14] SB Robbins, I.-S. Oh, H. Le, C. Button, Efectos de la intervención en la universidad desempeño y retención mediada por factores motivacionales, emocionales y factores de control social: análisis de rutas metaanalíticas integradas., Journal of Psicología Aplicada 94 (5) (2009) 1163.
 - [15] D. West, H. Huijser, D. Heath, A. Lizzio, D. Toohey, C. Miles,
 B. Searle, J. Bronnimann, Experiencias de profesores de educación superior con análisis de aprendizaje en relación con la retención de estudiantes, Australasian Journal de Tecnología Educativa 32 (5) (2016) 48–60.
 - [16] T. Anderson, C. Whittington, XJ Li, Classes to passs: Is class la asistencia es un determinante de las calificaciones en las materias de pregrado de ingeniería?, en: CONFERENCIA AAEE2016 Coffs Harbour, Australia, 2016.
- [17] KE Arnold, MD Pistilli, Señales del curso en Purdue: Uso del aprendizaje análisis para aumentar el éxito de los estudiantes, en: Actas de la 2.ª conferencia internacional sobre análisis de aprendizaje y conocimiento, ACM, 2012, págs. 267–270.
 - [18] B. Daniel, Big data y análisis en la educación superior: Oportunidades y desafíos, Revista británica de tecnología educativa 46 (5) (2015) 904–920.

- 530 [19] Q. Nguyen, B. Rienties, L. Toetenel, Unraveling the dynamics of práctica instruccional: un estudio longitudinal sobre el diseño del aprendizaje y el vle actividades, en: Actas del Séptimo International Learning Analytics
 & Knowledge Conference, LAK '17, ACM, Nueva York, NY, EE. UU., 2017, págs. 168–177. doi: 10.1145 / 3027385.3027409.
- URL http://doi.acm.org/10.1145/3027385.3027409
- [20] C. Herodotou, B. Rienties, A. Boroowa, Z. Zdrahal, M. Hlosta,
 G. Naydenova, Implementación de análisis de aprendizaje predictivo a gran escala:
 La perspectiva del maestro, en: Actas de la Séptima Internacional
 Conferencia sobre análisis y conocimiento del aprendizaje, LAK '17, ACM, Nueva York,
 Nueva York, Estados Unidos, 2017, págs. 267–271. doi: 10.1145/3027385.3027397.
 URL http://doi.acm.org/10.1145/3027385.3027397
 - [21] S. Rovira, E. Puertas, L. Igual, Sistema basado en datos para predecir las notas académicas y la deserción, PLOS ONE 12 (2) (2017) 1–21. doi:10.1371/ revista.pone.0171207.
- URL https://doi.org/10.1371/journal.pone.0171207
 - [22] C. Heaton-Shrestha, S. May, L. Burke, Retención de estudiantes en educación: ¿qué papel para los entornos virtuales de aprendizaje?, Journal of Further y Educación superior 33 (1) (2009) 83–92.
- [23] DT Tempelaar, B. Rienties, Q. Nguyen, Hacia un aprendizaje práctico
 análisis usando disposiciones, IEEE Transactions on Learning Technologies
 10 (1) (2017) 6–16.
 - [24] AG Picciano, La evolución de los grandes datos y el análisis del aprendizaje en la educación superior estadounidense., Journal of Asynchronous Learning Networks 16 (3) (2012) 9–20.
- 555 [25] R. Ball, R. Wilkinson, El uso y abuso de los indicadores de desempeño en el Reino Unido educación superior, Educación Superior 27 (4) (1994) 417–427.

- [26] D. Draper, M. Gittoes, Análisis estadístico de indicadores de desempeño en educación superior del Reino Unido, Journal of the Royal Statistical Society: Serie A (Estadísticas en la sociedad) 167 (3) (2004) 449–474.
- 560 [27] G. Richards, Medición del compromiso: análisis de aprendizaje en el aprendizaje en línea (2011).

URL http://www.academia.edu/download/37420980/ Kazan2011-Measuring_Engagement_vf2.docx

- [28] D. Gaÿsevi´c, S. Dawson, T. Rogers, D. Gasevic, Learning analytics should
 no promover una talla única para todos: Los efectos de las condiciones de instrucción en predicción del éxito académico, Internet y la educación superior 28 (2016)
 68–84.
- [29] RS Baker, D. Lindrum, MJ Lindrum, D. Perkowski, Análisis temprano factores de riesgo en cursos de e-learning de educación superior, en: Proceedings of the
 8ª Conferencia Internacional sobre Minería de Datos Educativos (EDM), 2015, págs. 150–155.
 URL http://www.educationaldatamining.org/EDM2015/proceedings/edm2015_actas.pdf
- [30] C. Ye, G. Biswas, Predicción temprana de la deserción y el rendimiento estudiantil en moocs utilizando información temporal de mayor granularidad, Journal of Learning Analítica 1 (3) (2014) 169–172. URL http://learning-analytics.info/journals/index.php/JLA/ artículo/vista/4212/4429
- [31] N. Sclater, A. Peasgood, J. Mullan, Análisis del aprendizaje en la educación superior,tecnología rep., CSAC (2017).
 - [32] D. Davis, Altis consulting: Los especialistas en gestión de la información presentación, Red de análisis de aprendizaje del Reino Unido (2015).
 URL https://analytics.jiscinvolve.org/wp/files/2015/05/
 Jisc-LA-Network-Davis.pdf

600

- 585 [33] A. Pardo, N. Mirriahi, R. Martínez-Maldonado, J. Jovanovic, S. Dawson,
 D. Gaÿsevi´c, Generando modelos predictivos procesables de rendimiento, en: Actas de la Sexta Conferencia Internacional sobre
 Learning Analytics & Knowledge, LAK '16, ACM, Nueva York, NY, EE. UU.,
 2016, págs. 474–478. doi: 10.1145 / 2883851.2883870.
 URL http://doi.acm.org/10.1145/2883851.2883870
 - [34] S. Slade, P. Prinsloo, Análisis de aprendizaje: cuestiones éticas y dilemas, Científico estadounidense del comportamiento 57 (10) (2013) 1510–1529.
 - [35] D. Gaÿsevi´c, S. Dawson, G. Siemens, No olvidemos: Analítica de aprendizaje tratan sobre el aprendizaje, TechTrends 59 (1) (2015) 64–71.
- 595 [36] E. Frank, MAH Hall, IH Witten, El banco de trabajo WEKA.
 Apéndice en línea, Minería de datos: herramientas prácticas de aprendizaje automático y Técnicas Cuarta Edición.
 - [37] K. Micere, Inscribirlos es solo la mitad de la batalla: Éxito en la universidad en función de la raza o el origen étnico, el género y la clase, American Journal of Ortopsiquiatría 83 (2pt3) (2013) 310–322. doi:10.1111/ajop.12033.
 - [38] M. Cred'e, SG Roch, UM Kieszczynka, Asistencia a clase en la universidad: A revisión metaanalítica de la relación de la asistencia a clase con las calificaciones y características de los estudiantes, Review of Educational Research 80 (2) (2010) 272–295.
- 605 [39] P. Massingham, T. Herrington, ¿Importa la asistencia? una examinacion de las actitudes, la participación, el rendimiento y la asistencia de los estudiantes., Revista de Práctica Universitaria de Enseñanza y Aprendizaje 3 (2) (2006) 82–103.
 - [40] J. Kittler, Selección y extracción de características, Manual de patrón reconocimiento y procesamiento de imágenes (1986) 59–83.
- 610 [41] AW Whitney, Un método directo de selección de medición no paramétrica, Transacciones IEEE en computadoras C-20 (9) (1971) 1100–1103. doi:10. 1109/TC.1971.223410.

- [42] M. Kudo, J. Sklansky, Comparación de algoritmos que seleccionan características para clasificadores de patrones, reconocimiento de patrones 33 (1) (2000) 25–41.
- 615 [43] MV Joshi, Sobre la evaluación del desempeño de los clasificadores para clases raras, en: 2002 Conferencia internacional IEEE sobre minería de datos, 2002. Actas., 2002, págs. 641–644. doi: 10.1109 / ICDM.2002.1184018.
 - [44] JR Quinlan, C4.5: Programas para el aprendizaje automático, Morgan Kaufmann Publishers Inc., San Francisco, CA, EE. UU., 1993.
- 620 [45] W. Blackstone, Comentarios sobre las leyes de Inglaterra, vol. 4, Collins y Hannay, 1830.
 - [46] L. Lasagna, Un juramento hipocrático moderno, Tufts University School of Medicamento.
- [47] S. Lonn, SJ Aguilar, SD Teasley, Investigación de la motivación estudiantil en
 el contexto de una intervención de análisis de aprendizaje durante un puente de verano
 programa, Computadoras en el comportamiento humano 47 (2015) 90–97.
 - [48] A. Pardo, G. Siemens, Principios éticos y de privacidad para el análisis del aprendizaje, Revista británica de tecnología educativa 45 (3) (2014) 438–450.
- [49] H. Drachsler, W. Greller, Privacidad y análisis: es un tema delicado
 una lista de verificación para análisis de aprendizaje confiables, en: Actas de la sexta conferencia internacional sobre análisis de aprendizaje y conocimiento, ACM, 2016, págs. 89–98.
 - [50] LP Dringus, Análisis de aprendizaje considerado dañino., Journal of Redes de aprendizaje asíncrono 16 (3) (2012) 87–100.
- 635 [51] AF Wise, Diseño de intervenciones pedagógicas para apoyar el uso de análisis de aprendizaje, en: Actas de la Cuarta Conferencia Internacional on Learning Analytics And Knowledge, ACM, 2014, págs. 203–211.

640

645

- [52] G. Siemens, Analítica de aprendizaje: visualizando una disciplina de investigación y una dominio de la práctica, en: Actas de la 2ª conferencia internacional sobre análisis de aprendizaje y conocimiento, ACM, 2012, pp. 4–8.
- [53] DS Yeager, GM Walton, Intervenciones sociopsicológicas en la educación: no son mágicas, Revisión de la investigación educativa 81 (2) (2011) 267–301.
- [54] B. Woolf, W. Burleson, I. Arroyo, T. Dragon, D. Cooper, R. Picard, Tutores conscientes del afecto: reconocer y responder al afecto del estudiante, Revista internacional de tecnología de aprendizaje 4 (3-4) (2009) 129–164.
 - [55] AM Klem, JP Connell, Las relaciones importan: Vincular el apoyo de los maestros a la participación y el rendimiento de los estudiantes, Revista de salud escolar 74 (7) (2004) 262–273.
- [56] T. Hoel, W. Chen, Implicaciones de la normativa europea de protección de datos para el diseño de análisis de aprendizaje, en: Workshop paper aceptado para presentación en el Taller Internacional sobre Análisis del Aprendizaje y Educación Minería de Datos (LAEDM 2016) en conjunto con el International Conferencia sobre Tecnologías de Colaboración (CollabTech 2016), Kanazawa, Japón, septiembre de 2016, págs. 14–16.

