

Artículo

Predicción del rendimiento académico de los estudiantes por medio de Clasificación asociativa

Luca Cagliero , lorenzo canale , Laura Farinetti , Elena Baralis y Enrico Venuto 

Departamento de Automatización e Informática, Politecnico di Torino, 10129 Torino, Italia;
lorenzo.canale@polito.it (LC); laura.farinetti@polito.it (LF); elena.baralis@polito.it (EB);
enrico.veni@polito.it (EV)

* Correspondencia: luca.cagliero@polito.it; Teléfono: +39-011-090-7179

Resumen: Recientemente, la comunidad de Learning Analytics ha prestado especial atención a la predicción temprana del rendimiento de los alumnos. Un enfoque establecido implica entrenar modelos de clasificación a partir de datos anteriores relacionados con el alumno para predecir la tasa de éxito del examen de un alumno mucho antes del final del curso. Las predicciones tempranas permiten a los maestros implementar acciones específicas, por ejemplo, apoyar a los estudiantes en riesgo para evitar que reprueben los exámenes o abandonen los cursos. Aunque se han propuesto varias soluciones de aprendizaje automático y minería de datos para aprender predictores precisos de datos anteriores, la interpretabilidad y la explicabilidad de los modelos con mejor rendimiento a menudo son limitadas. Por lo tanto, en la mayoría de los casos, las razones detrás de las decisiones de los clasificadores siguen sin estar claras. Este documento propone una solución de análisis de aprendizaje explicable para analizar los datos generados por los alumnos adquiridos por nuestra universidad técnica, que se basa en un modelo de aprendizaje combinado. Adopta técnicas de clasificación para predecir anticipadamente la tasa de éxito de unos 5000 estudiantes que estaban matriculados en los cursos de primer año de nuestra universidad. Propone aplicar clasificadores asociativos en diferentes puntos de tiempo y explorar las características de los modelos que llevaron a asignar tasas de éxito de aprobado o reprobado. Gracias a su interpretabilidad inherente, los modelos asociativos pueden ser explorados manualmente por expertos en el dominio con el doble objetivo de validar los resultados del clasificador a través de explicaciones locales basadas en reglas e identificar perfiles de estudiantes en riesgo/exitosos mediante la interpretación del modelo global basado en reglas. Los resultados de una evaluación empírica en profundidad demuestran que los modelos asociativos (i) funcionan tan bien como los modelos de clasificación de mejor rendimiento y (ii) brindan información relevante sobre las asignaciones de la tasa de éxito por estudiante.

Palabras clave: analítica de aprendizaje; algoritmos de clasificación y regresión; modelos de aprendizaje mixto



Cita: Cagliero, L.; Canale, L.; Farinetti, L.; Baralis E.; Ven, E.

Predicción del Rendimiento Académico de los Estudiantes por Medio de la Clasificación Asociativa. *aplicación ciencia* **2021**, *11*, 1420. <https://doi.org/10.3390/app11041420>

Editora Académica: Lidia

Jackowska-Strumillo

Recibido: 7 enero 2021

Aceptado: 27 de enero de 2021

Publicado: 4 febrero 2021

Nota del editor: MDPI se mantiene neutral con respecto a reclamos jurisdiccionales en mapas publicados y afiliación institucional acciones.



Copyright: © 2021 por los autores.
Licenciario MDPI, Basilea, Suiza.

Este artículo es un artículo de acceso abierto distribuido bajo los términos y condiciones de Creative Commons

Licencia de atribución (CC BY) (<https://creativecommons.org/licenses/by/4.0/>).

1. Introducción

Predicir el desempeño de los estudiantes es un problema establecido de Learning Analytics (LA) [1]. En el contexto de los cursos de nivel universitario, la comunidad de investigación ha reconocido la importancia de predicir el rendimiento de los estudiantes lo antes posible, lo que permite intervenciones oportunas dirigidas a los estudiantes en riesgo [2].

Para predicir anticipadamente las fallas en los exámenes o el abandono del curso, se han dedicado muchos esfuerzos de investigación al análisis de datos sobre los alumnos y sus contextos de aprendizaje a través de técnicas de aprendizaje automático (p. ej., [3–6]). Un enfoque común consiste en predicir la tasa de éxito de un examen por alumno mucho antes del final del curso mediante técnicas de clasificación [7]. La clasificación tiene como objetivo aprender modelos predictivos a partir de un conjunto de datos etiquetados (es decir, datos relacionados con los estudiantes para los que se conoce la tasa de éxito del examen). Se utiliza un conjunto de prueba para saber si los modelos funcionan con suficiente precisión. Nuestro objetivo aquí es pronosticar la tasa de éxito de un estudiante en función del resultado de un modelo de clasificación. Dado que los datos relacionados con los estudiantes y la información contextual cambian con el tiempo, el entrenamiento del modelo se repite varias veces en diferentes momentos (por ejemplo, antes de la inscripción del estudiante, al comienzo del curso, inmediatamente antes del comienzo de la sesión de examen). De esta forma, los modelos de clasificación incorporan toda la información sobre los alumnos y las actividades de aprendizaje disponibles en el momento actual.

Una fuerte limitación de muchos modelos de aprendizaje automático de última generación es su interpretabilidad y explicabilidad limitadas. La interpretabilidad del modelo está garantizada siempre que el modelo de clasificación pueda entenderse y explorarse fácilmente, mientras que la explicabilidad implica comprender las características subyacentes del modelo que influyen principalmente en sus predicciones [8].

En el contexto de la predicción del desempeño de los estudiantes, la falta de interpretabilidad y explicabilidad del modelo podría ser particularmente crítica, porque los maestros no pueden verificar la idoneidad de la predicción de la tasa de éxito ni adaptar las acciones posteriores a las necesidades reales de los alumnos.

Ya se han realizado intentos anteriores para abordar la predicción del rendimiento de los estudiantes utilizando modelos de clasificación interpretables, como reglas de decisión y reglas difusas (p. ej., [9–11]). Sin embargo, como se discutió en [12], estos modelos pueden sufrir el problema de la adaptabilidad ya que podrían tomar decisiones basadas en pequeñas muestras de datos y, por lo tanto, el clasificador final podría no ser representativo de las tendencias generales.

Este trabajo propone predecir tempranamente el desempeño de los estudiantes de nivel universitario por medio de la clasificación asociativa. Los clasificadores asociativos son modelos de clasificación interpretables pero precisos que consisten en reglas de asociación [13]. Se sabe que los clasificadores asociativos son más precisos que los árboles de decisión tradicionales y los algoritmos basados en reglas. Superan los problemas del árbol de decisión y los modelos difusos centrándose en las características de la instancia de prueba dada, lo que aumenta la posibilidad de generar más reglas que sean útiles para clasificar la instancia de prueba [12].

Las reglas asociativas representan fuertes implicaciones entre las combinaciones recurrentes de valores de características y la tasa de éxito prevista. Por ejemplo, una regla puede indicar que si una estudiante es mujer y ha accedido a la mayoría de los módulos del curso, es muy probable que apruebe el próximo examen. Las reglas se extraen automáticamente de un conjunto de datos etiquetados (potencialmente grande), se filtran y ordenan por relevancia y luego se aplican a los datos sin etiquetar. Gracias a su interpretabilidad inherente, los expertos en el dominio pueden explorar y validar manualmente los modelos asociativos. Se conocen las reglas aplicadas en la predicción de la tasa de éxito del examen de cada estudiante. Por lo tanto, dan una idea de la motivación real detrás de la asignación de tarifas (es decir, explicaciones locales). Evaluar la idoneidad de las predicciones generadas podría ayudar a los profesores a confiar en el modelo basado en datos, a decidir si recopilar nuevos datos o no, y a adaptar las acciones posteriores a los perfiles específicos de los estudiantes. Por ejemplo, si se demuestra que los perfiles en riesgo rara vez acceden a los materiales del curso en línea, los maestros podrían fomentar el uso de materiales en línea para evitar fallas en los exámenes.

Motivado por las características del modelo antes mencionado, este artículo tiene como objetivo explorar el potencial de las técnicas de clasificación asociativa para apoyar la predicción temprana del rendimiento de los estudiantes. Específicamente, se abordarán las siguientes preguntas de investigación: RQ(1) ¿Son los modelos asociativos tan precisos como los mejores clasificadores para predecir las tasas de éxito en los exámenes de los estudiantes de nivel universitario?

RQ(2) ¿Cuáles son las características más discriminatorias para pronosticar las tasas de éxito del examen en diferentes momentos?

RQ(3) ¿Qué combinaciones de valores de características se han utilizado con frecuencia para asignar el examen? índices de éxito?

Para responder a la pregunta (RQ1), analizamos los datos generados por los alumnos adquiridos por nuestra universidad técnica, que adopta un modelo de aprendizaje combinado, utilizando una variedad de modelos de clasificación con varios niveles de explicabilidad. Específicamente, como estudio de caso, consideramos alrededor de 5000 estudiantes matriculados en cursos de ingeniería de BS y sus datos personales, de admisión y de carrera académica. Además, la plataforma de aprendizaje rastrea la interacción de los estudiantes con el material educativo, donde un servicio de video educativo masivo, que ofrece grabaciones de video de las conferencias en clase, tiene un papel central [14]. Los resultados obtenidos muestran el rendimiento de L, un clasificador asociativo de última generación [15], es comparable al de los modelos de mejor rendimiento (no explicables) y, en promedio, superior al de los modelos de árboles de decisión. Para responder a las preguntas (RQ2) y (RQ3), analizamos en profundidad las características de las reglas aplicadas por el clasificador asociativo a los alumnos bajo

consideración. Además, hacemos un seguimiento de los cambios de perfil a lo largo del tiempo. En el caso de estudio considerado, los análisis realizados nos han permitido comprender mejor el progreso profesional de los estudiantes matriculados en nuestra universidad.

El resto del documento está organizado de la siguiente manera. La sección 2 ofrece una descripción general de la literatura relacionada con la predicción temprana del rendimiento de los estudiantes. La Sección 3 describe detalladamente la metodología propuesta. La sección 4 presenta los principales resultados experimentales. En la sección 5 se extraen conclusiones y se analizan las futuras líneas de investigación.

2. Revisión de la literatura

En el contexto de la predicción del desempeño de los estudiantes, hallazgos recientes [3] han demostrado la alta variabilidad del desempeño del clasificador según el contexto de aprendizaje, las características analizadas y los algoritmos considerados. Los principales trabajos de investigación realizados en este campo han abordado principalmente las siguientes preguntas de investigación: (A) ¿Cuáles son las características más discriminatorias

para pronosticar las tasas de éxito del examen?

(B) ¿Desde qué punto de tiempo se pueden considerar confiables las predicciones del clasificador?

(C) ¿Cuáles son las técnicas de clasificación más efectivas?

(D) ¿Podemos hacer que las soluciones de Learning Analytics sean interpretables y transparentes para el

¿los usuarios finales?

A continuación se presenta un análisis exhaustivo de cada rama de investigación.

(A) ¿Cuáles son las características más discriminatorias? Las funciones relacionadas con el alumno y el contexto describen las interacciones entre los alumnos, los profesores y los sistemas de gestión del aprendizaje en múltiples aspectos. Según el tipo de interacción, en [16] las características se clasifican en categorías de estudiante-estudiante, estudiante-profesor y estudiante-contenido. Los resultados obtenidos en los datos de Moodle LMS y presentados en [17,18] muestran que las interacciones alumno-alumno y alumno-profesor son relevantes para predecir la tasa de éxito de los cursos completamente en línea, mientras que las interacciones alumno-contenido se consideran relevantes para la clase. conferencias Los resultados informados en [19] confirman que los hábitos de los alumnos, las actividades sociales y los estilos de trabajo en equipo son relevantes para identificar los factores clave que influyen en el rendimiento de los alumnos. Para profundizar el análisis de las interacciones entre estudiantes y LMS, en [20,21] los autores analizan los datos adquiridos de Moodle LMS para descubrir qué características (por ejemplo, tiempo total en línea, número de descargas, cantidad de comunicaciones con compañeros) son significativamente correlacionada con la calificación final. Los resultados muestran que el tiempo total en línea y la cantidad de archivos vistos son las características más discriminatorias. En [22,23], los autores identifican un conjunto de factores de rendimiento clave que influyen en el rendimiento de los estudiantes tanto en entornos de aula como en línea. El objetivo de este trabajo es diferente al de todos los enfoques mencionados. Propone una metodología, basada en la clasificación asociativa, para realizar predicciones con precisión e interpretar los resultados. Al explorar las reglas de asociación extraídas, las características más significativas se pueden identificar automáticamente. Tenga en cuenta que, dado que la metodología presentada es general, se puede aplicar a un conjunto de funciones arbitrario.

(B) ¿Desde qué punto de tiempo se pueden considerar confiables las predicciones del clasificador?

Para permitir intervenciones oportunas, las predicciones de rendimiento deben realizarse lo antes posible.

Los trabajos presentados en [7,24,25] abordan este tema específico bajo diferentes puntos de vista.

Como era de esperar, la precisión de la predicción aumenta cuando se acerca la sesión de examen. Sin

embargo, para un porcentaje relevante de estudiantes, la calificación final parece estar fuertemente

correlacionada con el resultado de la prueba de ingreso [25]. Por lo tanto, la información útil sobre los

estudiantes en riesgo estará disponible muy pronto. El número de clics en los materiales en línea realizados en la semana inmediatamente anterior al curso resulta ser otro predictor importante [7].

Como era de esperar, los resultados de las evaluaciones en curso o de las convocatorias de exámenes

anteriores también están fuertemente correlacionados con la calificación [26]. Por lo tanto, deben

considerarse tan pronto como estén disponibles. Incluso la presencia de datos no etiquetados podría

contribuir a mejorar la fiabilidad de los predictores [27]. En [3], los autores analizan 17 cursos de

aprendizaje mixto utilizando Moodle LMS. Los modelos de predicción logran valores altos de recuerdo

(es decir, identifican a la mayoría de los estudiantes en riesgo) pero valores bajos de precisión (es decir,

el número de falsos positivos es bastante alto). La principal conclusión que extraen los autores es que es muy difícil

Amplio conjunto de variables que se pueden usar para predecir consistentemente el rendimiento de los estudiantes en múltiples cursos. Por lo tanto, existe la necesidad de adaptar los modelos de predicción al contexto de aprendizaje bajo análisis y profundizar el análisis de las correlaciones extraídas entre los datos. De esta forma, este artículo explora el potencial de los modelos de clasificación asociativa, que combinan precisión e interpretabilidad.

(C) ¿Cuáles son las técnicas de clasificación más efectivas? Se han aplicado con éxito varias técnicas de clasificación para predecir tempranamente el desempeño de los estudiantes. Específicamente, se ha dedicado un esfuerzo significativo al entrenamiento de redes neuronales tradicionales y profundas (por ejemplo, [28,29]). Paralelamente, los enfoques establecidos, como las máquinas de vectores de soporte [30], los clasificadores basados en la distancia [31], los conjuntos de métodos de clasificación (es decir, el aumento de gradiente y el bosque aleatorio) [32] y los métodos de pronóstico de series de tiempo [6] han logrado bastante valores de alta precisión. Este documento es, hasta donde sabemos, el primer intento de utilizar modelos asociativos para abordar la predicción temprana del rendimiento de los estudiantes.

(D) ¿Podemos hacer que las soluciones de Learning Analytics sean transparentes para los usuarios finales? Explainable Learning Analytics (XLA) se centra en mejorar la transparencia de las técnicas de Machine Learning en apoyo del dominio de Learning Analytics [33]. Dado que la mayoría de los modelos de ML actúan como cajas negras, los resultados a menudo son difíciles de interpretar. Por lo tanto, la comunidad XLA tiene como objetivo hacer que los resultados de ML sean explicables adaptándolos a las partes interesadas y usuarios finales particulares [8]. Por ejemplo, en [9] los autores utilizaron el conjunto de datos de análisis de aprendizaje de la Universidad Abierta para predecir los resultados de los estudiantes. Destacaron la necesidad de utilizar XAI en el ámbito educativo. En el contexto de la calificación automatizada de ensayos, los autores en [34] han estudiado el impacto y la confiabilidad de las redes neuronales por medio del marco de explicación SHAP [35]). Se han realizado intentos similares en los dominios del pensamiento computacional [36] y el rastreo del conocimiento [29]. SHAP produce explicaciones visuales al correlacionar las características de entrada con la clase de destino. Por el contrario, los clasificadores asociativos adoptados en el presente trabajo no tienen como objetivo estudiar el valor de impacto de una característica específica, sino que se centran en identificar las combinaciones específicas de valores de características que probablemente sean relevantes para predecir una etiqueta de clase de destino.

Se ha dedicado un esfuerzo paralelo a explicar las primeras predicciones del desempeño de los estudiantes utilizando modelos basados en árboles (p. ej., [10,11]). Se sabe que los clasificadores asociativos utilizados en el presente trabajo son más precisos que los árboles de decisión tradicionales y los algoritmos basados en reglas porque se basan en modelos globales basados en la co-ocurrencia [12].

3. Materiales y Métodos

Los clasificadores asociativos se utilizan para generar predicciones por estudiante de las tasas de éxito del examen. El esquema arquitectónico de la metodología propuesta se representa en la Figura 1. Los pasos principales se pueden resumir de la siguiente manera.




Figura 1. La metodología propuesta.

- **Adquisición y preparación de datos:** Los sistemas de gestión del aprendizaje (LMS) adoptados por la universidad adquieren los datos relacionados con los estudiantes durante todo el año académico, los recopilan en un repositorio unificado y los preparan para el proceso de clasificación.
- **Aprendizaje de modelos asociativos:** se entrenan múltiples clasificadores asociativos, que consisten en una selección de reglas de asociación [37], a partir de los datos preparados en diferentes momentos (p. ej., antes de la inscripción de los estudiantes, antes del comienzo del curso, antes del comienzo del sesión de examen). Cada clasificador describe las correlaciones más significativas entre una combinación de características de datos y la tasa de éxito del próximo examen.

- **Interpretación del modelo:** el modelo asociativo se explora manualmente para identificar perfiles de estudiantes en riesgo/exitosos según las reglas extraídas y para validar las predicciones de tasas por estudiante según el perfil asociado.

En las siguientes secciones se proporciona una descripción más detallada de cada paso.

3.1. Adquisición y preparación de datos

Los sistemas de gestión del aprendizaje hoy en día pueden adquirir, recopilar y almacenar datos relacionados con una variedad de datos diferentes relacionados con los estudiantes. De acuerdo con la clasificación dada en [6], podemos categorizar las características de los datos recopilados en las siguientes categorías: 1. **Características específicas del estudiante**, por ejemplo, género, edad, etnia, tipo de escuela secundaria, puntajes estandarizados, carga de créditos actual.

2. **Indicadores de participación de los estudiantes** personalizados para el curso bajo análisis, por ejemplo, satisfacción con el curso, frecuencia de inicio de sesión en portales en línea, frecuencia de acceso y descarga de materiales del curso, frecuencia de acceso y descarga de conferencias en video, número de debates publicados.

3. Puntajes de **evaluación**: resultado de la prueba de ingreso, calificación obtenida en los exámenes anteriores.

En la metodología propuesta se adquieren los valores de todas las características de datos potencialmente relevantes, recopilados en un repositorio único (independientemente de su categoría correspondiente), y se almacena en un conjunto de datos relacional.

Un conjunto de datos relacionales consta de un conjunto de registros, donde cada registro es un conjunto de elementos.

En nuestro contexto, los elementos son pares (característica, valor). La característica es una descripción textual de las características relacionadas con el estudiante, mientras que el valor es el valor correspondiente tomado por la característica. A continuación se presentan definiciones más formales de elemento y conjunto de datos relacional.

Definición 1. Artículo. Sea f_i una etiqueta, llamada característica, que describe una característica peculiar relacionada con el estudiante. Sea \mathcal{Y}_i el dominio discreto de la característica f_i . Cada par (f_i, valor_i) , donde $\text{valor}_i \in \mathcal{Y}_i$, es un elemento.

Para tratar con atributos continuos, el dominio se discretiza en intervalos, donde los intervalos se asignan a números enteros positivos consecutivos. Por ejemplo, (Resultado de la prueba de ingreso, De 70 a 85) es un elemento que indica que la calificación obtenida por el estudiante en el ingreso a la prueba está entre 70 y 85.

Definición 2. Conjunto de datos relacionales. Sea $F = \{f_1, f_2, \dots, f_n\}$ sea un conjunto de características y $\mathcal{Y} = \{\mathcal{Y}_1, \mathcal{Y}_2, \dots, \mathcal{Y}_n\}$ los dominios correspondientes. Un conjunto de datos relacional D es un conjunto de registros, donde cada registro r es un conjunto de elementos y contiene como máximo un elemento para cada característica en F .

Para fines de clasificación, una característica (en lo sucesivo denominada clase) se selecciona como predic objetivo de ción. De ahora en adelante, consideraremos como clase la tasa de éxito del próximo examen.

Definición 3. Conjunto de datos relacionales etiquetados. Sea D un conjunto de datos relacionales y $F = \{f_1, f_2, \dots, f_n\}$ su conjunto de funciones correspondiente. Sea f_n y F la clase y sea $\mathcal{Y}_n = C$ el dominio de la clase. Para cada registro de conjunto de datos r_i tal que $r_i \in D$, sea $c_i \in C$ su valor de clase. D es un conjunto de datos relacional etiquetado.

Un registro $r \in D$ para el cual se conoce el valor de clase se denomina registro de entrenamiento (etiquetado). Por el contrario, un registro $r_t \in D$ para el cual se desconoce el valor se denomina registro de prueba (sin etiquetar).

La Tabla 1 informa un ejemplo de un conjunto de datos de entrenamiento etiquetado cuyos registros están relacionados con diferentes estudiantes del curso de Análisis Matemático en el mismo momento. Tenga en cuenta que el conjunto de datos contiene características invariables en el tiempo, por ejemplo, la calificación de la prueba de ingreso (por ejemplo, 65 sobre 100) y dependientes del tiempo, por ejemplo, el número de videoconferencias a las que se accede. Para predecir las tasas de éxito de los estudiantes en un punto de tiempo dado, podemos entrenar el clasificador en el conjunto de datos de ejemplo en ejecución (excluyendo las identificaciones de los estudiantes) configurando como clase la función Tasa de éxito.

Tabla 1. Ejemplo de ejecución.

Estudiante	Examen de entrada Calificación	Vídeo accedido	Tasa de éxito (Clase)
		Conferencias (%)	
101010	[60, 70]	<5	fallar
202020	[80, 95]	[10, 20]	aprobar
303030	[60, 70]		fallar
404040	[70, 85]	[30, 40]	aprobar
505050	[60, 70]	[30, 40]	fallar
606060	[70, 85]	[80, 90]	aprobar

3.2. Aprendizaje de modelos asociativos

La clasificación de datos relacionales implica primero generar un modelo a partir de un conjunto de (etiquetados) registros de entrenamiento y luego aplicarlo a un conjunto de registros de prueba (sin etiquetar). Muchos diferentes

Se han propuesto enfoques de clasificación en la literatura (p. ej., clasificadores bayesianos, árboles de decisión, máquinas de vectores de soporte (SVM), redes neuronales y clasificadores asociativos).

Un inconveniente relevante de muchas técnicas de clasificación (p. ej., clasificadores bayesianos, SVM,

Neural Networks) es la limitada explicabilidad de los modelos generados. Estudiante predictor rendimiento académico mediante el uso de modelos no explicables implica confiar plenamente en el resultado de la predicción, porque los patrones utilizados para asignar la tasa de éxito del estudiante para un determinado

supuesto son desconocidos [38].

Los árboles de decisión y los clasificadores asociativos son las dos clases principales de explicables. modelos de clasificación. Los usuarios pueden explorar estos modelos para obtener información sobre decisiones de los clasificadores. Los árboles de decisión son técnicas de clasificación populares basadas en estructuras basadas en árboles creadas en el conjunto de datos de entrenamiento [39]. Los árboles de decisión realizan una búsqueda codiciosa para las reglas mediante la selección heurística de las características más prometedoras. Tal búsqueda codiciosa (local) puede descartar reglas importantes. Los clasificadores asociativos, por otro lado, realizan una buscar reglas que satisfagan algunas restricciones de calidad (es decir, soporte mínimo) [40]. Más específicamente, como se discutió en [41], los árboles de decisión sufren el problema de la adaptabilidad ya que podrían tomar decisiones en base a pequeñas muestras de datos y, por tanto, al clasificador final no podía ser representativa de las tendencias generales. La clasificación asociativa supera la dicho problema centrándose en las características de la instancia de prueba dada, aumentando así la posibilidad de generar más reglas que sean útiles para clasificar la instancia de prueba. Asociación las reglas representan fuertes asociaciones entre conjuntos de valores de características y la clase. Las reglas son extraídos, filtrados y ordenados antes de ser incluidos en el modelo de clasificación. En este trabajo aplicamos las metodologías de extracción y selección de reglas adoptadas por la L 3 de última generación algoritmo [15]. Una descripción más detallada de los pasos de extracción y evaluación de reglas es informado a continuación.

Reglas de asociación. Sea D un conjunto de datos relacionales (ver Definición 1) y sea X un conjunto arbitrario de elementos en D. Un conjunto de elementos es un conjunto de elementos, es decir, una combinación de valores de características que ocurre en un conjunto de datos. En el contexto de los datos relacionales, X es un conjunto de elementos si todos sus elementos pertenecen a características distintas.

Recordando el ejemplo en curso en la Tabla 1, {(Fracción de videoconferencias a las que se accedió, <5 %), (tasa de éxito, fracaso)} es un conjunto de elementos que representa la co-ocurrencia de dos elementos (relacionados con características diferentes) en el conjunto de datos de origen. Indica que los estudiantes que accedieron menos del 5% de las video-conferencias del curso reprobaron el examen.

Los conjuntos de elementos se caracterizan por su valor de soporte [37]. Indica la fracción de registros en el conjunto de datos de origen en los que todos los elementos del conjunto de elementos coexisten. Por ejemplo, {(Prueba de entrada, [60, 70]), (tasa de éxito, falla)} tiene un soporte igual al 33 % en el ejemplo en ejecución conjunto de datos, porque los dos elementos coexisten en dos registros de seis.

Una regla de asociación es una implicación $X \rightarrow Y$, donde X e Y son conjuntos de elementos disjuntos. A continuación se presenta una definición más formal.

Definición 4. Regla de asociación. Sean X e Y dos conjuntos de elementos en D tales que $X \cap Y = \emptyset$. Una regla de asociación se representa en la forma $R : X \rightarrow Y$, donde X e Y son el cuerpo y la cabeza de la regla respectivamente.

X e Y también se denotan como antecedente y consecuente de la regla $X \rightarrow Y$.

Por ejemplo, $\{(Prueba\ de\ entrada, [60, 70]), (Video-conferencias\ accedidas, <5\%)\} \rightarrow (Tasa\ de\ éxito, suspenso)$ es una regla de asociación. Indica que la concurrencia de dos condiciones específicas, es decir, aprobar la prueba de acceso con una nota entre 60 y 70 y acceder a menos del 5% de las videoconferencias, se correlaciona con la suspensión del examen.

La extracción de la regla de asociación suele estar impulsada por los índices de calidad de soporte (sup), confianza (conf) y correlación (corr) [37]. El soporte de la regla indica la frecuencia de ocurrencia de la implicación en el conjunto de datos de origen, mientras que el índice de confianza representa la fuerza de la regla.

Definición 5. Soporte de una regla de asociación. Sea D un conjunto de datos relacional. El soporte (sup) de una regla de asociación $R : X \rightarrow Y$ se define como el soporte de $X \cup Y$ en D .

Definición 6. Confianza de una regla de asociación. Sea D un conjunto de datos relacional. La confianza (conf) de una regla de asociación $R : X \rightarrow Y$ es la probabilidad condicional de ocurrencia en D de itemset $\sup(X \cup Y)$ dado el conjunto de elementos X , es decir, con $\frac{\sup(X \cup Y)}{\sup(X)}$.

Por ejemplo, la regla de asociación $\{(Prueba\ de\ entrada, [60, 70]), (Videoconferencias\ accedidas, <5\%)\} \rightarrow (Tasa\ de\ éxito, suspenso)$ tiene un apoyo igual al 33% y una confianza igual al 100%, porque en todos los registros en los que ocurre el antecedente ocurre también el consecuente. En nuestro contexto, el índice de confianza indica que en todos los casos en los que la nota de la prueba de acceso está entre 60 y 70 y el número de videoconferencias a las que se accede es muy bajo la tasa de éxito es de suspenso.

En algunos casos, medir la fuerza de una regla en términos de apoyo y confianza puede resultar engañoso [42]. Cuando el consecuente de la regla se caracteriza por un valor de soporte relativamente alto, la regla correspondiente puede caracterizarse por una confianza alta incluso si su fuerza real es relativamente baja. Para superar este problema, el índice de correlación (o elevación) [42] se puede utilizar para medir la correlación (simétrica) entre el cuerpo y la cabeza de las reglas extraídas.

Definición 7. Correlación de una regla de asociación. Sea $X \rightarrow Y$ una regla de asociación. Su índice de correlación $\frac{\sup(X \cup Y)}{\sup(X) \sup(Y)}$ (entonces $\sup(X \cup Y) \sup(Y) \sup(X) \sup(Y)$, y $\text{conf}(X \rightarrow Y)$ son, respectivamente, el soporte de la consecuencia de la regla y el soporte de la consecuencia de la regla).

Si $\text{corr}(X, Y)$ es igual o cercano a 1, los conjuntos de elementos X e Y no están correlacionados entre sí. Los valores de correlación significativamente inferiores a 1 muestran una correlación negativa, mientras que los valores significativamente superiores a 1 indican una correlación positiva entre los conjuntos de elementos X e Y , es decir, X e Y coexisten más de lo esperado.

Por ejemplo, la correlación de la regla $\{(Prueba\ de\ entrada, [60, 70]), (Fracción\ de\ videoconferencias\ accedido, <5\%)\} \rightarrow \{(tasa\ de\ éxito, fracaso)\}$ es $\frac{\frac{2}{6}}{\frac{2}{6} \cdot \frac{3}{6}} = 2$. Por lo tanto, la regla de correlación es positiva.

Reglas de clasificación. El clasificador 3 consiste en un subconjunto de reglas de asociación de alta calidad, en lo sucesivo denominadas reglas de clasificación fuertes. Una regla de clasificación [13] es una regla de asociación cuyo consecuente es un elemento de clase.

Por ejemplo, regla $\{(Prueba\ de\ ingreso, [60, 70]), (Fracción\ de\ videoconferencias\ a\ las\ que\ se\ accede, <5\%)\} \rightarrow \{(tasa\ de\ éxito, fracaso)\}$ es una regla de clasificación.

Las reglas de clasificación se seleccionan porque se pueden aplicar directamente a la prueba de etiquetas registros cuyos valores de características que no sean de clase coincidan con los que aparecen en el antecedente de la regla.

Una regla de clasificación es fuerte si sus valores de soporte, confianza y correlación están por encima de los umbrales (proporcionados por el analista).

Reglas de alta calidad

En [15], las reglas de clasificación fuerte se dividen en (i) reglas de alta calidad, es decir, reglas utilizadas en la clasificación de datos de entrenamiento, y (ii) reglas no comprobadas, es decir, reglas no utilizadas durante la clasificación. fase de entrenamiento, pero potencialmente útil para clasificar datos de prueba. En el próximo paso, consideraremos exclusivamente las reglas de alta calidad.

3.3. Los modelos asociativos generados

decisiones de los clasificadores . por la L se recopilan y analizan para obtener conocimiento sobre las

Las reglas de clasificación relacionadas con la tasa de reprobación describen perfiles de estudiantes en riesgo. Por ejemplo, la regla $\{(Prueba\ de\ ingreso, [60, 70]), (Fracción\ de\ videoconferencias\ a\ las\ que\ se\ accedió, <5\%)\}$ y $\{(Tasa\ de\ éxito, suspenso)\}$ describe un perfil de estudiantes que han logrado resultados bastante buenos en las pruebas. y que no han descargado las videgrabaciones de las conferencias presenciales. Por el contrario, las reglas de clasificación relacionadas con la tasa de aprobación describen perfiles de estudiantes exitosos.

Los perfiles se pueden clasificar como (i) perfiles en riesgo, si son peculiares a la tasa de éxito fallan, o (ii) perfiles exitosos, si son peculiares a la tasa de éxito pasa. Tenga en cuenta que los perfiles son propios de un determinado curso y período de tiempo. Por lo tanto, pueden cambiar al considerar diferentes cursos y períodos. Otras categorizaciones de perfiles pueden basarse en el número y tipo de características involucradas. Específicamente,

- Los perfiles de función única son perfiles caracterizados por una categoría de función única. De acuerdo con la categorización de características informada en la Sección 3.1, se pueden clasificar adicionalmente como perfiles sobre características específicas de los estudiantes (perfiles SSC, en resumen), perfiles sobre indicadores de compromiso de los estudiantes (perfiles SEI) o perfiles sobre puntajes de evaluación (perfiles AS) dependiendo de la categoría de la característica de referencia.
- Los perfiles de características mixtas son perfiles que se modelan en varias categorías de características de datos. Extienden los perfiles de una sola característica combinando características de diferentes categorías.

Si bien los perfiles de una sola característica también se pueden identificar utilizando modelos de árboles de decisión, los de características mixtas son peculiares de los modelos asociativos, que abarcan reglas que incluyen elementos que pertenecen a múltiples características en el antecedente de la regla. En aras de la simplicidad, las categorías de perfiles de características mixtas se denotarán combinando las mismas abreviaturas indicadas anteriormente para los perfiles de una sola característica. Por ejemplo, los perfiles SSC+AS son aquellos caracterizados por características que pertenecen tanto a las características específicas del estudiante como a los puntajes de evaluación.

Por ejemplo, se puede considerar la regla $\{(Prueba\ de\ entrada, [60, 70]), (Fracción\ de\ videoconferencias\ a\ las\ que\ se\ accedió, <5\%)\}$ y $\{(Tasa\ de\ éxito, fracaso)\}$ para construir un SEI+AS en riesgo perfil, porque la tasa de éxito asignada es reprobada, mientras que las características que no pertenecen a la clase en el antecedente de la regla pertenecen a las clases Indicadores de participación del estudiante y Puntajes de evaluación, respectivamente.

Los profesores pueden estar interesados en mirar el perfil asociado con un estudiante específico o en identificar los perfiles de estudiantes más recurrentes. En este último caso, una vez que ya se ha aplicado un modelo asociativo a un número significativo de alumnos, se pueden filtrar los perfiles correspondientes en función de su uso real. En concreto, identificar qué reglas de clasificación ha aplicado realmente el clasificador a cada alumno permite al profesorado asociar a los alumnos con perfiles de riesgo recurrentes. Por ejemplo, si la regla $\{(Prueba\ de\ ingreso, [60, 70]), (Fracción\ de\ videoconferencias\ a\ las\ que\ se\ accedió, <5\%)\}$ y $\{(Tasa\ de\ éxito, suspenso)\}$ se ha utilizado para clasificar al 5% de los estudiantes, entonces el perfil de riesgo correspondiente podría considerarse particularmente relevante para comprender el progreso profesional de los estudiantes.

Los perfiles en riesgo y exitosos se clasifican primero por número decreciente de estudiantes clasificados. Luego, los perfiles mejor clasificados se exploran manualmente para obtener información sobre los estudiantes analizados. Cuando los alumnos descritos por un perfil han realizado el examen del curso, los resultados del examen se utilizan para discriminar entre perfiles fiables y no fiables.

Por ejemplo, si la mayoría de los estudiantes que fueron clasificados usando la regla $\{(Prueba\ de\ ingreso, [60, 70]), (Fracción\ de\ videoconferencias\ a\ las\ que\ se\ accedió, <5\%)\}$ y $\{(Tasa\ de\ éxito, suspenso)\}$ realmente reprobó el examen, entonces el perfil correspondiente podría considerarse confiable.

Analizar perfiles de estudiantes confiables mucho antes del final del curso permite a los profesores realizar intervenciones oportunas. Para cada perfil, una o más acciones dirigidas pueden ser

recomendado. Las acciones dirigidas a perfiles de riesgo confiables son preventivas, porque su objetivo es prevenir fallas. Por el contrario, las acciones dirigidas a perfiles exitosos confiables están dirigidas a reforzar las buenas prácticas.

Por ejemplo, supongamos que, en base a la exploración de las reglas minadas, se presenta un perfil de riesgo mixto, compuesto por todos los estudiantes cuya calificación en la prueba de ingreso está por debajo del promedio y cuyo porcentaje de videoconferencias a las que acceden es muy bajo (<5%), es identificado. Una fuerte correlación entre las calificaciones de las pruebas de ingreso y las conferencias en video a las que se accedió y el resultado de los exámenes podría incitar a los administradores universitarios a planificar (i) cursos adicionales sobre conceptos básicos adaptados a los estudiantes en riesgo o (ii) acciones de refuerzo desencadenadas por el perfil descubierto (p. ej., enviar recordatorios a lo largo del curso notificando la publicación de nuevos materiales). Asimismo, un perfil puede representar a estudiantes extranjeros que no han descargado ni accedido mediante streaming a las videoclases del curso. Las recomendaciones periódicas dirigidas a estudiantes inactivos se pueden aprovechar para fomentar la participación de los estudiantes.

4. Resultados

Analizamos empíricamente la aplicabilidad de la metodología propuesta sobre los datos relacionados con los estudiantes adquiridos por nuestra universidad técnica.

Para realizar una evaluación cuantitativa y cualitativa de los datos analizados, realizamos experimentos en una CPU Intel(R) Core(TM) i7-8550U con 16 GB de RAM que ejecuta un servidor Ubuntu 18.04.

4.1. Contexto de aprendizaje y datos relacionados

La universidad ofrece cursos de ingeniería BS y MS y adopta un modelo de aprendizaje combinado. El modelo combinado se basa en un servicio de video educativo masivo, que ofrece grabaciones de video de las conferencias en clase. El acceso a las videoclases de un curso está permitido a todos los alumnos matriculados. Por lo tanto, los estudiantes pueden aprovechar las conferencias en video como materiales complementarios además de las conferencias en clase [43]. Desde 2010 la universidad tiene videograbados en el aula todos los cursos del primer año de la Licenciatura en Ingeniería, que es común a todos los planes de estudio de la Licenciatura en Ingeniería. El número de estudiantes matriculados en los cursos de 1er año es de aproximadamente 5000 por año académico.

La plataforma de aprendizaje de la universidad rastrea las interacciones de los estudiantes con los materiales educativos proporcionados. Específicamente, a través de la plataforma, los estudiantes pueden (i) acceder y descargar materiales educativos (p. ej., diapositivas, apuntes de conferencias, simulaciones de exámenes) y (ii) ver (transmitidos desde el servicio web educativo o descargados) los registros de video de los in- conferencias de clase.

Como caso de estudio, aplicamos la metodología propuesta sobre datos adquiridos en el curso académico 2018-2019. Específicamente, nos enfocamos en predecir la tasa de éxito del examen para todos los estudiantes inscritos en los cursos de BS de 1er año. El plan de estudios de 1er año comprende los siguientes cursos: Análisis Matemático (MA), Química (CH), Ciencias de la Computación (CS), Álgebra Lineal (LA) y Física (PH), más un curso electivo que no se considera en el presente. análisis porque los datos no son comparables. En el año académico considerado, los cursos MA, CH y CS se realizaron en el primer semestre (es decir, del 1 de octubre de 2018 al 15 de enero de 2019), mientras que los cursos LA y PH se realizaron en el segundo semestre (del 1 de marzo de 2019 al 15 de enero de 2019). junio de 2019).

Se programaron tres sesiones de examen dentro de un año académico: (i) la sesión del primer semestre (invierno), que se lleva a cabo al final del primer semestre (es decir, del 22 de enero de 2019 al 28 de febrero de 2019), (ii) la sesión del segundo semestre (verano), que se lleva a cabo al final del segundo semestre (es decir, del 16 de junio de 2019 al 22 de julio de 2019), (iii) la sesión de otoño, que se lleva a cabo después de las vacaciones de verano (es decir, del 1 de septiembre de 2019 al 22 de julio de 2019), 30 de septiembre de 2019). Los estudiantes son libres de asistir a todas y cada una de las sesiones de examen, siempre que ya hayan asistido al curso.

Para identificar temprano a los estudiantes en riesgo, para cada estudiante y examen predijimos la tasa de éxito en la próxima convocatoria de exámenes. Específicamente, entrenamos clasificadores separados en los doce puntos de tiempo diferentes informados en la Tabla 2. En aras de la brevedad, cada punto de tiempo

será denotado en lo sucesivo por el identificador correspondiente. En cada punto de tiempo predijimos el resultado del estudiante considerado en el próximo examen (independientemente del resultado real asistencia a exámenes). Más específicamente, para los cursos de 1er semestre (MA, CH, CS) en el momento puntos de t0 a t5 predijimos la tasa de éxito del examen de la sesión de invierno, de los puntos t6 a t9 predijimos la tasa de éxito del examen realizado en la convocatoria de verano, mientras que en puntos t10 y t11 predijimos el ritmo de la sesión de otoño. Para los cursos del segundo semestre, de t0 a t9 predijimos la tasa de éxito del examen en la sesión de verano (porque el sesión de invierno no es elegible para estudiantes de primera matrícula), mientras que en los puntos t10 y t11 predijo el ritmo de la sesión de otoño.

Para los cursos realizados en el primer semestre (MA, CH y CS), el primer examen después la asistencia al curso está prevista en la sesión de invierno, mientras que para los demás cursos (LA, PH) el primer examen está programado en la sesión de verano. Sin embargo, para todos los cursos de 1er año los alumnos podrán realizar el examen correspondiente en cualquiera de las citadas convocatorias (p. ej., pueden realizar el examen de maestría por primera vez durante la sesión de verano).

Detalles sobre los datos de origen

La fuente de datos considerada consta de dos tablas principales: tabla Estudiantes recopila general información sobre los estudiantes, mientras que la tabla Cursos-Actividades recopila información sobre asistencia al curso. El esquema de cada tabla se detalla en las Tablas 3 y 4. Las tablas no contienen ningún valor faltante. Generamos un conjunto de datos de entrenamiento a partir del original. tablas, donde cada registro de conjunto de datos corresponde a un par distinto de Id. de tiempo y Curso

valores de identificación.

La Tabla 5 informa la cantidad de registros por punto de tiempo y curso, así como el porcentaje de antigüedad de los registros por clase. Indica para cada curso el número de alumnos considerados en los datos de entrenamiento en diferentes puntos de tiempo. Por ejemplo, para el curso de maestría en puntos de tiempo de t0 a t5 (es decir, antes del primer examen) los datos de entrenamiento consisten en 4092 estudiantes, entre los cuales 1515 estudiantes que aprobarán el próximo examen y 2577 estudiantes que lo reprobarán.

Tabla 2. Puntos temporales de predicción.

	Punto de tiempo	Descripción
t0	31 de agosto de 2018	Antes de la prueba de ingreso
t1	7 septiembre 2018	Después de la prueba de entrada
t2	30 de octubre de 2018	Principios del 1er semestre
t3	31 noviembre 2018	A mitad de camino 1er semestre
t4	15 enero 2019	Cerca de los exámenes del 1er semestre
t5	22 enero 2019	Inicio de la sesión de exámenes del 1er semestre
t6	28 febrero 2019	Final de la sesión de exámenes del 1er semestre
t7	31 de marzo de 2019	Principios del segundo semestre
t8	30 abril 019	A mitad de camino 2do semestre
t9	15 junio 2019	Inicio de la convocatoria de exámenes del segundo semestre
t10	22 julio 2019	Final de la convocatoria de exámenes del segundo semestre
t11	31 agosto 2019	Después de las vacaciones de verano

Tabla 3. Esquema de la tabla de Estudiantes.

Atributo	Descripción	Tipo de datos	Dominio
Identificación del Estudiante	identificador del estudiante	categórico	{1,2,...}
Género	sexo edad del	categórico	{M = hombre, F = mujer}
Envejecer	estudiante—edad promedio de los estudiantes	ordinal	{y1,1,2,3}
BH-loc	identificador del país de nacimiento	identificador	{AF, AL, ...}
HM-loc	del país de origen	identificador	{AF, AL, ...}
HS-loc	escuela secundaria banda de calificaciones de la	identificador	{AF, AL, ...}
HS-gr	escuela secundaria calificación de la prueba	ordinal	{1 = bajo, 2 = promedio bajo, 3 = promedio, 4 = promedio alto, 5 = alto}
GRE-gr	de ingreso título de licenciatura	ordinal	{1 = bajo, 2 = promedio bajo, 3 = promedio, 4 = promedio alto, 5 = alto}
curso de licenciatura		categórico	{ingeniería mecánica, ingeniería informática...}

Tabla 4. Esquema de la tabla Cursos-Actividades.

Atributo	Descripción	Tipo de datos	Dominio
Identificación del Estudiante	identificador de estudiante	categorico	{1,2,.....}
Identificación del curso	raza identificar	categorico	{1,2,.....}
Punto de tiempo	identificador de punto de	ordinal	{0,1,...,12}
estera MA	tiempo frecuencia discretizada de conferencias en video'	categorico	{H = alto, F = promedio, L = poco, N = sin uso}
	descargas normalizadas al máximo		
MA-str	número de descargas realizadas hasta ese momento	categorico	{H = alto, F = promedio, L = poco, N = sin uso}
	a tiempo		
MA-str	frecuencia discretizada de los accesos a las	categorico	{H = alto, F = promedio, L = poco, N = sin uso}
	videoconferencias normalizadas al número máximo		
	de accesos hasta ese momento		

Tabla 5. Muestras de datos por punto de tiempo.

	t0 - t5		t6 - t9		t10 - t11	
	Aprobar	Fallar	Aprobar	Fallar	Aprobar	Fallar
MAMÁ	1515	2577	1183	332	1035	148
CS	1786	2307	1427	359	1127	300
CH	2697	1394	2397	300	2135	262
PH	2823	1270	2823	1270	2431	392
LA	1245	2848	1245	2848	1018	227

4.2. Comparación de rendimiento entre diferentes algoritmos

Llevamos a cabo una evaluación empírica del desempeño de varias clasificaciones algoritmos en el conjunto de datos analizado. El objetivo del análisis experimental es responder a la siguiente pregunta de investigación (RQ1): ¿Son los clasificadores asociativos tan precisos como los mejores? desempeño en la predicción del rendimiento académico de los estudiantes?

Para abordar el problema anterior, comparamos el rendimiento de L ³ clasificador con la de una variedad de otros clasificadores. Note que a pesar de comparaciones experimentales similares ya se han realizado en estudios previos (p. ej., [3]), hasta donde sabemos los modelos asociativos no han sido considerados todavía.

Modelos de clasificación

Consideramos los siguientes clasificadores [39]:

1. Vive y deja vivir (L ³) clasificador [15]: un clasificador asociativo de última generación.
2. C4.5 (DT): clasificadores populares basados en árboles de decisión.
3. Perceptrón multicapa (MLP): un popular modelo de redes neuronales de una sola capa.
4. LIBSVM (SVM): un modelo establecido de máquinas de vectores de soporte.
5. Bayesiano ingenuo multinomial (NB): un clasificador bayesiano multiclase establecido.
6. k-Nearest Neighbor (kNN): un clasificador perezoso basado en la distancia (los clasificadores perezosos no crear modelos, pero calcular sobre la marcha las distancias entre un registro de prueba y cada uno de ellos los registros de entrenamiento).
7. Random Forest (RF): método de conjunto.

para la L ³ utilizamos la implementación de C++ proporcionada por los autores, mientras que para todos los demás algoritmos usamos las implementaciones de Python disponibles en la biblioteca Scikit Learn [44]. Para ajustar el rendimiento del clasificador en cada punto de tiempo considerado, realizó una búsqueda en cuadrícula variando los valores de los parámetros más significativos. Lo sucesivo, en aras de la brevedad, informaremos los resultados logrados por la mejor configuración por separado para cada algoritmo.

Complejidad del tiempo

La complejidad del tiempo para entrenar y probar los modelos de clasificación osciló entre) y pocos segundos en conjuntos de datos más simples (p. ej., 7 s para MLP, 31 s ³aproximadamente una hora. para L en el peor de los casos). Sin embargo, la mayoría de los modelos de predicción se generaron en menos de 60 s.

Métricas de rendimiento

Para evaluar cuantitativamente el desempeño del clasificador en cada punto de tiempo, aplicamos una estrategia de validación cruzada estratificada de 5 veces y calculamos las siguientes métricas de desempeño:

- Precisión de la falla de la clase: es la relación entre el número de estudiantes que han sido etiquetados correctamente como pertenecientes a la clase reprobado (TN) dividido por el número total de alumnos asignados a la clase reprobado (TN + FN).
- Recordatorio de clase reprobada: Es la relación entre el número de alumnos que han sido etiquetados correctamente como pertenecientes a la clase reprobada (TN) dividido por el número total de alumnos que realmente pertenecen a la clase reprobada (TN + FP).
- F1-puntuación de fallo de clase: Es la media armónica de precisión y recuperación de fallo de clase.
- Precisión balanceada: Es el promedio del recuerdo calculado sobre las dos clases y viene dado por) [45].

$$F1 = \frac{2 \times \text{Precisión} \times \text{Recuerdo}}{\text{Precisión} + \text{Recuerdo}}$$
 Evalúa la capacidad del clasificador para asignar los estudiantes a las clases equilibradas de clase. Estos se prefieren ya que premia las predicciones correctas sobre la clase minoritaria. Cuando las muestras de prueba se equilibran entre las dos clases, corresponde a la medida de precisión convencional (es decir, porcentaje de predicciones correctas).

Si bien la medida de precisión es independiente de la clase, las otras métricas son específicas de la falla de clase. Dado que el objetivo principal de la predicción del rendimiento de los estudiantes es detectar de manera temprana a los estudiantes en riesgo, analizamos específicamente la capacidad de los clasificadores para clasificar correctamente esta categoría particular de estudiantes.

La Figura 2a–f traza para cada curso las puntuaciones de precisión logradas por los clasificadores en diferentes momentos. Las líneas discontinuas verticales indican las sesiones de examen previstas durante el curso académico. Los valores de precisión alcanzados por la mayoría de los algoritmos antes del inicio del primer semestre rondan el 60%. Para los cursos del primer semestre (MA, CH, CS), el rendimiento disminuye después de la primera sesión de exámenes, porque predecir los resultados de los estudiantes en las próximas sesiones (es decir, en la segunda prueba) es significativamente más desafiante. Para los cursos del segundo semestre (PH, LA) se lograron resultados similares después del primer examen, que está programado después de un tiempo tan largo como los clasificadores de mejor desempeño (K NN, MLP), mientras que los clasificadores de árboles de decisión (DT y RF) se desempeñaron peor. Se han mostrado ligeras fluctuaciones en la serie de valores de precisión en los últimos puntos de tiempo (t9–t11). La razón es que al disminuir el número de alumnos evaluados (porque la mayoría ya aprobó los exámenes), los modelos son menos robustos y más sensibles al ruido.

La Figura 2f–t, respectivamente, traza para cada curso la puntuación F1, la precisión y el recuerdo de la falla de clase logrados por los clasificadores en diferentes puntos de tiempo. Describen la capacidad de los clasificadores para predecir con precisión las fallas en los exámenes. Los valores de precisión y recuperación aumentan a medida que pasa el tiempo (p. ej., para MA, la precisión ³de un estudiante significativamente después de la t9) la sesión de examen (en t5 para los cursos del primer semestre, en t9 para los del segundo semestre) porque los estudiantes que reprobaron una vez tienen más probabilidades de reprobado nuevamente. L se desempeñó tan bien como los mejores clasificadores en ³ todos los cursos y en la mayoría de los puntos de tiempo considerados.

Para evaluar la significación estadística de las variaciones de rendimiento (calculadas en términos de precisión, puntaje F1, precisión y recuperación de la falla de clase), aplicamos el Wilcoxon

Pruebas t de rango con signo [46] utilizando un nivel de significación igual al 0,5%. Los resultados muestran que L se desempeñó significativamente mejor que DT y RF en puntos de tiempo específicos para la mayoría de los cursos analizados, mientras que se ³desempeñó tan bien como los mejores enfoques (K-NN, MLP). Por lo tanto, el modelo asociativo L podría considerarse ³los estudiantes modelo fiable para la predicción temprana del rendimiento de

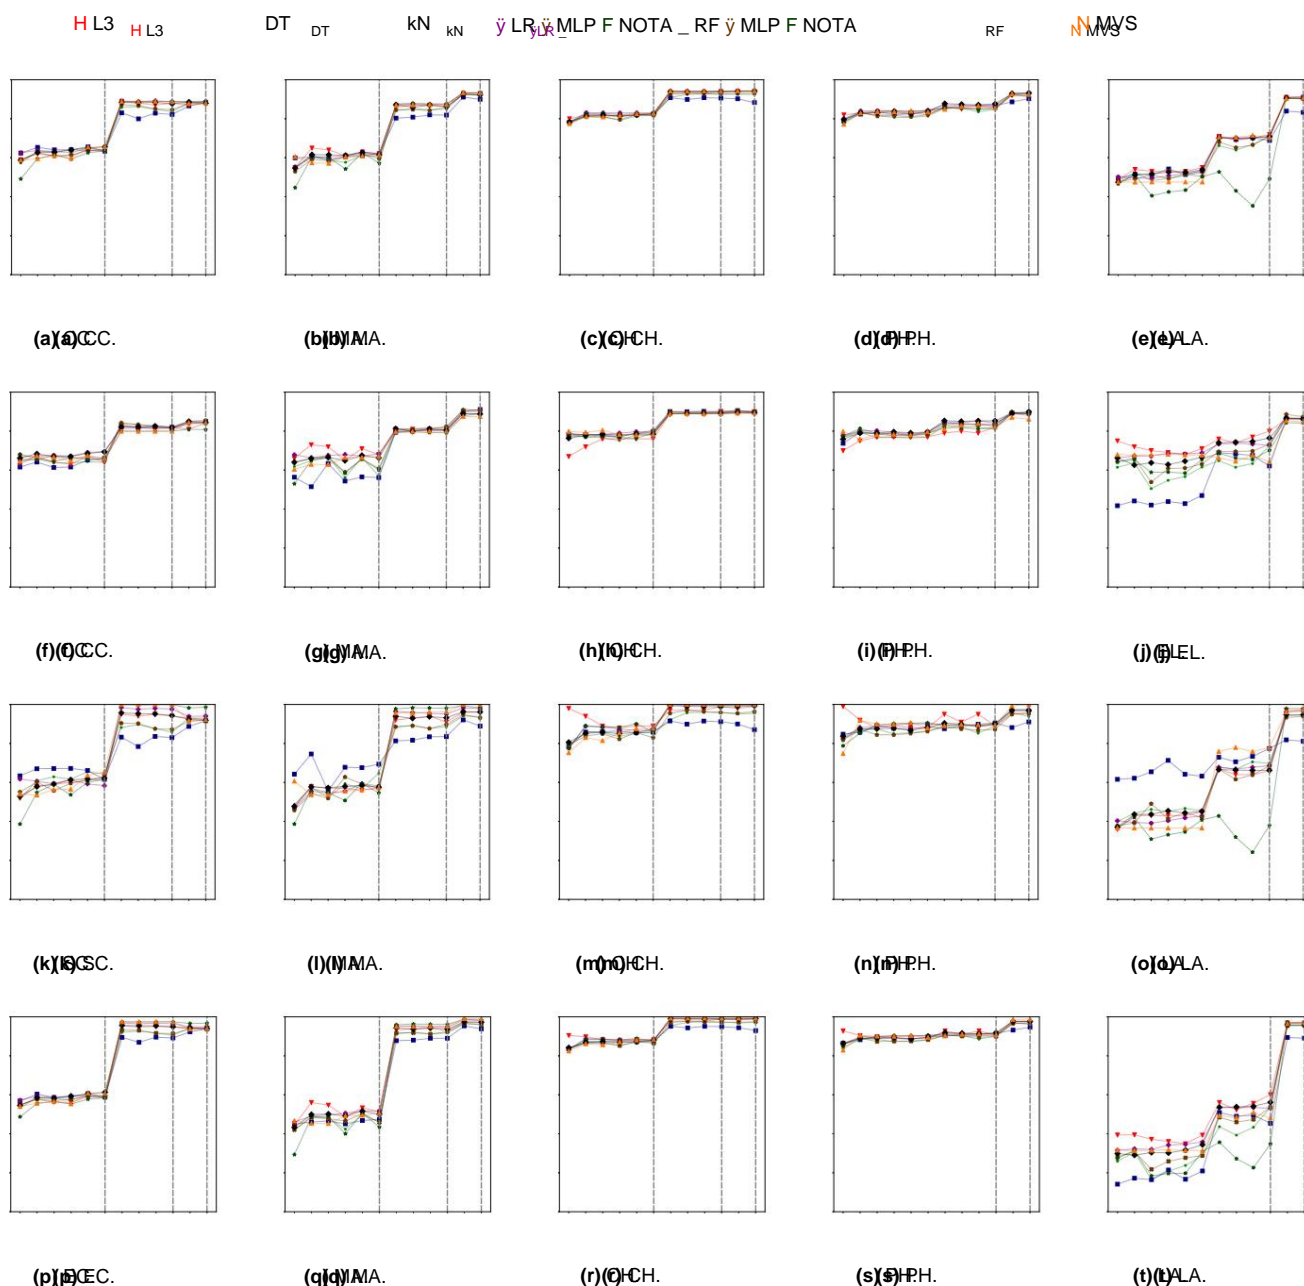


Figura 2. Comparación de algoritmos en términos de puntaje F1, precisión, recuperación y precisión equilibrada de falla de clase.

4.3. Modelo Exploración

530 diferentes disciplinas depende de la importancia percibida en su futuro. En t5, el efecto del clasificador 3
 531 reglas de alta calidad generadas por la descarga L 531 de manera adecuada. Para explorar las
 de la actividad de transmisión (por ejemplo, MA-str) para el más confiable perfiles de estudiantes. Específicamente,
 532 primero contamos, para cada alta calidad, los diferentes cursos son visibles. El título de bachillerato sigue
 siendo muy relevante, mientras que, por regla general, el número de alumnos clasificados así como los
 curso pueden influir en otros cursos. los clasificados. A continuación, analizamos el subconjunto de reglas de
 alta calidad que (i) se han aplicado 534 Por ejemplo, dado que MA proporciona a los estudiantes los
 producido exclusivamente predicciones correctas. Todo el grado 535 (siempre que esté disponible) es
 particularmente exigente. se descartaron otras reglas, ya que potencialmente generaban predicciones poco
 536 confiables. Regla Los diagramas de radar en la Figura 4 profundizan el análisis de características para el
 curso LA del segundo semestre. la exploración tiene como objetivo responder a las preguntas de

537 Las características se agrupan en diferentes categorías (datos personales e historial escolar, prueba de ingreso y Se trata de explorar la interpretabilidad del modelo ya que las reglas
 extraídas se pueden entender fácilmente 538 Elección de cursos de BS, actividad en dos cursos de muestra, MA y CS, descarga de material educativo por parte de no-usuarios finales.
 expertos y éxito en el examen) y se compara su importancia en todos los puntos de tiempo (de 0 a 9). Para el ejemplo 540, el gráfico (a) confirma que la calificación de la escuela secundaria (HS-

539 gr) tiene un impacto importante en el rendimiento del estudiante 541 durante todo el año académico. Por el contrario, el género es relevante solo al principio, 542 porque la actividad del
 estudiante durante el semestre se vuelve cada vez más 543 importante para prever la tasa de éxito del examen. El gráfico (b) muestra que la calificación de la prueba (GRE-gr) y el curso

de BS

Pregunta de investigación (RQ2): ¿Cuáles son las características más discriminadoras para pronosticar las tasas de éxito del examen en diferentes momentos?

Para responder a esta pregunta, analizamos la frecuencia de ocurrencia de las características individuales y de los pares de características en los perfiles de estudiantes seleccionados.

La Figura 3 muestra el porcentaje de reglas que incluyen características específicas en su antecedente en tres momentos representativos: t_0 (antes de la prueba de ingreso), t_1 (después de la prueba de ingreso y la elección del curso de BS, pero antes del inicio del semestre) y t_5 (al final del primer semestre). La gráfica destaca las características que más influyen en el desempeño de los estudiantes por separado para cada curso y punto de tiempo. En t_0 solo se consideran las características específicas del estudiante y, como era de esperar, la más importante es la calificación de la escuela secundaria (HS-gr).

La edad también se correlacionó fuertemente con la tasa de éxito, porque los estudiantes que son mayores que el promedio a menudo obtienen malos resultados durante la escuela secundaria. En t_1 , la calificación de la prueba de entrada (GRE-gr) juega un papel importante en la predicción de la tasa, en combinación con HS-gr. La elección del curso de BS (por ejemplo, ingeniería mecánica versus ingeniería informática) también es una característica importante, porque la actitud de los estudiantes hacia las diferentes disciplinas depende de la importancia percibida en su futuro. En t_5 es visible el efecto de la descarga de material educativo (p. ej., MA-mat) y de la actividad de streaming (p. ej., MA-str) para los diferentes cursos. El título de bachillerato sigue siendo muy relevante, mientras que en general la edad disminuye su importancia. Las actividades realizadas en un curso pueden influir en otros cursos. Por ejemplo, dado que MA proporciona a los estudiantes los conceptos básicos tanto para LA como para PH, la calificación del examen (siempre que esté disponible) es particularmente discriminadora.

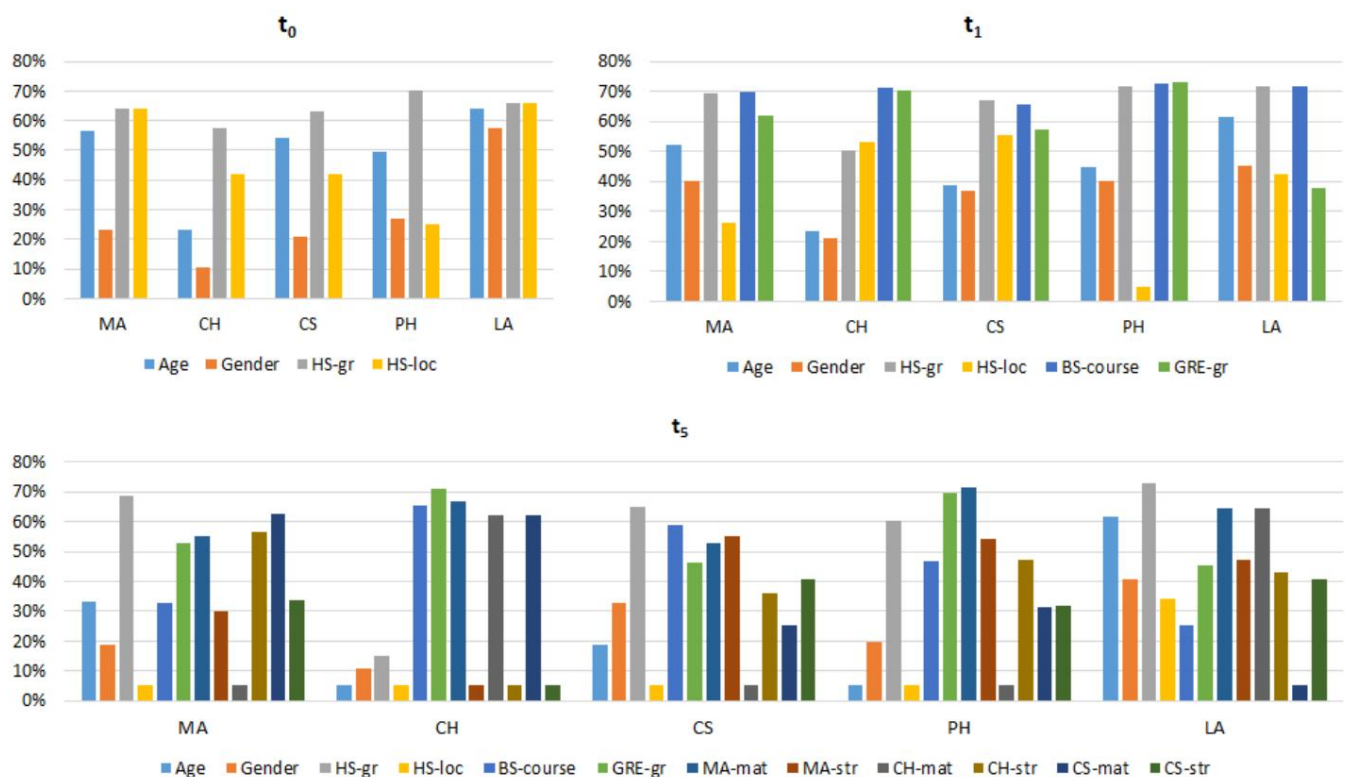


Figura 3. Frecuencia de ocurrencia (en porcentaje) de las características que aparecen en los antecedentes de la regla en diferentes momentos.

Los diagramas de radar en la Figura 4 profundizan el análisis de características para el curso LA del segundo semestre. Las funciones se agrupan en diferentes categorías (datos personales e historial académico, prueba de ingreso y elección de cursos de BS, actividad en dos cursos de muestra, MA y CS, descarga de material educativo y éxito en el examen) y su importancia se compara en todos los puntos de tiempo (desde 0 a 9). Por ejemplo, el gráfico (a) confirma que la calificación de la escuela secundaria (HS-gr) tiene un impacto importante en el desempeño de los estudiantes durante todo el año académico. Sobre el

(a) Personal data and scholastic history

(b) Entry test and BS course choice

(c) Activity in MA

(d) Activity in CS

(e) Material download activity

(f) Exam success

La extracción de reglas de asociación nos permite explicar las prioridades de los elementos más relevantes en relación con diferentes combinaciones de características [40]. La Figura 5 muestra la importancia de un subconjunto relativo a diferentes combinaciones de características [49]. La Figura 6 muestra la importancia de un subconjunto de combinaciones relevantes de características para LA en diferentes momentos. Por ejemplo, las combinaciones académicas relevantes de características para LA en diferentes momentos. Por ejemplo, el historial académico (HS-loc, HS-gr) es relevante para predecir la tasa de éxito antes de cualquier actividad universitaria. El historial (HS-loc, HS-gr) es relevante para predecir la tasa de éxito antes de cualquier actividad universitaria (es decir, es decir, antes de t1), incluyendo prueba de acceso y opción de curso de BS. Después de eso, y hasta casi antes de t1), incluyendo prueba de acceso y opción de curso de BS. Después de eso, y hasta casi al final del semestre (t4), la nota de la escuela secundaria y la nota de la prueba de ingreso junto con la del semestre (t4), la nota de la escuela secundaria y la nota de la prueba de entrada junto con el curso de BS BS opción (HS-gr, curso BS). (GRE-gr, curso BS) se convirtió en la opción de curso de características más relevante (HS-gr, curso BS), (GRE-gr, curso BS) se convirtió en la combinación de características más relevante. Durante el primer semestre (de t2 a t5) descarga de material didáctico de combinación. Durante el primer semestre (de t2 a t5), la descarga de material educativo de dos cursos tiene el efecto más fuerte (MA-mat, CS-mat), mostrando que el estudiante participa activamente en dos cursos tiene el efecto más fuerte (MA-mat, CS-mat), mostrando la participación activa de los estudiantes. Finalmente, durante el segundo cuatrimestre (cuando se imparte LA), la característica más relevante ción. Finalmente, durante el segundo semestre (cuando se imparte LA), la combinación de características más relevante es el número de descargas de material educativo combinado con la combinación de calificaciones que es el número de descargas de material educativo combinado con la calificación obtenida en el curso MA (LA -mat, MA-gr). logrado para el curso MA (LA-mat, MA-gr).



Reglas similares. Finalmente, se propone para el progreso profesional de los estudiantes inscritos en la columna Por ejemplo, la regla 4 en la Tabla 6 indica que los estudiantes que recibieron una admisión bastante baja Las reglas brindan información interesante sobre el progreso profesional de los estudiantes matriculados. Para prevenir Por ejemplo, la regla 4 en la Tabla 6 indica que los estudiantes que reprobaron un examen de admisión calificaciones y que son mayores que el promedio tienen más probabilidades de reprobar el examen de MA. bastante bajo, la universidad podría organizar cursos de recuperación para los estudiantes que tienen calificaciones y que son mayores que el promedio tienen más probabilidades de reprobar el examen de maestría. Evitar no alcanzar una calificación suficiente en la parte de las pruebas de admisión relacionadas con las matemáticas. fracasos en los exámenes, la universidad podría organizar cursos de recuperación para los estudiantes que tienen La regla 10 en la Tabla 7 indica que los estudiantes que han descargado una gran parte de no lograron una calificación suficiente en la parte de las pruebas de admisión relacionadas con las matemáticas. Es probable que los materiales educativos de la primera mitad del curso de maestría aprueben el examen. La regla 10 en la Tabla 7 indica que los estudiantes que han descargado una gran parte de La extracción de dicho perfil solicita una acción de refuerzo específica, es decir, enfatizar los materiales educativos para la primera mitad del curso de maestría, es probable que aprueben el examen. importancia de utilizar material didáctico y animar a los alumnos a seguir como ellos La extracción de dicho perfil incita a una acción de refuerzo específica, es decir, acentuar lo que están haciendo. importancia de utilizar material didáctico y animar a los alumnos a seguir como lo hacen La Regla 25 de la Tabla 9 indica lo que están haciendo los alumnos que acaban de descargar el video de la graduación del curso MA sin acceder al resto de los materiales didácticos son al menos La regla 25 en la Tabla 9 indica que los estudiantes que acaban de descargar e idéos probablemente aprobarán un examen los estudiantes que acaban de descargar e idéos es la probabilidad de MA que con la tasa de éxito de los materiales didácticos en los exámenes (pueden) probabilidad de aprobar el examen con la tasa de éxito de los materiales didácticos en los exámenes (pueden) probabilidad de aprobar el examen con la tasa de éxito de los materiales didácticos en los exámenes (pueden) correlación positiva entre esas tasas de éxito sólo ocurren a lo largo de los tres períodos de la carrera características (ver regla 24) sólo se observan de acuerdo con esas características. Con la tasa de éxito independientemente de las demás funciones (ver regla 24).

A la luz de los resultados del análisis de características y de la exploración de reglas en la Sección 4.3, se pueden sacar las siguientes conclusiones:

Tabla 6. Reglas de función única de alta calidad extraídas de los conjuntos de datos de MA que incluyen solo funciones de SSC. minup = 1%, minconf = 50%, mincorr = 2. Los valores de soporte y confianza de cada una de las reglas seleccionadas se promedian sobre los 5 pliegues de validación cruzada (se especifican el promedio y la desviación estándar).

Número de tiempo ID Cuerpo		Soporte de cabeza (%)		Confianza (%)		Descripción de elevación	
Prueba previa							
1	t0	HS-loc = Italia, HS-gr = 5, género = F	aprobar	10,0 ± 0,3	86,5 ± 0,7	7	Muy buen grado de bachillerato, bachillerato en Italia, mujer (independientemente de la edad)
2	t0	HS-loc = Italia, HS-gr = 4, edad = 0	aprobar	30,4 ± 0,2	79,2 ± 1,3	8	Buena nota de bachillerato, bachillerato en Italia, edad promedio
3	t0	HS-gr = 5, género = M, edad = 1	aprobar	14,1 ± 0,2	87,9 ± 1,0	4	Buen grado de secundaria, hombre, más joven. que la media (independientemente de la alta país de la escuela)
4	t0	HS-gr = 1, género = M, edad = 3	fallar	3,0 ± 0,1	90,7 ± 1,2	3	Grado de bachillerato muy bajo, varón, mucho mayor que el promedio
5	t0	HS-gr = 2, edad = 1	fallar	3,9 ± 0,1	89,7 ± 1,3	8	Bajo grado, mayor que el promedio (independientemente del género y del país de la escuela secund

Tabla 7. Reglas de función única de alta calidad extraídas de los conjuntos de datos de MA que incluyen solo funciones T-MAT. minup = 1%, minconf = 50%, mincorr = 2. Los valores de soporte y confianza de cada una de las reglas seleccionadas se promedian sobre los 5 pliegues de validación cruzada (se especifican el promedio y la desviación estándar).

Número de tiempo ID Cuerpo			Apoyo a la cabeza (%) Confianza (%)			Elevar	Descripción	Reglas similares
Principios del 1er semestre								
6	t2	MA-mat = L	aprobar	31,8 ± 0,2	68 ± 0,6	7	Poco uso del material de MA, pero ya al comienzo del semestre	CH (con fallo)
7	t2	MA-mat = F	aprobar	14,9 ± 0,3	75,2 ± 0,7	8	Uso promedio de material MA	CH
8	t2	CS-estera = L, CH-mat = L	aprobar	14,9 ± 0,1	68,3 ± 0,7	9	Poco uso de material de otros cursos.	CS
9	t2	MA-mat = N, CS-mat = N, CH-mat = N	fallar	65,4 ± 0,1	65,5 ± 0,7	6	Sin uso de material (inactivo)	CH, CS
A mitad de camino 1er semestre								
10	t3	MA-mat = H	aprobar	7,5 ± 0,3	78,9 ± 1,3	7	Alto uso de material MA	CH
11	t3	MA-mat = F	aprobar	21,1 ± 0,2	76,1 ± 0,8	7	Uso promedio de materiales MA, confirma t2	
12	t3	MA-mat = L	fallar	25,2 ± 0,2	64,4 ± 0,5	7	Poco uso de material MA no es suficiente ahora (ver t2)	CH, CS
13	t3	MA-mat = N, CS-mat = N, CH-mat = N	fallar	17,2 ± 0,2	87,4 ± 1,3	8	Sin uso de material (inactivo), confirma t2	CH, CS
Cerca de los exámenes del 1er semestre								
14	t4	MA-mat = F	aprobar	25,9 ± 0,1	78,2 ± 1,1	7	Uso promedio de material MA, confirma t2 y t3	CH, CS
15	t4	MA-mat = L	fallar	25,2 ± 0,1	73,9 ± 0,8	8	Poco uso de material MA, confirma t3	CH, CS
16	t4	MA-mat = N, CS-mat = N, CH-mat = N	fallar	13,2 ± 0,1	95,7 ± 0,6	7	Sin uso de material (inactivo), confirma t2 y t3	CH, CS
17	t4	CH-mat = H	fallar	3,9 ± 0,1	78,8 ± 0,8	8	Alto uso de otro material del curso	CS (con pase)

Tabla 8. Reglas de alta calidad extraídas de los conjuntos de datos de MA que incluyen solo características de STREAM-VL. minup = 1%, minconf = 50%, mincorr = 2. Los valores de soporte y confianza de cada una de las reglas seleccionadas se promedian sobre los 5 pliegues de validación cruzada (se especifica el promedio y la desviación estándar).

Número de tiempo ID Cuerpo			Apoyo a la cabeza (%) Confianza (%)			Elevar	Descripción	Reglas similares
Principios del 1er semestre								
18	t2	MA-str = L	aprobar	24,2 ± 0,2	70,0 ± 0,7	6	Poco uso de videos MA, pero pronto (octubre), coherente con material MA	CH (con fallo), CS (con fallar)
19	t2	CH-str = L	aprobar	20,1 ± 0,2	71,7 ± 1,2	4	Streaming de otros cursos tiene un impacto positivo incluso si no hay videos MA (muestra el compromiso de los estudiantes)	CS, CH (con fallo)
		CS-str = L		12,4 ± 0,1	69,1 ± 0,7	6		
		MA-str = N, CH-str = L		7,6 ± 0,3	72,5 ± 0,3	5		
		MA-str = N, CS-str = L		5,5 ± 0,2	70,9 ± 0,9	8		
A mitad de camino 1er semestre								
20	t3	MA-str = L	aprobar	29,1	69	6	Poco de los videos de MA es suficiente, con o sin otros cursos. Diferente del material MA: enfoque suficiente para video transmisión	no CS (reprobado)
		MA-str = L, CH-str = L		15,2 ± 0,1	70,6 ± 0,9	7		
		MA-str = L, CS-str = L, CH-str = N		10,4 ± 0,1	70,2 ± 0,2	7		
21	t3	CH-str = L	aprobar	24,9 ± 0,3	70,6 ± 1,3	4	Streaming de otros cursos tiene impacto positivo, con firmas t2	CS, CH (con fallo)
		CS-str = L, MA-str = N, CH-str = N		18,4 ± 0,2	68,2 ± 0,7	6		
Cerca de los exámenes del 1er semestre								
22	t4	MA-str = L, CH-str = L	aprobar	18,6 ± 0,2	69,9 ± 0,7	7	Poco de videos de MA es suficiente, confirma t3	CS (con fallo)
23	t4	MA-str = F, CH-str = F	aprobar	28,9 ± 0,2	70,2 ± 0,7	4	Streaming de otros cursos tiene impacto positivo, con firmas t2 y t3	CS, CH (con fallo)
		MA-str = F, CS-str = F		10,7 ± 0,2	69,6 ± 0,9	7		

Tabla 9. Reglas de características mixtas de alta calidad extraídas de los conjuntos de datos de MA. minsup = 1%, minconf = 50%, mincorr = 2. Soporte y los valores de confianza de cada una de las reglas seleccionadas se promedian sobre los 5 pliegues de validación cruzada (promedio y estándar se especifica la desviación).

Número de tiempo ID Cuerpo			Apoyo a la cabeza (%) Confianza (%)			Descripción del ascensor	
Principios del 1er semestre							
24	t2	MA-mat = N, MA-str = L	aprobar	7,5 ± 0,1	90,2 ± 0,9	45	La transmisión es eficaz incluso sin acceso a materiales
25	t2	MA-mat = N, MA-abajo = L	fallar	4,0 ± 0,1	65,2 ± 1,2	41	La descarga no es efectiva sin acceso a materiales
A mitad del 1.er semestre: mismas reglas							
Cerca de los exámenes del primer semestre: mismas reglas							

4.4. comida para llevar

A la luz de los resultados del análisis de características y de la exploración de reglas en la Sección 4.3, se pueden sacar las siguientes conclusiones:

- El grado de bachillerato influye mucho en el desempeño de los estudiantes. En las reglas de ejemplo, esto es ya evidente en t0 (ver Tabla 6) para el curso MA, pero la característica es muy relevante durante todo el año académico (ver (a) en la Figura 4) y el resultado es válido para todos los cursos (ver Figura 3). Planificación de cursos de recuperación ad hoc para estudiantes con baja alta grado escolar es, por tanto, una acción adecuada para evitar la deserción escolar.
- La edad también tiene un impacto significativo. Esto no es sorprendente porque los estudiantes que son mayores que el promedio probablemente tuvo resultados por debajo del promedio durante la escuela secundaria o son de medio tiempo trabajadores Las reglas 3, 4 y 5 de la Tabla 6 confirman esta afirmación para el curso MA, pero el

característica siempre es relevante, especialmente en la primera parte del año académico (ver (a) en la Figura 4) y el resultado es válido para la mayoría de los cursos (ver Figura 3). El hecho de que la influencia de esta característica disminuya durante el semestre demuestra que los estudiantes motivados aprenden a reaccionar poniendo un esfuerzo extra en el estudio. Las acciones de sensibilización hacia esta categoría de estudiantes pueden tener un efecto positivo.

- La inactividad en la descarga de material educativo está fuertemente relacionada con el fracaso. Las reglas 9, 13 y 16 reportadas en la Tabla 7 para el curso MA muestran que esto se cumple durante todo el semestre. Una invitación proactiva y reiterada a utilizar los materiales educativos disponibles podría ayudar a los estudiantes.
- Es muy importante iniciar muy pronto la actividad de estudio. La Tabla 7 muestra que un número limitado de descargas de los materiales educativos de MA es suficiente al comienzo del semestre (regla 6), pero no más adelante (reglas 12 y 15). Este resultado es coherente con el gráfico (e) de la Figura 4: la actividad de descarga de material educativo tiene una fuerte influencia en el rendimiento de los estudiantes ya al inicio del semestre. Esta es una recomendación útil para los estudiantes que quieren mejorar su rendimiento académico. • Poner esfuerzo en muchos cursos al mismo tiempo es una estrategia que paga al comienzo del semestre pero no cerca de la sesión de exámenes. La regla 8 de la tabla 7 muestra que trabajar en más de un curso en t2 aumenta la posibilidad de aprobar el curso MA, mientras que la regla 17 muestra que el mismo tipo de comportamiento en t4 produce efectos opuestos. Por lo tanto, se debe invitar a los estudiantes a trabajar duro desde el comienzo del semestre, pero también se les debe advertir que deben concentrarse en un curso específico cuando estén cerca del examen.
- El uso del servicio de videoconferencias en streaming siempre es positivo. La Tabla 8 muestra que la actividad de transmisión de conferencias en video, incluso si es limitada, tiene un impacto positivo en la aprobación del examen de maestría. Esto es válido para el uso de videoconferencias MA (reglas 18, 20 y 22), pero también para el uso de videoconferencias de otros cursos (reglas 19, 21 y 23), porque esta actividad probablemente identifica a estudiantes activos y motivados. La regla 24 de la Tabla 9 agrega que el streaming es positivo incluso sin descargar material educativo. Este resultado es muy positivo para nuestra institución, ya que demuestra que el servicio de videoconferencias es valioso, además de ser apreciado por los estudiantes. Animar a los estudiantes a utilizar activamente el servicio es otra acción fructífera para evitar el fracaso y la deserción. • La descarga de videoconferencias no es suficiente. La regla 25 en la Tabla 9 muestra que la descarga de videoconferencias sin el uso de material educativo no es suficiente para aprobar el examen de maestría. Esta regla identifica a los estudiantes que simplemente descargan todas las videoconferencias para un uso posterior, pero que muy probablemente (ya que no descargan el material educativo adjunto) no las ven. Este resultado está respaldado por lo que es evidente en los gráficos (c) y (d) de la Figura 4. La actividad de transmisión de videoconferencias y la actividad de descarga de material educativo se muestran como indicadores para el éxito del examen, mientras que este no es el caso para la videoconferencia . actividad de descarga de conferencias.

5. Conclusiones

El artículo propone explotar la clasificación asociativa para predecir tempranamente el desempeño académico de los estudiantes. Se ha demostrado que los modelos asociativos son tan precisos como los clasificadores de mejor rendimiento en datos reales relacionados con estudiantes adquiridos por nuestra universidad. Gracias a la interpretabilidad de los modelos asociativos, los expertos de dominio pueden identificar perfiles relevantes de estudiantes en riesgo y exitosos. Gracias a su explicabilidad, también pueden validar las asignaciones de las tasas de éxito del examen explorando las reglas aplicadas durante la fase de clasificación.

En el caso de estudio reportado, el análisis de los modelos basados en reglas nos ha permitido clasificar como estudiantes en riesgo a aquellos que tienen alguna combinación de las características enumeradas a continuación: (i) calificaciones bajas en la escuela secundaria o en las pruebas de ingreso; (ii) mayor que el promedio; (iii) uso limitado de material educativo, en general, o simplemente descargar video-conferencias (no streaming); (iv) no empezar a trabajar desde el inicio del semestre; (v) no concentrar su esfuerzo en un curso a la vez cerca de la convocatoria de exámenes. Los resultados obtenidos confirman

aplicabilidad de la metodología propuesta y abren las siguientes preguntas de investigación, las cuales planeamos abordar como trabajo futuro.

- ¿Es efectivo el modelo asociativo en los resultados predictivos de los exámenes en otros contextos de aprendizaje (p. ej., cursos de nivel superior, cursos de MS de nivel universitario)? • ¿Se podrían integrar los modelos asociativos en sistemas automatizados de soporte de decisiones que activan alertas personalizadas basadas en los resultados del proceso de predicción temprana? • ¿Cómo se pueden procesar y visualizar de manera efectiva los perfiles de los estudiantes para monitorear continuamente los avances en el proceso de aprendizaje de los estudiantes?

Contribuciones de los autores: Conceptualización, LC (Luca Cagliero), LC (Lorenzo Canale), LF, EB y EV; Análisis formal, LC (Luca Cagliero), LC (Lorenzo Canale) y LF; Investigación, LC (Luca Cagliero), LC (Lorenzo Canale) y LF; Metodología, LC (Luca Cagliero), LC

(Lorenzo Canale) y LF; Software, LC (Lorenzo Canale); Supervisión, LC (Luca Cagliero), LF y EB; Redacción—borrador original, LC (Luca Cagliero), LC (Lorenzo Canale) y LF; Redacción: revisión y edición, LC (Luca Cagliero), LC (Lorenzo Canale) y LF Todos los autores han leído y aceptado la versión publicada del manuscrito.

Financiamiento: Esta investigación no recibió financiamiento externo.

Declaración de la Junta de Revisión Institucional: No corresponde.

Declaración de consentimiento informado: No aplicable.

Declaración de disponibilidad de datos: No aplicable.

Conflictos de interés: Los autores declaran no tener ningún conflicto de interés.

Referencias

- Siemens, G.; Baker, RSJd Análisis de aprendizaje y minería de datos educativos: hacia la comunicación y la colaboración. En Actas de la 2ª Conferencia Internacional sobre Análisis del Aprendizaje y Conocimiento; ACM: Nueva York, NY, EE. UU., 2012; LAK '12, págs. 252–254. [\[Referencia cruzada\]](#)
- Romero, C.; Ventura, S. Editorial invitada: Edición especial sobre predicción temprana y respaldo del rendimiento del aprendizaje. Trans. IEEE. Aprender. Tecnología **2019**, 12, 145–147. [\[Referencia cruzada\]](#)
- Conijn, R.; Snijders, C.; Kleingeld, A.; Matzat, U. Predicción del rendimiento de los estudiantes a partir de los datos de LMS: una comparación de 17 cursos combinados con Moodle LMS. Trans. IEEE. Aprender. Tecnología **2017**, 10, 17–29. [\[Referencia cruzada\]](#)
- Adejo, OW; Connolly, T. Predicción del rendimiento académico de los estudiantes utilizando un enfoque de conjunto heterogéneo de modelos múltiples. Aplicación J. Res. Alto. Educ. **2018**, 10, 61–75. [\[Referencia cruzada\]](#)
- Yang, TY; Brinton, CG; Joe-Wong, C.; Chiang, M. Predicción de calificaciones basada en el comportamiento para MOOC a través de series temporales neuronales. Redes. IEEE J. Sel. Cima. Proceso de señal. **2017**, 11, 716–728. [\[Referencia cruzada\]](#)
- Hung, J.; Wang, MC; Wang, S.; Abdelrasoul, M.; Li, Y.; He, W. Identificación de estudiantes en riesgo para intervenciones tempranas: un enfoque de agrupación de series temporales. Trans. IEEE. emergente Cima. computar **2017**, 5, 45–55. [\[Referencia cruzada\]](#)
- Tempelaar, DT; Rienties, B.; Giesbers, B. En busca de los datos más informativos para la generación de retroalimentación: análisis de aprendizaje en un contexto rico en datos. computar Tararear. Comportamiento **2015**, 47, 157–167. [\[Referencia cruzada\]](#)
- Došilović, FK; Brčić, M.; Hlupić, N. Inteligencia artificial explicable: una encuesta. En Actas de la 41.ª Convención Internacional sobre Tecnologías de la Información y la Comunicación, Electrónica y Microelectrónica (MIPRO) de 2018, Opatija, Croacia, 21–25 de mayo de 2018, págs. 0210–0215. [\[Referencia cruzada\]](#)
- Alonso, JM; Casalino, G. Inteligencia artificial explicable para el análisis de datos centrado en humanos en entornos de aprendizaje virtual. En Educación Superior Metodologías y Tecnologías de Aprendizaje en Línea; Burgos, D., Cimitile, M., Ducange, P., Pecori, R., Picerno, P., Raviolo, P., Stracke, CM, Eds.; Springer International Publishing: Cham, Suiza, 2019; págs. 125–138.
- Guerrero-Higueras, A.M.; DeCastro-García, N.; Rodríguez-Lera, FJ; Matellán, V.; Ángel Conde, M. Predicción del éxito académico a través de la interacción de los estudiantes con Sistemas de Control de Versiones. Cómputo abierto. Esquí. **2019**, 9, 243 - 251. [\[Referencia cruzada\]](#)
- Hellas, A.; Ihantola, P.; Petersen, A.; Ajanovski, VV; Gútica, M.; Hynninen, T.; Knutas, A.; Leinonen, J.; Messom, C.; Liao, SN. Predicción del rendimiento académico: una revisión sistemática de la literatura. En Actas de la 23ª Conferencia Anual de ACM sobre Innovación y Tecnología en la Educación en Ciencias de la Computación; ACM: Nueva York, NY, EE. UU., 2018; ITiCSE 2018 Companion, págs. 175–199. [\[Referencia cruzada\]](#)
- Liu, B., Clasificación por análisis de reglas de asociación. En Enciclopedia de Sistemas de Base de Datos; Liu, L., Ozsu, MT, Eds.; Springer: Boston, MA, EE. UU., 2009; páginas. 335–340. [\[Referencia cruzada\]](#)
- Liu, B.; Hsu, W.; Ma, Y. Integración de clasificación y minería de reglas de asociación. En Actas de la Cuarta Internacional Conferencia sobre Descubrimiento de Conocimiento y Minería de Datos, Nueva York, NY, EE. UU., 27–31 de agosto de 1998; KDD'98, págs. 80–86.
- Baralis, E.; Cagliero, L.; Farinetti, L.; Mezzalama, M.; Venuto, E. Validación Experimental de un Servicio Educativo Masivo en un Ambiente de Aprendizaje Semipresencial. En Actas de la 41.ª Conferencia Anual de Aplicaciones y Software Informático del IEEE, COMPSAC 2017, Turín, Italia, 4–8 de julio de 2017; Volumen 1, págs. 381–390. [\[Referencia cruzada\]](#)

15. Baralis, E.; Chiusano, S.; Garza, P. Un enfoque perezoso a la clasificación asociativa. Trans. IEEE. Saber Ing. de datos **2008**, 20, 156–171.
[Referencia cruzada]
16. Moore, MG Editorial: Tres tipos de interacción. Soy. J. Educación a Distancia **1989**, 3, 1–7. [Referencia cruzada]
17. Joksimović, S.; Gašević, D.; Loughin, TM; Kovanović, V.; Hatala, M. Aprendizaje a distancia: Efectos de las huellas de interacción en logro académico. computar Educ. **2015**, 87, 204 – 217. [Referencia cruzada]
18. Agudo-Peregrina, AF; Iglesias-Pradas, S.; Conde-González, MA; Hernandez-García, A. ¿Podemos predecir el éxito a partir de los datos de registro en VLE? Clasificación de interacciones para análisis de aprendizaje y su relación con el rendimiento en aprendizaje en línea y F2F con soporte VLE . computar Tararear. Comportamiento **2014**, 31, 542–550. [Referencia cruzada]
19. Gitinabard, N.; Xu, Y.; Heckman, S.; Barnes, T.; Lynch, CF ¿Cuán ampliamente se pueden generalizar los modelos de predicción? Rendimiento Predicción en Cursos Blended. Trans. IEEE. Aprender. Tecnología **2019**, 12, 184–197. [Referencia cruzada]
20. Zacharis, NZ Un enfoque multivariante para predecir los resultados de los estudiantes en cursos de aprendizaje combinado habilitados para la web. Internet alto. Educ. **2015**, 27, 44–53. [Referencia cruzada]
21. Macfadyen, LP; Dawson, S. Minería de datos LMS para desarrollar un "sistema de alerta temprana" para educadores: una prueba de concepto. computar Educ. **2010**, 54, 588–599. [Referencia cruzada]
22. Hung, J.; Shelton, SER; Yang, J.; Du, X. Mejora del modelo predictivo para la identificación de estudiantes en riesgo: un enfoque de varias etapas. Trans. IEEE. Aprender. Tecnología **2019**, 12, 148–157. [Referencia cruzada]
23. Carson, A. Predicción del éxito estudiantil a partir del LASSI para el aprendizaje en línea (LLO). J. Educ. computar Res. **2011**, 45, 399–414.
[Referencia cruzada]
24. Hu, YH; Lo, CL; Shih, SP Desarrollo de sistemas de alerta temprana para predecir el desempeño del aprendizaje en línea de los estudiantes. computar Tararear. Comportamiento **2014**, 36, 469–478. [Referencia cruzada]
25. Jokhan, A.; Sharma, B.; Singh, S. Sistema de alerta temprana como predictor del desempeño de los estudiantes en la educación superior semipresencial cursos Semental. Alto. Educ. **2018**, 1–12. [Referencia cruzada]
26. Polyzou, A.; Karypis, G. Extracción de características para la predicción del desempeño estudiantil deficiente en el próximo período. Trans. IEEE. Aprender. Tecnología **2019**, 12, 237–248. [Referencia cruzada]
27. Livieris, I.; Drakopoulou, K.; Tampakas, V.; Mikropoulos, T.; Pintelas, P. Prediciendo el Desempeño de Estudiantes de Secundaria Utilizando un enfoque de aprendizaje semisupervisado. J. Educ. computar Res. **2017**, 57. [Referencia cruzada]
28. Al-Sudani, S.; Palaniappan, R. Predicción de la clasificación final de los estudiantes mediante un perfil extendido. Educ. información Tecnología **2019**, 24, 2357–2369. [Referencia cruzada]
29. Zhang, L.; Xiong, X.; Zhao, S.; Botello, A.; Heffernan, NT Incorporación de características enriquecidas en el rastreo de conocimiento profundo. En Actas de la Cuarta (2017) Conferencia ACM sobre Aprendizaje a Escala; ACM: Nueva York, NY, EE. UU., 2017; L@S '17, págs. 169–172.
[Referencia cruzada]
30. Asogbon, M.; Samuel, O.; Omisore, M.; Ojokoh, B. Un enfoque de máquina de vectores de soporte multiclase para estudiantes académicos Predicción de rendimiento. En t. J. Multidisciplinar. actual Res. **2016**, 4, 210–215.
31. Al-Shehri, H.; Al-Qarni, A.; Al-Saati, L.; Batoaq, A.; Badukhen, H.; Alrashed, S.; Alhiyafi, J.; Olatunji, SO Predicción del rendimiento de los estudiantes utilizando Support Vector Machine y K-Nearest Neighbor. En Actas de la 30.ª Conferencia Canadiense de Ingeniería Eléctrica e Informática (CCECE) del IEEE de 2017, Windsor, ON, Canadá, 30 de abril a 3 de mayo de 2017; págs. 1 a 4.
32. Amrieh, E.; Hamtini, T.; Aljarah, I. Minería de datos educativos para predecir el rendimiento académico de los estudiantes utilizando métodos de conjunto. En t. J. Aplicación de la teoría de bases de datos. **2016**, 9, 119–136. [Referencia cruzada]
33. Kukurova, M.; Zhou, Q.; Spikol, D.; Landolfi, L. Modelado de la competencia de resolución de problemas colaborativos con análisis de aprendizaje transparente: ¿son suficientes los datos de video? En Actas de la Décima Conferencia Internacional sobre Análisis y Conocimiento del Aprendizaje; Asociación de Maquinaria de Computación: Nueva York, NY, EE. UU., 2020; LAK '20, págs. 270–275. [Referencia cruzada]
34. Kumar, V.; Boulanger, D. Puntuación de ensayos automatizada explicable: el aprendizaje profundo realmente tiene valor pedagógico. Parte delantera. Educ. **2020**, 5. [Referencia cruzada]
35. Lundberg, S.; Erion, G.; Chen, H.; DeGrave, A.; Prutkin, J.; Nair, B.; Katz, R.; Himmelfarb, J.; Bansal, N.; Lee, SI De las explicaciones locales a la comprensión global con IA explicable para árboles. Nat. Mach. Intel. **2020**, 2. [Referencia cruzada] [PubMed]
36. Guggemos, J. Sobre los predictores del pensamiento computacional y su crecimiento en el nivel medio superior. computar Educ. **2021**, 161, 104060. [Referencia cruzada]
37. Agrawal, R.; Imielinski, T.; Swami. Reglas de Asociación Minera entre Conjuntos de Elementos en Grandes Bases de Datos; ACM SIGMOD: Washington, DC, EE. UU., 1993; págs. 207–216.
38. Ribeiro, MT; Singh, S.; Guestrin, C. "¿Por qué debería confiar en ti?": Explicando las predicciones de cualquier clasificador. En Actas de la 22ª Conferencia Internacional ACM SIGKDD sobre Descubrimiento de Conocimiento y Minería de Datos; ACM: Nueva York, NY, EE. UU., 2016; KDD '16, págs. 1135–1144. [Referencia cruzada]
39. Aggarwal, CC Introducción a la clasificación de datos. En Clasificación de Datos: Algoritmos y Aplicaciones; Prensa CRC: Boca Ratón, Florida, EE. UU., 2014; páginas. 1–36.
40. Veloso, A.; Meira, W., Jr.; Zaki, MJ Clasificación asociativa perezosa. En Actas de la Sexta Conferencia Internacional sobre Minería de Datos; IEEE Computer Society: Nueva York, NY, EE. UU., 2006; ICDM '06, pag. 645–654. [Referencia cruzada]
41. Padillo, F.; Luna, JM; Ventura, S. Evaluación de algoritmos de clasificación asociativa para Big Data. Anal de grandes datos. **2019**, 4, 2.
[Referencia cruzada]

-
42. Bronceado, PN; Kumar, V. Medidas de interés para patrones de asociación: una perspectiva. En KDD 2000 Taller sobre posprocesamiento en aprendizaje automático y minería de datos; 2000. Disponible en línea: https://www.kdd.org/exploration_files/KDD2000PostWkshp.pdf (consultado el 27 de enero de 2021).
43. Cagliero, L.; Farinetti, L.; Mezzalama, M.; Venuto, E.; Baralis, E. Servicios de videos educativos en las universidades: un análisis sistemático de la efectividad. En Actas de la Conferencia IEEE Frontiers in Education de 2017, FIE 2017, Indianápolis, IN, EE. UU., 18 al 21 de octubre de 2017; págs. 1 a 9. [\[Referencia cruzada\]](#)
44. Pedregosa, F.; Varoquaux, G.; Gramfort, A.; Michel, V.; Thirion, B.; Grisel, O.; Blondel, M.; Prettenhofer, P.; Weiss, R.; Dubourg, V.; et al. Scikit-learn: aprendizaje automático en Python. J. Mach. Aprender. Res. **2011**, 12, 2825–2830.
45. Brodersen, K.; Ong, CS; Stephan, K.; Buhmann, J. La precisión equilibrada y su distribución posterior. En Actas de la 20ª Conferencia Internacional sobre Reconocimiento de Patrones de 2010, Estambul, Turquía, 23–26 de agosto de 2010; págs. 3121–3124.
46. Guo, S.; Bocklitz, T.; Neugebauer, U.; Popp, J. Errores comunes en la validación cruzada de modelos de clasificación. Anal. métodos **2017**, 9, 4410–4417. [\[Referencia cruzada\]](#)