



Artículo

Una revisión sistemática de la literatura sobre el desempeño de los estudiantes Predicción utilizando técnicas de aprendizaje automático

Balqis Albreiki 1,2, Nazar Zaki 1,2* y Hany Alashwal 1,2

¹ Departamento de Ciencias de la Computación e Ingeniería de Software, Facultad de Tecnología de la Información, Universidad de los Emiratos Árabes Unidos, Al Ain 15551, Emiratos Árabes Unidos; 200907523@uaeu.ac.ae (BA); halashwal@uaeu.ac.ae (HA)

² Big Data Analytics Center, Universidad de los Emiratos Árabes Unidos, Al Ain 15551, Emiratos Árabes Unidos

* Correspondencia: Nzaki@uaeu.ac.ae

Resumen: La minería de datos educativos juega un papel fundamental en el avance del entorno de aprendizaje al contribuir con métodos, técnicas y aplicaciones de última generación. El desarrollo reciente proporciona herramientas valiosas para comprender el entorno de aprendizaje de los estudiantes al explorar y utilizar datos educativos utilizando técnicas de aprendizaje automático y minería de datos. Las instituciones académicas modernas operan en un entorno altamente competitivo y complejo. Analizar el desempeño, brindar una educación de calidad, estrategias para evaluar el desempeño de los estudiantes y acciones futuras son algunos de los desafíos predominantes que enfrentan las universidades. En estas universidades se deben implementar planes de intervención estudiantil para superar los problemas experimentados por los estudiantes durante sus estudios. En esta revisión sistemática, se revisa la literatura relevante de EDM relacionada con la identificación de la deserción estudiantil y los estudiantes en riesgo de 2009 a 2021. Los resultados de la revisión indicaron que se utilizan varias técnicas de Machine Learning (ML) para comprender y superar los desafíos subyacentes; predicción de estudiantes en riesgo y predicción de abandono escolar. Además, la mayoría de los estudios utilizan dos tipos de conjuntos de datos: datos de colegios universitarios de estudiantes/bases de datos universitarias y plataformas de aprendizaje en línea. Se confirmó que los métodos de aprendizaje automático desempeñan un papel esencial en la predicción de los estudiantes en riesgo y las tasas de abandono escolar, mejorando así el rendimiento de los estudiantes.

Keywords: minería de datos educativos; aprendizaje automático; MOOC; desempeño de los estudiantes; predicción; clasificación



Cita: Albreiki, B.; Zaki, N.;

Alashwal, H. Una literatura sistemática
Revisión del desempeño del estudiante

Predicción utilizando técnicas de aprendizaje
automático. Educ. ciencia **2021**, *11*, 552.

<https://doi.org/>

10.3390/educi11090552

Editor Académico: Riccardo Pecori

Recibido: 12 julio 2021

Aceptado: 12 de septiembre de 2021

Publicado: 16 septiembre 2021

Nota del editor: MDPI se mantiene neutral con respecto a reclamos jurisdiccionales en mapas publicados y afiliación institucional acciones.



Copyright: © 2021 por los autores.

Licenciatario MDPI, Basilea, Suiza.

Este artículo es un artículo de acceso abierto distribuido bajo los términos y condiciones de Creative Commons

Licencia de atribución (CC BY) (<https://creativecommons.org/licenses/by/4.0/>).

1. Introducción

Los desarrollos recientes en el sector de la educación se han inspirado significativamente en la minería de datos educativos (EDM). La amplia variedad de investigaciones ha descubierto y reforzado nuevas posibilidades y oportunidades para sistemas de aprendizaje mejorados tecnológicamente basados en las necesidades de los estudiantes. Los métodos y técnicas de aplicación de última generación de EDM juegan un papel central en el avance del entorno de aprendizaje. Por ejemplo, el EDM es fundamental para comprender el entorno de aprendizaje de los estudiantes al evaluar tanto el entorno educativo como las técnicas de aprendizaje automático. Según la información proporcionada en [1], la disciplina EDM se ocupa de explorar, investigar e implementar métodos de minería de datos (DM). La disciplina DM incorpora técnicas multidisciplinarias para su éxito. Tiene un método integral para extraer información valiosa e intelectual de datos sin procesar; el ciclo de minería de datos se representa en la Figura 1. El aprendizaje automático y los métodos estadísticos para datos educativos se analizan para determinar patrones significativos que mejoren el conocimiento de los estudiantes y las instituciones académicas en general.

Las instituciones educativas modernas operan en un entorno altamente competitivo y complejo. Por lo tanto, analizar el desempeño, brindar una educación de alta calidad, formular estrategias para evaluar el desempeño de los estudiantes e identificar las necesidades futuras son algunos de los desafíos que enfrentan la mayoría de las universidades en la actualidad. Los planes de intervención estudiantil se implementan en

universidades para superar los problemas de los estudiantes durante sus estudios. La predicción del desempeño de los estudiantes en el nivel inicial y durante los períodos posteriores ayuda a las universidades a desarrollar y evolucionar de manera efectiva los planes de intervención, donde tanto la gerencia como los educadores son los beneficiarios de los planes de predicción del desempeño de los estudiantes.

El e-learning es una forma de educación avanzada y de rápido crecimiento, donde los estudiantes están inscritos en cursos en línea. Las plataformas de aprendizaje electrónico, como los sistemas de tutoría inteligente (ITS), los sistemas de gestión del aprendizaje (LMS) y los cursos masivos abiertos en línea (MOOC), aprovechan al máximo la EDM para desarrollar y construir sistemas de recomendación de sistemas de calificación automática, así como sistemas adaptativos. Estas plataformas utilizan herramientas inteligentes que recopilan información valiosa del usuario, como; la frecuencia de acceso de un estudiante al sistema de aprendizaje electrónico, la precisión de las respuestas del estudiante a las preguntas y la cantidad de horas dedicadas a leer textos y ver videos tutoriales [2].

La información adquirida, con el tiempo, se procesa y analiza utilizando diferentes métodos de aprendizaje automático para mejorar la usabilidad y crear herramientas interactivas en la plataforma de aprendizaje. Según el Dr. Yoshua Bengio [3] de la Universidad de Montreal, “la investigación que utiliza Machine Learning (ML) es parte de la Inteligencia Artificial (IA), que busca brindar conocimiento a las computadoras a través de datos, observaciones y una interacción cercana con el mundo. Los conocimientos adquiridos permiten al ordenador generalizar correctamente a nuevos escenarios”. El aprendizaje automático es un subcampo de la IA, donde los sistemas ML aprenden de los datos, analizan patrones y predicen los resultados. Los crecientes volúmenes de datos, el almacenamiento más barato y los sistemas computacionales robustos son las razones detrás del renacimiento de la máquina desde solo un algoritmo de reconocimiento de patrones hasta métodos de aprendizaje profundo (DL). Los modelos ML pueden analizar de forma automática y rápida datos más grandes y complejos con resultados precisos y evitar riesgos inesperados.

Aunque el e-learning se considera ampliamente como una forma de educación menos costosa y más flexible en comparación con el tradicional en el campus, todavía se considera un entorno de aprendizaje desafiante ya que no hay interacción directa entre los estudiantes y los instructores del curso.

Específicamente, tres desafíos principales están asociados con los sistemas de e-learning; (i) la falta de medidas de evaluación estandarizadas para los estudiantes, lo que hace imposible la comparación con otras plataformas de aprendizaje; por lo tanto, es difícil determinar la efectividad de cada plataforma de aprendizaje; (ii) los sistemas de e-learning tienen tasas de deserción más altas que los estudios presenciales, debido a la pérdida de motivación, especialmente en los cursos autodidácticos y (iii) es difícil predecir las necesidades especializadas de los estudiantes debido a la falta de comunicación directa, especialmente en caso de discapacidad de un estudiante [4,5]. Los datos de registro a largo plazo de plataformas de aprendizaje electrónico como MOOC, LMS y Digital Environment to Enable Data-driven (DEED) se pueden usar para la evaluación de estudiantes y cursos.

Sin embargo, comprender los datos de registro es un desafío, ya que no todos los profesores y directores de cursos comprenden datos tan valiosos. MOOC y LMS brindan educación superior gratuita en todo el mundo. Estas plataformas brindan interacción estudiante-docente a través de sus portales de aprendizaje en línea [6]. En estos portales, el estudiante puede seleccionar, registrarse y realizar los cursos seleccionados desde cualquier lugar [7]. Los algoritmos de aprendizaje automático son herramientas útiles para la predicción temprana de los estudiantes en riesgo y sus posibilidades de abandono mediante la utilización de los datos de registro derivados. Esta técnica es más avanzada que la tradicional en el campus donde los registros de los estudiantes, como pruebas, asistencia, exámenes y calificaciones, se utilizan para evaluar y predecir su desempeño académico. La comunidad de investigación de EDM utiliza registros de sesión y bases de datos de estudiantes para procesar y analizar la predicción del rendimiento de los estudiantes mediante un algoritmo de aprendizaje automático. Esta revisión investiga la aplicación de diferentes técnicas de minería de datos y aprendizaje automático para; 1. Predecir el desempeño de los estudiantes en riesgo en las instituciones académicas 2. Determinar y predecir la deserción de los estudiantes de los cursos en curso 3. Evaluar el desempeño de los estudiantes con base en datos dinámicos y estáticos 4. Determinar los planes de remediación para los casos observados en el primero tres objetivos



Figura 1. El ciclo típico de la metodología de minería de datos, la imagen se deriva de [8].

Hay algunos intentos previos de examinar la literatura sobre rendimiento académico [9,10]; sin embargo, la mayoría de ellos son revisiones de literatura general y están dirigidos a la predicción genérica del desempeño de los estudiantes. Nuestro objetivo fue recopilar y revisar las mejores prácticas de minería de datos y aprendizaje automático. Además, nuestro objetivo fue proporcionar una revisión sistemática de la literatura, ya que la transparencia de la metodología y la estrategia de búsqueda reducen la replicabilidad de la revisión. En esto, no se incluye la literatura gris (como informes gubernamentales y documentos de políticas), lo que puede sesgar las perspectivas. Aunque hay una publicación reciente sobre Systematic Literature Review (SLR) de EDM [11], los criterios de inclusión y exclusión son diferentes y se enfocaron solo en datos históricos en comparación con nuestro trabajo, que se inclina más por los avances recientes de los últimos 13 años.

2. Método de investigación

Una revisión sistemática de la literatura se realiza con un método de investigación que debe ser imparcial y garantizar la integridad para evaluar toda la investigación disponible relacionada con el campo respectivo. Adoptamos la guía de Okoli [12] para realizar una revisión sistemática de literatura independiente. Aunque Kitchenham B. [13], Piper, Rory J. [14], Mohit, et al. [15], y muchos otros investigadores proporcionaron una revisión sistemática de la literatura del procedimiento integral, la mayoría de ellos se concentran solo en partes sustanciales del proceso, y solo unos pocos siguieron el proceso completo. El método elegido introduce la metodología rigurosa y estandarizada para la revisión sistemática de la literatura. Aunque la investigación se adapta principalmente a la investigación de sistemas de información, es lo suficientemente amplia como para ser aplicable y valiosa para académicos de cualquier campo de las ciencias sociales. La Figura 2 proporciona el diagrama de flujo detallado de la guía de revisión de literatura.

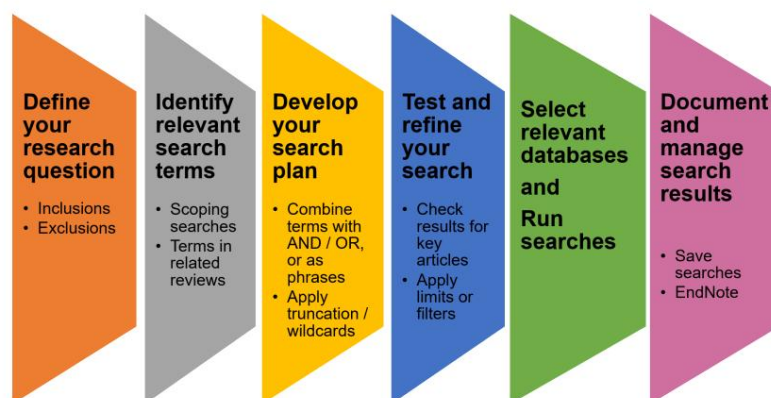


Figura 2. Guía de Okoli [12] para realizar una revisión sistemática de literatura independiente.

Dado que las preguntas de investigación son la máxima prioridad para que un revisor identifique y maneje en SLR, tratamos de abordar las siguientes preguntas de investigación a lo largo de la revisión.

2.1. Preguntas de investigación

- ¿Qué tipo de problemas existen en la literatura para la Predicción del Rendimiento Estudiantil?
- ¿Qué soluciones se proponen para abordar estos problemas?
- ¿Cuál es la productividad global de la investigación en este campo?

2.2. Fuentes de datos

Con el fin de realizar una extensa revisión sistemática de la literatura en base a los objetivos de esta revisión, explotamos seis bases de datos de investigación para encontrar los datos primarios y buscar para los papeles correspondientes. Se facilitan las bases de datos consultadas en todo el proceso de investigación en la Tabla 1. Estos repositorios fueron investigados en detalle utilizando diferentes consultas relacionadas con Técnicas de ML para predecir estudiantes en riesgo y sus tasas de abandono entre 2009 y 2021. Las consultas predeterminadas arrojaron muchos trabajos de investigación que se filtraron manualmente para retener solo las publicaciones más relevantes para esta revisión.

Tabla 1. Fuentes de datos.

Identificadores	bases de datos	Fecha de acceso	URL	Resultados
Sr.1	Puerta de la investigación	4 febrero 2021	https://www.researchgate.net/ https://	83
Sr.2	Biblioteca digital IEEE Xplore	4 febrero 2021	ieeexplore.ieee.org/ https://	78
Sr.3	Enlace Springer	6 febrero 2021	link.springer.com/ https://dl.acm.org/	20
Sr.4	Asociación para Maquinaria de Computación	4 febrero 2021	https://www.scopus.com/ https://	39
Sr.5	Scopus	4 febrero 2021	doaj.org/	33
Sr.6	Directorio de Revistas de Acceso Abierto	4 febrero 2021		54

2.3. Términos de búsqueda utilizados

Se utilizaron los siguientes términos de búsqueda (uno por uno) para obtener datos de las bases de datos de acuerdo con nuestras preguntas de investigación:

- EDM O Rendimiento O eLearning O Aprendizaje automático O Minería de datos
- Minería de datos educativos O Predicción del desempeño estudiantil O Evaluaciones de Estudiantes O Análisis de rendimiento de los estudiantes O Predicción de la curva de aprendizaje
- Intervención de los estudiantes O Predicción de la deserción O Riesgos de los estudiantes O Supervisión de los estudiantes O Requisitos de los estudiantes O Gestión del desempeño de los estudiantes O clasificación de los estudiantes.
- Predecir* Y estudiante Y aprendizaje automático

2.4. El procedimiento de selección de artículos para su revisión

El procedimiento de selección del trabajo se compone de identificación, selección, verificación de elegibilidad y reunión de criterios de inclusión de los trabajos de investigación. Los autores recopilaron de forma independiente los artículos de investigación y acordaron los artículos incluidos. La figura 3 proporciona la estructura detallada del procedimiento de selección de revisión después de aplicar la guía de Okli [12] para la revisión sistemática.

2.5. Los criterios de inclusión y exclusión

2.5.1. Inclusión

- Estudios relacionados con la Predicción del Desempeño de los Estudiantes;
- Artículos de investigación que fueron aceptados y publicados en revistas revisadas por pares a ciegas o conferencias;
- Papeles que fueron de 2009 a 2021 era;
- Papel que estaban en el idioma Inglés.

2.5.2. Exclusión

- Estudios distintos a la Predicción del Rendimiento del Estudiante usando ML.
- Artículos que no hayan realizado experimentos ni hayan validado los métodos propuestos.
- Artículos cortos, editoriales, carteles comerciales, patentes, revisiones ya realizadas, informes técnicos, artículos de Wikipedia, estudios de encuestas y artículos extensos de artículos ya revisados.

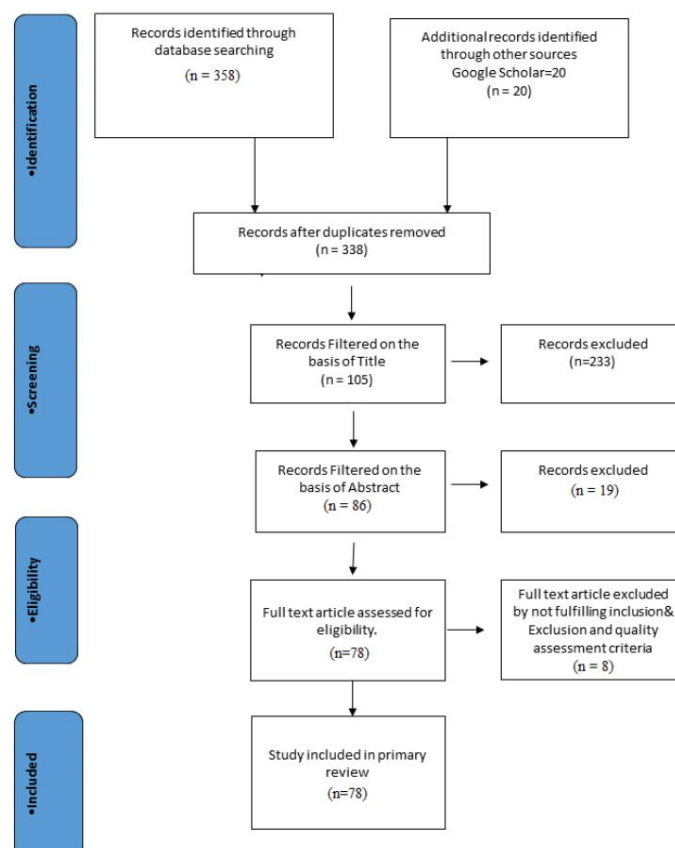


Figura 3. Estructura detallada del procedimiento de selección de revisión después de aplicar Okli [12] para análisis sistemático . revisión.

2.6. Ejecución de selección

La búsqueda se ejecuta para obtener la lista de estudios que se pueden utilizar para una evaluación adicional . La gestión bibliográfica de los estudios se realiza mediante una herramienta de bibliografía

llamado Mendeley. Estas bibliografías contienen aquellos estudios que se ajustan totalmente a los criterios de inclusión. Después de implementar con éxito los criterios de inclusión y exclusión, el resultado 78 artículos se describen en detalle en la siguiente sección. La Tabla 2 presenta el número de trabajos seleccionados de cada año. Todos los documentos que se mencionan a continuación han sido incluidos en la revisión

Tabla 2. Número de artículos de investigación de 2009 a 2021.

Año	Referencias	Contar
2009	[4,16,17]	3
2010	[1,18–21]	5
2011	[22]	1
2012	[23–27]	5
2013	[28–31]	4
2014	[7,32–37]	7
2015	[5,6,38–45]	10
2016	[31,46–52]	8
2017	[51,53–60]	9
2018	[33,45,51,61–67]	10
2019	[2,57,68–70]	5
2020	[71–77]	7
2021	[78–80]	4

2.7. Criterios de evaluación de la calidad

Se definen los siguientes criterios de calidad para la revisión sistemática de la literatura:

- QC1: ¿Están claramente definidos los objetivos de la revisión?
- QC2: ¿están bien definidos los métodos propuestos?
- QC3: ¿se mide y valida la precisión propuesta?
- QC4: ¿se establecen explícitamente las limitaciones de la revisión?

3. Resultados y discusión

3.1. Predecir el desempeño de los estudiantes en riesgo usando ML

La predicción del rendimiento de los estudiantes proporciona excelentes beneficios para aumentar las tasas de retención de estudiantes, la gestión eficaz de la inscripción, la gestión de ex alumnos, la mejora mercadeo dirigido y efectividad general del instituto educativo. Los programas de intervención en las escuelas ayudan a aquellos estudiantes que están en riesgo de no graduarse. El éxito

de tales programas se basa en la identificación y priorización precisa y oportuna de los estudiantes que requieren ayuda. Esta sección presenta una revisión cronológica de las publicaciones literatura de 2009 a 2021, que documenta el desempeño de estudiantes en riesgo utilizando técnicas de aprendizaje automático. Estudios de investigación relacionados con el tipo de conjunto de datos, métodos de selección de características, criterios aplicados para la clasificación, las herramientas de experimentación y el resultado de los enfoques propuestos son también resumido.

Kuzilek et al. [5] se centraron en la automatización general de hipótesis unarias (GUHA) y el análisis basado en la cadena de Markov para analizar las actividades de los estudiantes en los sistemas VLE. Un conjunto de escenarios se desarrolló conteniendo 13 escenarios. El conjunto de datos utilizado en esta revisión contenía dos tipos de información, es decir, (a) las calificaciones de las tareas de los estudiantes y (b) el registro de actividades de VLE que representaba la interacción del estudiante con el sistema VLE. Se llevó a cabo la implementación utilizando la herramienta LISP-Miner. Su investigación concluyó que ambos métodos podrían descubrir información valiosa sobre el conjunto de datos. El modelo gráfico basado en la cadena de Markov puede ayudar en visualizando el hecho, que puede ser más fácil de entender. Los patrones extraídos con el

Los métodos mencionados anteriormente brindan soporte de subestación al plan de intervención. El análisis de los datos de comportamiento de los estudiantes ayuda a predecir el rendimiento de los estudiantes durante su trayectoria académica.

Él et al. [6], examinan la identificación de estudiantes en riesgo en los MOOC. Propusieron dos algoritmos de aprendizaje de transferencia, a saber, "Regresión logística suavizada secuencialmente (LR-SEQ) y Regresión logística suavizada simultáneamente (LR-SIM)". Los algoritmos propuestos se evalúan utilizando conjuntos de datos DisOpt 1 y DisOpt2. Al comparar los resultados con el algoritmo de regresión logística (LR) de referencia, LR-SIM superó a LR-SEQ en términos de AUC, donde LR-SIM tuvo un valor de ACU alto en la primera semana. Este resultado indicó una predicción prometedora en la etapa temprana de admisión.

Kovacic, Z. [18] analizó la predicción temprana del éxito de los estudiantes utilizando técnicas de aprendizaje automático. La revisión investigó las características sociodemográficas, es decir, educación, trabajo, sexo, estatus, discapacidad, etc., y las características del curso, como el programa del curso, el bloque del curso, etc., para una predicción efectiva. Estas características que contienen el conjunto de datos se recopilaron de la Universidad Abierta de Nueva Zelanda. Los algoritmos de aprendizaje automático para la selección de características se utilizan para identificar las características esenciales que afectan el éxito de los estudiantes. El hallazgo clave de la investigación fue que el origen étnico, el programa del curso y el bloque del curso son las tres características principales que afectan el éxito de los estudiantes.

Kotsiaritis et al. [19] propusieron una técnica denominada conjunto incremental combinacional de clasificadores para la predicción del rendimiento de los estudiantes. En la técnica propuesta, se combinan tres clasificadores donde cada uno de los clasificadores calcula la salida de predicción. Se utiliza una metodología de votación para seleccionar la predicción final general. Esta técnica es útil para datos generados continuamente y, cuando llega una nueva muestra, cada clasificador predice el resultado. La predicción final se selecciona mediante el sistema de votación. En esta revisión, los datos de capacitación son proporcionados por la Universidad Helénica Abierta. El conjunto de datos comprende calificaciones de asignaciones escritas que contienen 1347 instancias, y cada una tiene cuatro atributos con cuatro características para puntajes de asignaciones escritas. Los tres algoritmos utilizados para construir el sistema utilizando un conjunto incremental combinacional son Naive Bayes (NB), Neural Network (NN) y WINDOW. El sistema funciona para que los modelos se entrenen inicialmente usando el conjunto de entrenamiento, seguido de la prueba de los modelos usando el conjunto de prueba. Cuando llega una nueva instancia de observación, los tres clasificadores predicen el valor y los que tienen alta precisión se seleccionan automáticamente. Craige et al. [22] utilizaron enfoques estadísticos, NN y enfoques de reducción de datos bayesianos para ayudar a determinar la eficacia de la prueba Evaluación de la Eficacia de la Enseñanza del Estudiante (SETE). Los resultados no muestran apoyo para SETE como un indicador general de la eficacia de la enseñanza o el aprendizaje de los estudiantes en la plataforma en línea. En otra revisión de Kotsiantis, Sotiris B. [23] propuso un sistema de apoyo a la decisión de un tutor para predecir el rendimiento de los estudiantes. Esta revisión considera los datos demográficos de los estudiantes, los registros del sistema de aprendizaje electrónico, los datos académicos y la información de admisión. El conjunto de datos se compone de 354 datos de estudiantes con 17 atributos cada uno. Se utilizan cinco clasificadores, a saber; Árbol modelo (MT), NN, regresión lineal (LR), regresión lineal ponderada localmente y máquina de vectores de soporte (SVM). El predictor MT alcanza un error ab

Osmanbegovic et al. [24] analiza los algoritmos Naive Bayes (NB), Decision Tree (DT) y Multilayer Perception (MLP) para predecir el éxito de los estudiantes. Los datos se componen de dos partes. La primera parte de los datos se recopila de la encuesta realizada en la Universidad de Tuzla en 2010–2011. Los participantes fueron los estudiantes de primer año del departamento de economía. La segunda parte de los datos se adquiere de la base de datos de inscripción.

En conjunto, el conjunto de datos tiene 257 instancias con 12 atributos. Utilizaron el software Weka como herramienta de implementación. Los clasificadores se evalúan utilizando la precisión, el tiempo de aprendizaje y la tasa de error. El NB alcanza una alta puntuación de precisión del 76,65 % con un tiempo de entrenamiento inferior a 1 s y altas tasas de error. Baradwaj y Pal [25] también revisan los enfoques de minería de datos para la predicción del rendimiento de los estudiantes. Investigan la precisión de DT, donde el DT se usa para extraer reglas valiosas del conjunto de datos. El conjunto de datos utilizado en su revisión se obtuvo de la Universidad de Purvarichal, India, y comprende los registros de 50 estudiantes, cada uno con ocho atributos.

Watson et al. [28] consideraron el registro de actividad de los estudiantes inscritos en la programación introductoria de un curso para predecir su desempeño. Esta revisión aconsejó un predictor basado en criterios medidos automáticamente en lugar de una base directa para determinar la evolución del desempeño de los estudiantes a lo largo del tiempo. Propusieron un algoritmo de puntuación llamado WATWIN que asigna puntuaciones específicas a cada actividad de programación de los estudiantes. El algoritmo de calificación considera la habilidad del estudiante para lidiar con los errores de programación y el tiempo para resolver dichos errores. Esta revisión utilizó los datos del registro de actividad de programación de 45 estudiantes de 14 sesiones como conjunto de datos. A la actividad de cada estudiante se le asignó una puntuación WATWIN, que luego se utiliza en regresión lineal. La regresión lineal que utiliza la puntuación WATWIN logra una precisión del 76 %. Para una predicción efectiva, el conjunto de datos debe estar equilibrado. Los datos equilibrados significan que cada una de las clases de predicción tiene el mismo número de atributos.

Márquez-Vera et al. [29] arrojó luz sobre la naturaleza desequilibrada del conjunto de datos disponible para la predicción del rendimiento de los estudiantes. Los algoritmos genéticos rara vez se utilizan para la predicción. Esta revisión ha sido comparada entre 10 algoritmos de clasificación estándar implementados en Weka y tres variaciones de algoritmos genéticos. Los 10 algoritmos de clasificación implementados por Weka son Jrip, NNge, OneR, Prison, Ridor, ADTree, J48, Random Tree, REPTree y Simple CART, mientras que tres variaciones del algoritmo genético son (Minería de reglas de clasificación interpretable) ICRM v1, ICRM v2, y ICRM v3 que emplea el algoritmo genético basado en la gramática (G3P). Para el balanceo de clases, el autor usó SMOTE, también implementado en Weka. Los resultados muestran que el algoritmo genético ICRM v2 obtiene una alta precisión cuando los datos están equilibrados, mientras que el rendimiento es ligeramente bajo cuando los datos no están equilibrados. Los datos utilizados en esta revisión tienen tres tipos de atributos, que incluyen una encuesta específica (45 atributos), una encuesta general (25 atributos) y puntajes (siete atributos).

Hu et al. [32] explora los atributos dependientes del tiempo para predecir el rendimiento del aprendizaje en línea de los estudiantes. Propusieron un sistema de alerta temprana para predecir el desempeño de los estudiantes en riesgo en un entorno de aprendizaje en línea. Aconsejaron la necesidad de variables dependientes del tiempo como un factor esencial para determinar el rendimiento de los estudiantes en los Sistemas de Gestión del Aprendizaje (LMS). El documento se centró en tres objetivos principales de la siguiente manera; (i) investigación de técnicas de minería de datos para alerta temprana, (ii) determinación de los impactos de variables dependientes del tiempo, (iii) selección de técnicas de minería de datos con poder predictivo superior. Utilizando datos de 330 estudiantes de cursos en línea del LMS, evaluaron el rendimiento de tres modelos de clasificación de aprendizaje automático, a saber, "C4.5 Classification and Regression Tree (CART), Logistic Regression (LGR) y Adaptive Boosting (AdaBoost)". Cada una de las instancias en el conjunto de datos constaba de 10 características, y el desempeño de los clasificadores se evaluó utilizando errores de precisión, tipo I y tipo II. El algoritmo CART supera a los otros algoritmos logrando una precisión superior.

Lakkaraju et al. [38] propusieron un marco de aprendizaje automático para identificar al estudiante en riesgo de no graduarse o estudiantes en riesgo de no graduarse a tiempo. Usando este marco, los datos de los estudiantes fueron recolectados de dos escuelas en dos distritos. Cinco algoritmos de aprendizaje automático utilizados con fines de experimentación incluyen; Support Vector Machine (SVM), Random Forest, Logistic Regression, Adaboost y Decision Tree. Estos algoritmos se evalúan mediante precisión, recuperación, exactitud y AUC para la clasificación binaria. Cada estudiante se clasifica en función del puntaje de riesgo estimado a partir de la clasificación, como se mencionó anteriormente en el modelo. Los resultados revelaron que Random Forest logra el mejor rendimiento. Los algoritmos se evalúan utilizando precisión y recuperación en las posiciones de los estudiantes. Para comprender el error más probable, el marco propuesto puede hacer que los autores sugieran cinco pasos críticos para los educadores. Éstas incluyen; (a) identificación de patrones frecuentes en los datos usando el algoritmo FP-Growth, (b) uso del riesgo del puntaje para clasificar a los estudiantes, (c) adición de un nuevo campo en los datos y asignación de un puntaje de uno (1) si el framework falló en predecir correctamente de lo contrario una puntuación de cero (0), (d) cálculo de la probabilidad de error para cada uno de los patrones frecuentes, y (e) clasificación de los patrones en función de la probabilidad de error.

Ahmed et al. [45] recolectó datos de estudiantes entre 2005 y 2010 de la base de datos de estudiantes del instituto educativo. El conjunto de datos contiene 1547 instancias que tienen diez atributos. El

los atributos seleccionados recopilaron información como; departamentos, grados de escuela secundaria, calificaciones de mitad de período, calificaciones de exámenes de laboratorio, desempeño en seminarios, puntajes de tareas, participación de los estudiantes, asistencia, tareas y calificaciones finales. Se utilizan dos métodos de clasificación de aprendizaje automático, DT y ID3 Decision Tree, para la clasificación de datos. La herramienta de minería de datos Weka se utiliza luego para la experimentación. La información obtenida se utiliza para seleccionar el nodo raíz; el atributo de término medio ha sido elegido para ser el nodo raíz.

La predicción del rendimiento de las nuevas tomas es estudiada por Ahmed et al. [45]. Contemplaron un marco de aprendizaje automático para predecir el rendimiento de los estudiantes de primer año en FIC, UniSZA Malaysia. Esta revisión recopiló los datos de los estudiantes de las bases de datos universitarias, donde se extrajeron nueve atributos, incluidos el género, la raza, la ciudad de origen, el GPA, los ingresos familiares, el ingreso al modo universitario y las calificaciones de SPM en inglés, malayo y matemáticas. Después de preprocesar y limpiar el conjunto de datos, se extraen los datos demográficos de 399 estudiantes de 2006–2007 a 2013–2014. Se examinaron tres clasificadores, incluido el árbol de decisiones, el basado en reglas y el rendimiento de Naive Bayes. Los resultados reconocen al clasificador basado en reglas como el de mejor rendimiento con un 71,3 % de precisión. La herramienta Weka se utiliza con fines de experimentación. La predicción del rendimiento de los estudiantes en el entorno de aprendizaje en línea es significativa ya que la tasa de abandono es muy alta en comparación con el sistema de aprendizaje tradicional [6].

Al-Barrak y Al-Razgan [46] consideraron las calificaciones de los estudiantes en cursos anteriores para predecir el GPA final. Para ello, utilizaron los datos del expediente académico de los estudiantes y aplicaron un algoritmo de árbol de decisiones para extraer reglas de clasificación. La aplicación de estas reglas ayuda a identificar los cursos requeridos que tienen un impacto significativo en el GPA final del estudiante. El trabajo de Marbouti et al. [47] se diferenció de los estudios anteriores en que su investigación analizó modelos predictivos para identificar a los estudiantes en riesgo en un curso que usa calificaciones basadas en estándares. Además, para reducir el tamaño del espacio de características, adoptaron métodos de selección de características utilizando los datos del curso de ingeniería de primer año en la Universidad Midwestern de EE. UU. de los años 2013 y 2014, participación del equipo, hitos del proyecto, prueba de actividad de modelado matemático y puntajes de examen. Seis clasificadores de aprendizaje automático analizados incluyeron LR, SVM, DT, MLP, NB y KNN. Estos clasificadores fueron evaluados utilizando diferentes medidas de precisión tales como; precisión general, precisión para los alumnos aprobados y precisión para los alumnos reprobados. El método de selección de características usó el valor del coeficiente de correlación de Pearson, donde se usaron características con un valor de coeficiente de correlación $> 0,3$ en Los clasificadores Naive Bayes tuvieron mayor precisión (88%) utilizando 16 características.

En una revisión similar, Iqbal et al. [53] también predijeron el GPA de los estudiantes utilizando tres enfoques de aprendizaje automático; CF, MF y RBM. El conjunto de datos que utilizaron en esta revisión se recopila de la Universidad de Tecnología de la Información (ITU), Lahore, Pakistán. Propusieron un modelo de retroalimentación para calcular la comprensión del estudiante de un curso específico. También sugirieron un procedimiento de ajuste para el modelo oculto de Markov para predecir el desempeño de los estudiantes en un curso específico. Para el experimento, la división de datos fue del 70 % para el conjunto de entrenamiento y del 30 % para los datos de prueba. Los clasificadores basados en ML se evaluaron mediante RMSE, MSE y el error absoluto medio (MAE). Durante el análisis de datos, RBM logró puntuaciones bajas de 0,3, 0,09 y 0,23 para RMSE, MSE y MAE, respectivamente. Zhang et al. [54] optimizó el parámetro del clasificador Gradient Boosting Decision Tree (GBDT) para predecir la calificación del estudiante en la tesis de graduación en universidades chinas. Con parámetros personalizados, GBDT supera a KNN, SVM, Random Forest (RF), DT, LDA y Adaboost en términos de precisión de predicción general y AUC. El conjunto de datos utilizado en esta revisión comprendió 771 muestras con 84 características de la Universidad de Zhejiang, China. La división de datos fue 80% conjunto de entrenamiento y 20% conjunto de prueba.

Hilal Almarabeh [55] investigó el desempeño de diferentes clasificadores para el análisis del desempeño de los estudiantes. En esta revisión, se realizó una comparación entre cinco clasificadores basados en ML. Estos clasificadores incluyen Naive Bayes, Bayesian Network, ID3, J48 y Neural Networks. La implementación de Weka de todos estos algoritmos se utiliza en experimentos. Los datos para el análisis se obtienen de la base de datos del colegio con 225 instancias, donde cada instancia comprendía diez atributos. Los resultados que se muestran en esta revisión revelan el bayesiano

Network como el algoritmo de predicción más práctico. Jie Xu et al. [56] propuso un nuevo método de aprendizaje automático que tiene dos características destacadas. La primera característica fue una estructura en capas para la predicción teniendo en cuenta el comportamiento de rendimiento en constante evolución de los estudiantes. La estructura en capas se compone de múltiples bases y predictores de conjunto. La segunda característica importante del método propuesto consideró el enfoque basado en datos utilizado para descubrir la relevancia del curso. El conjunto de datos consistió en el registro de 1169 estudiantes matriculados en los departamentos de Ingeniería Aeroespacial y Mecánica de UCLA. El método propuesto mostró resultados prometedores en términos del error cuadrático medio (MSE).

Al-shehri et al. [57] llevó a cabo una revisión similar que comparó el rendimiento de los clasificadores de aprendizaje supervisado, SVM y KNN, utilizando datos de la Universidad de Minho que tenían 33 atributos. El conjunto de datos primero se convirtió de forma nominal a numérica antes de analizar estadísticamente. El conjunto de datos se recopiló inicialmente mediante cuestionarios e informes de dos escuelas en Portugal. Los datos originales también contenían 33 características, entre las cuales la distribución de atributos nominales, binarios y numéricos era 4, 13 y 16, respectivamente, con 395 el número total de instancias. La herramienta Weka se utilizó en el experimento en el que se probaron los algoritmos utilizando diferentes conjuntos de particiones de datos. El resultado fue que la SVM logra una alta precisión cuando se utiliza una validación cruzada de 10 veces y una relación de partición.

Alowibdi, J. [58] examinó la aplicación de análisis de aprendizaje avanzado para la predicción del rendimiento de los estudiantes. Consideraron a esos estudiantes becados en Pakistán. Esta investigación analizó los modelos discriminativos CART, SVM, C4.5 y los modelos generativos Bayes Network y NB. Se utilizaron el recuerdo de precisión y la puntuación F para evaluar el rendimiento del predictor. Inicialmente se recolectaron datos de 3 mil estudiantes del 2004 al 2011, los cuales se redujeron a 776 estudiantes luego del preprocesamiento y eliminación de redundancia. Entre estos 776 estudiantes, 690 completaron su título con éxito, mientras que 86 no completaron los programas de grado. Se clasificaron un total de 33 características en cuatro grupos: gastos familiares, ingresos familiares, información personal del estudiante y bienes familiares. La revisión encontró que el gasto de gas natural, el gasto de electricidad, el trabajo por cuenta propia y la ubicación fueron los factores predictivos más destacados del rendimiento académico de los estudiantes. El clasificador SVM supera a todos los demás enfoques al obtener una puntuación F1 de 0,867.

Al-Obeidat et al. proponen un enfoque de clasificación híbrido. [61] combinando PROAFTAN -un clasificador multicriterio- y clasificadores DT. El algoritmo propuesto funciona en tres etapas; en la primera etapa, se aplica el algoritmo C4.5 al conjunto de datos con discretización seguido de la etapa de filtrado y preprocesamiento de datos, y finalmente, se mejora C4.5 con PROAFTAN con selección de atributos y discretización. Utilizaron el mismo conjunto de datos UCI que el utilizado en [81]. El conjunto de datos estaba compuesto por estudiantes matriculados en cursos de idiomas y matemáticas.

El algoritmo de clasificación híbrido propuesto se evalúa utilizando precisión, recuperación y medida F. Los autores registraron una mejora significativa en la precisión tanto de Idiomas (82,82 %) como de Matemáticas (82,27 %) en el conjunto de datos de los estudiantes. En las comparaciones con los algoritmos RF, NB, Meta Bagging (MB), Clasificador seleccionado de atributos, Logística simple (SL) y Tabla de decisiones (DT), el enfoque híbrido propuesto logró exactitud, precisión, recuperación y F

medir puntuaciones.

Kaviyarasi y Balasubramanian [62] examinaron los factores que afectan el desempeño de los estudiantes. Los autores clasificaron a los estudiantes en tres clases; Aprendizaje rápido, aprendizaje promedio y aprendizaje lento. Los datos utilizados pertenecían a universidades afiliadas de la Universidad de Periyar, donde se extrajeron 45 características del conjunto de datos. Para la clasificación, se utilizó el clasificador Extra Tree (ET) para calcular la importancia de estas características. Se identificaron doce características principales como características importantes para predecir el rendimiento académico de los estudiantes. Zaffar et al. [63] comparó el rendimiento de los métodos de selección de características utilizando dos conjuntos de datos. El conjunto de datos 1 constaba de 500 registros de estudiantes con 16 características. Mientras que el conjunto de datos 2 contenía 300 registros de estudiantes con 24 características. La herramienta Weka se utilizó para la experimentación y los resultados revelaron que el rendimiento de los métodos de selección de características depende de la clasificadores utilizados y la naturaleza del conjunto de datos.

Chuy et al. [64] consideró el tiempo de entrenamiento extendido del clasificador y propuso un clasificador de máquina de vectores de soporte basado en vectores de entrenamiento reducido (RTV-SVM) para predecir

estudiantes marginales o en riesgo en función de su rendimiento académico. RTV-SVM es un cuatro algoritmo de etapas. La primera etapa es la definición de entrada, seguida por la multivariable. enfoque, ya que la segunda etapa se utiliza para la eliminación de nivel 1 de vectores de entrenamiento. en el tercero etapa de RTV-SVM, la transformación de vectores para la eliminación de nivel 2 de los vectores de entrenamiento es utilizado, y el modelo SVM está en la etapa final utilizando el algoritmo SMO. El conjunto de datos de OULA fue utilizado en [64], que consta de 32,593 registros de estudiantes que contienen datos demográficos de estudiantes datos y registro de sesión de la interacción del estudiante con el sistema VLE. TRV-SVM puntuó alto precisión del 93,8% y 93,5% para predecir el estudiante en riesgo y el estudiante marginal respectivamente mientras reduce significativamente el tiempo de entrenamiento en un 59%.

Msaci et al. [65] propusieron métodos estadísticos y de aprendizaje automático para examinar la determinantes de la puntuación de la prueba PISA 2005. El autor analizó los datos de PISA 2005 de varios condados, incluidos Alemania, EE. UU., Reino Unido, España, Italia, Francia, Australia, Japón y Canadá. Esta investigación tuvo como objetivo explorar las características de los estudiantes y de las instituciones académicas que pueden influir en los logros de los estudiantes, donde los enfoques propuestos trabajar en dos pasos. En el primer paso, se aplica un árbol de regresión multinivel considerando los estudiantes anidados con las escuelas y las características de los estudiantes relacionadas con el rendimiento de los estudiantes. son identificados. En el segundo paso, se estiman las adiciones de valor de la escuela, lo que permite identificar las características relacionadas con la escuela utilizando técnicas de árbol de regresión y de impulso. El Se utilizó el conjunto de datos de PISA 2015 de los nueve países donde el número total de atributos a nivel escuela y nivel estudiante fue de 19 y 18, respectivamente. el numero de estudiantes en el tamaño de la muestra (Cuadro 3). Los resultados obtenidos sugirieron que tanto el nivel de estudiante como las características del nivel escolar tienen un impacto en los logros de los estudiantes.

Livieris et al. [68] sugirió un enfoque de aprendizaje automático semisupervisado para predecir el rendimiento de los estudiantes de secundaria. El enfoque considerado en esta revisión incluía la autoformación y otra idea en dos etapas (YATSI). El conjunto de datos tenía datos de rendimiento de 3716 estudiantes recopilados por Microsoft Showcase School. Cada instancia en el El conjunto de datos tiene 12 atributos. Los enfoques semisupervisados funcionan bien con los datos en comparación con los enfoques de aprendizaje supervisado y no supervisado. Para una mejor toma de decisiones, Nieto et al. [69] comparó el desempeño de SVM y ANN, donde los datos de 6130 estudiantes se recopiló, y después del preprocesamiento y la limpieza, 5520 instancias con múltiples características fueron extraídos. Se utilizó la herramienta de software KNIME para la implementación de SVM y ANN. Se observó que la SVM alcanzó una alta precisión del 84,54 % y altos valores de AUC.

Tabla 3. Tamaño de la muestra de estudiantes en los nueve países seleccionados según el conjunto de datos de PISA de 2015.

No.	País	Tamaño de la muestra
1	Canadá	20,058
2	Australia	14,530
3	Reino Unido	14,157
4	Italia	11,586
5	España	6736
6	Japón	6647
7	Alemania	6504
8	Francia	6108
9	nuestros	5712

Aggarwal et al. [78] compararon características académicas y discutieron la importancia de características no académicas, como la información demográfica, mediante la aplicación de ocho ML diferentes algoritmos Utilizaron un conjunto de datos de un colegio técnico en la India, que tiene información unos 6807 estudiantes con características académicas y no académicas. Aplicaron sintético métodos de sobremuestreo minoritarios para reducir la asimetría en el conjunto de datos. Reclamaron J48

Puntuación F1 del 93,2 % con árbol de decisión, 90,3 % con logística, 91,5 % con perceptrón multicapa, 92,4 % con máquina de vectores de soporte, 92,4 % con AdaBoost, 91,8 % con embolsado, 93,8 % con bosque aleatorio y 92,3 % con votación. También sugirieron que el rendimiento académico no solo depende de las características académicas, sino que también tiene una gran influencia en la información demográfica; sugirieron usar las características no académicas con una combinación de características académicas para predecir el desempeño del estudiante.

Zeineddine et al. [79] utilizó el concepto de AutoML para mejorar la precisión de la predicción del rendimiento de los estudiantes mediante la explotación de las funciones antes del inicio del nuevo programa académico (datos previos al inicio). Lograron una precisión del 75,9 % con AutoML con una tasa de predicción falsa más baja. Con un Kapa de 0,5. En consecuencia, alientan a los investigadores en este campo a adoptar AutoML en su búsqueda de un modelo óptimo de predicción del rendimiento de los estudiantes, especialmente cuando se utilizan datos previos al inicio. Sugirieron utilizar los datos de preadmisión e iniciar sesiones de intervención y consultoría antes de iniciar el progreso académico, para que los estudiantes que necesitan ayuda inmediata puedan sobrevivir en la sociedad. Observaron los datos disponibles desequilibrados, emplearon el método de preprocesamiento SMOTE y luego emplearon los métodos Ensemble generados automáticamente para predecir los alumnos que reprobarían con una precisión general del 83 %. Los autores reconocieron la limitación de generalización excesiva de SMOTE y discutieron algunos métodos para reducir el problema de datos desequilibrados sin el problema de generalización excesiva. OuahiMariame y Samira [80] evaluaron el uso de redes neuronales en el campo de EDM con la perspectiva de la selección de características para la clasificación.

Utilizaron varias redes neuronales en diferentes bases de datos de estudiantes para comprobar su rendimiento. Afirmaron que la NN había superado varios algoritmos como Naïve Bayes, máquina de vectores de soporte (SVM), RandomForest y Red Neural Artificial (ANN), para evaluar con éxito el desempeño del estudiante.

Thai-Nghe et al. [82] propusieron un sistema de recomendación para la predicción del rendimiento de los estudiantes. En este método, el rendimiento del enfoque de filtrado colaborativo de elemento de usuario, factorización matricial y regresión logística se compara utilizando el conjunto de datos KDD Challenge 2010. El conjunto de datos contiene un archivo de registro de los estudiantes que se obtiene cuando los estudiantes interactúan con el sistema de tutoría asistido por computadora. Los resultados de esta revisión sugirieron que los sistemas de recomendación basados en enfoques de factorización matricial y filtrado colaborativo de elementos de usuario tienen un error cuadrático medio (RMSE) promedio bajo de 0,30016.

Buenaño-Fernández [83] propuso el uso de métodos ML para la predicción de calificaciones finales de los estudiantes utilizando datos históricos. Se aplicaron los datos históricos de la ingeniería informática de las universidades del Ecuador. Uno de los objetivos estratégicos de esta investigación fue cultivar datos extensos pero completos. Su implementación produjo una cantidad panóptica de datos que se pueden convertir en varias aplicaciones útiles relacionadas con la educación si se procesan adecuadamente. Este artículo propone una técnica novedosa para el preprocesamiento y la agrupación de estudiantes que tienen los mismos patrones. Posteriormente, aplicaron muchos métodos de aprendizaje supervisado para identificar a los estudiantes que tenían patrones similares y sus calificaciones finales previstas. Finalmente, los resultados de los métodos ML se analizaron y compararon con los métodos anteriores del estado del arte. Afirmaron una precisión del 91,5 % con técnicas de conjunto, lo que demuestra la eficacia de los métodos de aprendizaje automático para estimar el rendimiento de los estudiantes.

Reddy y Rohith [84] comentaron que muchos investigadores habían utilizado los algoritmos avanzados de ML para predecir el desempeño del estudiante de manera efectiva; sin embargo, no proporcionaron pistas competentes para los estudiantes de bajo rendimiento. Su objetivo era superar la limitación y trabajaron para identificar las características humanas explicables que pueden determinar que el estudiante tenga un desempeño tutorial deficiente. Utilizaron los datos de la Universidad de Minnesota y aplicaron SVM, RF, Gradient Boosting y Decision Trees. Afirmaron tener más del 75 % de precisión para identificar los factores que son lo suficientemente genéricos para detectar qué estudiantes reprobarán este período.

Anal Archrya y Devadatta Sinha [85] también propusieron un sistema de predicción temprana utilizando métodos de clasificación basados en ML que utilizan los métodos de selección de características integrados para reducir el tamaño del conjunto de características. El número total de características en esta revisión es 15, que son

recogidos a través de cuestionarios. Los participantes de la encuesta son educadores y estudiantes de informática de diferentes universidades en Kolkata, India. Los autores informaron que el clasificador C4.5 es el algoritmo de mejor rendimiento en comparación con la percepción multicapa (MLP), Naive Bayes (NB), K-NN y SMO. En otra revisión realizada en The Open University, Reino Unido por Kuzilek et al. [5], desarrolló un sistema compuesto por tres algoritmos predictivos para identificar a los estudiantes en riesgo. Los tres algoritmos basados en ML (incluidos Naive Bayes, K-NN y CART) obtienen una puntuación predictiva utilizando dos conjuntos de datos. El primer conjunto de datos es un conjunto de datos demográficos recopilados de la base de datos de la universidad y el segundo conjunto de datos consistió en datos de registro con interacción estructural en el sistema de entorno de aprendizaje virtual (VLE). La puntuación final de cada alumno se calculó como la suma de la puntuación predictiva de cada algoritmo. Si la puntuación final fue >2 , se determinó que el estudiante estaba en riesgo y se implementaron las medidas apropiadas. Sin embargo, si el puntaje final fue <3 , el estudiante no está en riesgo y no requiere intervención. La puntuación de precisión y recuperación ayuda a evaluar el rendimiento del sistema propuesto.

Las plataformas de aprendizaje electrónico recibieron una atención considerable por parte de la comunidad de investigación de EDM en los últimos años. Hussain et al. [81] examinó los métodos de ML para predecir las dificultades que encuentran los estudiantes en un sistema de aprendizaje electrónico llamado Digital Electronics Education and Design Suits (DEEDS). Las técnicas de EDM consideran la interacción del estudiante con el sistema para identificar patrones significativos que ayuden al educador a mejorar sus políticas. En este trabajo, se utilizan datos de 100 estudiantes de primer año de licenciatura de la Universidad de Génova. Los datos se componen de registros de sesión creados cuando los estudiantes interactúan con la herramienta DEEDS y están disponibles públicamente en el repositorio de aprendizaje automático de UCI. Cinco características seleccionadas para la predicción del desempeño de los estudiantes incluyeron el tiempo promedio, el número total de actividades, el tiempo de inactividad promedio, el número promedio de cigüeñas críticas y el total de actividades relacionadas. LOS cinco algoritmos ML DE ESTA REVISIÓN incluidos; ANN, LR, SVM, NBC y DT. El rendimiento de los clasificadores se evaluó mediante el RMSE, la curva de características del operador del receptor (ROC) y el coeficiente Kappa de Cohen. La exactitud, la precisión, la recuperación y la puntuación F también se utilizaron como parámetros de rendimiento. ANN y SVM tuvieron resultados idénticos en términos de RMSE y parámetros de rendimiento. Los autores argumentaron la importancia de los algoritmos SVM y ANN y propusieron un sistema DEEDS modificado donde ANN y SVM son parte de dichos sistemas para la predicción del rendimiento de los estudiantes.

Comparaciones de los enfoques de predicción del rendimiento

La predicción precisa del rendimiento de los estudiantes y la identificación de los estudiantes en riesgo en la plataforma de aprendizaje electrónico utilizaron cuatro enfoques; (i) predicción del rendimiento académico, (ii) identificación de estudiantes en riesgo, (iii) determinación de dificultades en una plataforma de e-learning, y (iv) evaluación de la plataforma de aprendizaje. De estos enfoques, la mayoría de los estudios de investigación muestran que la predicción del desempeño académico de los estudiantes es un área de interés crucial, con un total de 16 estudios de investigación realizados entre 2009 y 2021. La identificación de estudiantes en riesgo fue la segunda después de la predicción del desempeño, con 12 estudios de investigación. estudios realizados en el mismo período. Cada investigación es única en la metodología utilizada y los atributos de tipo seleccionados para determinar los algoritmos relevantes aplicados durante la clasificación. La interacción de los estudiantes con la plataforma e-learning fue el atributo más buscado, donde los estudiantes de 1er año fueron los más considerados durante el proceso de investigación. Muy pocos estudios (5) buscaron comprender la plataforma de e-learning y su impacto en el desempeño de los estudiantes. En general, los algoritmos comúnmente aplicados fueron; DT, LR, NB, MT y SVM. La Tabla 4 proporciona detalles para la predicción del desempeño y la identificación de estudiantes en riesgo.

Tabla 4. Predicción del desempeño de los estudiantes e identificación de estudiantes en riesgo en e-learning.

Acercarse	Metodología	Atributos	Algoritmos	Contar referencias
Predicción de rendimiento	Predicción temprana- ML conjunto incremental	sociodemográfico	Base de reglas	2 [18,58]
		Enseñanza de la eficacia	NB, 1-NN y VENTANA	2 [19,22]
	Sistema de recomendación	Interacción de la plataforma del estudiante	MT, NN, LR, LWLR, SVM, NB, DT, MLP	5 [23,24,82]
	Medición automática	Registro de actividad de los	WATWIN	2 [25,28]
	Enfoque dinámico	estudiantes Estudiantes de 1er año	LR-SEQ, LR-SIM, DT, basado en reglas y NB	3 [28,29]
	ML semisupervisado	Escuelas secundarias	YATSI, SVM, ANN	6 [6,34,39]
Identificación de estudiantes en riesgo		En riesgo de no graduarse		3
	Marco de aprendizaje automático	Predicción temprana de estudiantes en riesgo	SVM, RF, LR, Adaboost, CART y DT CART, C4.5,	1 [32,38,45]
	Reducir el tamaño del conjunto de características	Resultados finales de GPA	MLP, NB, KNN y SMO CF MF, RBM, GBDT, KNN,	[85]
	Grados anteriores del estudiante	Identificación de	SVM, RF, DT, LDA, Adaboost LR, SVM, DT,	3 [46,53,54]
	Modelos predictivos - clasificación	estudiantes en riesgo	MLP, NB y KNN Extra Tree (ET), RTV-	2 [47,57]
	Factores que afectan-en-riesgo	Aprendiz rapido,	SVM	3 [62–64]
Predecir las dificultades de la plataforma de aprendizaje	examen de métodos de aprendizaje automático	Dificultades encontradas en el sistema de e-learning	ANN, LR, SVM, NBC y DT	2 [61,81]
Desempeño de los clasificadores	Comparación cruzada	Comparación entre cinco clasificadores basados en ML	NB, BN, ID3, J48 y NN	2 [55,56]
Evaluación de MOOC en desarrollo los países	Discriminantes de la puntuación de la prueba PISA 2005	Características de los estudiantes e instituciones académicas	ML y métodos estadísticos	1 [anexo y texto]

3.2. Predicción de abandono de estudiantes usando ML

La predicción precisa de la deserción de los estudiantes durante las primeras etapas ayuda a eliminar el problema subyacente al desarrollar e implementar mecanismos de intervención rápidos y consistentes. Esta sección describe en detalle la predicción de la deserción mediante técnicas de aprendizaje automático a través de una revisión de investigaciones relacionadas basadas en conjuntos de datos, características utilizadas en los métodos de ML y el resultado de los estudios.

La primera revisión de Quadri y Kalyankar [17,20] utilizó el árbol de decisión y la regresión logística para identificar las características para la predicción de la deserción. En estos estudios, los autores utilizaron el conjunto de datos de los registros de sesión de los estudiantes, donde se utilizó un árbol de decisión para extraer los factores de abandono mientras que la regresión logística se utilizó para cuantificar las tasas de abandono. Loumos, V. [16] también investigó la combinación de técnicas de ML para la predicción de la deserción utilizando tres algoritmos de aprendizaje automático: Feed-Forward Network, SVM y ARTMAP. Se sugirieron tres esquemas de decisión para la reducción de la deserción utilizando las técnicas de ML del método anterior, es decir, en el esquema de decisión 1, el estudiante se consideró desertor si al menos un algoritmo lo clasifica como desertor. En el esquema de decisión 2, un estudiante se considera un abandono potencial si dos algoritmos clasifican a un estudiante de esta manera, y en el esquema de decisión 3, un estudiante se considera un abandono si todos los algoritmos lo declaran como desertor. El conjunto de datos utilizado en su revisión comprendía registros de estudiantes registrados entre 2007 y 2008 en dos cursos de aprendizaje electrónico. El número total de estudiantes es de 193, incluidos; género, residencia, experiencia laboral, nivel de educación, calificaciones de la prueba MCQ, calificación del proyecto, fecha de presentación del proyecto y actividad de la sección. Para propósitos de experimentación, los datos del año 2007 se usan para capacitación, mientras que los datos de 2008 se usaron para fines de prueba. Se utilizaron medidas de exactitud, sensibilidad y precisión para evaluar el desempeño de los clasificadores, y los resultados indicaron que el esquema de decisión 1 es el esquema apropiado para predecir la deserción de los estudiantes.

Oyedeji et al. [71] aplicaron técnicas basadas en el aprendizaje automático para analizar el rendimiento académico del estudiante para ayudar a los educadores e instituciones que tienen curiosidad por extraer los métodos que pueden mejorar el rendimiento del individuo en la academia. Su revisión realizó el análisis de resultados pasados con la combinación de atributos individuales

como la edad del estudiante, su distribución demográfica, la actitud individual hacia la revisión y los antecedentes familiares mediante el empleo de varios algoritmos basados en el aprendizaje automático. Llegaron a la conclusión de tres modelos significativos para el análisis de rendimiento comparativo, es decir, aprendizaje supervisado de regresión lineal y aprendizaje profundo. Sugirieron MAE de 3.26, 6.43 y 4.6, respectivamente.

Ghorbani y Ghousi [77] compararon numerosas técnicas de remuestreo para predecir la deserción del estudiante utilizando dos conjuntos de datos. Estas técnicas incluyen sobremuestreo aleatorio, Borderline SMOTE, SMOTE, SVM-SMOTE, SMOTE-Tomek y SMOTE-ENN. Su objetivo principal es manejar los problemas de desequilibrio de datos al tiempo que propone una solución adecuada para la predicción del rendimiento. Aplicaron muchos algoritmos en datos equilibrados como RF, KNN, ANN, XG-boost, SVM, DT, LG y NB. Afirmaron que la combinación del clasificador Random Forest con la técnica de equilibrio de SVM-SMOTE proporcionó los mejores resultados con una precisión del 77,97 % mediante el empleo de pruebas de validación cruzada aleatorias de 5 pliegues en múltiples conjuntos de datos.

Alhusban et al. [72] empleó el análisis de aprendizaje automático para medir y mejorar la deserción de los estudiantes de pregrado. Recopilaron los datos de los estudiantes de la Universidad Al-Al Bayt y midieron varios factores para el análisis práctico, como el género, el tipo de inscripción, las calificaciones de admisión, la ciudad de nacimiento, el estado civil, la nacionalidad y las materias estudiadas en la etapa k-12. Se incluyen muchas funciones, lo que hace que los datos de muestra sean grandes; explotaron Hadoop, una plataforma de código abierto basada en aprendizaje automático. Descubrieron que existe un efecto significativo de las calificaciones de las pruebas de admisión en la especialización. Además, sugirieron que géneros específicos, como los que dominan ciertos campos, son una gran cantidad de niñas que se especializan en medicina en comparación con los niños. También afirmaron los efectos del estatus social de los estudiantes en el rendimiento. Finalmente, afirmaron que los estudiantes solteros se desempeñaron mejor en comparación con los casados o los que tenían algunas relaciones.

Hussain et al. [76] aplicó una metodología basada en el aprendizaje automático para la predicción del rendimiento esperado de los estudiantes. Recolectaron los datos curriculares y no curriculares de la actividad diaria universitaria. Sugirieron la aplicación de una red neuronal difusa que fue entrenada explotando el método metaheurístico. Como el FNN original se basaba en la corrección de errores basada en gradientes y tenía una eficiencia general limitada, sugirieron aplicar la optimización de solubilidad de gas Henry y ajustar los parámetros de FNN. Compararon la metodología propuesta con varios BA, ABC, PSO, CS, NB, k-NN, RF, ANN, DNN, ADDE y apilamiento híbrido de última generación. Llevaron a cabo experimentos rigurosos sobre la metodología propuesta y aseguraron una precisión del 96,04 % en el desempeño del estudiante de predicción temprana. Wakelam et al. [75] describieron un experimento que puede llevarse a cabo con los estudiantes de la universidad que están en su último año usando una cohorte de módulos de 23. Usan características fácilmente disponibles como la asistencia a conferencias, el entorno de aprendizaje, las calificaciones de las pruebas y las evaluaciones intermedias. Encontraron estos factores como una característica potencial para la predicción del desempeño de un individuo. Emplearon DT, KNN y RF en los datos autogenerados y afirmaron una precisión promedio del 75 % en la predicción del rendimiento con solo pocos datos y atributos pequeños y fácilmente accesibles.

Walia et al. [74] aplicaron algoritmos de clasificación para predecir el rendimiento académico del estudiante, como NB, DT, RF, ZeroR y JRip. Encontraron que la escuela, la actitud del estudiante, el género y el tiempo de revisión afectan el desempeño en términos de la calificación final. Han realizado una gran cantidad de experimentos con la ayuda de la herramienta Weka y afirmaron tener una precisión de más del 80,00 % en su conjunto de datos autogenerado. Del mismo modo, Gafarov, FM, et al. [73] aplicó el análisis de datos en los registros de estudiantes de la Universidad Federal de Kazan. Los datos fueron recopilados con la colaboración de la institución desde 2012 hasta 2019. Se aplicaron herramientas de análisis estándar como Weka e IBM-SPSS y se idearon diferentes resultados. Llegaron a la conclusión de que si se recopilan suficientes datos, puede ser mucho más fácil aplicar el algoritmo avanzado y lograr una precisión de más del 98 % utilizando herramientas y lenguajes de programación modernos.

La tasa de deserción se considera alta en los cursos de educación a distancia en comparación con los cursos presenciales tradicionales. Kotsiantis, S. [17] argumentan que la predicción de la deserción estudiantil

es fundamental para las universidades que imparten educación a distancia. El conjunto de datos recopilados para predecir la deserción es de naturaleza desequilibrada, ya que la mayoría de las instancias pertenecen a una clase. En [17], el conjunto de datos de aprendizaje a distancia de la Universidad Helénica Abierta (HOU) se utilizó con fines experimentales. El conjunto de funciones comprendía dos tipos de funciones; funciones basadas en el plan de estudios y funciones basadas en el desempeño de los estudiantes. En esta revisión, los autores sugieren un algoritmo de predicción sensible al costo que se basa en K-NN. El algoritmo propuesto logró un rendimiento prometedor en el conjunto de datos de desequilibrio en comparación con el método de referencia. Márquez vera [21] también consideró problemas de desequilibrio de clase para determinar el fracaso de los estudiantes utilizando la información de 670 estudiantes de Zacatecas. Para el balance de clases se implementó el algoritmo SMOTE utilizando la herramienta de software Weka. SMOTE es un método de sobremuestreo para el remuestreo de datos. Los resultados muestran que la aplicación de algoritmos de ML sobre datos equilibrados y la selección de características en función de sus frecuencias puede mejorar el rendimiento del clasificador para predecir la posibilidad de abandono de los estudiantes.

Mark Plagge [30] estudió algoritmos de redes neuronales artificiales (ANN) para predecir la tasa de retención de estudiantes de primer año entre 2005 y 2010 matriculados en la Universidad Estatal de Columbus. En esta revisión, se investigaron dos algoritmos ANN, (i) red neuronal de alimentación hacia adelante y (ii) red neuronal de alimentación hacia adelante en cascada. Los resultados sugirieron que la ANN de alimentación directa de 2 capas logró una alta precisión del 89 %. Saurabh Pal [26] propuso un modelo predictivo para identificar las posibles deserciones de los estudiantes mediante la utilización de las variantes del árbol de decisiones que incluyen CART, ADT, IDB y C4.5 en el proceso de predicción. El conjunto de datos contenía 1650 instancias con 14 atributos cada una. La herramienta Weka también se usó para implementar la varianza de las variantes del árbol de decisión en las que el resultado mostró que ID3 alcanzó una alta precisión del 90,90 % seguido de C4.5, CART y ADT con una puntuación de precisión del 89,09 %, 86,66 % y 82,27% respectivamente.

Ser dueño de la naturaleza temporal de los factores de deserción [35] Mi y Yeung [40] propusieron modelos temporales aplicables. Su revisión propuso dos versiones del Modelo de Markov Oculto (HMM) y las denominó Modelo de Markov Oculto de Entrada-Salida (IOHMM) IOHMM1 y IOHMM2. Además, en esta revisión también se propuso una versión modificada de la Red Neural Recurrente con celda LSTM como unidad oculta. A continuación, se comparó el rendimiento de los métodos propuestos con el modelo de clasificación de referencia utilizando un conjunto de datos recopilados de la plataforma de MOOC. Los resultados mostraron el dominio de RNN combinado con LSTM como el mejor modelo de clasificación, mientras que IOHMM1 e IOHMM2 funcionan en línea con la línea de base. Kloft et al. [7] consideró los datos del flujo de clics para la clasificación de abandonos en el entorno de los MOOC utilizando el conjunto de datos EMNLP 2014. El resultado de la revisión propuesta de selección de características y canalización de extracción para la ingeniería de características.

Yukselturk et al. [36] revisión para investigar las técnicas de extracción de datos para la predicción de la deserción en la que los datos se recopilaron a través de cuestionarios en línea. El cuestionario en línea tenía diez atributos: edad, sexo, nivel educativo, experiencia previa en línea, cobertura, conocimiento previo, autoeficacia, ocupación y locus de control. El número total de participantes fue de 189 estudiantes. La revisión empleó cuatro clasificadores de aprendizaje automático y utilizó el método de selección de características basado en algoritmos genéticos. Los resultados muestran a 3NN como el mejor clasificador con un 87 % de precisión. Teniendo en cuenta el conjunto de datos más grande, [37] estudia el rendimiento de ANN, DT y BN. El conjunto de datos utilizado en esta revisión contiene datos de 62 y 375 estudiantes de aprendizaje en línea. Los atributos del conjunto de datos se agruparon en dos categorías, es decir, las características de los estudiantes y el rendimiento académico. El resultado final indicó que el clasificador del árbol de decisiones alcanzó una alta puntuación de precisión y efectividad general.

La predicción de la deserción en la etapa inicial del curso puede proporcionar a la dirección y a los instructores una intervención temprana. Sara et al. [41] utilizó un gran conjunto de datos del sistema de administración de revisión Macom Lectio utilizado por las escuelas secundarias de Danis. El conjunto de datos incluía 72 y 598 instancias, donde cada instancia constaba de 17 valores de atributos. El software Weka se utilizó como herramienta de implementación para los algoritmos RF, CART, SVM y NB. El desempeño de los clasificadores se evaluó utilizando precisión y AUC, donde RF alcanza valores altos para ambas medidas. El trabajo de Kostopoulos [42] sirvió como una revisión pionera para

utilizar técnicas de aprendizaje automático semisupervisadas para predecir la deserción de los estudiantes. A continuación, se utilizó la herramienta de software KEEL para implementar los métodos de aprendizaje semisupervisados y se compararon los rendimientos. El conjunto de datos contenía 244 instancias con 12 atributos cada una. Los resultados obtenidos de la investigación sugirieron el algoritmo de aprendizaje semisupervisado Tri-Training Multi-Classified como el método más efectivo.

En los últimos años, la plataforma MOOC ha tomado el centro del escenario en la investigación minera educativa [48,49,59,60]. Todos estos estudios se centraron en la detección temprana de la deserción de los estudiantes. En [48], los autores arrojan luz sobre la importancia de las características temporales en la predicción del abandono escolar. Las características temporales capturaron las características en evolución del desempeño de los estudiantes utilizando datos obtenidos de puntajes de pruebas e información recopilada de foros de discusión a través de la API de Canvas. Las características extraídas de los datos incluyen; semana de abandono, número de publicaciones de discusión, número de visitas al foro, número de visitas al cuestionario, número de visitas al módulo, grado de red social y días activos. La Red Bayesiana General (GBN) y el Árbol de Decisión (DT) fueron los dos enfoques de clasificación empleados en la clasificación.

En [59], los autores investigaron modelos de aprendizaje profundo capaces de extraer características automáticamente de datos MOC sin procesar. Se propuso un método de aprendizaje profundo llamado "Red ConRec" mediante la combinación de CNN y RNN, en el que la extracción de características se lleva a cabo automáticamente en la capa de agrupación. El modelo de red ConRec propuesto logró valores de alta precisión, recuperación, puntuación F y ACU. Liang y Zhen [49] analizaron los datos de las actividades de aprendizaje de los estudiantes para medir las probabilidades de abandono de los estudios en los próximos días. El marco propuesto comprendía la recopilación de datos de la plataforma XuetangX, el preprocesamiento de datos, la extracción de características, la selección y los métodos de aprendizaje automático. El conjunto de datos de aprendizaje en línea de XuetangX cubrió 39 cursos basados en Open Edx. Los datos contenían registros de comportamiento de los estudiantes durante 40 días. Los datos de registro necesitan procesamiento previo para que puedan usarse para entrenar algoritmos de ML. Se extrajeron ciento doce características en tres categorías; funciones de usuario, funciones del curso y funciones de inscripción. Luego, el conjunto de datos se dividió en conjuntos de entrenamiento y prueba que contenían 120 054 y 80 360 instancias, respectivamente. Los clasificadores Gradient Boosting Tree (GBT), SVM y RF se utilizan cuando GBT obtiene una puntuación AUC promedio alta.

El potencial de ML para la predicción de la deserción escolar en una etapa temprana también fue resaltado por [50,51]. El conjunto de datos de estudiantes de la Universidad de Washington que contiene 69.116 registros de estudiantes matriculados entre los años 1998 y 2003 fue utilizado en experimentos por [50]. De este conjunto de datos, el 75,5% de las instancias pertenecían a la clase de graduados, mientras que el 24,5% restante pertenecía a la clase de no graduados. La clase mayoritaria se volvió a muestrear utilizando la técnica de "submuestreo" mediante la eliminación de instancias aleatorias, y el número de instancias se reduce a 16.269 para cada clase. El conjunto de características contiene características demográficas, información de ingreso preuniversitario e información de transcripciones. Los algoritmos de regresión logística (LG), RF y KNN se utilizan para la clasificación, donde LG se desempeña mejor en cuanto a precisión y valores ROC. Agregaron además que los GPA en Matemáticas, Psicología, Química e Inglés son potentes predictores de la retención de estudiantes. En [51], los autores sugirieron un Sistema de alerta temprana (EWS) basado en métodos de aprendizaje automático. Los autores propusieron la Programación genética basada en la gramática (GBCP), una versión modificada de la Minería de reglas de clasificación interpretables (ICRM) propuesta en 2013. El algoritmo ICRM2 puede funcionar tanto en conjuntos de datos de equilibrio como de desequilibrio. El autor mide el rendimiento de ICRM2 con SVM, NB y DT y encontró que ICRM es el mejor predictor incluso si el conjunto de datos está desequilibrado.

Burgas et al. [51] analizan los datos de calificación del curso para predecir la deserción. Según sus experimentos, propusieron que combinar tanto el plan de predicción como el de tutoría reduce la tasa de abandono escolar en un 14 %. Más recientemente, Gordner y Brook [66] propusieron la Tarea de selección de modelos (MST) para la selección de modelos predictivos y la extracción de características. Sugirieron dos etapas basadas en las pruebas estadísticas de Friedman y Nemenyi para la selección del modelo. Esta revisión recopiló datos de 298 909 estudiantes de la plataforma MOOC para seis cursos en línea. Este conjunto de datos contenía 28 funciones agrupadas en tres categorías, es decir, funciones de seguimiento de clics, funciones académicas y funciones de foro de discusión. Los clasificadores CART y Adaboosting Tree se utilizaron con fines de predicción. Esta revisión concluyó que el clic-

La función de transmisión fue más beneficiosa, mientras que en la selección del método ML, la distancia crítica entre el rendimiento del clasificador fue una mejor medida. Desmarais et al. [70] mostró la importancia de los métodos de aprendizaje profundo para la predicción de la deserción y comparó el rendimiento con los algoritmos KNN, SVM y DT. El algoritmo de aprendizaje profundo logró valores de AUC y precisión más altos que los algoritmos de ML, en los que el conjunto de datos contenía el flujo de clics de los estudiantes y los datos de discusión del foro con 13 funciones en total.

Comparaciones de los enfoques de predicción de la deserción

La predicción temprana de la posible deserción de los estudiantes es fundamental para determinar las medidas correctivas necesarias. Los enfoques más utilizados incluyeron la identificación de las características de deserción, el plan de estudios y el desempeño de los estudiantes, la tasa de retención, los factores de deserción y la predicción temprana. Las características del estudiante y el rendimiento académico fueron atributos comúnmente utilizados por la mayoría de los investigadores para determinar las características de la deserción. La predicción temprana de la posible deserción de los estudiantes se llevó a cabo utilizando conjuntos de datos tanto dinámicos como estáticos. Los algoritmos comúnmente aplicados en la predicción de la deserción fueron: DT, SVM, CART, KNN y NB (tabla 5).

Tabla 5. Predicción de la deserción estudiantil mediante técnicas ML y métodos EDM.

Acercarse	Atributos	Algoritmos	Contar referencias
Funciones para la predicción de la deserción, incluidas funciones temporales	características personales y rendimiento académico de los estudiantes	DT, LR, SVM, ARTMAP, radiofrecuencia, CARRITO, y NB	10 [17,20,37] [41–43] [48,59,60] [49]
basado en el plan de estudios y características basadas en el rendimiento de los estudiantes	Problemas de desequilibrio de la clase de rendimiento de los estudiantes	K-NN, SMOTE	2 [17,21]
Tasa de retención	estudiantes de primer año	DT, Redes Neuronales Artificiales (ANN)	2 [26,30]
factores de abandono	Evaluación de modelos temporales útiles (Modelo Oculto de Markov (HMM))	RNN combinado con LSTM	3 [35,36,40]
Predicción en etapa temprana de posible deserción estudiantil	información de ingreso preuniversitario e información de expediente académico	ICRM2 con SVM, NB, DT, ID3, DL y KNN, CARRO y Árbol de arranque	4 [26,51,66] [70]

3.3. Evaluación del Desempeño de los Estudiantes Basada en Datos Estáticos y Datos Dinámicos

Los datos de desempeño de los estudiantes utilizados para predecir el desempeño de los estudiantes se pueden clasificar en dos grupos; (a) datos estáticos y (b) datos dinámicos. De acuerdo con [27], los datos dinámicos de rendimiento de los estudiantes contienen registros de éxito y fracaso de los estudiantes recopilados a medida que interactúan con el sistema de aprendizaje. Los registros de interacción de los estudiantes con el sistema de aprendizaje electrónico son un ejemplo de datos dinámicos, ya que las características del conjunto de datos cambian con el tiempo. Por otro lado, los datos estáticos de desempeño de los estudiantes se adquieren una vez y no pueden cambiar con el tiempo. Un ejemplo incluye la inscripción de los estudiantes y los datos demográficos. Las siguientes secciones presentan discusiones sobre el uso de datos estáticos y dinámicos en la minería de datos educativos.

Thaker et al. [27] propuso un modelo dinámico de conocimiento del estudiante para libros de texto adaptativos. El marco propuesto utiliza la lectura de los estudiantes y los datos de las actividades de las pruebas para predecir el estado actual de conocimiento de los estudiantes. El marco contiene dos versiones avanzadas del Modelo de Comportamiento (BM) básico, es decir, (i) Modelo de Comportamiento-Rendimiento (BPM) y (ii) Modelo de Comportamiento-Rendimiento Individualizado (IBPM). Se utilizó la herramienta Feature Aware Student Knowledge Tracing (FAST) para implementar los modelos propuestos. El enfoque propuesto logró valores bajos de RMSE y altos de ACU en comparación con el modelo de comportamiento básico.

Carlos et al. [52] presentan un modelo basado en la clasificación para predecir el rendimiento de los estudiantes que incluye un método de recopilación de datos para recopilar datos de comportamiento y aprendizaje de los estudiantes a partir de actividades de capacitación. Como método de clasificación se utilizó el algoritmo SVM que clasifica a los estudiantes en tres categorías según su desempeño: alto, medio y bajo.

niveles de desempeño Se recogieron datos de 336 estudiantes con 61 características. Se realizaron cuatro experimentos de la siguiente manera; en el experimento 1, solo se consideraron características de comportamiento para la clasificación; en el experimento 2, solo se utilizaron funciones de aprendizaje; en el experimento 3, se combinaron las características de aprendizaje y comportamiento para la clasificación, y en el experimento 4, solo se usaron características seleccionadas para la predicción del rendimiento de los estudiantes. En general, el conjunto de datos contenía ocho características de comportamiento y 53 características de aprendizaje, y el desempeño de los estudiantes se pronosticó durante diez semanas. Los resultados mostraron que la precisión del clasificador aumentó en la semana siguiente a medida que crecían los datos. Además, tanto las funciones de comportamiento como las de aprendizaje combinadas lograron un alto rendimiento de clasificación con una precisión del 74,10 % durante la semana 10.

Desmarais et al. [70] propusieron cuatro modelos lineales basados en la factorización matricial utilizando datos estáticos de los estudiantes para la evaluación de las habilidades de los estudiantes, donde el rendimiento de los modelos lineales propuestos se comparó con la conocida Teoría de Respuesta al Ítem (IRT) y el k- vecino más cercano. En esta revisión, se utilizaron tres conjuntos de datos, a saber; (a) álgebra fraccionaria compuesta por 20 preguntas y 149 estudiantes, (b) capa UNIX compuesta por 34 preguntas y 48 estudiantes, y (c) matemáticas universitarias compuesta por 60 preguntas y 250 estudiantes. Los resultados experimentales mostraron que los enfoques IRT tradicionales lograron una mayor precisión que el modelo lineal propuesto y los enfoques del vecino más cercano.

Aplicación de enfoques de datos estáticos y dinámicos La

predicción temprana del rendimiento de los estudiantes, la identificación de los estudiantes en riesgo es esencial para determinar la deserción potencial y las medidas correctivas precisas. Un total de 15 estudios de investigación utilizaron datos dinámicos para los estudiantes, como la lectura de los estudiantes, los resultados de las pruebas y los registros de actividad del sistema de aprendizaje electrónico (Tabla 6). Solo nueve estudios utilizaron datos estáticos que se centraron en los detalles de inscripción y la información demográfica, mientras que 14 utilizaron conjuntos de datos dinámicos y estáticos. Esto indica que el desempeño y las actividades de los estudiantes en la plataforma de aprendizaje brindan mucha retroalimentación necesaria para la predicción del desempeño. Los algoritmos comúnmente aplicados en la predicción temprana utilizando datos estáticos y dinámicos fueron; KNN, NB, SVM, DT, RF, ID3 e ICRM2.

Tabla 6. Utilidad de los datos estáticos y dinámicos para la predicción temprana del rendimiento de los alumnos.

Acercarse	Atributos	Algoritmos	Contar	Referencias
Dinámica	Datos de desempeño de los estudiantes, actividades de lectura y cuestionarios de los estudiantes	K-NN, SMOTE, BM, SVM, NB, BN, DT, CR, ADTree, J48 y RF	15	[23,25,28,53,54,82] [21,47,57,62–64] [33,44,49,86]
Estático	Inscripción y datos demográficos	Teoría de Respuesta al Ítem (IRT), ICRM2, SVM, NB, DT, ID3, DL y KNN, CART y árbol de arranque Ada	9	[6,26,30,34,39,51,66] [27,70]
Ambos	Información de ingreso preuniversitario e información de expediente académico	ICRM2 con SVM, DL, ID3, KNN, DT, LR, SVM, ARTMAP, RF, CART y NB	14	[17,20,26,37,41–43] [45,48,49,59,60,66,70]

3.4. Plan de acción correctivo

La identificación temprana del estudiante en riesgo es crucial y contribuye al desarrollo de acciones correctivas prácticas, lo que contribuye aún más a la mejora del desempeño de los estudiantes. Esta sección proporcionó detalles del trabajo académico reciente sobre el plan de acción correctivo para mejorar el rendimiento de los estudiantes durante sus estudios.

Ahadi et al. [52] sugirió que los algoritmos de aprendizaje automático pueden detectar a los estudiantes de bajo y alto rendimiento en etapas tempranas y propusieron un plan de intervención durante la programación del trabajo del curso. La detección temprana de estudiantes de bajo y alto rendimiento puede beneficiar a los instructores para guiar a los estudiantes con dificultades y ayudarlos durante sus futuros estudios. En esta revisión, los autores evaluaron el trabajo presentado por Jadwad y Watson et al. [28] en el conjunto de datos dado. Además, también utilizaron algoritmos de aprendizaje automático para predecir

los estudiantes de bajo y alto rendimiento en la primera semana de un curso de introducción a la programación. Se utilizó el conjunto de datos de los estudiantes de dos semestres para cursos de introducción a la programación en la Universidad de Helsinki. El conjunto de datos se recopiló utilizando la herramienta Test My Code [44] para evaluar el rendimiento de los estudiantes automáticamente. Un total de datos de 296 estudiantes de los semestres de primavera (86 estudiantes) y otoño (210 estudiantes) se dividieron en tres grupos de la siguiente manera; (a) "se da una pregunta de programación algorítmica en el examen", (b) "el curso general", y (c) "combinación de dos". Durante la clasificación, se utilizaron nueve algoritmos ML de tres tipos. Estos incluyen NB, BN (bayesiano), DT, regla conjunta (CR), PART (aprendizaje de reglas), ADTree, J48, RF y Decision Stump (DS) (árbol de decisiones). Se extrajo un total de 53 características del conjunto de datos después de aplicar tres métodos de selección de características: mejor primer método, búsqueda genética y codicioso paso a paso. Luego se redujo el número de funciones eliminando aquellas con poca ganancia de información. La herramienta de minería de datos Weka se utilizó para la clasificación y selección de características, y la implementación del algoritmo. Los resultados sugirieron que los clasificadores logran una precisión del 88% al 93% cuando se evalúan utilizando métodos de validación cruzada de 10 k veces y división porcentual. También concluyeron que los enfoques de aprendizaje automático funcionaron mejor que Jadwad y Watson et al. [28] métodos. Además, los autores sugirieron prácticas adicionales para los estudiantes de bajo rendimiento, como ensayar y alentar a los estudiantes a hacer más experimentos en lugar de solo corregir los experimentos.

Jenhani et al. [87] propuso un plan de acción correctivo basado en la clasificación que se basa en un conjunto de datos de acción correctiva. En esta revisión, los autores primero construyeron conjuntos de datos de acciones correctivas de diferentes fuentes y múltiples semestres donde se aplicó un conjunto de algoritmos de aprendizaje automático supervisado para predecir acciones correctivas prácticas. El sistema propuesto ayuda al instructor a tomar las medidas correctivas adecuadas. El sistema utilizado fue entrenado en datos históricos basados en acciones de expertos e instructores para mejorar el bajo resultado de aprendizaje. Varias fuentes recopilan los datos, incluidos "Blackboard LMS", sistemas heredados y calificaciones de los instructores. Cada instancia en el conjunto de datos contiene 13 atributos, mientras que nueve etiquetas de clase representan acciones correctivas. Los atributos incluían código de curso, resultado de aprendizaje del curso (CLO), NQFDomain, género, tamaño de sección, nivel de curso, semestre, Haslab, evaluación. Las nueve clases de acciones correctivas utilizadas fueron CCES-Centro de soporte y tutorial, Software de práctica, Mejorar la coordinación del laboratorio de clase, Revisar concepto, Cuestionarios adicionales, Ejemplos de práctica, Asignaciones adicionales, Presentación de discusión y Demostraciones, Libro de texto complementario y Materiales. Se seleccionaron y usaron un total de 10 algoritmos de clasificación para la clasificación utilizando la herramienta de minería de datos Weka, y todos los clasificadores lograron una precisión promedio del 80 %.

Elhassan et al. [31] propusieron un sistema de recomendación de acciones correctivas (RARS) para abordar las deficiencias en el desempeño de los estudiantes. El sistema de recomendación propuesto se basó en un enfoque de clasificación de etiquetas múltiples. Esta revisión fue una extensión de [87], donde cada instancia en el conjunto de datos tenía más de una etiqueta. El conjunto de datos utilizado contenía 1008 instancias en las que la cantidad promedio de etiquetas por instancia era seis con siete funciones cada una. La herramienta de minería de datos Weka se utilizó con fines de implementación, donde el conjunto de datos se dividió primero en una proporción de 70:30. El 70 % de las instancias se utilizó como conjunto de entrenamiento, mientras que el 30 % restante se utilizó como conjunto de prueba. Se emplearon cuatro métodos de envoltura durante la fase de experimentación, que incluyen "Relevancia binaria", "Cadena clasificadora (CC)", "Random K-fold (RK)" y "Rank+ Threshold (RT)". Los algoritmos de clasificación C4.5, NB y K-NN se utilizan para los métodos de envoltura. El rendimiento de los clasificadores se evalúa utilizando pérdidas de hamming, pérdida de cero uno, pérdida de un error y precisión promedio. Los resultados concluyeron que el árbol de decisión C4.5 tenía una pérdida de error baja (0,0) y una precisión promedio alta del 98,4 % para el método de envoltorio de relevancia binaria (BR).

Burgos et al. [51] investigó el uso de la técnica de descubrimiento de conocimiento y propuso un plan de acción de tutoría para reducir la tasa de abandono en un 14%. Los modelos de regresión logística se utilizan como métodos predictivos para detectar la posible deserción de los estudiantes utilizando las calificaciones de actividad. El método de predicción propuesto utiliza una función iterativa que evalúa el desempeño de los estudiantes cada semana. El rendimiento del método LOGIT-Act propuesto se comparó con los algoritmos SVM, FFNN, PESFAM y SEDM. El algoritmo propuesto

alcanza puntuaciones altas de exactitud, precisión, recuperación y especificidad de 97,13 %, 98,95 %, 96,73 % y 97,14 %, respectivamente. Esta revisión de la investigación también sugirió un plan de acción de tutoría semanal que puede evitar que los estudiantes abandonen los estudios. El plan de acción propuesto incluía: • Llamada de cortesía al inicio del año académico • El mensaje público de bienvenida al curso a través de un aula virtual • La sesión de bienvenida por videoconferencia • Correo electrónico a potencial abandono • Llamada telefónica a potencial abandono • Llamada telefónica a potencial abandono (de uno o más cursos)

Enfoques de acción correctiva

Esta investigación ha revelado que la detección temprana basada en el desempeño de los estudiantes es importante para determinar las medidas correctivas requeridas. Por otro lado, se realizan acciones de remediación utilizando las características del curso y tecnologías del sistema e-learning. La revisión también reveló que la detección temprana estándar y el algoritmo correctivo era NB, ya que la mayoría de los estudios anteriores explotaron NB para la tarea y lograron resultados significativos.

En general, se aplicaron algoritmos DT, NB y SVM para el rendimiento y durante las predicciones de abandono utilizando datos estáticos y dinámicos. La Tabla 7 proporciona un resumen de los enfoques de acción correctiva. La Figura 4 muestra el enfoque metodológico común utilizado por la mayoría de los estudios de investigación evaluados.

Tabla 7. Acción correctiva basada en resultados de predicción.

Acercarse	Atributos	Algoritmos	Contar	Referencias
Detección temprana	rendimiento de los estudiantes	Nota, BN, DT, CR, PARTE (aprendiz de reglas), ADTree, J48 y RF	12	[17,20,28,37,41,42] [43,44,48,49,59,60]
Acción correctiva	código del curso, resultado del aprendizaje del curso (CLO), NQFDomain, género, tamaño de la sección, nivel del curso, semestre, Haslab, evaluación, U, M, A, E.	RARS, C4.5, NB y K-NN 7		[26,31,51,66,70] [45]

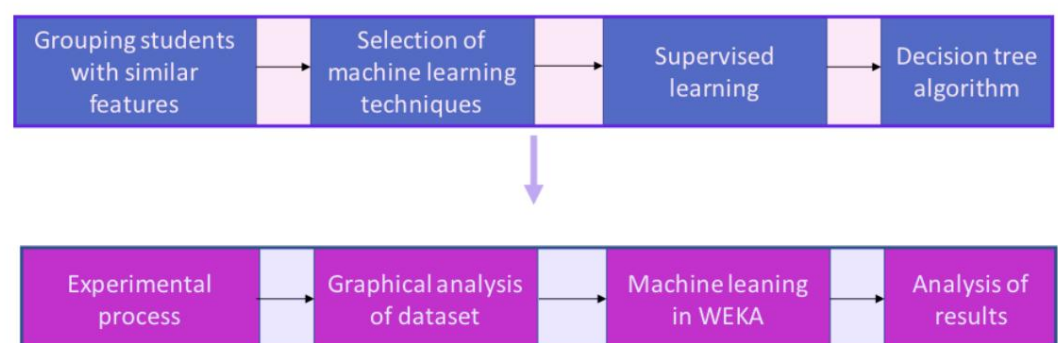


Figura 4. Enfoque metodológico adoptado por la mayoría de las investigaciones.

4. Discusión y Revisión Crítica

Para abordar nuestras dos primeras preguntas de investigación, recopilamos los estudios que intentan abordar los problemas. Identificamos los problemas y sus soluciones en la literatura. Para responder a la tercera pregunta, la productividad general de la investigación se muestra utilizando la distribución por país en la Figura 5, la distribución por conferencia/revista en la Figura 6 y la distribución por año en la Figura 7 de los estudios incluidos en la revisión. Se puede observar que la comunidad de investigación de Alemania y el Reino Unido se centró más en el campo que los otros países. Del mismo modo, 2018 fue un año caluroso para el tema de predicción del rendimiento de los estudiantes en general. Mientras tanto, más revistas se centraron en el tema en comparación con las conferencias.




Figura 5. Distribución por países de las publicaciones incluidas.




Figura 6. Distribución inteligente de las publicaciones incluidas en congresos y revistas.




Figura 7. Distribución por años de las publicaciones incluidas.

Este documento presenta una descripción general de la técnica de aprendizaje automático utilizada en la minería de datos educativos, centrándose en dos aspectos críticos; (a) predicción precisa de los estudiantes en riesgo y (b) predicción precisa de la deserción de los estudiantes. Tras una extensa revisión bibliográfica de publicaciones críticas entre 2009 y 2021, se llegan a las siguientes conclusiones; • La mayoría de los estudios utilizaron datos mínimos para entrenar los métodos de aprendizaje automático. Sin embargo, es un hecho que los algoritmos de ML necesitan datos masivos para funcionar con precisión.

- La revisión también reveló que algunos estudios se han centrado en el equilibrio de clases o el equilibrio de datos. El equilibrio de clases se considera principalmente importante para obtener un alto rendimiento de clasificación [50]. • La naturaleza temporal de las características utilizadas para las predicciones de los estudiantes en riesgo y que abandonan los estudios no se ha estudiado en su potencial. Los valores de estas características cambian con el tiempo debido a su naturaleza dinámica. La incorporación de características temporales para la clasificación tiene la capacidad de mejorar el rendimiento del predictor [40,48,67]. Khan et al. [67] examinan las características temporales para la clasificación del texto.
- También se observó que la predicción de estudiantes en riesgo y estudios de deserción para estudiantes en el campus utilizó el conjunto de datos con un número mínimo de instancias. Es posible que los algoritmos de aprendizaje automático entrenados en pequeños conjuntos de datos no logren resultados satisfactorios. Además, la técnica de preprocesamiento de datos puede contribuir significativamente a obtener resultados más precisos.
- La mayoría de las investigaciones abordaron el problema como una tarea de clasificación. Mientras que muy pocos estudios se centraron en algoritmos de agrupamiento que detectaron las clases de estudiantes en el conjunto de datos. Además, los problemas mencionados anteriormente se tratan como una clasificación binaria, mientras que se introducirían varias otras clases para ayudar a la gerencia a desarrollar planes de intervención más efectivos.
- Se ha prestado menos atención a las tareas de ingeniería de características, donde los tipos de características pueden influir en el rendimiento del predictor. Tres características se utilizaron principalmente en los estudios, es decir, la demografía de los estudiantes, registros académicos y de sesiones de interacción de aprendizaje electrónico.
- También se observó que la mayoría de los estudios utilizaron algoritmos tradicionales de aprendizaje automático como SVM, DT, NB, KNN, etc., y solo unos pocos investigaron el potencial de los algoritmos de aprendizaje profundo.
- Por último, pero no menos importante, la literatura actual no considera la naturaleza dinámica del desempeño de los estudiantes. El desempeño de los estudiantes es un proceso evolutivo y mejora o disminuye constantemente. El rendimiento de los predictores en datos dinámicos en tiempo real aún no se ha explorado.

Como resultado, ML tiene todo el potencial para acelerar el progreso en el campo educativo y se puede notar que la eficiencia de la educación crece significativamente. Al aplicar técnicas de ML en el campo educativo de una manera adecuada y eficiente, esto transformará la educación y cambiará fundamentalmente la enseñanza, el aprendizaje y la investigación. Los educadores que usan ML obtendrán una mejor comprensión de cómo sus estudiantes están progresando con el aprendizaje, por lo tanto, podrán ayudar antes a los estudiantes con dificultades y tomar medidas para mejorar el éxito y la retención.

5. Conclusiones

Con los avances recientes en los sistemas de adquisición de datos y los indicadores de desempeño del sistema, los sistemas educativos ahora se estudian de manera más efectiva pero con mucho menos esfuerzo. Se han propuesto técnicas de aprendizaje automático y minería de datos de última generación para analizar y monitorear datos masivos, dando lugar a un campo completamente nuevo de análisis de big data. En general, esta revisión logró sus objetivos de mejorar el desempeño de los estudiantes al predecir el riesgo y la deserción de los estudiantes, destacando la importancia de usar datos tanto estáticos como dinámicos. Esto proporcionará la base para nuevos avances en minería de datos educativos utilizando enfoques de aprendizaje automático y minería de datos. Sin embargo, solo unos pocos estudios propusieron soluciones correctivas para proporcionar comentarios oportunos a los estudiantes, instructores y educadores para abordar los problemas. La investigación futura se centrará más en desarrollar un método de conjunto eficiente para implementar de forma práctica la metodología de predicción del rendimiento basada en ML y buscar formas o métodos dinámicos para predecir el rendimiento de los estudiantes y proporcionar las acciones correctivas automáticas necesarias para ayudar a los estudiantes lo antes posible.

Finalmente, enfatizamos las direcciones prometedoras para futuras investigaciones utilizando técnicas de ML para predecir el rendimiento de los estudiantes. Estamos buscando implementar algunos de los excelentes trabajos existentes y enfocándonos más en la naturaleza dinámica del desempeño de los estudiantes. Como un

Como resultado, los instructores pueden obtener más sugerencias para desarrollar intervenciones adecuadas para los alumnos y lograr objetivos educativos de precisión.

Contribuciones de los autores: Conceptualización, metodología, software, análisis estadístico, redacción del borrador original, preparación: BA, NZ y HA; curación de datos: BA; revisión de escritura y edición: revisión de literatura, discusión: BA, NZ y HA. Todos los autores han leído y están de acuerdo con la versión publicada del manuscrito.

Financiamiento: Esta investigación no recibió financiamiento externo.

Conflictos de interés: Los autores declaran no tener ningún conflicto de interés.

abreviaturas

En este manuscrito se utilizan las siguientes abreviaturas:

RF	Bosque aleatorio
LG	Regresión Logística
Red neuronal NN	
Máquina de vectores de soporte SVM	
Perceptrón multicapa MLP	
DT	Árbol de decisión
redes bayesianas	bayesiana ingenua
KNN	K-vecinos más cercanos
Técnica de sobremuestreo de minorías sintéticas SMOTE	

Referencias

- Romero, C.; Ventura, S.; Pechenizkiy, M.; Baker, RS Manual de Minería de Datos Educativos; CRC Press: Boca Ratón, FL, EE. UU., 2010.
- Hernández-Blanco, A.; Herrera-Flores, B.; Tomás, D.; Navarro-Colorado, B. A systematic review of deep learning approaches to minería de datos educativos. *Complejidad* **2019**, 2019, 1306039. [\[Referencia cruzada\]](#)
- Bengio, Y.; Lecun, Y.; Hinton, G. Aprendizaje profundo para IA. *común ACM* **2021**, *64*, 58–65. [\[Referencia cruzada\]](#)
- Lykourantzou, I.; Giannoukos, I.; Mpardis, G.; Nikolopoulos, V.; Loumos, V. Predicción temprana y dinámica del rendimiento estudiantil en cursos de e-learning utilizando redes neuronales. *Mermelada. Soc. información ciencia Tecnología* **2009**, *60*, 372–380. [\[Referencia cruzada\]](#)
- Kuzilek, J.; Hlosta, M.; Herrmannova, D.; Zdrahal, Z.; Wolff, A. Análisis de OU: Análisis de estudiantes en riesgo en The Open University. *Aprender. Anal. Rev.* **2015**, 2015, 1–16.
- Él, J.; Bailey, J.; Rubinstein, BI; Zhang, R. Identificación de estudiantes en riesgo en cursos masivos abiertos en línea. En *Actas de la Vigésimonovena Conferencia AAAI sobre Inteligencia Artificial*, Austin, TX, EE. UU., 25–30 de enero de 2015.
- Kloft, M.; Stiehler, F.; Zheng, Z.; Pinkwart, N. Predicción del abandono de MOOC durante semanas utilizando métodos de aprendizaje automático. En *Actas del Taller EMNLP 2014 sobre análisis de interacción social a gran escala en MOOC*; Departamento de Ciencias de la Computación, Universidad Humboldt de Berlín: Berlín, Alemania, 2014; págs. 60–65.
- Alapont, J.; Bella-Sanjuán, A.; Ferri, C.; Hernández-Orallo, J.; Llopis-Llopis, J.; Ramírez-Quintana, M. Herramientas especializadas de automatización de minería de datos para la gestión hospitalaria. En *Actas de la Primera Conferencia de Europa del Este sobre Modelado y Cómputo de Atención Médica*, Craiova, Rumania, 31 de agosto a 2 de septiembre de 2005; págs. 7–19.
- Hellas, A.; Ihtantola, P.; Petersen, A.; Ajanovski, VV; Gútica, M.; Hynninen, T.; Knutas, A.; Leinonen, J.; Messom, C.; Liao, SN. Predicción del rendimiento académico: una revisión sistemática de la literatura. En *Actas de la 23.ª Conferencia Anual de ACM sobre Innovación y Tecnología en la Educación en Ciencias de la Computación*, Larnaca, Chipre, 2 al 4 de julio de 2018; págs. 175–199.
- Alyahyan, E.; Düstegör, D. Predicción del éxito académico en la educación superior: revisión de literatura y mejores prácticas. En *t. J. Educ. Tecnología Alto. Educ.* **2020**, *17*, 1–21. [\[Referencia cruzada\]](#)
- Namun, A.; Alshanqiti, A. Predecir el rendimiento de los estudiantes utilizando técnicas de análisis de aprendizaje y minería de datos: un análisis sistemático revisión de literatura. *aplicación ciencia* **2021**, *11*, 237. [\[Referencia cruzada\]](#)
- Okoli, C. Una guía para realizar una revisión sistemática de la literatura independiente. *común Asoc. información sist.* **2015**, *37*, 43. [\[Referencia cruzada\]](#)
- Kitchenham, B. Procedimientos para realizar revisiones sistemáticas; Universidad de Keele: Keele, Reino Unido, 2004; Volumen 33, págs. 1–26.
- Piper, RJ Cómo escribir una revisión sistemática de la literatura: una guía para estudiantes de medicina. *nacional AMR Foster. Medicina. Res.* **2013**, *1*, 1–8.
- Bhandari, M.; Guyatt, GH; Montori, V.; Devereaux, P.; Swiontkowski, MF Guía del usuario de la literatura ortopédica: Cómo utilizar una revisión sistemática de la literatura. *JBJS* **2002**, *84*, 1672–1682. [\[Referencia cruzada\]](#)
- Loumos, V. Predicción de abandono en cursos de e-learning mediante la combinación de técnicas de aprendizaje automático. *computar Educ.* **2009**, *53*, 950–965.
- Kotsiantis, S. Minería de datos educativos: un estudio de caso para predecir estudiantes propensos a la deserción. En *t. J. Knowl. Ing. Paradigma de datos blandos.* **2009**, *1*, 101–111. [\[Referencia cruzada\]](#)
- Kovacic, Z. Predicción temprana del éxito estudiantil: extracción de datos de inscripción de estudiantes. En *Proceedings of the Informing Science and Conferencia conjunta sobre educación en tecnología de la información*, Cassino, Italia, del 19 al 24 de junio de 2010.

19. Kotsiantis, S.; Patriarcas, K.; Xenos, M. Un conjunto incremental combinatorial de clasificadores como técnica para predecir estudiantes. Llevar a cabo. Educación a distancia Sistema basado en conocimientos. **2010**, 23, 529–535. [\[Referencia cruzada\]](#)
20. Quadri, M.; Kalyankar, N. Función de abandono de los datos de los estudiantes para el rendimiento académico mediante técnicas de árboles de decisión. globo j computar ciencia Tecnología **2010**, 10. ISSN 0975-4172. Disponible en línea: <https://computerresearch.org/index.php/computer/article/ver/891> (consultado el 15 de agosto de 2021).
21. Márquez-Vera, C.; Romero, C.; Ventura, S. Predicción del fracaso escolar mediante minería de datos. En Actas de la 4ª Internacional Conferencia sobre Minería de Datos Educativos, Eindhoven, Países Bajos, 6–8 de julio de 2011.
22. Galbraith, C.; Merrill, G.; Kline, D. ¿Las evaluaciones de los estudiantes sobre la eficacia de la enseñanza son válidas para medir los resultados del aprendizaje de los estudiantes en clases relacionadas con los negocios? una red neuronal y análisis bayesianos. Res. Educación Superior **2011**, 53, 353–374. [\[Referencia cruzada\]](#)
23. Kotsiantis, SB Uso de técnicas de aprendizaje automático para propuestas educativas: un sistema de apoyo a la decisión para pronosticar las calificaciones de los estudiantes. Artefacto Intel. Rev. **2012**, 37, 331–344. [\[Referencia cruzada\]](#)
24. Osmanbegovic, E.; Suljic, M. Enfoque de minería de datos para predecir el desempeño de los estudiantes. economía Rev. J. Econ. Autobús. **2012**, 10, 3–12.
25. Baradwaj, BK; Pal, S. Minería de datos educativos para analizar el desempeño de los estudiantes. arXiv **2012**, arXiv:1201.3417.
26. Pal, S. Minería de datos educativos para reducir las tasas de abandono escolar de los estudiantes de ingeniería. En t. J.Inf. Ing. Electrón. Autobús. **2012**, 4, 1–7. [\[Referencia cruzada\]](#)
27. Thaker, K.; Huang, Y.; Brusilovsky, P.; Daqing, H. Modelado de conocimiento dinámico con actividades heterogéneas para libros de texto adaptativos. En Actas de la 11.ª Conferencia Internacional sobre Minería de Datos Educativos, Buffalo, NY, EE. UU., 15–18 de julio de 2018.
28. Watson, C.; Li, FW; Godwin, JL Predicción del rendimiento en un curso de introducción a la programación mediante el registro y el análisis del comportamiento de programación de los estudiantes. En las Actas de la 13.ª Conferencia Internacional del IEEE sobre Tecnologías Avanzadas de Aprendizaje, Beijing, China, 15 al 18 de julio de 2013; págs. 319–323.
29. Márquez-Vera, C.; Cano, A.; Romero, C.; Ventura, S. Predicción del fracaso estudiantil en la escuela utilizando programación genética y diferentes enfoques de minería de datos con datos de alta dimensión y desequilibrados. aplicación Intel. **2013**, 38, 315–330. [\[Referencia cruzada\]](#)
30. Plagge, M. Uso de redes neuronales artificiales para predecir las tasas de retención de segundo año de los estudiantes tradicionales de primer año. En Procedimientos de la 51.ª Conferencia Sudeste de la ACM, Savannah, GA, EE. UU., 4 al 6 de abril de 2013.
31. Elhassan, A.; Jenhani, I.; Brahim, G. Recomendación de acciones correctivas a través de la clasificación de múltiples etiquetas: un curso de aprendizaje método de mejora. En t. J. Mach. Aprender. computar **2018**, 8, 583–588.
32. Hu, YH; Lo, CL; Shih, SP Desarrollo de sistemas de alerta temprana para predecir estudiantes. Aprender en línea. Llevar a cabo. computar Tararear. Comportamiento **2014**, 36, 469–478. [\[Referencia cruzada\]](#)
33. Villagra-Arnedo, CJ; Gallego-Durán, F.; Compán, P.; Largo, F.; Molina-Carmona, R. Predicción del rendimiento académico a partir de datos de comportamiento y aprendizaje. 2016. Disponible en línea: <http://hdl.handle.net/10045/57216> (consultado el 2 de enero de 2021).
34. Wolff, A. Modelado del comportamiento en línea de los estudiantes en un entorno de aprendizaje virtual. arXiv **2018**, arXiv:1811.06369.
35. Vosotros, C.; Biswas, G. Predicción temprana de la deserción y el rendimiento de los estudiantes en los MOOC utilizando información temporal de mayor granularidad. J. Aprende. Anal. **2014**, 1, 169–172. [\[Referencia cruzada\]](#)
36. Yukselturk, E.; Ozekes, S.; Turel, Y. Prediciendo la deserción estudiantil: una aplicación de métodos de minería de datos en una educación en línea programa. EUR. J. Aprendizaje electrónico a distancia abierta. **2014**, 17, 118–133. [\[Referencia cruzada\]](#)
37. Bronceado, M.; Shao, P. Predicción de la deserción de los estudiantes en el programa de aprendizaje electrónico mediante el uso del método de aprendizaje automático. En t. J.Emerg. Tecnología Aprender. (iJET) **2015**, 10, 11–17. [\[Referencia cruzada\]](#)
38. Lakkaraju, H.; Aguiar, E.; Shan, C.; Miller, D.; Bhanpuri, N.; Ghani, R.; Addison, K. Un marco de aprendizaje automático para identificar a los estudiantes en riesgo de resultados académicos adversos. En Actas de la 21.ª ACM SIGKDD, Conferencia internacional sobre descubrimiento de conocimientos y datos, Sydney, NSW, Australia, 10 al 13 de agosto de 2015.
39. Ahmad, F.; Ismail, N.; Aziz, A. La predicción del rendimiento académico de los estudiantes utilizando técnicas de minería de datos de clasificación. aplicación Matemáticas. ciencia **2015**, 9, 6415–6426. [\[Referencia cruzada\]](#)
40. Fei, M.; Yeung, DY Modelos temporales para predecir la deserción estudiantil en cursos masivos abiertos en línea. En las Actas de la Conferencia Internacional IEEE sobre el Taller de Minería de Datos (ICDMW), Atlantic City, NJ, EE. UU., 14 al 17 de noviembre de 2015.
41. Sara, NB; Halland, R.; Igel, C.; Alstrup, S. Predicción de la deserción escolar mediante el aprendizaje automático: un estudio danés a gran escala. En Actas del Simposio Europeo sobre Redes Neuronales Artificiales, Inteligencia Computacional, Brujas, Bélgica, 22–24 de abril de 2015.
42. Kostopoulos, G.; Kotsiantis, S.; Pintelas, P. Estimación de la deserción estudiantil en educación superior a distancia mediante técnicas semisupervisadas. En Actas de la 19.ª Conferencia Panhelénica sobre Informática, Atenas, Grecia, 1 al 3 de octubre de 2015; págs. 38–43.
43. Xing, W.; Chen, X.; Stein, J.; Marcinkowski, M. Predicción temporal de abandonos en MOOC: Alcanzando la fruta al alcance de la mano a través de la generalización de apilamiento. computar Tararear. Comportamiento **2016**, 58, 119–129. [\[Referencia cruzada\]](#)
44. Vihavainen, A.; Vikberg, T.; Luukkainen, M.; Pärtel, M. Andamiaje del aprendizaje de los estudiantes usando Test My Code. En Actas de la 18.ª Conferencia ACM sobre Innovación y Tecnología en la Educación en Ciencias de la Computación, Canterbury, Inglaterra, Reino Unido, 1 al 3 de julio de 2013; págs. 117–122.
45. Ahmed, A.; Elaraby, I. Minería de datos: una predicción del rendimiento de los estudiantes utilizando el método de clasificación. Mundo J. Cómputo. aplicación Tecnología **2014**, 2, 43–47. [\[Referencia cruzada\]](#)
46. Al-Barrak, M.; Al-Razgan, M. Predecir el GPA final de los estudiantes usando árboles de decisión: un estudio de caso. En t. J.Inf. Educ. Tecnología **2016**, 6, 528. [\[Referencia cruzada\]](#)

47. Marbutí, F.; Diefes-Dux, H.; Madhavan, K. Modelos para la predicción temprana de estudiantes en riesgo en un curso que utiliza estándares clasificación computar Educ. **2016**, *103*, 1–15. [\[Referencia cruzada\]](#)
48. Wang, W.; Yu, H.; Miao, C. Modelo profundo para la predicción de la deserción en los MOOC. En Actas de la 2da Conferencia Internacional on Crowd Science and Engineering, Beijing, China, del 6 al 9 de julio de 2017; págs. 26–32.
49. Aulck, L.; Velagapudi, N.; Blumenstock, J.; West, J. Predicción de la deserción estudiantil en la educación superior. arXiv **2016**, arXiv:1606.06364.
50. Márquez-Vera, C.; Cano, A.; Romero, C.; Noamán, A.; Fardoun, H.; Ventura, S. Predicción de la deserción temprana mediante minería de datos: un estudio de caso con estudiantes de secundaria. Sistema experto **2016**, *33*, 107–124. [\[Referencia cruzada\]](#)
51. Burgos, C.; Campanario, M.; de la Peña, D.; Lara, J.; Lizcano, D.; Martı́nez, M. Minería de datos para modelar el desempeño de los estudiantes: Un plan de acción de tutoría para prevenir el abandono académico. computar eléctrico Ing. **2017**, *66*, 541–556. [\[Referencia cruzada\]](#)
52. Ahadi, A.; Lister, R.; Haapala, H.; Vihavainen, A. Exploración de métodos de aprendizaje automático para identificar automáticamente a los estudiantes. necesidad de asistencia. En Actas de la undécima anual. Conferencia internacional sobre investigación en educación informática internacional, Omaha, NE, EE. UU., 9 al 13 de julio de 2015; págs. 121–130.
53. Iqbal, Z.; Qadir, J.; Mian, A.; Kamiran, F. Predicción de calificaciones de estudiantes basada en aprendizaje automático: un estudio de caso. arxiv **2017**, arXiv: 1708.08744.
54. Zhang, W.; Huang, X.; Wang, S.; Shu, J.; Liu, H.; Chen, H. Predicción del desempeño de los estudiantes a través del análisis del comportamiento de aprendizaje en línea. En Actas del Simposio Internacional sobre Tecnología Educativa (ISET), Hong Kong, China, 27–29 de junio de 2017.
55. Almarabeh, H. Análisis del desempeño de los estudiantes mediante el uso de diferentes clasificadores de minería de datos. En t. Mod. J. Educ. computar ciencia **2017**, *9*, 9. [\[Referencia cruzada\]](#)
56. Xu, J.; Luna, K.; Schaar, MD Un enfoque de aprendizaje automático para rastrear y predecir el desempeño de los estudiantes en programas de grado. IEEE J. Sel. Cima. Proceso de señal. **2017**, *11*, 742–753. [\[Referencia cruzada\]](#)
57. Al-Shehri, H.; Al-Qarni, A.; Al-Saati, L.; Batoaq, A.; Badukhen, H.; Alrashed, S.; Alhiyafi, J.; Olatunji, S. Predicción del rendimiento de los estudiantes utilizando una máquina de vectores de soporte y el vecino más cercano. En las Actas de la 30.ª Conferencia Canadiense de Ingeniería Eléctrica e Informática (CCECE) del IEEE de 2017, Windsor, ON, Canadá, del 30 de abril al 3 de mayo de 2017.
58. Alowibdi, J. Predecir el desempeño de los estudiantes utilizando análisis de aprendizaje avanzado. En Actas de la 26.ª Conferencia Internacional sobre World Wide Web Companion, Comité Directivo de Conferencias Internacionales de World Wide Web, Perth, Australia, 3–7 de abril de 2017; págs. 415–421.
59. Nagrecha, S.; Dillon, J.; Chawla, N. Mooc predicción de deserción: Lecciones aprendidas al hacer que las canalizaciones sean interpretables. En Actas de la 26.ª Conferencia Internacional, World Wide Web Companion, International World Wide Web Conferences Steering Committee, Perth, Australia, 3–7 de abril de 2017; págs. 351–359.
60. Liang, J.; Li, C.; Zheng, L. Aplicación de aprendizaje automático en MOOC: predicción de abandono. En Actas de la 11ª Internacional Conferencia sobre Ciencias de la Computación y Educación (ICCSE), Nagoya, Japón, 23–25 de agosto de 2016; págs. 52–57.
61. Al-Obeidat, F.; Tubaishat, A.; Dillon, A.; Shah, B. Analizando el rendimiento de los estudiantes mediante la clasificación de criterios múltiples. grupo. computar **2018**, *21*, 623–632. [\[Referencia cruzada\]](#)
62. Kaviyarasi, R.; Balasubramanian, T. Explorando los factores de alto potencial que afectan a los estudiantes. Academia Llevar a cabo. En t. J. Educ. Administrar Ing. **2018**, *8*, 15.
63. Zaffar, M.; Iskander, S.; Hashmani, M. Un estudio de algoritmos de selección de características para predecir el rendimiento académico de los estudiantes. En t. j adv. computar ciencia aplicación **2018**, *9*, 541–549. [\[Referencia cruzada\]](#)
64. Chui, K.; Fung, D.; Lytras, M.; Lam, T. Predicción de estudiantes universitarios en riesgo en un entorno de aprendizaje virtual a través de una máquina algoritmo de aprendizaje. computar Tararear. Comportamiento **2020**, *107*, 105584. [\[Referencia cruzada\]](#)
65. Masci, C.; Johnes, G.; Agasisti, T. Rendimiento de los estudiantes y las escuelas en todos los países: un enfoque de aprendizaje automático. EUR. J. Oper. Res. **2018**, *269*, 1072–1085. [\[Referencia cruzada\]](#)
66. Xing, W.; Du, D. Predicción de abandono en MOOC: uso del aprendizaje profundo para una intervención personalizada. J. Educ. computar Res. **2019**, *57*, 547–570. [\[Referencia cruzada\]](#)
67. Kan, S.; Islam, M.; Aleem, M.; Iqbal, M. Clasificación de texto basada en especificidad temporal para la recuperación de información. Turco. J. Electr. Ing. computar ciencia **2018**, *26*, 2915–2926. [\[Referencia cruzada\]](#)
68. Livieris, I.; Drakopoulou, K.; Tampakas, V.; Mikropoulos, T.; Pintelas, P. Predicción en estudiantes de secundaria. Llevar a cabo. útil Aprendizaje semisupervisado. Enfoque J. Educ. computar Res. **2019**, *57*, 448–470.
69. Nieto, Y.; García-Díaz, V.; Montenegro, C.; Crespo, RG Apoyando la toma de decisiones académicas en instituciones de educación superior utilizando algoritmos basados en aprendizaje automático. Cómputo suave. **2019**, *23*, 4145–4153. [\[Referencia cruzada\]](#)
70. Desmarais, M.; Naceur, R.; Beheshti, B. Modelos lineales de las habilidades de los estudiantes para datos estáticos. En Talleres UMAP; Citaseer: Universidad Park, Pensilvania, EE. UU., 2012.
71. Oyedele, AO; Salame, AM; Folorunso, O.; Abolade, OR Análisis y predicción del rendimiento académico de los estudiantes mediante el aprendizaje automático. JITCE (J. Inf. Technol. Comput. Ing.) **2020**, *4*, 10–15. [\[Referencia cruzada\]](#)
72. Alhusban, S.; Shatnawi, M.; Yasin, MB; Hmeidi, I. Medición y mejora del rendimiento de los estudiantes de pregrado mediante el uso de herramientas de aprendizaje automático. En Actas de la 11.ª Conferencia Internacional sobre Sistemas de Información y Comunicación (ICICS) de 2020, Copenhague, Dinamarca, 24–26 de agosto de 2020; págs. 261–265.
73. Gafarov, F.; Rudneva, YB; Sharifov, UY; Trofimova, A.; Bormotov, P. Análisis del rendimiento académico de los estudiantes mediante el uso de herramientas de aprendizaje automático. En Actas de la Conferencia científica internacional "Digitalización de la educación: historia, tendencias y perspectivas" (DETP 2020), Ekaterimburgo, Rusia, 23 y 24 de abril de 2020; Atlantis Press: París, Francia, 2020; págs. 574–579.

74. Walia, N.; Kumar, M.; Nayar, N.; Mehta, G. Predicción del Rendimiento Académico de los Estudiantes en el Académico Utilizando Técnicas de Minería de Datos. En Actas de la Conferencia Internacional sobre Informática y Comunicaciones Innovadoras (IICIC); Springer: Berlín/Heidelberg, Alemania, 2020.
75. Wakelam, E.; Jefferies, A.; Davey, N.; Sun, Y. El potencial para la predicción del desempeño de los estudiantes en pequeñas cohortes con un mínimo atributos disponibles. *Hermano J. Educ. Tecnología* **2020**, *51*, 347–370. [\[Referencia cruzada\]](#)
76. Hussain, K.; Talpur, N.; Aftab, MU; NoLastName, Z. Un nuevo enfoque metaheurístico para la optimización del sistema neurodifuso para la predicción del rendimiento de los estudiantes. *J. Computación suave. Datos mín.* **2020**, *1*, 1–9. [\[Referencia cruzada\]](#)
77. Ghorbani, R.; Ghousi, R. Comparación de diferentes métodos de remuestreo para predecir el rendimiento de los estudiantes mediante técnicas de aprendizaje automático. *Acceso IEEE* **2020**, *8*, 67899–67911. [\[Referencia cruzada\]](#)
78. Aggarwal, D.; Mittal, S.; Bali, V. Importancia de los parámetros no académicos para predecir el desempeño de los estudiantes usando Ensemble Técnicas de aprendizaje. En t. Sistema J. Din. aplicación (IJSDA) **2021**, *10*, 38–49.
79. Zeineddine, H.; Braendle, U.; Farah, A. Mejora de la predicción del éxito de los estudiantes: enfoque de aprendizaje automático automatizado. *computar eléctrico Ing.* **2021**, *89*, 106903. [\[Referencia cruzada\]](#)
80. OuahiMariame, SK Feature Engineering, Minería para predecir el éxito de los estudiantes en función de la interacción con el entorno de aprendizaje virtual mediante una red neuronal artificial. *Ana. ROM. Soc. Biol celular.* **2021**, *25*, 12734–12746.
81. Hussain, M.; Zhu, W.; Zhang, W.; Abidi, S.; Ali, S. Uso del aprendizaje automático para predecir las dificultades de los estudiantes en la sesión de aprendizaje datos. *Artefacto Intel. Rev.* **2019**, *52*, 381–407. [\[Referencia cruzada\]](#)
82. Thai-Nghe, N.; Drumond, L.; Krohn-Grimberghe, A.; Schmidt-Thieme, L. Sistema de recomendación para predecir el desempeño de los estudiantes. *Cómputo de procedimientos. ciencia* **2010**, *1*, 2811–2819. [\[Referencia cruzada\]](#)
83. Buenaño-Fernández, D.; Gil, D.; Luján-Mora, S. Aplicación del aprendizaje automático en la predicción del rendimiento para computadora Estudiantes de ingeniería: un estudio de caso. *Sustentabilidad* **2019**, *11*, 2833. [\[CrossRef\]](#)
84. Reddy, P.; Reddy, R. Student Performance Analyzer utilizando algoritmos de aprendizaje supervisado. 2021. Disponible en línea: <https://easychair.org/publications/preprint/QhZK> (consultado el 4 de agosto de 2021).
85. Acharya, A.; Sinha, D. Predicción temprana del rendimiento de los estudiantes utilizando técnicas de aprendizaje automático. En t. J. Cómputo. aplicación **2014**, *107*, 37–43. [\[Referencia cruzada\]](#)
86. Muzamal, JH; Tariq, Z.; Khan, UG Recuento de multitudes con respecto a la edad y el género mediante el uso de una detección más rápida basada en R-CNN. En Actas de la Conferencia Internacional de Matemáticas Aplicadas y de Ingeniería (ICAEM) de 2019, Taxila, Pakistán, 27–29 de agosto de 2019, Volumen 10, págs. 157–161.
87. Jenhani, I.; Brahim, G.; Elhassan, A. Mejora del rendimiento de los resultados del aprendizaje del curso: un enfoque basado en la clasificación de acciones correctivas. En Actas de la 15.ª Conferencia internacional IEEE sobre aplicaciones y aprendizaje automático (ICMLA) de 2016, Anaheim, CA, EE. UU., 18 al 20 de diciembre de 2016; págs. 408–413.