

Recibido el 7 de diciembre de 2020, aceptado el 27 de diciembre de 2020, fecha de publicación 5 de enero de 2021, fecha de la versión actual 13 de enero de 2021.

Identificador de objeto digital 10.1109/ACCESS.2021.3049446

Predicción de estudiantes en riesgo en diferentes Porcentajes de la duración del curso para Early Intervención con máquina Modelos de aprendizaje

MUHAMMAD ADNAN¹, ASAD HABIB¹, JAWAD ASHRAF¹, SHAFaq MUSSADIQ¹,
ARSALAN ALI RAZA², MUHAMMAD ABID¹, MARYAM BASHIR¹ Y SANA ULLAH KHAN¹

¹Instituto de Computación, Universidad Kohat de Ciencia y Tecnología, Kohat 26000, Pakistán

²Departamento de Ciencias de la Computación, COMSATS University Islamabad, Vehari Campus, Islamabad 45550, Pakistán

Autor para correspondencia: Muhammad Adnan (adnan@kust.edu.pk)

RESUMEN Las plataformas de aprendizaje en línea como Massive Open Online Course (MOOC), Virtual Learning Environments (VLE) y Learning Management Systems (LMS) facilitan que miles o incluso millones de estudiantes aprendan de acuerdo con sus intereses sin restricciones espaciales y temporales. Además de muchas ventajas, las plataformas de aprendizaje en línea enfrentan varios desafíos, como la falta de interés de los estudiantes, la alta tasa de deserción, el bajo compromiso, el comportamiento autorregulado de los estudiantes y obligar a los estudiantes a asumir la responsabilidad de establecer sus propios objetivos. En este estudio, proponemos un modelo predictivo que analiza los problemas que enfrentan los estudiantes en riesgo y, posteriormente, facilita a los instructores una intervención oportuna para persuadir a los estudiantes a aumentar su compromiso de estudio y mejorar su rendimiento en el estudio. El modelo predictivo se entrena y prueba utilizando varios algoritmos de aprendizaje automático (ML) y aprendizaje profundo (DL) para caracterizar el comportamiento de aprendizaje de los estudiantes según sus variables de estudio. El rendimiento de varios algoritmos de ML se compara mediante el uso de exactitud, precisión, compatibilidad y puntuación f. El algoritmo de ML que ofrece el mejor resultado en términos de exactitud, precisión, recuperación, compatibilidad y métrica de puntaje f se selecciona en última instancia para crear el modelo predictivo en diferentes porcentajes de la duración del curso. El modelo predictivo puede ayudar a los instructores a identificar temprano en el curso a los estudiantes en riesgo para una intervención oportuna y así evitar la deserción de los estudiantes. Nuestros resultados mostraron que los puntajes de las evaluaciones de los estudiantes, la intensidad del compromiso, es decir, los datos del flujo de clics, y las variables dependientes del tiempo son factores importantes en el aprendizaje en línea. Los resultados experimentales revelaron que el modelo predictivo entrenado con Random Forest (RF) da los mejores resultados con precisión promedio = 0,60 %, 0,79 %, 0,84 %, 0,88 %, 0,90 %, 0,92 %, recuerdo promedio = 0,59 %, 0,79 %, 0,84 %, 0,88 %, 0,90 %, 0,91 %, puntaje F promedio = 0,59 %, 0,79 %, 0,84 %, 0,88 %, 0,90 %, 0,91 % y precisión promedio = 0,59 %, 0,79 %, 0,84 %, 0,88 %, 0,90 %, 0,91 % al 0 %, 20 %, 40 %, 60 %, 80 % y 100 % de la duración del curso.

TÉRMINOS DEL ÍNDICE Modelo predictivo, predicción más temprana posible, estudiantes en riesgo, aprendizaje automático, red neuronal de avance, bosque aleatorio, intervención temprana.

I. INTRODUCCIÓN

Las rápidas innovaciones en el diseño y desarrollo de plataformas de aprendizaje en línea como Massive Open Online Course (MOOC), Virtual Learning Environments (VLE) y Learning Management System (LMS) no solo han superado las limitaciones de espacio y tiempo, sino que también han hecho acceso a la educación fácil y asequible. evaluando y

El editor asociado que coordinó la revisión de este manuscrito y lo aprobó para su publicación fue Utku Kose.

El análisis de los datos de los estudiantes generados a partir de las plataformas de aprendizaje en línea puede ayudar a los instructores a comprender y monitorear el progreso del aprendizaje de los estudiantes. Cuanto antes se detecte el desempeño de los estudiantes en los VLE, mejor será para el instructor persuadir y advertir a los estudiantes para mantenerlos en el camino correcto. Estudios anteriores informan que las variables de aprendizaje de los estudiantes almacenadas en los registros de la base de datos pueden ayudar a los instructores a predecir el desempeño de los estudiantes en el futuro. Pero predecir el desempeño de los estudiantes al principio del curso sería más útil en comparación con predecir el desempeño de los estudiantes.

rendimiento una vez que hayan finalizado el curso y hayan realizado el examen final. Sin embargo, desarrollar un modelo predictivo que pueda identificar el comportamiento de aprendizaje exacto de los estudiantes al principio del curso mediante el análisis de sus datos de comportamiento es una tarea desafiante. En un entorno de aprendizaje en línea, donde se genera una gran cantidad de datos todos los días, las técnicas de aprendizaje automático (ML) podrían ayudar a analizar las variables que definen a los estudiantes y generar resultados que describan mejor su comportamiento de aprendizaje, por lo que ML puede ayudar a revelar información que es beneficiosa tanto para los instructores como para los estudiantes [4].

Identificar a los estudiantes en riesgo de abandono y fracaso lo antes posible durante un curso podría ayudar a los instructores a ejecutar intervenciones/persuaciones oportunas y necesarias para ayudar a los estudiantes a mantenerse estables durante sus estudios [6].

En general, en entornos de aula tradicionales y entornos de aprendizaje en línea, se sigue un enfoque general en el que se definen las mismas pautas para todos los estudiantes, ignorando el descontento individual. Para brindar retroalimentación y apoyo personalizados desde el comienzo del semestre, los diseñadores de VLE requieren el desarrollo de un modelo predictivo que tome decisiones rápidas sobre cómo y cuándo intervenir a los estudiantes para obtener apoyo. Las herramientas, técnicas y productos de minería de datos educativos (EDM) han progresado significativamente, ayudando a los educadores a hacer que la educación sea fácil y efectiva [7]. Sin embargo, estas técnicas carecen de identificar a los estudiantes en riesgo antes en la línea de tiempo del curso, lo que obliga a los instructores a realizar un trabajo manual significativo para la identificación de problemas de los estudiantes para mantenerlos encaminados.

El surgimiento de las técnicas de inteligencia artificial (IA), aprendizaje automático (ML) y aprendizaje profundo (DL) ha facilitado y permitido a los investigadores desarrollar una serie de modelos predictivos para revelar patrones de estudio ocultos que explican las fortalezas y debilidades de los estudiantes en línea [8], [9]. Para reducir las tasas de deserción, los investigadores pueden usar técnicas de ML para estudiar diferentes variables que afectan significativamente la deserción de los estudiantes. Los poderes de los modelos predictivos mediante técnicas de ML pueden presentar una imagen precisa de los estudiantes que probablemente abandonen sus estudios, lo que facilita a los instructores idear medidas preventivas antes de que se produzca un comportamiento de abandono. El objetivo principal de nuestro estudio de investigación es la identificación lo antes posible de los estudiantes que corren el riesgo de abandonar los estudios aprovechando las técnicas de ML para comprender las variables asociadas con el comportamiento de aprendizaje de los estudiantes y cómo interactúan con el VLE.

Al analizar el conjunto de datos de Open University Learning Analytics (OULA), se observó que los estudiantes son inconsistentes en sus actividades de aprendizaje en línea a lo largo de las semanas del curso, lo que resulta en una gran cantidad de abandonos al final del curso. Con base en nuestras observaciones, desarrollamos un modelo predictivo que puede identificar a los estudiantes en riesgo de abandono escolar al comienzo del curso. El modelo predictivo es capaz de facilitar a los docentes la intervención de los estudiantes a través de mensajes persuasivos que animen a los estudiantes a mantenerse en el camino correcto evitando así la deserción. La contribución de este estudio incluye:

- Desarrollar y evaluar modelos predictivos usando varios algoritmos ML/DL para predecir el desempeño de los estudiantes en los estudios.
- Identificación lo antes posible de los estudiantes en VLE que están en riesgo de abandono durante el curso.
- Integrar retroalimentaciones personalizadas con un modelo predictivo para ayudar a los instructores a intervenir a los estudiantes en un momento óptimo.
- Discutir varias técnicas de persuasión que pueden ayudar a los estudiantes a mejorar su desempeño en el estudio.

El resto del documento está organizado de la siguiente manera: la Sección II presenta los antecedentes y el trabajo relacionado. La Sección III trata sobre el conjunto de datos Open University Learning Analytics (OULA), seleccionado para predecir estudiantes en riesgo en un porcentaje de edad diferente de la duración del curso. La Sección IV presenta detalles sobre la configuración experimental para entrenar varios modelos predictivos. La Sección V discute los resultados experimentales. Varias técnicas relacionadas con la intervención de los estudiantes a través de la persuasión se discuten en la sección VI. La conclusión, las limitaciones y el trabajo futuro se presentan en la sección VII.

II. ANTECEDENTES Y TRABAJO RELACIONADO

A. MINERÍA DE DATOS EDUCATIVOS (EDM)

EDM es una disciplina emergente destinada a utilizar métodos estadísticos y de ML para analizar un gran depósito de datos educativos para una mejor comprensión de los patrones de comportamiento de los estudiantes y los entornos de aprendizaje. Se han llevado a cabo varios estudios de EDM que aprovechan las técnicas de ML para descubrir variables que influyen significativamente en el rendimiento, la deserción, el compromiso y la interacción de los estudiantes en las plataformas de aprendizaje en línea. La mayoría de estos estudios tienen como objetivo analizar las variables que se generan a partir de las actividades en línea de los estudiantes [10]–[12], mientras que algunos estudios también usan variables demográficas para observar su efecto en el comportamiento de estudio de los estudiantes [13], [14]. Anteriormente, las principales variables a considerar para el análisis eran el tiempo de estudio, la duración del estudio, el tipo de contenido de aprendizaje y las variables derivadas de las actividades de interacción social. A medida que la plataforma de aprendizaje en línea se volvió más estable e interactiva, se agregaron en el proceso de análisis variables como puntajes de evaluación, puntajes de tareas, flujo de clics, interacción en el foro en línea y ubicación [15]. La identificación de variables significativas se convierte en un desafío para los investigadores debido a la diversidad de LMS, VLE, MOOC, cursos ofrecidos y tipos de actividades del curso.

En la literatura, la mayoría de los estudios tienen como objetivo recopilar variables y predecir el desempeño de los estudiantes al final del curso. Los resultados obtenidos de esos estudios sirvieron para identificar las variables significativas que más influyen en el desempeño de los estudiantes; sin embargo, no se brindaron soluciones para evitar la deserción y el fracaso de los estudiantes.

Por otro lado, las plataformas de aprendizaje en línea generan enormes datos asociados con la interacción de los estudiantes, flujos de clics y cursos, etc. desde el comienzo del curso. Se puede desarrollar un modelo predictivo integral mediante el análisis de datos variables desde el comienzo del curso que sería efectivo para prevenir fallas/abandonos y facilitar

instructores para realizar intervenciones efectivas en el momento óptimo.

Un estudio realizado por [16] implementó cuatro algoritmos de ML para la identificación temprana de estudiantes con alta probabilidad de fracaso. Los resultados revelaron que Support Vector Machine (SVM) fue el algoritmo más efectivo en la identificación temprana de estudiantes con un 83% de precisión.

El estudio también indicó que el proceso de preprocesamiento de datos es muy esencial para aumentar el rendimiento de los algoritmos de ML. Los resultados de estudios anteriores mostraron que el desarrollo de modelos predictivos es posible en una etapa más temprana del curso, sin embargo, muchos desafíos limitan su aplicación a una plataforma de aprendizaje específica. Uno de los principales desafíos para los investigadores es hacer que los modelos predictivos sean flexibles y capaces de ajustarse/adaptarse en diferentes entornos de aprendizaje. Las principales razones que limitan que los modelos predictivos se vuelvan flexibles, generales y transferibles se deben a las diferentes estructuras de cursos, diseños de instrucción y plataformas en línea [17].

En los últimos años, los estudios de investigación utilizaron modelos estadísticos y predictivos para encontrar información en un gran depósito de datos, tanto en entornos educativos formales como informales [13], [18], [19]. Por ejemplo, varios estudios de investigación [20]–[23] investigaron el papel de las variables demográficas para contribuir al desempeño exitoso del aprendizaje o la retención de los estudiantes.

Un estudio realizado por [24] investigó y comparó más de 120 conjuntos de datos diferentes relacionados con la demografía y el comportamiento de interacción de estudiantes universitarios de economía y negocios en entornos en línea. El estudio observó la influencia de una variedad de variables, como antecedentes educativos, datos de flujo de clics, puntajes de evaluación, puntajes de pruebas de ingreso y datos de personalidad de aprendizaje en el desempeño de los estudiantes. Si bien la mayoría de los estudios tienen como objetivo descubrir el impacto de las variables clave en el desempeño de los estudiantes, hay otros estudios [25]–[27] que fomentan la intervención temprana, el apoyo informado y la retroalimentación oportuna para guiar a los estudiantes en riesgo. Numerosos estudios llevados a cabo en la Open University, Reino Unido [28], [29] intentaron identificar a los estudiantes en riesgo utilizando varias variables predictoras. Los estudios mapearon el comportamiento de estudio de los estudiantes para predecir 1) bajo rendimiento (cuando el rendimiento cae por debajo de un valor umbral) 2) si los estudiantes tienen éxito o no al final del curso. Los estudios también indicaron que las variables demográficas utilizadas junto con las variables de comportamiento de los estudiantes proporcionaron modelos predictivos mejorados en términos de rendimiento y precisión.

Lee y Choi [30] realizaron un estudio en el que intentaron identificar variables relevantes que obligan a los estudiantes a decidir abandonar el curso. La variable responsable de la deserción de los estudiantes se clasificó en tres categorías. 1) variables demográficas de los estudiantes, como género, antecedentes, experiencia relevante, habilidades, atributos psicológicos, educación anterior, etc. 2) variable relacionada con la estructura del curso y requisitos, como el número de evaluaciones, apoyo institucional, interacción, nivel de dificultad, tiempo, duración, etc. 3) entornos/factores contextuales como la tecnología utilizada, la ubicación, el ruido externo, el entorno laboral, el entorno doméstico, etc.

[31] utilizó un enfoque de agrupamiento de series de tiempo para la identificación más temprana posible de estudiantes en riesgo que toman cursos en línea. En comparación con los enfoques de agregación tradicionales, el enfoque de agrupamiento de series temporales generó modelos predictivos con mayor precisión. Sofer y Cohen utilizaron varias técnicas de análisis de aprendizaje sobre variables de compromiso generadas a partir de cursos en línea para encontrar su impacto en los logros de rendimiento de los estudiantes [32]. Los resultados indicaron que los estudiantes que logran buenas posiciones académicas tienen un mayor porcentaje de compromiso en comparación con los estudiantes que logran posiciones académicas inferiores. Como ejemplo, los estudiantes que completaron el curso fueron el doble de interactivos que los estudiantes que no lo completaron.

Un estudio realizado por [33] argumentó que las variables del flujo de clics que representan la participación en línea de los estudiantes son más precisas, objetivas y completas que los datos autoinformados para medir el comportamiento de aprendizaje de los estudiantes. Los datos del flujo de clics son más confiables, ya que se recopilan en un entorno de aprendizaje auténtico mientras ocurre el comportamiento de aprendizaje en comparación con los datos autoinformados que a menudo se generan a partir de los recuerdos descontextualizados y poco confiables de los estudiantes. Además, los datos del flujo de clics son discretos y no requieren la atención total de los estudiantes, ya que se pueden recopilar sin interrupciones sin interrumpir el proceso de aprendizaje de los estudiantes [34]. Por último, los datos de flujo de clics recopilados de manera intuitiva pueden proporcionar medidas oportunas y a gran escala del comportamiento de aprendizaje de los estudiantes, lo que podría ayudar a los instructores a conocer los compromisos en línea de los estudiantes todos los días.

Recientemente, se ha llevado a cabo una gran cantidad de estudios de investigación para analizar los datos del flujo de clics generados a partir de plataformas de aprendizaje en línea (MOOC, LMS, VLE) para medir la participación en línea de los estudiantes. Si bien la mayoría de los estudios intentan explorar la relación entre los datos del flujo de clics y la participación en línea de los estudiantes, estudios limitados han dado un paso más para ayudar a los instructores a saber cuándo y cómo intervenir a los estudiantes en el momento óptimo, p. ej., [35]–[38]

Shivangi Gupta y A. Sai Sabitha en su estudio de investigación intentaron descifrar aquellas variables que son responsables de la retención de estudiantes en e-learning [39]. Se usó el algoritmo del árbol de decisión (DT) para determinar las características importantes para ayudar a los estudiantes y diseñadores de MOOC a mejorar el contenido del curso, el diseño del curso y la entrega. Se aplicaron varias técnicas de minería de datos a tres conjuntos de datos de MOOC para analizar el comportamiento de los estudiantes en línea durante el curso. Finalmente, los autores afirmaron que los modelos que usaron podrían ser útiles para predecir características significativas para minimizar la tasa de deserción.

Akçapınar Gökhan desarrolló un sistema de alerta temprana que utilizó los datos de lectura de libros electrónicos de los estudiantes para predecir el riesgo de fracaso académico de los estudiantes [40]. Para desarrollar el mejor modelo predictivo, se usaron 13 algoritmos de ML para entrenar el modelo usando datos de diferentes semanas del semestre. Se seleccionó el mejor modelo predictivo de acuerdo con la métrica de precisión/Kappa y recomendando el tiempo óptimo para que los instructores intervinieran. El estudio reveló que todos los modelos predictivos mejoraron sus resultados de rendimiento cuando se utilizaron más y más datos semanales durante el proceso de entrenamiento. la alerta temprana

Los modelos predictivos del sistema lograron clasificar a los estudiantes de bajo y alto rendimiento con una precisión del 79 % a partir de la 3.ª semana. Cuando se proporcionaron datos completos de 15 semanas a varios algoritmos, Random Forest (RF) superó a otros algoritmos, mientras que con los datos transformados, J48 superó a todos los demás algoritmos. Además, al utilizar datos categóricos, el Naïve Bayes (NB) mostró un mejor desempeño.

Predecir el desempeño de los estudiantes al principio del curso es un problema desafiante en los entornos de aprendizaje en línea debido a la diversidad en la estructura del curso y el diseño de los MOOC. Si bien la popularidad de LMS/MOOC está aumentando rápidamente, existe la necesidad de un sistema de intervención automatizado que pueda brindar retroalimentación oportuna a los estudiantes. Para integrar el sistema de intervención automatizado con LMS/MOOC, los investigadores han implementado varios algoritmos ML que pueden ayudar a los instructores a brindar asistencia informada a los estudiantes durante el proceso de aprendizaje. Los algoritmos de ML como K-Nearest Neighbors (KNN), Support Vector Machine (SVM), Decision Trees (DT) y Random Forest (RF), etc. se entrenan comúnmente utilizando datos de registro de estudiantes diarios, semanales o mensuales para encontrar estudiantes. 'Patrones de aprendizaje. Los algoritmos de aprendizaje profundo (DL) ahora también se utilizan para crear modelos predictivos, ya que pueden procesar datos sin procesar directamente. Kyrösi, Gábor y Richard Farkas utilizaron el algoritmo de Red Neural Recurrente (RNN) entrenado en registros de estudiantes de registro sin procesar para predecir el rendimiento de aprendizaje de los estudiantes al final del curso [41]. Los resultados mostraron el predominio de RNN al proporcionar un rendimiento superior en comparación con los métodos estándar de referencia.

Alberto C. y John DL utilizaron un enfoque de programación genética multivista para desarrollar reglas de clasificación para analizar el comportamiento de aprendizaje de los estudiantes, predecir su rendimiento académico y activar alertas en el momento óptimo para animar a los estudiantes en riesgo a mejorar su rendimiento en el estudio [42].

Se empleó la técnica de programación genética, ya que funciona muy bien con el aprendizaje de múltiples vistas. El modelo de predicción aprendido y desarrollado es directamente explicable sin más ajustes. Además, mientras que el enfoque de programación genética da como resultado la evolución natural de las reglas de clasificación con el tiempo a medida que hay más y más datos disponibles, es decir, las reglas de clasificación evolucionaron con la disponibilidad de nuevos datos.

El sistema de alerta temprana construido con reglas comprensibles de clasificación de Programación Genética se dirige específicamente a estudiantes de bajo rendimiento y subrepresentados. Se proporcionan comentarios comprensibles a los estudiantes, instructores y personal administrativo utilizando tres interfaces para brindar apoyo oportuno a los estudiantes para mantenerlos en el camino correcto. El principal inconveniente de este estudio fue que el autor no mencionó explícitamente las diversas etapas semestrales en las que se calcularon las métricas de rendimiento, como precisión, sensibilidad, especificidad y Kappa, etc., utilizando un algoritmo de programación genética multivista junto con otros algoritmos de aprendizaje automático. .

Un estudio de investigación llevado a cabo por [43] usó un algoritmo de ML llamado regresión logística para identificar a los estudiantes que se espera que abandonen un curso de aprendizaje electrónico. El algoritmo utiliza las calificaciones históricas de los estudiantes como entrada para modelar las calificaciones de los estudiantes

rendimiento. En comparación con la red neuronal feed-forward (FFNN), Support Vector Machine (SVM), un sistema para la minería de datos educativos (SEDM) y Probabilistic Ensemble Simplified Fuzzy ARTMAP - técnicas de PESFAM de mapeo de teoría de resonancia adaptativa, la caída propuesta La técnica de detección mostró una puntuación de rendimiento más alta en términos de precisión, recuerdo, especificidad y exactitud. El plan de acción de tutoría basado en regresión logística logró reducir la tasa de deserción en un 14%.

Lara JA *et al.*, propusieron el uso del descubrimiento de conocimiento en bases de datos (KDD) para extraer información que pudiera ayudar a los docentes a conocer la interacción de los estudiantes con los sistemas de e-learning [44]. La técnica propuesta construye modelos de referencia histórica de los estudiantes que se pueden utilizar para clasificar a los estudiantes en clases de abandono o no abandono. El sistema propuesto, denominado Sistema para la Minería de Datos Educativos (SEDM), analiza dos grupos de estudiantes para un solo curso, es decir, estudiantes que abandonaron la escuela y no pudieron presentarse al examen final y estudiantes que no abandonaron la escuela y aprobaron las evaluaciones del curso y pueden participar. el examen final

SEDM pudo generar patrones de estudio para los dos grupos que pueden ser muy útiles para que los instructores mejoren el rendimiento de estudio de los estudiantes. La Tabla 1 presenta un resumen de los estudios de investigación recientes que utilizan técnicas de ML/DL para crear modelos predictivos, realizar clasificaciones de acuerdo con el rendimiento de los estudiantes, predecir la deserción y realizar una intervención temprana. Los estudios discutidos anteriormente están relacionados con evitar la deserción de los estudiantes, el tiempo óptimo, la predicción de los estudiantes en riesgo de abandono y la clasificación de los estudiantes en diferentes grupos de rendimiento; sin embargo, ninguno de estos estudios predice estudiantes en riesgo de abandono en un porcentaje diferente de la duración del curso. El modelo predictivo propuesto podría ayudar a las instituciones educativas y a los instructores a identificar lo antes posible a los estudiantes en riesgo, interviniendo así a los estudiantes a través de técnicas persuasivas adecuadas para alentarlos a estar encaminados y mejorar su desempeño en el estudio.

tercero DESCRIPCIÓN DE

LOS DATOS Utilizamos un conjunto de datos de análisis de aprendizaje de la Universidad Abierta (OULAD, por sus siglas en inglés) disponible gratuitamente, proporcionado por la Universidad Abierta, Reino Unido. Los datos de los estudiantes se distribuyen en 7 tablas, cada una de las cuales contiene información centrada en los estudiantes, como la demografía de los estudiantes, la interacción del entorno de aprendizaje virtual (VLE) de los estudiantes, las evaluaciones, el registro del curso y los cursos ofrecidos. Las tablas se relacionan entre sí a través de identificadores clave. Las actividades diarias de los estudiantes y la interacción VLE se representan como datos de secuencias de clics (número de clics) almacenados en la tabla VLE del estudiante. Los puntajes de las evaluaciones de los estudiantes se almacenan en un triplete de conjuntos de datos llamado presentación del módulo del estudiante. El OULAD fue generado para el año 2013 y 2014 conteniendo 7 cursos, 22 módulos-presentaciones con 32,593 alumnos registrados. Se puede acceder libremente a OULAD en https://analyse.kmi.open.ac.uk/open_dataset y ha sido certificado por el Open Data Inst

TABLA 1. Resumen de los estudios de investigación que utilizan técnicas de ML/DL para la deserción de los estudiantes y la predicción del rendimiento junto con los algoritmos particulares utilizados, su rendimiento, problema abordado y limitaciones.

| Research Studies related to the use of ML/DL techniques in creating predictive models | Algorithm Used and Performance achieved | Problem addressed | Limitations |
|---|--|---|---|
| Chung, J. Y. and Lee, S. [6] | Random Forest (RF) with 95% accuracy | Students binary classification | Predictive model suffers from potential inaccuracy in calculating the weights of the features |
| Gray, C. C. and Perkins, D. [45] | 1-Nearest-neighbor with 97% accuracy | Identifying possible failing students at week 3 of the fall semester | The predictive model was stable, only applicable to Bangor university students |
| Al-Shabandar, R. et al. [46] | Gradient Boosting Model with 95% accuracy | Identification of at-risk students with intensive earlier intervention in online courses | Temporal features were not considered. The predictive model was not validated with additional datasets |
| Lee, S. and Chung, J. Y. et al. [47] | Random Forest, boosted decision trees (BDT) with BDT having the highest accuracy of 99% | Improving the performance of dropout prediction model using the ML-based early warning system | A limited NEIS database was used. All features were not included in creating a predictive model. |
| Behr, A. et al. [48] | Random Forest with AUC (area under the curve) of 0.86 | Binary classification, modeling student's dropout | Students' satisfaction (wishes and needs) features were not considered. |
| Martins, L. C. B. et al. [49] | Gradient Boosting Machine, Deep Learning, Distributed Random Forest. The deep learning model achieved the highest True Positive Rate of 71.1% | Earliest possible prediction of students' attrition | Data about the first semester of the study was not included. |
| Hussain, M. et al. [4] | Artificial neural network (ANN) and Support vector machine (SVM) achieved the highest accuracy of 75% | Predicting students' difficulties in online learning | Students' dropout prediction was not performed. Model accuracy was low. |
| Mduma, N. et al. [50] | Linear regression with a ROC score of .88 | Identification of at-risk students using a machine learning method | The under-sampling approach with a penalized model was not used. |
| Figueroa-Cañas, J. and Sancho-Vinuesa [51] | Decision Trees (DT) with more than 90% accuracy | Identifying dropout-prone students earlier in online statistical course | The methodology used both the training set and validation set of the students enrolled in the same academic year |
| Ortigosa, A. et al. [52] | C5.0 algorithm with more than 85% accuracy | Identification of real-life challenges of the early dropout prevention system | Comprehensive real-world performance of the prediction model and the effectiveness of retention action is needed. |
| Imran, A. S. et al. [53] | A feed-forward deep neural network with accuracy >90% | predicting and explaining student dropout | Prediction is done after the course completion |
| Wu, Nannan et al. [54] | CLMS-Net. Combination of Convolutional Neural Network, Long Short-Term Memory network, and Support Vector Machine. Accuracy = 91.55% | Predicting dropout in MOOCs | The validity of the predictive model on more datasets are needed |
| Rosé, Carolyn P et al. [55] | Traditional machine learning models. Machine learning models do not generalize well | Understanding why ML models alone are not the solution | ML models are not interpretable and actionable |
| Mubarak, A. A. et al. [56] | LSTM, ANN, SVM, Logistic Regression. LSTM with highest accuracy of 93% | Using a deep neural network to predict learning analytics in MOOCs courses videos | The current model only employs' learners interaction patterns with videos. A complete learning activity pattern of learners is missing. |
| Liao, S. N. et al. [57] | Support Vector Machine with AUC = .70 | Identifying students at-risk of performing poorly in courses | The study did not predict at-risk students earlier in the course. |
| Sekeroglu, B et al. [58] | Support Vector Regression (SVR), LSTM, SVM, Gradient Boosting Classifier (GBC), ANN. ANN with the highest accuracy of 87.78%. | Students performance classification and prediction using ML techniques | The study does not address the earliest possible identification of at-risk students. The dataset size was very small |
| Mao, Ye [59] | Bayesian Knowledge Tracing (BKT), Intervention-BKT (IBKT), LSTM. LSTM and LSTM+SK achieved the highest accuracy of 74% | Developing students model for intervention | The model hyperparameters were tuned manually. Moreover, intervention techniques were introduced after the course completion |
| Iqbal, Z et al. [60] | Collaborative Filtering (CF), Matrix Factorization (MF), and Restricted Boltzmann Machines (RBM) techniques. RBM showed better performance having RMSE = 0.3, MSE = 0.09, MAE = 0.23 | Grade prediction of students using ML techniques. | Features related to students' motivation were not included. A limited dataset was used. The early prediction was not rendered. |
| Fwa, H. L. and Marshall, L. [61] | Hidden Markov Model (HMM) Leave-One-Out Cross-Validation (LOOCV) | Modeling programming students using unsupervised ML techniques | Techniques related to student engagement were not used and implemented. The early prediction was not rendered. |
| Xu, Jie et al. [62] | Linear Regression Logistic Regression Random Forest kNN EPP. Ensemble-based Progressive Prediction showed the best result having the lowest mean square error | Tracking and predicting students performance using ML techniques | Courses prediction to the students was not carried out. No intervention technique was discussed. |

Cuando se analiza y modela adecuadamente, OULAD puede proporcionar una plataforma muy adecuada para un pronóstico temprano de estudiantes en riesgo.

A. PREPROCESAMIENTO

DE DATOS Para mejorar la eficiencia de rendimiento de los modelos predictivos, todas las instancias de variables faltantes en forma de NaN , los valores nulos o el ruido se eliminaron o reemplazaron por sus valores medios del OUAD. Como ejemplo, faltaban los valores de fecha en la tabla de evaluaciones que representa la fecha en que se tomaron/enviaron las evaluaciones. Dado que la fecha es una variable importante en la predicción temprana de estudiantes en riesgo, todas las instancias de fecha que tenían valores N/A, nulos o faltantes se reemplazaron por el valor medio de la fecha.

TABLA 2. Triplete Estudiante-Evaluación-Clickstream.

| Students Demographics | Students relative assessment performance score during the different length of the course modules | Late assignment/assessments during the different length of the course modules | Sum of clicks per course module during the different length of the course modules | Average clicks per course module during the different length of the course modules | Final Performance |
|--|--|---|---|--|---|
| code_module, code_presentation, id_student, gender, region, highest_education, imd_band, age_band, num_of_prev_attempts, studied_credits, disability | AS20, AS40, AS60, AS80, AS100 | LS20, LS40, LS60, LS80, LS100 | SC20, SC40, SC60, SC80, SC100 | AC20, AC40, AC60, AC80, AC100 | Final result having values Withdrawn, Fail, Pass, Distinction |

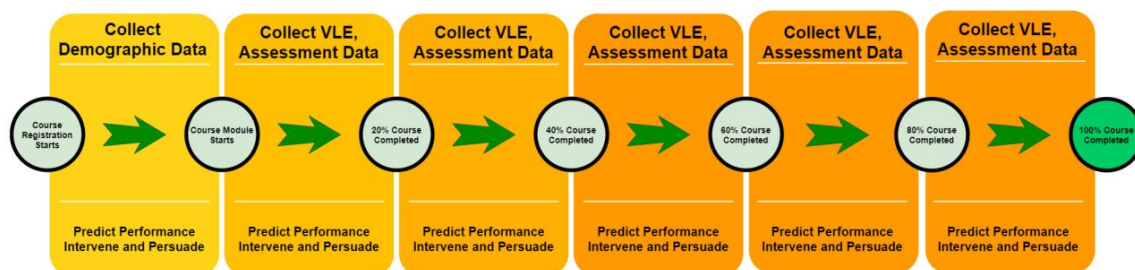


FIGURA 1. Predicción e intervención de estudiantes en riesgo en diferentes porcentajes de la duración del curso.

B. INGENIERÍA DE CARACTERÍSTICAS

Para la predicción más temprana posible del desempeño de los estudiantes, dividimos la duración del curso en 5 partes, es decir, 20 %, 40 %, 60 %, 80 % y 100 % del curso completado. También asumimos que los datos demográficos únicamente se pueden usar para predecir el desempeño futuro de los estudiantes en las evaluaciones y los exámenes finales. La predicción del desempeño futuro de los estudiantes se determinó modelando los modelos predictivos usando solo datos demográficos, usando datos demográficos y 20 % de finalización del curso, datos demográficos y 40 % de finalización del curso, y así sucesivamente.

Para predecir el desempeño de los estudiantes en diferentes momentos del módulo del curso, se crearon varias variables nuevas a partir de las variables existentes. Las variables de puntuación relativa (RS) se crearon para representar el rendimiento relativo del estudiante al 20 %, 40 %, 60 %, 80 % y 100 % de finalización del módulo del curso (RS20, RS40, RS60, RS80, RS100). Las variables que indican el número de entregas tardías se crearon cuando se completó el 20 %, 40 %, 60 %, 80 % y 100 % del módulo del curso (LS20, LS40, LS60, LS80, LS100). También se crearon variables que representan los puntajes de evaluación sin procesar al 20 %, 40 %, 60 %, 80 % y 100 % de finalización del módulo del curso (AS20 %, AS40 %, AS60 %, AS80 %, AS100 %). Se crearon variables que representan la interacción VLE de los estudiantes en forma de secuencias de clics para los diferentes porcentajes de duración del módulo del curso. Se crearon dos tipos de variables, a saber, sum_clicks y mean_clicks, para indicar la suma de los clics y el promedio de clics al 20 %, 40 %, 60 %, 80 % y 100 % de finalización del módulo del curso (SC20 %, SC40 %, SC60 %, SC80 %, SC100 %, AC20 %, AC40 %, AC60 %, AC80 %, AC100 %). La tabla de datos demográficos de los estudiantes se fusionó con la tabla de evaluación de los estudiantes para obtener datos demográficos y de evaluación en una sola tabla. Además, la información de VLE, es decir, los datos de flujo de clics de los estudiantes, también se fusionó con datos demográficos para saber

la interacción de los estudiantes con los contenidos de aprendizaje de VLE durante un módulo de curso. En la tabla 2 se detalla más información acerca de la tabla de flujo de clics de evaluación de estudiantes de tripletes. La tabla de flujo de clics de evaluación de estudiantes de tripletes contiene 31 columnas con 32593 filas.

IV. CONFIGURACIÓN EXPERIMENTAL PARA EL MODELADO

PREDICTIVO Para predecir el rendimiento de los estudiantes en riesgo en un porcentaje diferente de la duración del curso, se utilizaron las variables sobre la demografía de los estudiantes, la interacción VLE y las evaluaciones. Este flujo de trabajo se muestra en la figura 1, donde la duración del curso se divide en 6 periodos, es decir, comienza el curso, 20 %, 40 %, 60 %, 80 % y 100 % del curso estudiado.

Se seleccionaron seis algoritmos ML y un algoritmo DL para entrenar/probar los modelos predictivos durante las diferentes etapas del curso. Para modelar el conjunto de datos analíticos de aprendizaje de la Universidad Abierta (OULAD), estos algoritmos fueron designados para clasificar el desempeño de los estudiantes en cuatro categorías, es decir, Retirados (estudiantes que no pudieron completar el curso), Reprobados (estudiantes que completaron el curso pero no pudieron completar el curso), marcas de aprobación seguras, Aprobado (cursos completados con un puntaje de aprobación), Distinción (cursos completados con calificaciones excelentes). Se utilizaron los scripts de Python 3.7.8 para la construcción de modelos predictivos. Las bibliotecas de Python utilizadas fueron TensorFlow, Keras, sklearn, numpy y seaborn.

A. CRITERIOS DE EVALUACIÓN

Antes de entrenar y probar los modelos predictivos en varias etapas de la duración del módulo del curso, el conjunto de datos en cuestión se dividió en conjuntos de entrenamiento y prueba utilizando la técnica de validación cruzada K-fold donde el valor de k se estableció en 10. Al usar el k-fold técnica de validación cruzada, el conjunto de datos se divide en k conjuntos donde k-1 conjuntos se utilizan para el entrenamiento del modelo y el resto




FIGURA 2. Mapa de calor que muestra la correlación entre las variables demográficas y el resultado final.

1 juego se usa para pruebas de modelos, es decir, para medir la predicción rendimiento del modelo en los datos no vistos no utilizados durante la formación del modelo. Las métricas seleccionadas para medir la El rendimiento de los modelos predictivos incluye lo siguiente:

1) PRECISIÓN

La precisión se calcula dividiendo el número de errores clases predichas por el número total de clases, es decir, precisión = (Verdaderos positivos + Verdaderos negativos)/todas.

2) PRECISIÓN

Determina la fracción de verdaderos positivos entre los verdaderos positivos y los falsos positivos predichos, es decir, precisión = verdadero positivos/(verdaderos positivos + falsos positivos). Si un pequeño porcentaje de estudiantes (1%) se está dando de baja o reprobando el Por supuesto, podríamos construir un modelo predictivo que siempre prediga con precisión si los estudiantes se están retirando, reprobando o pase, o distinción. Este modelo predictivo sería del 99% precisa pero 0% útil y confiable.

3) RECUERDA

La recuperación garantiza que el modelo predictivo no pase por alto a algunos estudiantes de VLE que se están retirando, reprobando, Calificaciones de Aprobado o Distinción. Supongamos que si solo el 1% de los estudiantes están consiguiendo la posición de Distinción y el resto está consiguiendo Calificaciones de Retirado, Reprobado o Aprobado, luego el modelo predictivo

predeciría correctamente las calificaciones de Retirado, Reprobado o Aprobado con 99% de precisión. El modelo predictivo tendrá una precisión del 99% y los estudiantes que tienen una posición de Distinción probablemente clasificarse entre los estudiantes Retirados, Reprobados y Aprobados. Recall asegura que no estamos pasando por alto ese 1% de los estudiantes que tienen una posición de Distinción. Recordar = TP/(TP + FN).

4) PUNTUACIÓN F

Determina la media armónica de recuperación y la precisión de un modelo predictivo. La medida F1 es buena para problemas de clasificación donde las etiquetas de destino están desequilibradas. Medida F = 2 * (Precisión * Recuperación)/(Precisión + Recuperación).

V. RESULTADOS EXPERIMENTALES Y DISCUSIÓN

A. FASE 1: USO ÚNICO DE DATOS DEMOGRÁFICOS PARA CONSTRUCCIÓN DE MODELOS PREDICTIVOS

Antes de entrenar los 7 modelos predictivos utilizando solo datos de gráficos de demostración, se construyó un mapa de calor para conocer la Correlaciones de las variables demográficas con el resultado final. Como se muestra en la figura 2, notamos que no existe una correlación positiva o negativa significativa entre las variables demográficas y el resultado final. Solo estudié_credits y num_of_prev_attempts tiene una correlación positiva débil entre ellos. Todas las variables demográficas se consideraron para el entrenamiento RF, SVM, K-NN, ET, clasificador AdaBoost, Clasificador de aumento de gradiente y modelos ANN.

TABLA 3. Puntuación de rendimiento de los 7 modelos predictivos cuando se entrenaron solo en datos demográficos.

| Precision | RandomForest | SupportVectorMachine | KNearestNeighbor | ExtraTreeClassifier | AdaBoostClassifier | GradientBoosting |
|-------------|--------------|----------------------|------------------|---------------------|--------------------|------------------|
| Distinction | 0.1531 | 0.0383 | 0.1154 | 0.1479 | 0.0136 | 0.0122 |
| Fail | 0.2439 | 0.1786 | 0.2839 | 0.2484 | 0.1042 | 0.1120 |
| Pass | 0.4586 | 0.6135 | 0.5051 | 0.4604 | 0.7078 | 0.7162 |
| Withdrawn | 0.4291 | 0.2595 | 0.3299 | 0.3928 | 0.4884 | 0.4914 |
| Averaged | 0.3820 | 0.7527 | 0.3844 | 0.3709 | 0.5968 | 0.6017 |
| Recall | RandomForest | SupportVectorMachine | KNearestNeighbor | ExtraTreeClassifier | AdaBoostClassifier | GradientBoosting |
| Distinction | 0.1691 | 0.0376 | 0.1512 | 0.1666 | 0.3151 | 0.3482 |
| Fail | 0.2725 | 0.2679 | 0.2641 | 0.2633 | 0.3843 | 0.3815 |
| Pass | 0.4372 | 0.4444 | 0.4193 | 0.4285 | 0.4448 | 0.4498 |
| Withdrawn | 0.4122 | 0.1789 | 0.4286 | 0.3999 | 0.4554 | 0.4649 |
| Averaged | 0.3745 | 0.3541 | 0.3664 | 0.3644 | 0.4442 | 0.4500 |
| F-score | RandomForest | SupportVectorMachine | KNearestNeighbor | ExtraTreeClassifier | AdaBoostClassifier | GradientBoosting |
| Distinction | 0.1605 | 0.0177 | 0.1307 | 0.1565 | 0.0260 | 0.0236 |
| Fail | 0.2574 | 0.1507 | 0.2736 | 0.2556 | 0.1639 | 0.1731 |
| Pass | 0.4475 | 0.4255 | 0.4580 | 0.4438 | 0.5462 | 0.5525 |
| Withdrawn | 0.4202 | 0.1585 | 0.3724 | 0.3961 | 0.4709 | 0.4775 |
| Averaged | 0.3777 | 0.4641 | 0.3716 | 0.3672 | 0.4967 | 0.5020 |
| Accuracy | RandomForest | SupportVectorMachine | KNearestNeighbor | ExtraTreeClassifier | AdaBoostClassifier | GradientBoosting |
| Distinction | 0.1691 | 0.0757 | 0.1510 | 0.1665 | 0.3306 | 0.3557 |
| Fail | 0.2724 | 0.2764 | 0.2641 | 0.2633 | 0.3838 | 0.3809 |
| Pass | 0.4370 | 0.4063 | 0.4194 | 0.4284 | 0.4448 | 0.4497 |
| Withdrawn | 0.4121 | 0.3270 | 0.4283 | 0.4000 | 0.4551 | 0.4646 |
| Averaged | 0.3745 | 0.3541 | 0.3664 | 0.3644 | 0.4442 | 0.4500 |

La Tabla 3 presenta los resultados de 7 modelos predictivos cuando se entrenaron solo en los datos demográficos utilizando técnicas de validación cruzada de K-fold donde el valor de k se estableció en 10. La variable de resultado final se estableció como la variable objetivo que los modelos predictivos intentarán predecir, mientras que todas las demás variables demográficas actuaron como entrada de los modelos predictivos. Los valores de precisión, recuperación, exactitud y puntaje f de los modelos predictivos para varias posiciones de los resultados finales de los estudiantes cuando se entrenan solo en los datos demográficos indican el rendimiento muy bajo de los modelos predictivos. Además, el rendimiento de todos los modelos predictivos para la posición de falla es muy malo. En los sistemas de intervención temprana, donde la identificación de los estudiantes en riesgo es vital, los resultados de desempeño de los modelos predictivos para los estudiantes que fallan se vuelven más cruciales, ya que los estudiantes en riesgo pueden ser intervenidos antes en el curso para mejorar el comportamiento de estudio.

B. FASE II: USO DE DATOS DEMOGRÁFICOS Y CLICKSTREAM PARA CONSTRUIR MODELOS PREDICTIVOS

Para mejorar el rendimiento de los modelos predictivos, se consideraron los datos del flujo de clics (la interacción de los estudiantes con VLE en forma de números de clics durante la línea de tiempo del curso) junto con la demografía para entrenar los modelos predictivos.

En el mapa de calor de la figura 3, notamos que la correlación del resultado final con todas las demás variables es similar y todavía no hay una

correlación positiva/negativa significativa de los gráficos de demostración y las variables del flujo de clics con el resultado final. La correlación entre sum_clicks100 y mean_clicks100 es moderada pero está lejos de ser significativa. A continuación, consideramos todas las variables demográficas y de flujo de clics para entrenar y probar los modelos predictivos.

La Tabla 4 muestra los resultados de rendimiento de los modelos predictivos desarrollados utilizando datos demográficos y flujo de clics.

datos. En el caso de la clase Pass, los clasificadores RF, ET, AdaBoost y Gradient Boost están mostrando resultados satisfactorios mientras que, para la clase Fail y Distinction, las puntuaciones de rendimiento siguen siendo muy bajas. Aunque las puntuaciones de rendimiento de los modelos predictivos son mejores que cuando se entrenan solo con datos demográficos, están mucho más lejos de ser aceptables.

C. FASE III: CONSIDERANDO PUNTUACIONES DEMOGRÁFICAS, CLICKSTREAM Y EVALUACIÓN PARA DESARROLLO DE MODELOS PREDICTIVOS

Los puntajes de evaluación se agregaron a la demografía y al flujo de clics para una posible mejora del rendimiento del modelo predictivo. En el mapa de calor de la figura 4, observamos una correlación moderada entre las puntuaciones de la evaluación y el resultado final. Curiosamente la variable puntaje promedio (AS100) tiene una correlación negativa moderada con el resultado final lo que implica un aumento en el puntaje del resultado final cuando el puntaje promedio de la evaluación por edad disminuye. Como era de esperar, se observó una fuerte correlación positiva (0,87) entre la puntuación media y la variable puntuación relativa. Además, las variables promedio de clics (MC100) y suma de clics (SC100) también tenían una correlación positiva significativa con las variables de puntaje de evaluación. Finalmente, se observó una correlación débil entre la variable presentación tardía (LS100) y el resultado final.

La Tabla 5 presenta las puntuaciones de rendimiento de los modelos predictivos cuando se entrenan en los datos demográficos, de seguimiento de clics y de evaluación. Se observó una mejora sustancial en el rendimiento de los modelos predictivos para las clases Aprobado, Retirado, Destacado y Reprobado cuando se agregaron datos de evaluación para construir los modelos predictivos. Los resultados de rendimiento de los modelos SVM y K-NN aún eran muy bajos con una precisión de .32 y .38.




FIGURA 3. Mapa de calor que muestra la correlación entre la demografía más las variables de flujo de clics y el resultado final.

TABLA 4. Puntuación de rendimiento de los 7 modelos predictivos cuando se entrenaron los datos demográficos más los datos del flujo de clics.

| Precision | RandomForest | SupportVectorMachine | KNearestNeighbor | ExtraTreeClassifier | AdaBoostClassifier | GradientBoosting |
|-------------|--------------|----------------------|------------------|---------------------|--------------------|------------------|
| Distinction | 0.0602 | 0.1222 | 0.1440 | 0.0792 | 0.0760 | 0.0674 |
| Fail | 0.2759 | 0.4993 | 0.3313 | 0.2884 | 0.2479 | 0.2863 |
| Pass | 0.9085 | 0.2440 | 0.6962 | 0.8690 | 0.8846 | 0.9133 |
| Withdrawn | 0.7182 | 0.5654 | 0.6039 | 0.7004 | 0.7337 | 0.7396 |
| Averaged | 0.7611 | 0.7154 | 0.5607 | 0.7229 | 0.7457 | 0.7727 |
| Recall | RandomForest | SupportVectorMachine | KNearestNeighbor | ExtraTreeClassifier | AdaBoostClassifier | GradientBoosting |
| Distinction | 0.4770 | 0.0663 | 0.2045 | 0.3935 | 0.4560 | 0.5071 |
| Fail | 0.4840 | 0.3318 | 0.3524 | 0.4605 | 0.4485 | 0.5192 |
| Pass | 0.6244 | 0.3012 | 0.5820 | 0.6178 | 0.6338 | 0.6320 |
| Withdrawn | 0.7147 | 0.6411 | 0.6780 | 0.6987 | 0.6819 | 0.7189 |
| Averaged | 0.6336 | 0.3871 | 0.5373 | 0.6175 | 0.6247 | 0.6451 |
| F-score | RandomForest | SupportVectorMachine | KNearestNeighbor | ExtraTreeClassifier | AdaBoostClassifier | GradientBoosting |
| Distinction | 0.1068 | 0.0795 | 0.1689 | 0.1317 | 0.1300 | 0.1187 |
| Fail | 0.3514 | 0.2918 | 0.3414 | 0.3546 | 0.3186 | 0.3689 |
| Pass | 0.7401 | 0.2374 | 0.6339 | 0.7221 | 0.7384 | 0.7470 |
| Withdrawn | 0.7164 | 0.5159 | 0.6387 | 0.6995 | 0.7064 | 0.7290 |
| Averaged | 0.6773 | 0.4528 | 0.5455 | 0.6542 | 0.6681 | 0.6886 |
| Accuracy | RandomForest | SupportVectorMachine | KNearestNeighbor | ExtraTreeClassifier | AdaBoostClassifier | GradientBoosting |
| Distinction | 0.4778 | 0.1880 | 0.2054 | 0.3937 | 0.4590 | 0.5215 |
| Fail | 0.4840 | 0.2526 | 0.3526 | 0.4605 | 0.4462 | 0.5191 |
| Pass | 0.6244 | 0.5661 | 0.5818 | 0.6178 | 0.6338 | 0.6321 |
| Withdrawn | 0.7147 | 0.5036 | 0.6779 | 0.6986 | 0.6819 | 0.7188 |
| Averaged | 0.6336 | 0.3872 | 0.5373 | 0.6175 | 0.6247 | 0.6451 |

D. INGENIERÍA DE CARACTERÍSTICAS

Para mejorar aún más los resultados de rendimiento, se realizó una operación de combinación donde las clases de Distinction-Pass fueron combinadas en la clase Aprobado y las clases Retirado-Reprobado fueron

fusionado en la clase Fail ya que estas clases son del mismo tipo y retratar información similar. El objetivo de realizar la La técnica de ingeniería de características era mejorar el rendimiento de los modelos predictivos, especialmente para la clase Fail como




FIGURA 4. Mapa de calor que muestra la correlación entre la demografía, el flujo de clics y las variables de evaluación con resultado final.

TABLA 5. Puntuación de rendimiento de los 7 modelos predictivos cuando se entrenaron variables demográficas, flujo de clics y evaluación.

| Precision | RandomForest | SupportVectorMachine | KNearestNeighbor | ExtraTreeClassifier | AdaBoostClassifier | GradientBoosting |
|-------------|--------------|----------------------|------------------|---------------------|--------------------|------------------|
| Distinction | 0.4589 | 0.0505 | 0.2242 | 0.4818 | 0.4512 | 0.5091 |
| Fail | 0.3691 | 0.4907 | 0.3680 | 0.3780 | 0.3517 | 0.3693 |
| Pass | 0.9027 | 0.4426 | 0.8333 | 0.8978 | 0.8434 | 0.8967 |
| Withdrawn | 0.8304 | 0.6754 | 0.7553 | 0.8148 | 0.7171 | 0.8409 |
| Averaged | 0.7757 | 0.7382 | 0.6942 | 0.7660 | 0.7012 | 0.7788 |
| Recall | RandomForest | SupportVectorMachine | KNearestNeighbor | ExtraTreeClassifier | AdaBoostClassifier | GradientBoosting |
| Distinction | 0.6586 | 0.0406 | 0.3848 | 0.6528 | 0.5355 | 0.6668 |
| Fail | 0.5807 | 0.3396 | 0.4568 | 0.5647 | 0.4575 | 0.5938 |
| Pass | 0.7570 | 0.6008 | 0.7064 | 0.7614 | 0.7456 | 0.7651 |
| Withdrawn | 0.7492 | 0.7351 | 0.7258 | 0.7479 | 0.6980 | 0.7483 |
| Averaged | 0.7235 | 0.4888 | 0.6518 | 0.7210 | 0.6620 | 0.7292 |
| F-score | RandomForest | SupportVectorMachine | KNearestNeighbor | ExtraTreeClassifier | AdaBoostClassifier | GradientBoosting |
| Distinction | 0.5403 | 0.0450 | 0.2828 | 0.5541 | 0.4893 | 0.5772 |
| Fail | 0.4511 | 0.3045 | 0.4075 | 0.4527 | 0.3855 | 0.4553 |
| Pass | 0.8234 | 0.3972 | 0.7646 | 0.8240 | 0.7914 | 0.8256 |
| Withdrawn | 0.7876 | 0.6852 | 0.7402 | 0.7799 | 0.7015 | 0.7919 |
| Averaged | 0.7415 | 0.5441 | 0.6685 | 0.736936 | 0.6760 | 0.7464 |
| Accuracy | RandomForest | SupportVectorMachine | KNearestNeighbor | ExtraTreeClassifier | AdaBoostClassifier | GradientBoosting |
| Distinction | 0.6579 | 0.3252 | 0.3842 | 0.6527 | 0.5363 | 0.6675 |
| Fail | 0.5800 | 0.2485 | 0.4568 | 0.5648 | 0.4425 | 0.5936 |
| Pass | 0.7570 | 0.6460 | 0.7064 | 0.7615 | 0.7455 | 0.7651 |
| Withdrawn | 0.7493 | 0.7043 | 0.7259 | 0.7480 | 0.6989 | 0.7484 |
| Averaged | 0.7235 | 0.4888 | 0.6518 | 0.7210 | 0.6620 | 0.7292 |

los estudiantes pertenecientes a la clase Suspenso están en riesgo y necesitan orientación informada. Tabla 6 un aumento decente en el rendimiento del modelo predictivo después de realizar la ingeniería de funciones. En promedio, todos los modelos predictivos lograron mayor

puntuación de rendimiento superior al 80 % en precisión, recuperación, puntuación F, y precisión. En general, RF superó a todos los demás valores de referencia modelos mientras que el SVM mostró el rendimiento más bajo. Las puntuaciones de rendimiento de GradientBoosting, AdaBoost y

TABLA 6. Rendimiento de los modelos predictivos después de realizar la ingeniería de características.

| Precision | RandomForest | SupportVectorMachine | KNearestNeighbor | ExtraTreeClassifier | AdaBoostClassifier | GradientBoosting |
|-----------|--------------|----------------------|------------------|---------------------|--------------------|------------------|
| Fail | 0.8943 | 0.8220 | 0.8710 | 0.8899 | 0.8902 | 0.8931 |
| Pass | 0.9493 | 0.7916 | 0.9254 | 0.9516 | 0.9396 | 0.9457 |
| Averaged | 0.9220 | 0.9032 | 0.8985 | 0.9212 | 0.9150 | 0.9195 |
| Recall | RandomForest | SupportVectorMachine | KNearestNeighbor | ExtraTreeClassifier | AdaBoostClassifier | GradientBoosting |
| Fail | 0.9517 | 0.8823 | 0.9288 | 0.9536 | 0.9427 | 0.9484 |
| Pass | 0.8892 | 0.8330 | 0.8651 | 0.8854 | 0.8844 | 0.8877 |
| Averaged | 0.9202 | 0.8079 | 0.8966 | 0.9190 | 0.9135 | 0.9179 |
| F-score | RandomForest | SupportVectorMachine | KNearestNeighbor | ExtraTreeClassifier | AdaBoostClassifier | GradientBoosting |
| Fail | 0.9221 | 0.8266 | 0.8990 | 0.9206 | 0.9157 | 0.9199 |
| Pass | 0.9182 | 0.7382 | 0.8942 | 0.9172 | 0.9111 | 0.9157 |
| Averaged | 0.9201 | 0.8307 | 0.8966 | 0.9189 | 0.9134 | 0.9178 |
| Accuracy | RandomForest | SupportVectorMachine | KNearestNeighbor | ExtraTreeClassifier | AdaBoostClassifier | GradientBoosting |
| Fail | 0.9517 | 0.8155 | 0.9288 | 0.9536 | 0.9427 | 0.9484 |
| Pass | 0.8892 | 0.7993 | 0.8651 | 0.8854 | 0.8844 | 0.8877 |
| Averaged | 0.9202 | 0.8079 | 0.8966 | 0.9190 | 0.9135 | 0.9179 |

Los clasificadores ExtraTree eran casi similares y más cercanos al RF.

En última instancia, se seleccionó el clasificador de RF para entrenar y probar el modelo predictivo para las diferentes duraciones (0 %, 20 %, 40 %, 60 %, 80 %, 100 %) del módulo del curso.

E. FASE IV: MODELO PREDICTIVO DE ENTRENAMIENTO MEDIANTE RED NEURONAL DEEP FEED FORWARD (DFFNN)

Después de entrenar los modelos predictivos usando métodos tradicionales de ML, luego usamos una técnica de aprendizaje profundo llamada Deep Feed Forward Neural Network (DFFNN) para entrenar el modelo predictivo usando OUAD. Las técnicas de DL difieren de las técnicas utilizadas en los algoritmos de ML tradicionales en que estructuran los algoritmos en capas que pueden aprender y emitir juicios sensatos por sí mismos. Los algoritmos de DL procesan datos mediante el uso de gráficos de neuronas en las capas de entrada, ocultas y de salida. Al igual que los algoritmos de ML tradicionales, DFFNN se entrenó repetidamente utilizando datos demográficos, datos demográficos + flujo de clics, datos demográficos + flujo de clics + datos de evaluación y, por último, en todas las variables de OUAD, estableciendo el resultado final como la variable objetivo y el resto de las variables como el variables predictoras. Los modelos predictivos basados en DFFNN se entrenaron inicializando primero los pesos de los bordes de las neuronas a números cercanos a cero usando TensorFlow Dense Class. Utilizando la clase TensorFlow Sequential, la primera observación de OUAD se envió a la DFFNN mediante la aplicación de la técnica de propagación directa. Aplicando la Unidad Lineal Rectificada (ReLU), las neuronas durante el proceso de propagación hacia adelante se activaron de tal manera que el impacto de la activación de cada neurona estaba restringido por los pesos de los bordes.

Para el entrenamiento de modelos predictivos, la API de Keras ofrece componentes totalmente configurables que se pueden conectar simultáneamente con la menor cantidad de restricciones posible. En particular, la API de Keras proporciona esquemas de inicialización de redes neuronales feed-forward, funciones de activación, optimizadores de función de costos y componentes de esquemas de regularización que se pueden combinar para crear modelos predictivos.

La estructura (capas de entrada, ocultas y de salida) de DFFNN se modificó de acuerdo con la cantidad de variables proporcionadas. Por ejemplo, cuando solo las variables demográficas

se utilizaron, las ocho variables categóricas ('code_module', 'code_presentation', 'gender', 'region', 'highest_education', 'imd_band', 'age_band', 'disability') se convirtieron en variables ficticias usando codificación one-hot técnica y una variable numérica ('num_of_prev_attempts') se escaló utilizando el escalador MinMax. Después de realizar una operación de codificación y escalado one-hot, se crearon un total de 47 variables listas para ser alimentadas a la DFFNN. Por lo tanto, según las variables de entrada, se usaron 47 neuronas en la capa de entrada, 24 en la primera capa oculta, 12 en la segunda capa oculta y cuatro neuronas en la capa de salida para representar Retirado, Reprobado, Aprobado, y Clases de distinción. Del mismo modo, a medida que se agregaron nuevas variables de flujo de clics y evaluación a las variables demográficas, se crearon nuevas estructuras de capas DFFNN para un proceso de capacitación fluido. Los hipermetros usados para entrenar el modelo predictivo usando DFFNN fueron loss='categorical_crossentropy', Optimizer='adam', metrics='accuracy', función de activación en capas ocultas = ReLU, función de activación en la capa de salida = softmax, epochs = 100, conjunto de entrenamiento = 85% y conjunto de prueba = 15%. Las tablas 7, 8, 9 y 10 presentan la precisión, el recuerdo, la puntuación f, el soporte, la precisión promedio, el promedio macro y las puntuaciones promedio ponderadas de los modelos de predicción cuando se entrenaron con variables demográficas, ICS demográficas + variables de secuencia de clics, demografía + secuencia de clics + evaluación de variables, y todas las variables. Los resultados indicaron que el modelo predictivo generó puntajes mediocres cuando se entrenó solo en datos demográficos, lo que implica que los datos demográficos solo no se pueden usar para la predicción más temprana posible de estudiantes en riesgo. Cuando se entrenaron solo gráficos de demostración + variables de flujo de clics, la puntuación de desempeño del modelo predictivo mejoró, lo que sugiere que las variables de flujo de clics son un indicador importante del desempeño de los estudiantes.

Al agregar las variables de evaluación con variables demográficas y de flujo de clics, la puntuación de precisión mejoró un 8 %, mientras que la precisión, el recuerdo y la puntuación f permanecieron bajos para las clases Distinción, Reprobado y Retirado. Finalmente, cuando se utilizaron todas las variables predictoras en el proceso de entrenamiento, se notó una ligera mejora en las variables métricas.

TABLA 7. Resultados de rendimiento de DFFNN cuando se entrena solo en variables demográficas.

| | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| Distinction | 0.56 | 0.01 | 0.02 | 434 |
| Fail | 0.39 | 0.12 | 0.18 | 1093 |
| Pass | 0.44 | 0.70 | 0.54 | 1819 |
| Withdrawn | 0.42 | 0.45 | 0.44 | 1543 |
| accuracy | | | .43 | 4889 |
| macro avg | 0.45 | 0.32 | 0.30 | 4889 |
| weighted avg | 0.43 | 0.43 | 0.38 | 4889 |

TABLA 8. Resultados de desempeño de DFFNN cuando se capacita en variables demográficas y de flujo de clics.

| | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| Distinction | 0.77 | 0.02 | 0.04 | 480 |
| Fail | 0.52 | 0.20 | 0.29 | 1075 |
| Pass | 0.62 | 0.92 | 0.74 | 1832 |
| Withdrawn | 0.67 | 0.76 | 0.71 | 1502 |
| accuracy | | | 0.63 | 4889 |
| macro avg | 0.64 | 0.48 | 0.45 | 4889 |
| weighted avg | 0.63 | 0.63 | 0.56 | 4889 |

TABLA 9. Resultados de desempeño de DFFNN cuando se entrenó en variables demográficas, flujo de clics y evaluación.

| | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| Distinction | 0.66 | 0.47 | 0.55 | 440 |
| Fail | 0.55 | 0.36 | 0.44 | 1081 |
| Pass | 0.74 | 0.90 | 0.81 | 1831 |
| Withdrawn | 0.76 | 0.80 | 0.78 | 1537 |
| accuracy | | | 0.71 | 4889 |
| macro avg | 0.68 | 0.63 | 0.64 | 4889 |
| weighted avg | 0.70 | 0.71 | 0.70 | 4889 |

TABLA 10. Resultados de desempeño de DFFNN cuando se entrenó en todas las variables.

| | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| Distinction | 0.64 | 0.49 | 0.55 | 447 |
| Fail | 0.55 | 0.37 | 0.44 | 1040 |
| Pass | 0.76 | 0.91 | 0.82 | 1886 |
| Withdrawn | 0.76 | 0.80 | 0.78 | 1516 |
| accuracy | | | 0.72 | 4889 |
| macro avg | 0.68 | 0.64 | 0.65 | 4889 |
| weighted avg | 0.70 | 0.72 | 0.70 | 4889 |

con solo un aumento del 1% en la puntuación de precisión promedio. Las Figuras 5a, 5b, 5c y 5d presentan las matrices de confusión para los modelos predictivos cuando las predicciones se evaluaron utilizando el conjunto de prueba. Los elementos diagonales son las clases correctamente predichas donde se puede notar que las predicciones correctas aumentaron al agregar más y más datos durante el proceso de entrenamiento del modelo predictivo.

1) USO DE INGENIERÍA DE CARACTERÍSTICAS PARA MEJORAR DFFNN RENDIMIENTO

Para mejorar aún más el rendimiento de DFFNN, se aplicó la técnica de ingeniería de características a la variable de resultado final donde las clases de Aprobado-Distinción se combinaron en la clase Aprobado y las clases Retiradas-Reprobadas se fusionaron en la clase Reprobado. Una vez más, el modelo predictivo basado en DFFNN se entrenó con 81 neuronas en la capa de entrada,

TABLA 11. Rendimiento de DFFNN después del paso de ingeniería de características para Fail y Pasar clases.

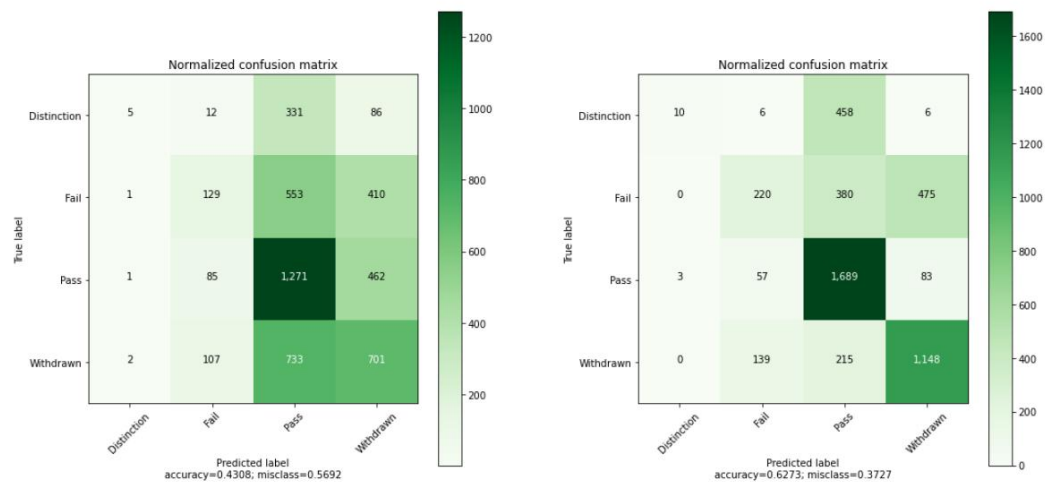
| | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| Fail | 0.98 | 0.83 | 0.90 | 2572 |
| Pass | 0.84 | 0.98 | 0.90 | 2317 |
| accuracy | | | 0.90 | 4889 |
| macro avg | 0.91 | 0.90 | 0.90 | 4889 |
| weighted avg | 0.91 | 0.90 | 0.90 | 4889 |

24 neuronas en la capa oculta 1, 12 neuronas en la capa oculta 2 y 2 neuronas en la capa de salida. Los hiperparámetros utilizados fueron `loss='binary_crossentropy'`, `Optimizer='adam'`, `metrics='accuracy'`, funciones de activación en capas ocultas = ReLU, función de activación en la capa de salida = sigmoide y épocas = 100. La Tabla 11 presenta la puntuación de rendimiento de DFFNN con puntajes mucho mejores que el arreglo de clasificación multiclase. En general, se notó una mejora del 18 % en la puntuación de precisión promedio. La figura 6 ilustra la matriz de confusión para el modelo predictivo cuando las predicciones se evaluaron usando el conjunto de prueba considerando solo las clases de Aprobado y Reprobado. Después de la operación fusionada, la precisión del modelo predictivo mejoró sustancialmente, pero también notamos que, en comparación con la precisión del modelo predictivo basado en RF, todavía es un 2 % menor, por lo tanto, para predecir el rendimiento de los estudiantes en diferentes duraciones del módulo del curso, el RF finalmente se seleccionó el método.


F. FASE V: CONSTRUCCIÓN DEL MODELO PREDICTIVO DE RF EN DIFERENTE PORCENTAJE DE DURACIÓN DEL MÓDULO DEL CURSO

La Tabla 12 muestra el resultado del modelo predictivo de RF cuando se entrenó y probó repetidamente con datos demográficos, 20 % de datos de curso, 40 % de datos de curso, 60 % de datos de curso, 80 % de datos de curso, 100 % de datos de curso. Random Forest (RF) utiliza técnicas de ensamblaje mediante la construcción de una multitud de árboles de decisión (DT) para tareas de clasificación y regresión. Durante el proceso de entrenamiento de RF, se construyen múltiples DT utilizando diferentes submuestras de datos de entrenamiento, y las puntuaciones medias se usan para mejorar la precisión de la predicción y evitar el ajuste excesivo.

El modelo predictivo de RF, cuando se entrenó solo en variables demográficas, dio puntajes de desempeño inferiores con precisión promedio = .60, recuerdo = .59, puntaje f = .59 y precisión = .59 para las clases de Reprobado y Aprobado. Cuando se entrenó con el 20 % de los datos del curso, el rendimiento del modelo predictivo de RF mejoró con una precisión promedio = 0,79, recuperación = 0,79, puntuación f = 0,79 y precisión = 0,79 para las clases de Reprobado y Aprobado. También se observó que la puntuación de rendimiento para la clase Aprobado fue alta en comparación con la clase Reprobado cuando se proporcionaron más datos de flujo de clics y evaluación al modelo predictivo de RF. Se observó una mayor mejora en la puntuación de rendimiento del modelo predictivo de RF cuando se proporcionaron datos de seguimiento de clics y datos de evaluación al 40 % de finalización del curso con una precisión media = 0,84, recuerdo = 0,84, puntuación f = 0,84 y precisión = .84. Los resultados de la puntuación de rendimiento revelaron que el rendimiento del modelo predictivo de RF mejoró cuando se proporcionaron más y más datos de flujo de clics y evaluación, lo que infiere que el modelo estaba aprendiendo qué variables tienen un impacto significativo.



(a) Normalized confusion matrix showing the DFFNN prediction results when tested on demographics variables (b) Normalized confusion matrix showing the DFFNN prediction results when tested on demographics, and clickstream variables



(c) Normalized confusion matrix showing the DFFNN prediction results when tested on demographics, clickstream, and assessment variables (d) Normalized confusion matrix showing the DFFNN prediction results when tested on all variables

FIGURA 5. Matrices de confusión DFFNN cuando se prueban en diferentes variables de OUAD.

TABLA 12. Puntuaciones de rendimiento del modelo predictivo de RF en diferentes porcentajes de duración del curso.

| Precision | No Clickstream, Assestment | 20% Course | 40% Course | 60% Course | 80% Course | 100% Course |
|-----------|----------------------------|------------|------------|------------|------------|-------------|
| Fail | 0.6593 | 0.7501 | 0.7992 | 0.8519 | 0.8811 | 0.8936 |
| Pass | 0.5279 | 0.8408 | 0.8874 | 0.9201 | 0.9351 | 0.9473 |
| Averaged | 0.6033 | 0.7980 | 0.8456 | 0.8869 | 0.9084 | 0.9207 |
| Recall | No Clickstream, Assestment | 20% Course | 40% Course | 60% Course | 80% Course | 100% Course |
| Fail | 0.6097 | 0.8404 | 0.8881 | 0.9225 | 0.9382 | 0.9499 |
| Pass | 0.5809 | 0.7504 | 0.7980 | 0.8475 | 0.8755 | 0.8884 |
| Averaged | 0.5972 | 0.7929 | 0.8408 | 0.8841 | 0.9066 | 0.9190 |
| F-score | No Clickstream, Assestment | 20% Course | 40% Course | 60% Course | 80% Course | 100% Course |
| Fail | 0.6334 | 0.7927 | 0.8413 | 0.8858 | 0.9087 | 0.9209 |
| Pass | 0.5529 | 0.7930 | 0.8403 | 0.8822 | 0.9043 | 0.9169 |
| Averaged | 0.5989 | 0.7929 | 0.8408 | 0.8840 | 0.9065 | 0.9189 |
| Accuracy | No Clickstream, Assestment | 20% Course | 40% Course | 60% Course | 80% Course | 100% Course |
| Fail | 0.6096 | 0.8404 | 0.8881 | 0.9225 | 0.9382 | 0.9499 |
| Pass | 0.5806 | 0.7505 | 0.7980 | 0.8475 | 0.8755 | 0.8884 |
| Averaged | 0.5972 | 0.7929 | 0.8408 | 0.8841 | 0.9066 | 0.9190 |

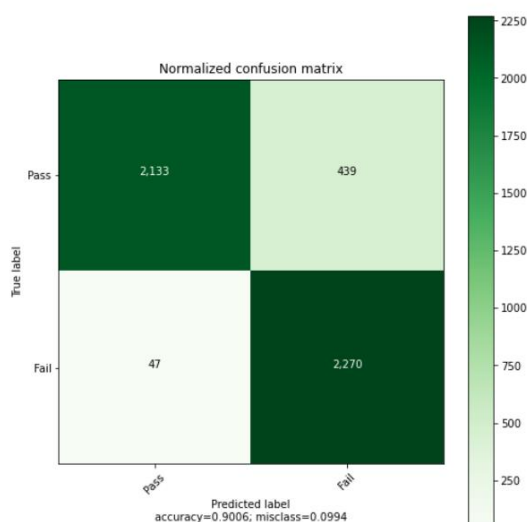


FIGURA 6. Matriz de confusión normalizada que muestra la predicción DFFNN para las clases de Reprobado y Aprobado.

relación con el resultado final de los estudiantes. Al 60 % de completar el curso, se observó una mejora general del 4 % en la puntuación de rendimiento del modelo predictivo de RF con una precisión promedio = 0,88, recuperación = 0,88, puntuación f = 0,88 y precisión = 0,88. Al 80 % de completar el curso, se observó un aumento del 2 % en la puntuación de rendimiento con una precisión promedio = 0,90, recuperación = 0,90, puntuación f = 0,90 y precisión = 0,90 para las clases de Reprobado y Aprobado. Finalmente, al completar el 100 % del curso, observamos la puntuación de rendimiento del modelo predictivo de RF más alta con una precisión promedio = 0,92, recuperación = 0,91, puntuación f = 0,91 y precisión = 0,91 para las clases de Reprobado y Aprobado.

Las puntuaciones de precisión, recuperación, puntuación f y precisión mejoraron cuando se proporcionaron más y más datos del curso al modelo de predicción de RF. En general, la puntuación de precisión mejoró de 0,60 a 0,92, la puntuación de recuerdo mejoró de 0,59 a 0,91, la puntuación F mejoró de 0,59 a 0,91 y la puntuación de precisión mejoró de 0,59 a 0,91. Los resultados de la métrica de desempeño concluyeron que el desempeño del modelo predictivo de RF mejoró con la duración del curso. Incluso al 20 % de la duración del curso, el modelo predictivo de RF mostró una puntuación de desempeño decente con precisión para la clase Reprobada = .75, clase Aprobada = .84, recuperación para la clase Reprobada = .85, clase Aprobada = .75, puntuación f para Clase reprobada = 0,79, clase aprobada = 0,79 y precisión para clase reprobada = 0,84, clase aprobada = 0,75, lo que indicó que el modelo podría ser muy útil para intervenir a los estudiantes en riesgo desde el 20 % de la duración del curso. Como resultado, el modelo predictivo de RF al 20 % de finalización del curso puede ayudar a los instructores a intervenir a los estudiantes y ayudarlos durante sus estudios. Además, los puntajes de desempeño mejoraron aún más con 40 %, 60 %, 80 % y 100 % de la duración del curso, lo que indicó que el modelo predictivo de RF puede ayudar a los instructores con mayor precisión para intervenir a los estudiantes y proporcionar la retroalimentación necesaria. Intervenir a los estudiantes al 100% de la duración del curso es inútil ya que el estudiante habría completado el curso pero el objetivo

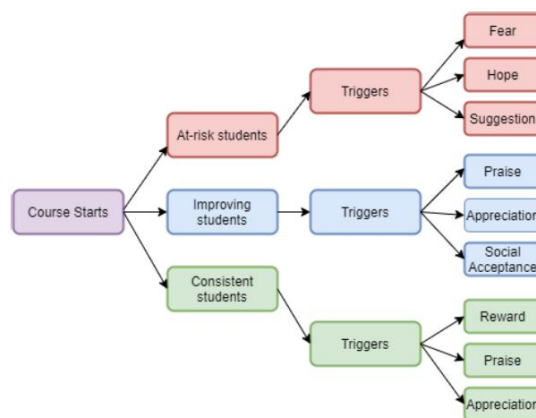


FIGURA 7. Diferentes tipos de disparadores para estudiantes que tienen diferentes estados de desempeño.

del modelo predictivo es apoyar a los instructores lo antes posible en el cronograma del curso para ayudar a los estudiantes en riesgo de fallar o abandonar los estudios.

VI. INTERVENCIÓN DE ESTUDIANTES A TRAVÉS DE TÉCNICAS PERSUASIVAS

El modelo de comportamiento de Fogg (FBM) sugiere que tres factores (habilidad, motivación y desencadenantes) deben estar presentes al mismo tiempo para aumentar la actitud de las personas de manera positiva [64]. Para intervenir y persuadir a los estudiantes para que mejoren su comportamiento de estudio, la selección óptima del tiempo es importante. Según los resultados satisfactorios (con un 79 % de exactitud, precisión, recuperación, puntuación f) del modelo predictivo de RF, se puede intervenir a los estudiantes después del 20 % de la duración del curso. Además, si se incluyen detalles completos en los datos demográficos de los estudiantes, la intervención y la persuasión se pueden llevar a cabo al comienzo del curso. La Figura 7 resume los tipos de desencadenantes presentados a los estudiantes que tienen un rendimiento de estudio frágil, en mejora y constante. Los factores de miedo, esperanza y sugestión se suman a los disparadores dirigidos a los estudiantes en riesgo. De manera similar, para los disparadores destinados a mejorar y mantener a los estudiantes, se agregan los factores de elogio, recompensa, aprecio y aceptación social. El momento óptimo para enviar disparadores a los estudiantes depende de los resultados del modelo predictivo durante las diferentes etapas del curso. A modo de ejemplo, el factor desencadenante que tiene esperanza para que los estudiantes en riesgo mejoren su conducta de estudio podría ser el siguiente: **Según nuestro modelo predictivo, la puntuación de su evaluación alcanzó una tasa de éxito del 50 %. Hiciste un esfuerzo encomiable esta semana. Su posición en la clase puede mejorar aún más si sigue con cautela las conferencias de la próxima semana.**

Si envía todas sus evaluaciones a tiempo la próxima semana, obtendrá un puntaje acumulativo del 60%.

Del mismo modo, desencadene tener un factor de miedo para los estudiantes en riesgo. para mejorar su comportamiento de estudio podría ser el siguiente:

De acuerdo con nuestro modelo predictivo, obtiene constantemente una puntuación de evaluación baja. Sería genial si nadie se da de baja del curso debido a una baja puntuación en la evaluación.

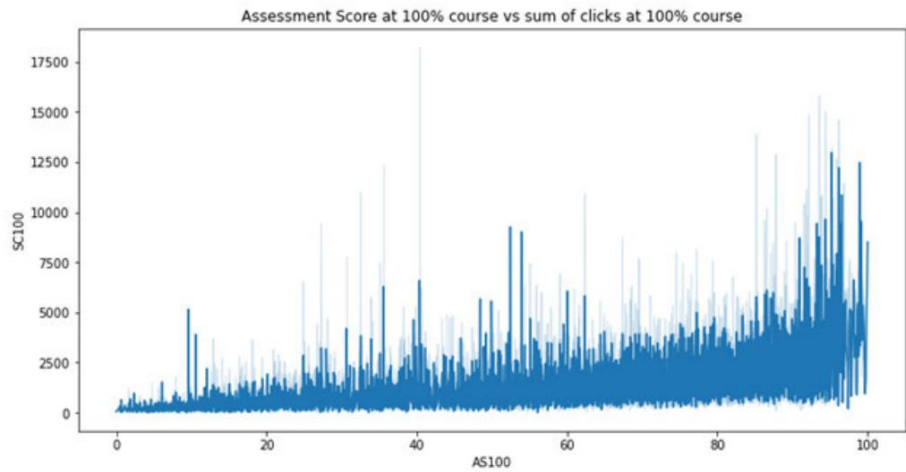


FIGURA 8. Puntuación de evaluación al 100 % del curso frente a la suma de clics al 100 % del curso.




FIGURA 9. Envío tardío vs suma de clics al 100% del curso.




FIGURA 10. Puntaje de evaluación vs suma de clics al 100% del curso.

VIII. CONCLUSIÓN, LIMITACIÓN Y TRABAJO FUTURO Predecir e intervenir a los estudiantes durante las diferentes etapas de la duración del curso proporciona beneficios tanto para los estudiantes como para los estudiantes. instructores Brinda a los instructores la oportunidad de ayudar a los estudiantes en riesgo de abandonar los estudios y realizar una intervención en el momento óptimo para mejorar su comportamiento de estudio. En

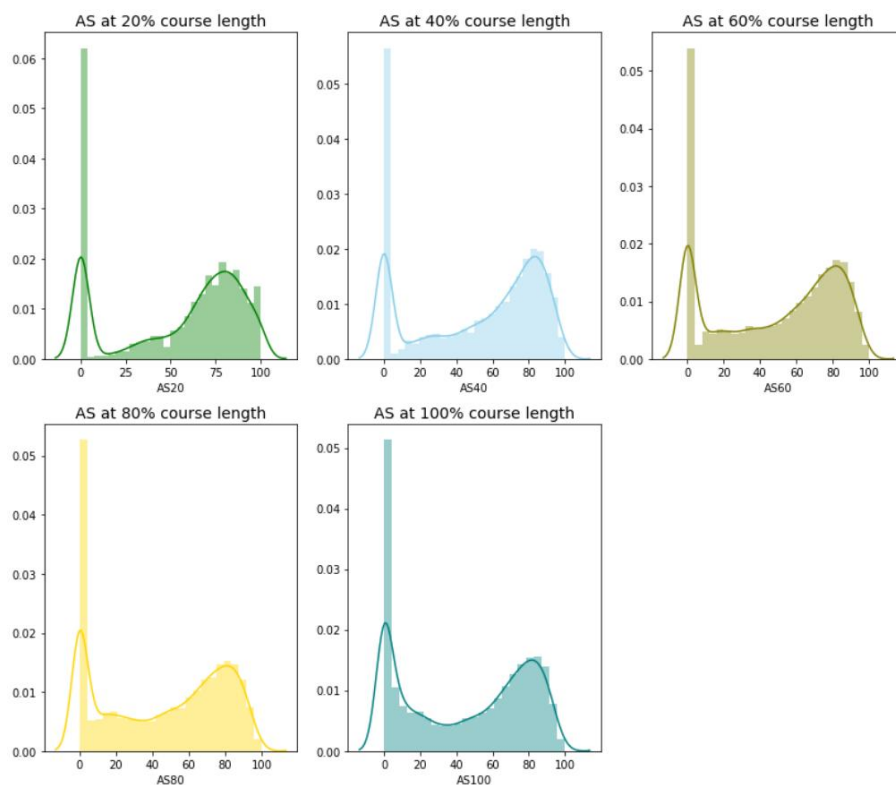


FIGURA 11. Rendimiento de la evaluación en diferentes porcentajes de duración del curso.

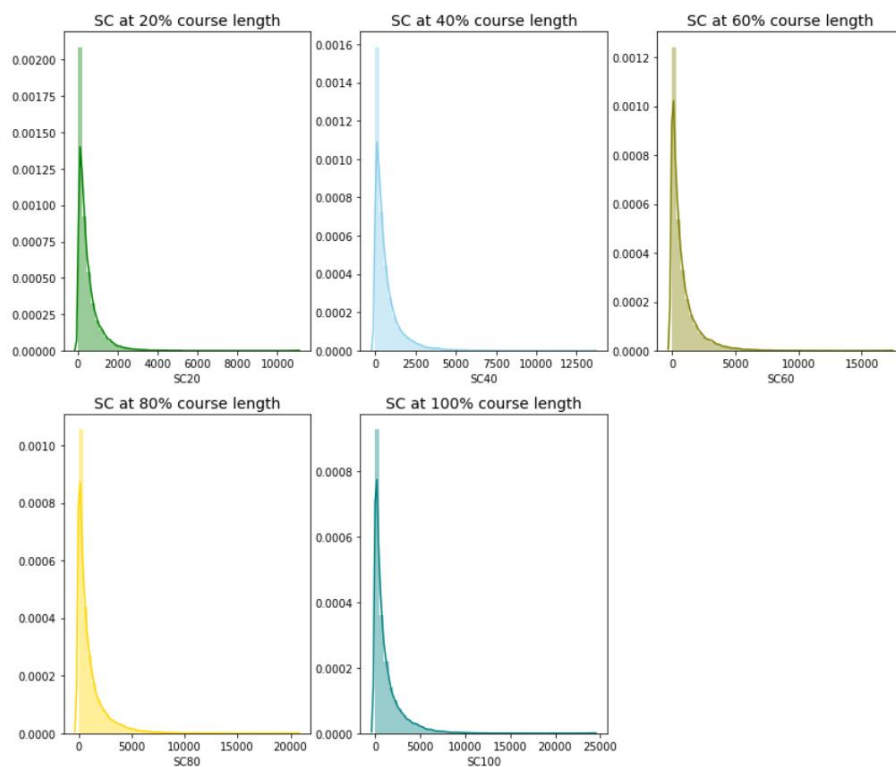


FIGURA 12. Suma de clics en diferentes porcentajes de duración del curso.

presente estudio, propusimos varios modelos predictivos entrenados en varios algoritmos ML y DL para predecir los

rendimiento basado en variables demográficas, ics demográficos + variables de flujo de clics y datos demográficos + flujo de clics

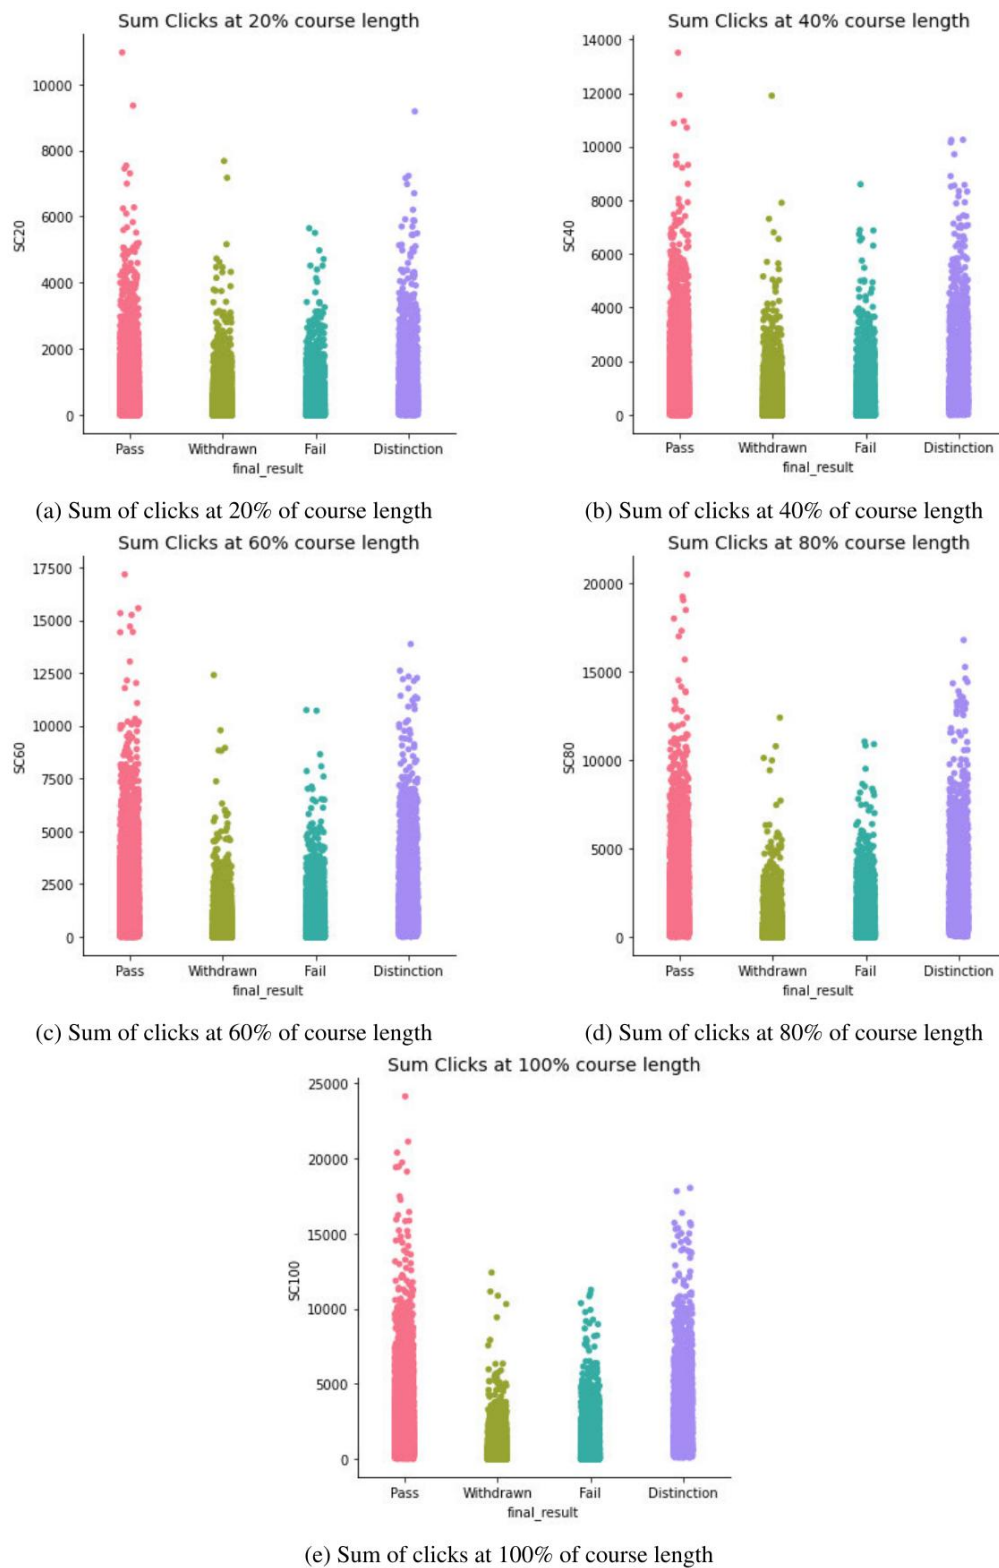


FIGURA 13. Interacción VLE de los estudiantes vs posiciones de calificación final en diferentes porcentajes de duración del curso.

+ variables de evaluación. Finalmente, se seleccionó el modelo predictivo de RF con las puntuaciones de rendimiento más altas para predecir

rendimiento de los estudiantes en las diferentes duraciones del curso. Semejante un modelo predictivo puede ayudar a los instructores a tomar decisiones oportunas

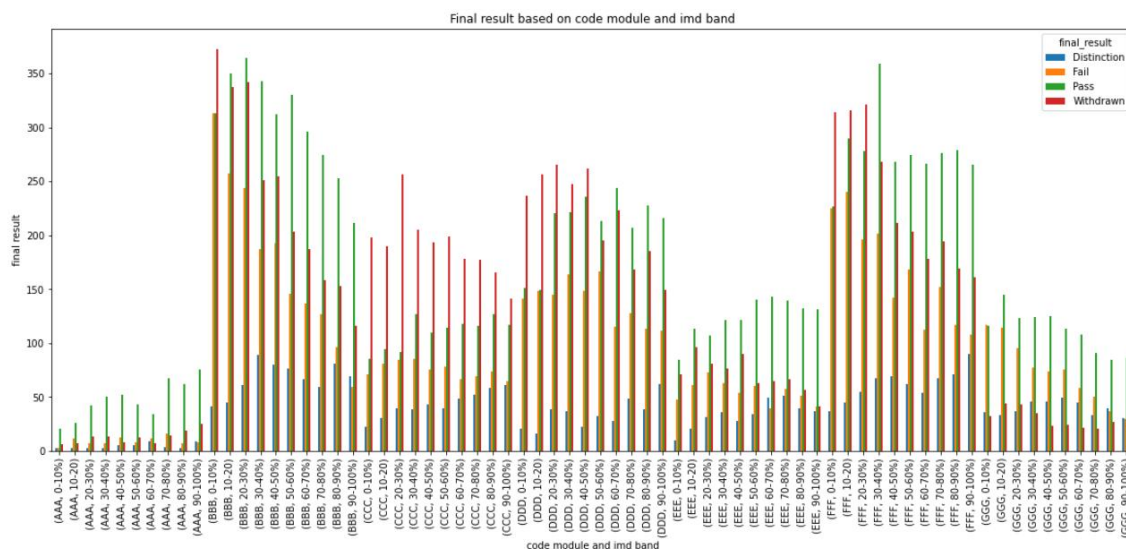


FIGURA 14. Relación de Code module e imd_band con el resultado final donde se observa mayor rendimiento en curso BBB, FFF y menor rendimiento en curso AAA.

intervenciones y persuadir a los estudiantes en riesgo para que mejoren su desempeño en el estudio. De muchas variables, el flujo de clics y las variables de evaluación tenían el impacto más significativo en el resultado final de los estudiantes.

Este estudio reveló que técnicas como la ingeniería de funciones mejoran de forma significativa el rendimiento de los modelos predictivos. Durante la línea de tiempo del módulo del curso, el rendimiento de los estudiantes se pronosticó desde el principio cuando solo estaban disponibles las variables demográficas. Posteriormente, el desempeño de los estudiantes se pronosticó al 20%, 40%, 60%, 80% y 100% de la duración del curso. Incluso con el 20 % de la duración del curso, el modelo predictivo de RF estaba produciendo resultados prometedores con un puntaje de precisión promedio del 79 %, un puntaje de recuperación promedio del 79 %, un puntaje f promedio del 79 % y un puntaje de precisión promedio del 79 %. Al 60 % de la duración del curso, el rendimiento del modelo predictivo de RF mejoró significativamente con un 88 % de precisión, recuperación, puntaje f y exactitud promedio. Finalmente, al completar el curso al 100 %, se observaron los puntajes más altos de rendimiento del modelo predictivo de RF con una precisión promedio del 92 %, recuperación promedio del 91 %, puntaje f promedio del 91 % y precisión promedio del 91 %. También observamos que las puntuaciones de rendimiento para la clase Suspenso individualmente después del proceso de ingeniería de funciones fueron mejores que las puntuaciones de rendimiento de la clase Aprobado. Obtener un puntaje de desempeño más alto para la clase de Reprobado se debió a un problema de clase desequilibrado con 17,208 estudiantes Reprobados y 15,385 estudiantes Aprobados.

En general, los resultados del modelo predictivo RF demostraron efectividad en la predicción más temprana posible del desempeño de los estudiantes en riesgo. Dichos estudios basados en datos pueden ayudar a los administradores e instructores de VLE en la formulación del marco de aprendizaje en línea que puede contribuir al proceso de toma de decisiones. También consideramos que se requieren estudios más profundos para evaluar varias actividades en línea en el OULD. En particular, cuán diversos principios

Las técnicas de intervención se pueden implementar en el entorno de aprendizaje en línea para alentar a los estudiantes a seguir el camino correcto. En el futuro, planeamos examinar la importancia sabia de la actividad que tiene una influencia destacada en el desempeño de los estudiantes mediante el modelado de variables textuales relacionadas con los comentarios de los estudiantes utilizando modelos de aprendizaje profundo y técnicas de procesamiento de lenguaje natural.

APÉNDICE

ANÁLISIS DE DATOS EXPLORATORIOS DE OUAD (EDA)

Antes de entrenar los modelos predictivos, se realizó EDA en OUAD para comprender las relaciones entre diferentes variables. La Figura 8 presenta la comparación de los datos del flujo de clics con la puntuación de la evaluación al final del curso, lo que indica que con una puntuación de evaluación más alta, la suma de clics por alumno aumenta.

La figura 9 muestra que los estudiantes que entregaron más evaluaciones tarde interactuaron más con el VLE, pero la relación no es muy significativa. En el gráfico de líneas, se puede observar que los estudiantes que tuvieron 12 entregas tardías de evaluación participaron más que cualquiera de las entregas tardías restantes.

La Figura 10 revela que los estudiantes que obtuvieron calificaciones de Distinción (cursos completados con calificaciones excelentes) y Aprobado (cursos completados con un puntaje de aprobación) en el estudio interactuaron más con el VLE en comparación con el estudiante que obtuvo Reprobado (estudiantes que completaron el curso pero no pudieron obtener calificaciones para aprobar) y Retirados (estudiantes que no pudieron completar el curso).

Las cinco subparcelas de la figura 11 muestran el rendimiento de evaluación de los estudiantes al 20 %, 40 %, 60 %, 80 % y 100 % de la duración del curso. Las subtramas revelan puntajes de evaluación de estudiantes similares en un porcentaje diferente de la duración del curso. Estudiantes que presentan un rendimiento evaluativo más bajo al inicio de

el curso tienen una puntuación similar durante el resto de la duración del curso.

De manera similar, las subparcelas en la figura 12 muestran un patrón de flujo de clics en diferentes etapas de la duración del curso. Se puede observar que el patrón de flujo de clics sigue siendo el mismo para la mayoría de los estudiantes durante un porcentaje diferente de la duración del curso. Sin embargo, también podemos observar que la interacción VLE al comienzo del curso (al 20 % y al 40 % de la duración del curso) es mayor, pero permanece casi igual después del 50 % de finalización del curso (al 60 %, 80 % y 100 % de la duración del curso).

De manera similar, las subtramas de la figura 13 muestran a los estudiantes patrones de flujo de clics similares en un porcentaje diferente de la duración del curso para los casos de Aprobado, Retirado, Suspenso y Distinción.

Finalmente, la figura 14 presenta una relación entre el resultado final y el módulo de código/imd_band donde se puede observar que los estudiantes mostraron el rendimiento más bajo en el módulo de código AAA y el rendimiento más alto en el módulo de código BBB y FFF.

REFERENCIAS

- [1] LP Macfadyen y S. Dawson, "Extracción de datos LMS para desarrollar un 'sistema de alerta temprana' para educadores: una prueba de concepto", *Comput. Educación*, vol. 54, núm. 2, págs. 588–599, febrero de 2010.
- [2] C. Romero, S. Ventura y E. García, "Minería de datos en sistemas de gestión de cursos: estudio de caso y tutorial de Moodle", *Comput. Educación*, vol. 51, núm. 1, págs. 368–384, agosto de 2008.
- [3] S. Valsamidis, S. Kontogiannis, I. Kazanidis, T. Theodosiou y A. Karakos, "Una metodología de agrupación de datos de registro web para sistemas de gestión de aprendizaje", *J. Educ. Tecnología Soc.*, vol. 15, núm. 2, págs. 154 a 167, 2012.
- [4] M. Hussain, W. Zhu, W. Zhang, SMR Abidi y S. Ali, "Uso del aprendizaje automático para predecir las dificultades de los estudiantes a partir de los datos de la sesión de aprendizaje", *Artif. Intell. Rev.*, vol. 52, no. 1, pp. 381–407, Jun. 2019.
- [5] OE Aissaoui, YEA El Madani, L. Oughdir y YE Alloui, "Combinación de algoritmos de aprendizaje automático supervisados y no supervisados para predecir los estilos de aprendizaje de los alumnos", *Procedia Comput. ciencia*, vol. 148, págs. 87–96, enero de 2019.
- [6] JY Chung y S. Lee, "Sistemas de alerta temprana de deserción para estudiantes de secundaria que utilizan el aprendizaje automático", *Children Youth Services Rev.*, vol. 96, págs. 346–353, enero de 2019.
- [7] SA Salloum, M. Alshurideh, A. Elnagar y K. Shaalan, "Minería en datos educativos: revisión y direcciones futuras", en *Proc. Solicitad conjunta de taller europeo de EE. UU. Cálculo de invariancia*. Vis. El Cairo, Egipto: Springer, 2020, págs. 92–102.
- [8] A. Hernández-Blanco, B. Herrera-Flores, D. Tomás y B. Navarro-Colorado, "Una revisión sistemática de los enfoques de aprendizaje profundo para la minería de datos educativos", *Complexity*, vol. 2019, mayo de 2019, art. No. 1306039.
- [9] KS Rawat e I. Malhan, "Un método de clasificación híbrido basado en clasificadores de aprendizaje automático para predecir el rendimiento en la minería de datos educativos", en *Proc. 2do Int. Conf. Comun., Comput. Neto*. Chandigarh, India: Instituto Nacional de Formación e Investigación de Profesores Técnicos, Departamento de Informática e Ingeniería, 2019, págs. 677–684.
- [10] SM Jayaprakash, EW Moody, EJM Lauria, JR Regan y JD Baron, "Alerta temprana de estudiantes en riesgo académico: una iniciativa de análisis de fuente abierta", *J. Learn. Analítica*, vol. 1, no. 1, págs. 6 a 47, mayo de 2014.
- [11] C. Márquez-Vera, A. Cano, C. Romero, AYM Noaman, H. Mousa Fardoun, and S. Ventura, "Predicción de la deserción temprana usando minería de datos: un estudio de caso con estudiantes de secundaria", *experto Syst.*, vol. 33, núm. 1, págs. 107 a 124, febrero de 2016.
- [12] S. Palmer, "Modelado del rendimiento académico de los estudiantes de ingeniería mediante el análisis académico", *Int. J. Ing. Educación*, vol. 29, núm. 1, págs. 132 a 138, 2013.
- [13] Z. Papamitsiou y A. Economides, "Análisis de aprendizaje y minería de datos educativos en la práctica: una revisión sistemática de la literatura de la evidencia empírica", *Edu. Tecnología Soc.*, vol. 17, núm. 4, págs. 49 a 64, 2014.
- [14] A. Peña-Ayala, "Minería de datos educativos: una encuesta y un análisis basado en la minería de datos de trabajos recientes", *Expert Syst. aplicación*, vol. 41, núm. 4, págs. 1432–1462, marzo de 2014.
- [15] NZ Zacharis, "Un enfoque multivariante para predecir los resultados de los estudiantes en cursos de aprendizaje combinado habilitados para la Web", *Internet Higher Edu.*, vol. 27, págs. 44–53, octubre de 2015.
- [16] EB Costa, B. Fonseca, MA Santana, FF de Araújo y J. Rego, "Evaluación de la efectividad de las técnicas de minería de datos educativos para la predicción temprana del fracaso académico de los estudiantes en cursos de introducción a la programación", *Comput. Tararear. Comportamiento*, vol. 73, págs. 247–256, agosto de 2017.
- [17] D. Gašević, S. Dawson, T. Rogers y D. Gasevic, "La analítica de aprendizaje no debe promover una talla única: los efectos de las condiciones de instrucción en la predicción del éxito académico", *Internet Higher Edu.*, vol. 28, págs. 68–84, enero de 2016.
- [18] A. Bozkurt e IE Aydin, "La diversidad cultural y sus implicaciones en los espacios de aprendizaje en red en línea", en *Supporting Multiculturalism Open Distance Learning Spaces*. Hershey, Pensilvania, EE. UU.: IGI Global, 2018, págs. 56–81.
- [19] RS Baker y PS Inventado, "Minería de datos educativos y análisis de aprendizaje", en *Learning Analytics*. Nueva York, NY, EE. UU.: Springer, 2014, págs. 61–75.
- [20] L. Cen, D. Ruta, L. Powell, B. Hirsch y J. Ng, "Enfoque cuantitativo para el aprendizaje colaborativo: predicción del desempeño, evaluación individual y composición del grupo", *Int. J. Comput.-Supported Collaborative Learn.*, vol. 11, núm. 2, págs. 187–225, junio de 2016.
- [21] A. Mueen, B. Zafar y U. Manzoor, "Modelado y predicción del rendimiento académico de los estudiantes mediante técnicas de minería de datos", *Int. Mod. J. Edu. computar ciencia*, vol. 8, núm. 11, pág. 36, 2016.
- [22] S. Huang y N. Fang, "Predicción del rendimiento académico de los estudiantes en un curso de ingeniería dinámica: una comparación de cuatro tipos de modelos matemáticos predictivos", *Comput. Educación*, vol. 61, págs. 133–145, febrero de 2013.
- [23] F. Marbouti, HA Diefes-Dux y K. Madhavan, "Modelos para la predicción temprana de estudiantes en riesgo en un curso que utiliza calificaciones basadas en estándares", *Comput. Educación*, vol. 103, págs. 1 a 15, diciembre de 2016.
- [24] DT Tempelaar, B. Rienties y B. Giesbers, "En busca de los datos más informativos para la generación de retroalimentación: análisis de aprendizaje en un contexto rico en datos", *Comput. Tararear. Comportamiento*, vol. 47, págs. 157 y 167, junio de 2015.
- [25] RF Kizilec, M. Pérez-Sanagustín y JJ Maldonado, "Estrategias de aprendizaje autorregulado predicen el comportamiento del alumno y el logro de objetivos en cursos masivos abiertos en línea", *Comput. Educación*, vol. 104, págs. 18 a 33, enero de 2017.
- [26] J. Kuzilek, M. Hlosta, D. Herrmannova, Z. Zdrahal y A. Wolff, "Ou analyse: Análisis de estudiantes en riesgo en la universidad abierta", *Learn. Analytic ics Rev.*, vol. 8, págs. 1 a 16, marzo de 2015.
- [27] A. Wolff, Z. Zdrahal, A. Nikolov y M. Pantucek, "Mejora de la retención: predicción de estudiantes en riesgo mediante el análisis del comportamiento de clics en un entorno de aprendizaje virtual", en *Proc. 3ª Int. Conf. Aprender. Analytics Knowl.*, 2013, págs. 145–149.
- [28] M. Hlosta, D. Herrmannova, L. Vachova, J. Kuzilek, Z. Zdrahal y A. Wolff, "Modelado del comportamiento en línea de los estudiantes en un entorno de aprendizaje virtual", 2018, *arXiv:1811.06369*. [En línea]. Disponible: <http://arxiv.org/abs/1811.06369> [29] Y. Cui, F. Chen y A. Shiri, "Ampliar los modelos predictivos para la detección temprana de estudiantes en riesgo: un estudio de viabilidad", *información Aprender. ciencia*, vol. 121, núms. 3–4, págs. 97–116, febrero de 2020.
- [30] Y. Lee y J. Choi, "Una revisión de la investigación sobre abandono de cursos en línea: implicaciones para la práctica y la investigación futura", *Educ. Tecnología Res. Desarrollar.*, vol. 59, núm. 5, págs. 593–618, octubre de 2011.
- [31] J.-L. Hung, MC Wang, S. Wang, M. Abdelrasoul, Y. Li y W. He, "Identificación de estudiantes en riesgo para intervenciones tempranas: un enfoque de agrupamiento de series de tiempo", *IEEE Trans. emergente Temas Computación*, vol. 5, núm. 1, págs. 45 y 55, noviembre de 2015.
- [32] T. Soffer y A. Cohen, "Las características de participación de los estudiantes predicen el éxito y la finalización de los cursos en línea", *J. Comput. Ayudar. Aprende.*, vol. 35, núm. 3, págs. 378–389, junio de 2019.
- [33] PH Winne, "Mejorando las medidas del aprendizaje autorregulado", *Educ. Psicólogo*, vol. 45, núm. 4, págs. 267–276, octubre de 2010.
- [34] L. Sha, C.-K. Looi, W. Chen y BH Zhang, "Comprensión del aprendizaje móvil desde la perspectiva del aprendizaje autorregulado", *J. Comput. Ayudar. Aprende.*, vol. 28, núm. 4, págs. 366–378, agosto de 2012.
- [35] R. Baker, B. Evans, Q. Li y B. Cung, "¿Inducir a los estudiantes a programar la visualización de conferencias en clases en línea mejora su rendimiento académico? Un análisis experimental de una intervención de gestión del tiempo", *Res. Educación Superior*, vol. 60, núm. 4, págs. 521–552, 2019.
- [36] A. Cicchinelli, E. Veas, A. Pardo, V. Pammer-Schindler, A. Fessl, C. Barreiros y S. Lindstädt, "Finding traces of self-regulated learning in activity streams", en *proc. 8ª Int. Conf. Aprender. Anal. Knowl.*, marzo de 2018, págs. 191–200.
- [37] JM Lim, "Predicción de la finalización exitosa usando indicadores de retraso de los estudiantes en cursos en línea a su propio ritmo de pregrado", *Distance Edu.*, vol. 37, núm. 3, págs. 317–332, septiembre de 2016.

- [38] J. Park, K. Denaro, F. Rodriguez, P. Smyth y M. Warschauer, "Detecting changes in student behavior from clickstream data", en *Proc. 7th Int. Aprender. Anal. Saber Conf.*, marzo de 2017, págs. 21–30.
- [39] S. Gupta y AS Sabitha, "Descifrando los atributos de la retención de estudiantes en cursos masivos abiertos en línea utilizando técnicas de minería de datos", *Edu. información Tecnología*, vol. 24, núm. 3, págs. 1973–1994, mayo de 2019.
- [40] G. Akçapınar, MN Hasnine, R. Majumdar, B. Flanagan y H. Ogata, "Desarrollo de un sistema de alerta temprana para detectar estudiantes en riesgo mediante el uso de registros de interacción de libros electrónicos", *Smart Learn. Medio ambiente*, vol. 6, núm. 1, pág. 4 de diciembre de 2019.
- [41] G. Kyrösi y R. Farkas, "Predicción del rendimiento de Mooc mediante el aprendizaje profundo a partir de datos sin procesar del flujo de clics", en *Proc. En t. Conf. Adv. computar ciencia de datos* La Valeta, Malta: Springer, 2020, págs. 474–485.
- [42] A. Cano y JD Leonard, "Sistema de alerta temprana multivista interpretable adaptado a poblaciones estudiantiles subrepresentadas", *IEEE Trans. Aprender. Tecnología*, vol. 12, núm. 2, págs. 198–211, abril de 2019.
- [43] C. Burgos, ML Campanario, DDL Peña, JA Lara, D. Lizcano y MA Martínez, "Minería de datos para modelar el desempeño de los estudiantes: un plan de acción de tutoría para prevenir la deserción académica", *Comput. eléctrico Ing.*, vol. 66, págs. 541–556, febrero de 2018.
- [44] JA Lara, D. Lizcano, MA Martínez, J. Pazos, and T. Riera, "A system for Knowledge Discovery in E-Learning Environments within the European Higher Education Area—Application to Student Data from Open University of Madrid", *UDIMA, Cómputo. Educación*, vol. 72, págs. 23 a 36, marzo de 2014.
- [45] CC Gray y D. Perkins, "Usando el compromiso temprano y el aprendizaje automático para predecir los resultados de los estudiantes", *Comput. Educación*, vol. 131, págs. 22 y 32, abril de 2019.
- [46] R. Al-Shabandar, AJ Hussain, P. Liatsis y R. Keight, "Detectar estudiantes en riesgo con intervenciones tempranas utilizando técnicas de aprendizaje automático", *IEEE Access*, vol. 7, págs. 149464–149478, 2019.
- [47] S. Lee y JY Chung, "El sistema de alerta temprana de deserción basado en el aprendizaje automático para mejorar el rendimiento de la predicción de deserción", *Appl. ciencia*, vol. 9, núm. 15, pág. 3093, julio de 2019.
- [48] A. Behr, M. Giese y K. Theune, "Predicción temprana de la deserción universitaria: un enfoque de bosque aleatorio", *J. Nat. Stat.*, vol. 1, págs. 743–789, febrero de 2020.
- [49] LCB Martins, RN Carvalho, RS Carvalho, MC Victorino y M. Holanda, "Predicción temprana de la deserción universitaria usando minería de datos", en *Proc. 16 IEEE Int. Conf. Mach. Aprender. aplicación (ICMLA)*, diciembre de 2017, págs. 1075–1078.
- [50] N. Mduma, K. Kalegele y D. Machuve, "Enfoque de aprendizaje automático para reducir las tasas de deserción de los estudiantes", *Int. J. adv. computar Res.*, vol. 9, núm. 42, 2019, doi: [10.19101/IJACR.2018.839045](https://doi.org/10.19101/IJACR.2018.839045).
- [51] J. Figueroa-Cañas y T. Sancho-Vinuesa, "Predecir la deserción temprana de los estudiantes es cuestión de verificar cuestionarios completados: El caso de un módulo de estadísticas en línea", en *Proc. LASI-ESPAÑA*, 2019, pp. 100–111.
- [52] A. Ortigosa, RM Carro, J. Bravo-Agapito, D. Lizcano, JJ Alcolea, and O. Blanco, "Del laboratorio a la producción: lecciones aprendidas y desafíos de la vida real de un sistema temprano de prevención de la deserción estudiantil", *IEEE Trans. Aprender. Tecnología*, vol. 12, núm. 2, págs. 264–277, abril de 2019.
- [53] AS Imran, F. Dalipi y Z. Kastrati, "Predicción de la deserción estudiantil en un MOOC: una evaluación de un modelo de red neuronal profunda", en *Proc. 5to Int. Conf. computar Artefacto Intel. (ICCAI)*, 2019, págs. 190–195.
- [54] N. Wu, L. Zhang, Y. Gao, M. Zhang, X. Sun y J. Feng, "CLMS-net: predicción de abandono en MOOC con aprendizaje profundo", en *Proc. ACM Turing Celebration Conf.*, mayo de 2019, págs. 1–6.
- [55] CP Rosé, EA McLaughlin, R. Liu y KR Koedinger, "Modelos de aprendizaje explicativos: por qué el aprendizaje automático (solo) no es la respuesta", *Brit. J. Educ. Tecnología*, vol. 50, núm. 6, págs. 2943–2958, 2019.
- [56] AA Mubarak, H. Cao y SAM Ahmed, "Análisis de aprendizaje predictivo utilizando un modelo de aprendizaje profundo en videos de cursos MOOC", *Edu. información Tecnología*, vol. 6, págs. 1 al 22 de julio 2020.
- [57] SN Liao, D. Zingaro, K. Thai, C. Alvarado, WG Griswold y L. Porter, "Una técnica robusta de aprendizaje automático para predecir estudiantes de bajo rendimiento", *ACM Trans. computar Educación*, vol. 19, núm. 3, págs. 1 a 19, junio de 2019.
- [58] B. Sekeroglu, K. Dimillier y K. Tuncal, "Predicción y clasificación del rendimiento de los estudiantes mediante algoritmos de aprendizaje automático", en *Proc. 8th Int. Conf. Educ. información Technol.*, marzo de 2019, págs. 7–11.
- [59] Y. Mao, "Aprendizaje profundo frente a rastreo de conocimiento bayesiano: modelos de estudiantes para intervenciones", *J. Educ. Minería de datos*, vol. 10, núm. 2, págs. 1 a 27, 2018.
- [60] Z. Iqbal, J. Qadir, A. Noor Mian y F. Kamiran, "Predicción de calificaciones de estudiantes basada en el aprendizaje automático: un estudio de caso", 2017, *arXiv: 1708.08744*. [En línea]. Disponible: <http://arxiv.org/abs/1708.08744>
- [61] HL Fwa y L. Marshall, "Modelado del compromiso de los estudiantes de programación usando una técnica de aprendizaje automático no supervisado", *GSTF J. Comput.*, vol. 6, núm. 1, págs. 1 a 6, 2018.
- [62] J. Xu, KH Moon y M. van der Schaar, "Un enfoque de aprendizaje automático para rastrear y predecir el desempeño de los estudiantes en programas de grado", *IEEE J. Sel. Temas Signal Process.*, vol. 11, núm. 5, págs. 742–753, agosto de 2017.
- [63] J. Kuzilek, M. Hlosta y Z. Zdrahal, "Conjunto de datos de análisis de aprendizaje universitario abierto", *Sci. Datos*, vol. 4, núm. 1, dic. 2017, art. No. 170171.
- [64] BJ Fogg, "Modelo de comportamiento de Fogg", Behav. Des. Lab., Stanford Univ., Stanford, CA, EE. UU., Tech. Rep., 2019. [En línea]. Disponible: <https://behaviormodel.org/>



MUHAMMAD ADNAN recibió la licenciatura en informática de la Universidad de Peshawar y la maestría en tecnología de la información de la Escuela de Ingeniería Eléctrica y Ciencias de la Computación de la Universidad Nacional de Ciencia y Tecnología de Islamabad, donde actualmente está cursando el doctorado. D. la licenciatura. Actualmente es profesor en el Instituto de Tecnología de la Información de la Universidad de Ciencia y Tecnología de Kohat. Su área de investigación incluye dispositivos móviles

aprendizaje automático, aprendizaje automático, aprendizaje adaptativo y sistemas ubicuos.



ASAD HABIB recibió el Ph.D. título del Instituto de Ciencia y Tecnología de Nara, Nara, Japón. Actualmente es profesor asistente en el Instituto de Tecnología de la Información de la Universidad de Ciencia y Tecnología de Kohat. Está involucrado en el área de procesamiento de lenguaje natural, interacción humano-computadora, inteligencia artificial, tecnologías de aprendizaje, aprendizaje móvil y diseño de interfaz adaptable.



JAWAD ASHRAF recibió el Ph.D. Licenciado por el Departamento de Ciencias de la Computación de la Universidad de Leicester, Reino Unido. Actualmente trabaja en el Instituto de Tecnología de la Información de la Universidad de Ciencia y Tecnología de Kohat, donde trabaja en un algoritmo de programación basado en socios para flujos de trabajo de cuadrícula en un entorno de reserva anticipada, K -variante de ruta más corta para el enrutamiento en el entorno de reserva anticipada y técnica novedosa de selección de trabajo de flujo de trabajo.



SHAFaq MUSSADIQ recibió la maestría en ciencias de la computación y el Ph.D. título de la Escuela de Ingeniería Eléctrica y Ciencias de la Computación, NUST, Islamabad. Actualmente es profesora asistente en el Instituto de Tecnología de la Información de la Universidad de Ciencia y Tecnología de Kohat, Kohat. Su trabajo de investigación incluye aprendizaje automático, redes neuronales profundas, tecnologías multimedia y big data en educación.



ARSALAN ALI RAZA actualmente está cursando el Ph.D. licenciatura en ciencias de la computación con la Universidad Kohat de Ciencia y Tecnología, Kohat, Pakistán. Actualmente es profesor de informática en el Instituto COMSATS de Tecnología de la Información de Pakistán. Su interés de investigación incluye la ingeniería del lenguaje natural, la minería de datos, el aprendizaje automático y la inteligencia artificial.



MUHAMMAD ABID recibió el Ph.D. título del Instituto de Computación, Universidad de Ciencia y Tecnología de Kohat, Kohat. Actualmente trabaja en varios proyectos relacionados con la automatización y transparencia de las instituciones educativas. Su área de investigación incluye procesamiento de lenguaje natural, aprendizaje automático y minería de datos.



SANA ULLAH KHAN recibió la maestría en informática de la Islamia College University Peshawar en 2014, donde actualmente está cursando el doctorado. Grado en el campo del procesamiento de imágenes médicas. También es miembro permanente de la facultad del Instituto de Computación de la Universidad de Ciencia y Tecnología de Kohat (KUST), Kohat, donde se desempeñó como profesor durante los últimos tres años. Es autor de diversos artículos de investigación de revistas y congresos. Sus intereses de investigación

incluyen visión por computadora, imágenes médicas, aprendizaje automático, computación en la nube y aprendizaje profundo.

...

MARYAM BASHIR actualmente está cursando el Ph.D. título con el Instituto de Computación, Universidad Kohat de Ciencia y Tecnología, Pakistán. Su doctorado La tesis es sobre minería de datos de trayectoria. Actualmente es profesora invitada en el Government Post Graduate College, Kohat.