


Listas de contenidos disponibles en [ScienceDirect](https://www.sciencedirect.com)

Informática y Educación: Inteligencia Artificial

página de inicio de la revista: www.elsevier.com/locate/caeai



Redes neuronales artificiales en la predicción del rendimiento académico: Sistemática implementación y evaluación de predictores



Carlos Felipe Rodríguez-Hernández^{a,*}, Mariel Mussó^B, Eva Kyndt^{CD}, Eduardo Cascallar^a

^a Centre for Professional Learning & Development, Corporate Training and Lifelong Learning, KU Leuven, Bélgica, Dekenstraat 2, PB3772, 3000, Lovaina, Bélgica
Centro Interdisciplinario de Investigaciones en Psicología Matemática y Experimental (CIIPME), Consejo Nacional de Investigaciones (CONICET), UADE, Argentina, Juan D. Perón, 2158, Buenos Aires, Argentina

^c Departamento de Formación y Ciencias de la Educación, Universidad de Amberes, Sint-Jacobstraat 2, 2000, Amberes, Bélgica

^D Centro para la Nueva Fuerza Laboral, Universidad Tecnológica de Swinburne, Melbourne, Australia

INFORMACIÓN DEL ARTÍCULO

Palabras clave:

Redes neuronales artificiales

Predicción

Desempeño académico

Educación más alta

ABSTRACTO

Las aplicaciones de la inteligencia artificial en la educación se han incrementado en los últimos años. Sin embargo, más conceptos y se necesita comprensión metodológica para avanzar en la implementación sistemática de estos enfoques. El primer objetivo de este estudio es probar un procedimiento sistemático para implementar redes neuronales artificiales para predecir rendimiento académico en la educación superior. El segundo objetivo es analizar la importancia de varios predictores bien conocidos del rendimiento académico en la educación superior. La muestra incluyó a 162.030 estudiantes de ambos géneros de universidades públicas y privadas de Colombia. Los resultados sugieren que es posible sistemáticamente implementar redes neuronales artificiales para clasificar el rendimiento académico de los estudiantes como alto (precisión del 82%) o bajo (precisión del 71%). Las redes neuronales artificiales superan a otros algoritmos de aprendizaje automático en la evaluación métricas como el recuerdo y la puntuación F1. Además, se encuentra que el rendimiento académico previo, las condiciones socioeconómicas y las características de la escuela secundaria son predictores importantes del rendimiento académico de los estudiantes en la educación superior. Finalmente, este estudio discute recomendaciones para implementar redes neuronales artificiales y varias consideraciones para el análisis del rendimiento académico en la educación superior.

1. Introducción

La educación, al igual que muchas otras áreas de la sociedad y la actividad humana, ha sido impactado significativamente por los avances tecnológicos recientes. Las revisiones de las últimas cinco décadas han demostrado (Chen, Zou, Cheng y Xie, 2020; Chen, Zou y Xie, 2020). Una de esas áreas de grandes avances ha sido la aplicación de la inteligencia artificial en la educación (AIED). Esta ha crecido en los últimos 25 años (Roll & Wylie, 2016) e implica conocimientos recién adquiridos de las ciencias de la computación y la educación campo. La simulación del comportamiento inteligente humano usando computadora. implementaciones ha resultado en varias aplicaciones educativas reportadas en la literatura, tales como un "tutor inteligente, tutelado, aprendizaje herramienta/socio o asesor en la formulación de políticas" (Hwang et al., 2020, p. 2). En evaluación educativa, estas nuevas metodologías han mejorado todos aspectos de sus procesos mediante la introducción de redes de datos de alta velocidad y la gestión de una amplia gama de datos para evaluaciones sin necesidad de traditional testing (Cascallar et al., 2006; Kyndt et al., 2015; Musso &

Cascallar, 2009; Musso et al., 2012, 2013; Musso et al., 2020). A relevante el objetivo de la investigación al respecto es la evaluación del desempeño y la experiencia de los estudiantes (Hwang et al., 2020). En concreto, la predicción del rendimiento académico en la educación superior proporciona varios beneficios a docentes, estudiantes, legisladores e instituciones. Lograr tal capacidad predictiva con una precisión razonable podría mejorar la selección proceso de los estudiantes que deben recibir ayudas o becas, podría evitar futuros fracasos académicos y aumentar la retención proporcionando conocimientos avanzados sobre la necesidad de intervenciones positivas, y podría servir para identificar qué prácticas docentes podrían tener un impacto más positivo impacto en el aprendizaje de los estudiantes (Musso et al., 2013).

En cuanto a la perspectiva metodológica, Golino y Gomes (2014) reportan que los coeficientes de correlación, análisis de regresión lineal y logística, análisis de varianza (ANOVA) y modelado de ecuaciones estructurales (SEM) son los métodos más utilizados para predecir el rendimiento académico de los estudiantes. Las técnicas estadísticas tradicionales deben cumplir una serie de supuestos tales como independencia de las observaciones, homogeneidad de la varianza,

* Autor correspondiente.

Direcciones de correo electrónico: rodriguezcf@gmail.com (CF Rodríguez-Hernández), mariel.musso@hotmail.com (M. Musso), eva.kyndt@uantwerpen.be (E. Kyndt), cascallar@msn.com (E. Cascallar).

<https://doi.org/10.1016/j.caeai.2021.100018>

Recibido el 12 de diciembre de 2020; Recibido en forma revisada el 29 de marzo de 2021; Aceptado el 31 de marzo de 2021

2666-920X/© 2021 El(los) autor(es). Publicado por Elsevier Ltd. Este es un artículo de acceso abierto bajo la licencia CC BY-NC-ND (<http://creativecommons.org/licenses/by-nc-nd/4.0/>).

normalidad y linealidad (Field, 2009; Tacq, 1997). Sin embargo, varios de estos supuestos no siempre son informados por los investigadores. Posibles efectos indeseables de violar supuestos estadísticos tales como tipo I y errores tipo II (Nimon, 2012) y estimación inadecuada de los tamaños del efecto de parámetros estadísticos (Osborne & Waters, 2002) son ignorados. Además, cuando se analizan grandes conjuntos de datos mediante técnicas estadísticas tradicionales, los valores p de los modelos predictivos se aproximan a cero, por lo que los resultados son siempre estadísticamente significativos debido al tamaño de la muestra más que la existencia de una relación verdaderamente significativa (Khalilzadeh y Tasci, 2017). Por lo tanto, se puede argumentar que el uso de los tradicionales las técnicas estadísticas podrían haber introducido algún sesgo al investigar el desempeño académico de los estudiantes en la educación superior.

Una importante contribución de la inteligencia artificial y la El área de aprendizaje automático ha sido la capacidad de construir modelos predictivos del rendimiento académico de los estudiantes a través de redes neuronales artificiales (ANN) (Ahmad & Shahzadi, 2018; Kyndt et al., 2015; Lau et al., 2019; Musso et al., 2012, 2013; Yildiz Yildiz Aybek & Okur, 2018). Las RNA implican la posibilidad de utilizar todas las interacciones entre variables predictoras para lograr una mejor estimación de la variable resultado (Cascallar et al., 2015) y posee la capacidad de obtener una predicción incluso cuando el las variables independientes y dependientes están relacionadas de forma no lineal (Somers & Casal, 2009). Las ANN también permiten el análisis de grandes volúmenes de información y la construcción de modelos predictivos independientemente de la distribución estadística de los datos (Garson, 2014). Sin embargo, una falta de comprensión conceptual y metodológica ha impedido un aumento en el uso de ANN entre los investigadores educativos, ya que han preferido para ajustar modelos predictivos basados en enfoques más tradicionales como regresiones lineales múltiples (p. ej., Bonsaksen, 2016; De Clercq et al., 2013; Gerken & Volkwein, 2000; Zheng et al., 2002).

En su reciente publicación, Alyahyan y Düştegor (2020) proponen un framework para aplicar técnicas de minería de datos para predecir el desempeño académico de los estudiantes. Alyahyan y Düştegor (2020) afirman que este marco podría promover un acceso más fácil a las técnicas de minería de datos para investigadores educativos, por lo que las ventajas de estas herramientas de análisis pueden ser totalmente explotado. Como tal, se deben considerar tres elementos: (1) la definición de rendimiento académico; (2) los predictores de rendimiento académico rendimiento; y (3) las seis etapas para construir un modelo predictivo, a saber, recopilación de datos, preparación inicial, análisis estadístico, datos preprocesamiento, implementación de modelos y evaluación de modelos.

Basado en el marco sugerido por Alyahyan y Düştegor (2020) El primer objetivo de este estudio es probar un procedimiento sistemático para la implementación de ANN para modelar dos niveles de rendimiento diferentes grupos de la prueba SABER PRO en una cohorte de 162.030 estudiantes universitarios colombianos. Se presta especial atención a la implementación del modelo y etapas de evaluación del modelo, ya que estas etapas comprenden la mayoría de las decisiones de diseño que deben tomarse al implementar ANN. Lo esperado contribución implica la sugerencia de varias decisiones de diseño para implementar ANN para que su uso pueda extenderse aún más entre la educación investigadores

El segundo objetivo de este estudio es analizar la importancia relativa del rendimiento académico previo, el nivel socioeconómico, la educación secundaria características y estado de trabajo al predecir cada rendimiento grupo de nivel. La contribución esperada es identificar los mejores indicadores de futuros de bajo rendimiento, lo que podría proporcionar información útil como sistema de alerta temprana en el ámbito educativo. Además, comprender qué patrones específicos de factores conducen a un alto rendimiento futuro ayudaría a promover estas condiciones positivas.

En línea con estos objetivos generales, este estudio se centra en cuatro preguntas específicas de investigación:

1. Qué efectos se identifican durante el ajuste de hiperparámetros de las RNA para clasificar el rendimiento académico de los estudiantes de educación superior?
2. ¿Cómo se pueden obtener curvas de error con límites de desviación estándar de las RNA capacitadas para clasificar el rendimiento académico de los estudiantes en niveles superiores ¿educación?

3. ¿Cuál es la calidad general de los modelos predictivos del desempeño académico de los estudiantes en la educación superior basados en ANN en comparación con los basados en otras metodologías predictivas?
4. ¿Cuál es la importancia de los logros académicos previos, el estatus socioeconómico, las características de la escuela secundaria y el estatus laboral cuando son seleccionados como predictores del rendimiento académico de los estudiantes en ¿educación más alta?

2. Vanguardia

2.1. Las pruebas estandarizadas como indicador del rendimiento académico

Las pruebas estandarizadas se pueden usar de diferentes maneras, incluida la capacidad de rendición de cuentas, la evaluación y la evaluación (Morris, 2011). En particular, las pruebas estandarizadas evalúan el nivel de conocimiento en áreas temáticas (p. ej., matemáticas, física y química) o desempeño en competencias (p. ej., razonamiento verbal, cuantitativo y escritura) (Kuncel & Hezlett, 2007). Exámenes como el Scholastic Assessment Test (SAT) administrados en EE . UU . (Sackett et al., 2012) o el SweSAT administrado en Suecia (Cliffordson, 2008) se ha informado que son predictores de un mayor rendimiento académico en las universidades. Como un caso único en la educación superior, Las pruebas estandarizadas se utilizan en Colombia no solo para verificar la preparación académica de los estudiantes antes de la universidad, sino también para medir tanto la competencias genéricas y específicas que hayan adquirido durante sus estudios universitarios. En este sentido, el Instituto Colombiano para la Educación Evaluación (Instituto Colombiano de Evaluación Educativa, ICFES) diseña y gestiona dos pruebas nacionales para la educación superior.

El SABER 11 es una prueba estandarizada requerida para la admisión a la educación superior. instituciones educativas en Colombia. La versión de la prueba SABRE 11 utilizado en el presente estudio es un grupo de exámenes que evalúan el nivel de los estudiantes de logro en ocho áreas temáticas al final de la escuela secundaria: biología, física, química, matemáticas, español, inglés, ciencias sociales y filosofía. Cada prueba de materia consta de preguntas de opción múltiple con solo una respuesta correcta y tres distractores. Los resultados de las pruebas se reportan utilizando una escala de 0 a 100 para cada tema resultante de un ítem. análisis de la teoría de la respuesta (IRT) de los datos. Una nueva versión del SABRE 11 prueba (introducida en 2014) evalúa el desempeño de los estudiantes en las secciones de lectura crítica, matemáticas, ciencias sociales, competencias cívicas, ciencias naturales e inglés; y mantiene el mismo tipo de pregunta y sistema de puntuación como la versión anterior de la prueba (ICFES, 2021a).

El SABER PRO es un examen estandarizado requerido para graduarse de instituciones de educación superior en Colombia. Este examen evalúa a los estudiantes desempeño en las siguientes competencias genéricas: lectura crítica, razonamiento cuantitativo, comunicación escrita, competencias cívicas y Inglés. Cada sección de la prueba consta de preguntas de opción múltiple con solo una respuesta correcta y tres distractores. Además, el SABRE PRO evalúa competencias específicas como el pensamiento científico para la ciencia y la estudiantes de ingeniería; enseñanza, formación y evaluación de estudiantes de educación; gestión de conflictos y comunicación judicial para estudiantes de derecho; producción agropecuaria para estudiantes de ciencias agropecuarias; diagnóstico y tratamiento médico para estudiantes de medicina; y organizacional y gestión financiera para estudiantes de administración de empresas. El marcador para cada competencia genérica se informa utilizando una escala que va de 0 a 300 resultado de un análisis IRT de los datos (ICFES, 2021b).

2.2. Predictores del rendimiento académico en la educación superior

Aunque una revisión exhaustiva de estudios previos sobre la predicción del rendimiento académico excede la meta de este artículo, la Tabla 1 resume los hallazgos más recientes en el campo durante los últimos 10 años, destacando los predictores analizados más importantes, la metodología enfoques utilizados y los principales resultados informados (ver Tabla 1). La literatura muestra un aumento significativo en las técnicas de aprendizaje automático utilizadas con fines de predicción del rendimiento académico. Sin embargo, los procedimientos utilizados en la implementación de estos algoritmos involucran varias decisiones

Tabla 1

Resumen de estudios previos sobre la predicción del rendimiento académico.

predictores	Enfoque metodológico	Referencias	Resultados de precisión
Académico previo logro (resultados de la escuela secundaria, resultados de la prueba de admisión, GPA semestral, curso individual marcas de letras e individuales evaluación Los grados)	Red bayesiana, árbol de decisión, k más cercano vecinos, regresión logística, bayesiano ingenuo, red neuronal NN (probabilística), basada en reglas, inducción de reglas, bosque aleatorio, árbol aleatorio.	Adekitan y Salau (2019); Ahmed et al. (2015); Al-barrak y Al-razgan (2016); Almarabeh (2017); Aluko et al. (2018); Anuradha y Velmurugan (2015); Asif et al. (2017); Asif et al. (2015); Cascallar et al. (2006); Garg (2018); Hamoud et al. (2018); Mesario c and Sebalj (2016); Mohamed and Waguih (2017); Mueen et al. (2016); Musso and Cascallar (2009); Singh y Kaur (2016); Sivasakthi (2017); Yassein et al. (2017)	Predicción a nivel de grado y año: precisiones del 62 % al 89 % Predicción del éxito a nivel de curso: precisiones más del 89%. La mejor precisión se obtuvo en el nivel del curso con un 93% (MLP; Sivasakthi, 2017) Una fuerte relación entre WM y el aprendizaje de categorías, con una sola variable latente. WM media el aprendizaje de categorías en una amplia gama de tareas. (Lewandowsky, 2011) La atención sostenida predice la escuela desempeño más allá de la inteligencia (R2 ¼ .13)
Procesos cognitivos (WM General Inteligencia Atención Ejecutivo Funciones)	La mayoría de ellos clásico usado regresión lineal estadística. Pocos estudios aplicaron ANN	Lewandowsky (2011); Kingston y Lyddy (2013); Pérez et al. (2012); Steinmayr et al. (2010); Cascallar et al. (2006); Kyndt et al. (2015); Luft et al. (2013); Musso et al. (2012); Musso et al. (2013); Musso et al. (2020)	Steinmayr et al. (2010) RNA: 83,7% de precisión total que predice el bajo rendimiento (Luft et al., 2013) ANN logró niveles de precisión del 90 al 100 % (Autores)
autorregulado Factores de aprendizaje (Creencias motivacionales, autoeficacia, Aprendiendo Estrategias, interés del estudiante, comportamiento de estudio, estrés, ansiedad, tiempo de preocupación)	La mayoría de ellos utilizaron regresión lineal estadística clásica, modelado de ecuaciones estructurales, correlaciones. Pocos estudios aplicaron enfoques de aprendizaje automático	Bulús (2011); Kingston y Lyddy (2013); Pérez et al. (2012) Garg (2018); Hamud et al. (2018); Kyndt et al. (2015); Mueen et al. (2016); Musso et al. (2012); Musso et al. (2020); Putpuek et al. (2018)	Académico el logro fue predicho por orientaciones de meta y locus de control todo juntos (R2 ¼ .60) (Bulus, 2011) La autoeficacia y la WM predicen el 19 % de la varianza en las puntuaciones de las pruebas de aritmética (Kingston & Lyddy, 2013). El total SEM (R2 ¼ .659). Habilidad, esfuerzo y estrategias de aprendizaje mediadas entre las metas académicas y el Rendimiento Académico (Perez et al., 2012)
estudiante social datos demográficos (Género, edad, raza/etnicidad, nivel socioeconómico)	Red bayesiana, árbol de decisión, k más cercano vecinos, regresión logística, bayesiano ingenuo, red neuronal NN (probabilística), basada en reglas, inducción de reglas, bosque aleatorio, árbol aleatorio.	(2015); Anuradha y Velmurugan (2015); Garg (2018); Hamud et al. (2018); Mohamed y Waguih (2017); Muen et al. (2016); Putpuek et al. (2018); Singh y Kaur (2015)	Ahmed et al. (2015): RB-71,3% Anuradha y Velmurugan (2015): NB 75,2%)

Tabla 1 (continuación)

predictores	Enfoque metodológico	Referencias	Resultados de precisión
entorno del estudiante (tipo de clase, semestre duración, tipo de programa)	Red bayesiana, árbol de decisión, k más cercano vecinos, regresión logística, naïve Bayes (NB), red neuronal NN (probabilística), basada en reglas, inducción de reglas, bosque aleatorio, árbol aleatorio.	(2016); Sivasakti (2017) Adekitan y Salau (2019); Ahmed et al. (2015); Hamud et al. (2018); Mesari c y Sebalj (2016); Mohamed y Waguih (2017); Muen et al. (2016)	Hamoud et al. (2018): REPTree-62.3% Mohamed y Waguih (2017): J48–85,6% Muen et al. (2016): NB-86% Putpuek et al. (2018): Nota: 43,18 % Singh y Kaur (2016): J48–67,37 % Sivasakthi (2017): MLP-93% Adekitan y Salau (2019): LR - 89,15% Mesari c y Sebalj (2016): J48 - NA

Fuente: Basado en Alyahyan y Düs,tegor (2020) y Musso (2016)

puntos y el ajuste fino de los parámetros del modelo que continúan aplicándose caso por caso y están más influenciados por la elección individual que por metodologías consistentes. El presente estudio aborda este vacío metodológico explorando sistemáticamente el procedimiento involucrado en la implementación de ANN y brindando pautas para las decisiones necesarias en las diversas etapas de implementación del análisis de datos y evaluación del modelo.

Por otro lado, se han realizado un número considerable de estudios para identificar qué factores pueden explicar el rendimiento académico de los estudiantes en la educación superior. Estos factores se han clasificado en varias categorizaciones teóricas. Por ejemplo, McKenzie y Schweitzer (2001) proponen cuatro categorías: factores académicos, cognitivos, demográficos y psicosociales. El metanálisis de Richardson et al. (2012) propone seis categorías: datos demográficos (es decir, género, edad y nivel socioeconómico), factores tradicionales (es decir, logros académicos previos), rasgos personales, factores motivacionales, experiencias de aprendizaje autorreguladas e influencias contextuales psicosociales. Una clasificación adicional que abarca cuatro categorías ha sido propuesta por De Clercq et al. (2017) que distinguen el desempeño pasado, el estatus socioeconómico, las creencias de autoeficacia y la elección de estudios. Una comparación entre estas diferentes clasificaciones revela que el rendimiento académico previo y el estatus socioeconómico son dos categorías compartidas de predictores del rendimiento académico de los estudiantes. Sin embargo, también se han explorado en la literatura dos categorías adicionales de predictores: características de la escuela secundaria (p. ej., Black et al., 2015; Win & Miller, 2005) y estado laboral (p. ej., Triventi, 2014; Yanbarisova, 2015).

2.3. Red neuronal artificial (RNA)

Una RNA es un sistema de procesamiento de información formado por unidades de procesamiento denominadas neuronas (Garson, 2014; Haykin, 2009). Una neurona, que permite mapear diferentes entradas en una salida, es el elemento más fundamental en cualquier ANN. Para ello, cada neurona tiene un bloque de suma donde se suman las entradas después de ser ponderadas y una función de activación, donde se calcula la salida después de recibir el resultado del bloque de suma. Los pesos representan la fuerza de la conexión entre las neuronas y la información utilizada por la red para minimizar el error con respecto a la salida (Fausett, 1994). En general, cualquier ANN podría caracterizarse por (1) su disposición de conexiones entre las neuronas (llamada su topología), (2) su enfoque para obtener la fuerza o los pesos en las conexiones (llamado su algoritmo de entrenamiento o aprendizaje), y (3) su función de activación (Fausett, 1994).

2.3.1. El perceptrón multicapa (MLP)

La topología ANN elegida para el presente estudio es la MLP. Las MLP son probablemente el tipo más común de ANN y son conocidas por su utilidad predictiva (Garson, 2014). Un MLP tiene una estructura que consta de al menos tres capas: la capa de entrada, la capa oculta y la capa de salida.

La capa de entrada representa las variables independientes o predictores, la capa oculta es donde se realiza el mapeo para relacionar la entrada y la salida, y la capa de salida se asemeja a la variable dependiente (Somers & Casal, 2009). Los MLP se pueden utilizar para resolver problemas de predicción y clasificación (Garson, 2014; Haykin, 2009). Además, se pueden seleccionar varias funciones de activación al implementar un MLP. El uso de funciones como la tangente hiperbólica o sigmoide permite que las redes neuronales identifiquen relaciones complejas y no lineales entre las entradas y las salidas (Somers & Casal, 2009).

2.3.2. Entrenamiento del MLP Una

forma común de entrenar un MLP es el aprendizaje supervisado. En los problemas de clasificación, el propósito del aprendizaje supervisado es determinar si los sujetos pertenecen a ciertos grupos o categorías en función del conjunto de predictores. Como tal, hay una categoría objetivo para la cual se maximiza la precisión de la clasificación. Como también hay información sobre el conjunto de predictores y la salida correspondiente para cada sujeto, un MLP puede aprender de estos patrones de información. Según Haykin (2009), el aprendizaje supervisado de un MLP puede ocurrir de dos maneras diferentes: aprendizaje por lotes y en línea. En el aprendizaje por lotes, todos los casos en la partición de entrenamiento se presentan al MLP a la vez; mientras que en el aprendizaje en línea, cada caso en la partición de capacitación se entrega al MLP individualmente. El método de aprendizaje en línea que usa aprendizaje supervisado ha sido seleccionado para el presente estudio ya que este método es fácil de implementar, es capaz de rastrear pequeños cambios en los datos de entrenamiento y es ampliamente utilizado para resolver problemas de clasificación (Haykin, 2009).

2.3.3. El algoritmo de retropropagación El uso

del método en línea con aprendizaje supervisado para un MLP se ha incrementado con la implementación del algoritmo de retropropagación, que ocurre en dos etapas (Haykin, 2009). En la etapa de avance, se calculan los pesos predictivos del MLP y la señal de entrada se transmite a través de las capas hasta llegar a la salida. Luego, en la segunda etapa, se genera una señal de error comparando la salida del MLP con el valor esperado. Esta señal de error también se propaga capa por capa pero en sentido inverso. De esta forma, un MLP puede optimizar el valor de los pesos predictivos anteriores minimizando el error en cada ciclo hasta alcanzar un cierto nivel de precisión. Para hacerlo, un MLP usa una función de optimización para optimizar los pesos para reducir el error de la función de error. El descenso de gradiente es la función de optimización elegida en el presente estudio para minimizar el error de la función de error cuadrático medio.

Dos parámetros de un MLP se ajustan durante el algoritmo de propagación hacia atrás: la tasa de aprendizaje, que cambia el valor de los pesos en cada iteración del proceso de aprendizaje; y el impulso, que aumenta la velocidad del proceso de aprendizaje al agregar una fracción del cambio de peso anterior al cambio de peso actual (Attoh-Okine, 1999).

2.3.4. Métricas para evaluar la clasificación obtenida por modelos ANN

Hay dos formas diferentes de evaluar la calidad de las clasificaciones obtenidas a través de modelos ANN. El primero es obtener una curva de error durante la fase de entrenamiento (Garson, 2014; Haykin, 2009). Esto puede permitir comparar el resultado deseado con el resultado real proporcionado por el modelo para cada iteración del entrenamiento. El segundo es el uso de conocidas métricas de evaluación basadas en la matriz de confusión del

clasificación (Saito & Rehmsmeier, 2015). En este sentido, se deben obtener índices como el de Verdadero Positivo (TP), Verdadero Negativo (TN), Falso Positivo (FP) y Falso Negativo (FN) para calcular varias métricas de evaluación (Musso et al., 2013; Saito & Rehmsmeier, 2015). Estas métricas de evaluación son la precisión definida como $(TP \div TN) / (TP \div FP \div FN \div TN)$,

el recuerdo definido como $TP / (TP \div FN)$, la precisión definida como $TP / (TP \div FP)$ y la puntuación F1 definida como $2(\text{Recuerdo} * \text{Precisión}) / (\text{Recuerdo} \div \text{Precisión})$.

Cuando la clasificación de interés involucra datos no balanceados, el valor de precisión puede ser engañoso, especialmente cuando la categoría negativa es la dominante, ya que un valor de precisión alto indicaría que solo la categoría negativa se está clasificando correctamente (Juba & Le, 2019). Por eso es necesario calcular medidas adicionales como la precisión, el recuerdo y la puntuación F1. Dado que existe un equilibrio entre la precisión y el recuerdo (Álvarez, 2002), es importante elegir qué métrica proporciona más información sobre la calidad de la clasificación proporcionada por los modelos ANN. Tal elección implica penalizar ya sea la FP (una decisión de precisión) o la FN (una decisión de revocación). En este estudio, nuestro objetivo es obtener ANN con alto recuerdo, lo que lleva a clasificar la mayor cantidad posible de estudiantes que realmente pertenecen a cada uno de los grupos de desempeño.

3. Material y métodos

3.1. Seis etapas para la implementación sistemática de modelos ANN

La figura 1 muestra las seis etapas propuestas por Alyahyan y Düs,tegor (2020), las cuales se siguieron para responder las tres primeras preguntas de investigación planteadas en este estudio. Esta sección describe cada una de las etapas y explica cualquier decisión de diseño tomada durante la implementación de las ANN.

3.1.1. Recopilación de datos

El ICFES proporcionó los datos para este estudio. El conjunto de datos original contenía aproximadamente 200.000 registros de estudiantes universitarios colombianos que se presentaron a la prueba SABER PRO en 2016. Para cada estudiante, había información sobre sus resultados de la prueba SABER 11, su información socioeconómica, sus características de escuela secundaria y su estado laboral. El conjunto de datos original también contenía información adicional, como el género, la edad y el programa académico de los estudiantes. Tenga en cuenta que la identidad de los estudiantes permaneció en el anonimato ya que los estudiantes fueron etiquetados mediante un código en el conjunto de datos proporcionado por el ICFES.

3.1.2. Preparación inicial

Después de eliminar los datos faltantes, incorrectos o duplicados en el conjunto de datos original, la muestra final incluyó a 162 030 estudiantes de ambos sexos, mujeres (60 %) y hombres (40 %), con una edad media de 23,5 años (DE $\frac{1}{2}$ 2,89 años). tanto de universidades privadas (64,4%) como públicas (35,6%) en Colombia.

Los alumnos egresaron de secundarias académicas (61,6%), secundarias tanto académicas como técnicas (18,1%), secundarias técnicas (16,7%) y secundarias de formación docente (3,6%).

Además, los estudiantes de la muestra estaban estudiando alguno de los diferentes programas académicos: agronomía, medicina veterinaria y carreras afines (1,3%); artes (3,5%); economía, gestión y contabilidad (25,4%); educación (8,7%); ingenierías, arquitectura, urbanismo y carreras afines (25,6%); salud (11,4%); matemáticas y ciencias naturales (2,1%); y ciencias sociales y humanas (21%). A continuación, las variables existentes en el conjunto de datos se ordenaron en función de sus similitudes, lo que llevó a la creación de las siguientes categorías: Rendimiento académico previo. Los puntajes de los estudiantes en las siete áreas temáticas (biología, física, química, matemáticas, español, ciencias sociales y filosofía) de la prueba SABER 11 (entre 2006 y 2011) fueron seleccionados como indicadores de rendimiento académico previo.

Tasas de matrícula. Esta medida se refiere a cómo los estudiantes pagan sus tasas de matrícula. Los estudiantes pagan sus tasas de matrícula a través de una o varias fuentes de financiación: padres, préstamos educativos, recursos propios y becas.

Situación socioeconómica de los estudiantes. El nivel educativo de los padres, la ocupación de los padres y el ingreso familiar mensual se seleccionan como indicadores del estatus socioeconómico de los estudiantes (Rodríguez-Hernandez et al., 2020; Sirin, 2005; Van Ewijk & Slegers, 2010).

Características del hogar de los estudiantes. El número de cuartos, si un estudiante tiene computadora y acceso a Internet en el hogar, el tipo de alojamiento (permanente o temporal) y el estrato del hogar se combinan bajo esta medida. El estrato de origen se refiere a los siete



Fig. 1. Etapas del marco de Minería de Datos Educativos (Alyahyan & Düşteğör, 2020).

categorías (de 0 a 6) utilizadas por el gobierno colombiano para clasificar los hogares en función de sus características físicas y del entorno de la vivienda. La razón principal detrás de esta clasificación del gobierno es establecer y ajustar jerárquicamente el precio de los servicios públicos en cada área (The World Bank, 2012).

Estado del hogar de los estudiantes. Esta medida indica si un estudiante es cabeza de familia y, de ser así, el número de personas que tiene a su cargo.

Antecedentes de los estudiantes. La edad de los estudiantes al tomar la prueba SABER PRO y su género definen sus antecedentes.

Características de la escuela secundaria. Varias características de la escuela secundaria son parte de esta medida. Estas características incluyen el calendario académico de la escuela secundaria de los estudiantes (indicado por el mes de inicio del año académico), la "composición de género" de la escuela secundaria (solo hombres, solo mujeres o mixta), el tipo de escuela secundaria (pública o privada), horario de la escuela secundaria (es decir, jornada completa, solo por la mañana, solo por la tarde, solo por la noche o solo el fin de semana) y diploma de escuela secundaria (académica, técnica, técnica académica o formación docente).

Estado de trabajo. El número de horas trabajadas semanalmente es un indicador de la situación laboral de los estudiantes (Beauchamp et al., 2016; Triventi, 2014).

Antecedentes universitarios. Bajo esta medida de formación universitaria se analizan el número de semestres académicos completados por el estudiante antes de tomar la prueba SABER PRO, el tipo de universidad (por ejemplo, pública o privada) y el programa académico del estudiante.

Rendimiento académico en la educación superior. Los resultados de los estudiantes en la sección cuantitativa de la prueba SABER PRO de la administración 2016 fueron elegidos como la operacionalización del rendimiento académico en la educación superior.

3.1.3. análisis estadístico

El Apéndice A incluye las estadísticas descriptivas de las variables analizadas en este estudio. Tanto las frecuencias relativas como las absolutas se calcularon para las variables categóricas, mientras que las medias y las desviaciones estándar se calcularon para las variables continuas. No se encontraron valores atípicos en estos análisis.

Además, se encontraron coeficientes de correlación moderados entre los resultados de la prueba SABRE 11 y la prueba SABRE PRO: español ($r(162,030) = .42, p < .01$), matemáticas ($r(162,030) = .578, p < .01$), ciencias sociales ($r(162,030) = .451, p < .01$), filosofía ($r(162,030) = .328, p < .01$), biología ($r(162,030) = .469, p < .01$), química ($r(162,030) = .486, p < .01$) y física ($r(162,030) = .403, p < .01$).

3.1.4. Preprocesamiento de

datos Se siguieron cinco pasos para preprocesar el conjunto de datos analizados en este estudio. En el paso 1, los resultados de los estudiantes de la prueba SABER PRO se categorizaron utilizando los niveles de desempeño utilizados por el ICFES. De esta manera, la categorización de los niveles de desempeño de los estudiantes se basó en estándares de desempeño preexistentes en lugar de clasificarse con un enfoque de referencia normativa. Específicamente, el ICFES clasifica los puntajes de los estudiantes desde el nivel 1 (desempeño más bajo) hasta el nivel 4 (desempeño más alto) con base en estándares referidos a criterios, definiendo descriptores generales y específicos de lo que los estudiantes son capaces de hacer en cada nivel de desempeño, tal como se presenta en la Tabla 2. A medida que aumenta el nivel de desempeño, también aumenta la complejidad de los descriptores, ya que un mayor nivel de desempeño abarca tanto los descriptores de ese nivel como los descriptores de todos los niveles anteriores. Como tal, etiquetamos a todos los estudiantes clasificados en el nivel 1 como el grupo de "bajo rendimiento", mientras que todos los estudiantes clasificados en el nivel 4 fueron etiquetados como el grupo de "alto rendimiento". En el paso 2, los estudiantes fueron codificados ficticiamente como pertenecientes o no pertenecientes a

cada grupo de actuación. En el paso 3, se estandarizó cualquier variable continua independiente (es decir, se convirtió a una puntuación z) tal como se midió originalmente usando diferentes escalas. En el paso 4, todas las variables categóricas se codificaron de forma ficticia. Además, cada variable continua y cada categoría de las variables nominales y categóricas representa un nodo de entrada para las RNA. En consecuencia, había 122 nodos de entrada (capa de entrada) y 2 nodos de salida (capa de salida) en cada una de las ANN. En el paso 5, la muestra total se dividió en un conjunto de entrenamiento (70 %, $n = 113\,421$), un conjunto de validación cruzada (10 %, $n = 16\,203$) y un conjunto de prueba (20 %, $n = 32\,406$).

3.1.5. Implementación del modelo

La herramienta de software elegida para los análisis en este estudio fue Neuro Solutions 7.1, un paquete de red neuronal que combina una interfaz de diseño modular basada en iconos con la implementación de inteligencia artificial avanzada y algoritmos de aprendizaje con una interfaz fácil de usar. La etapa de implementación del modelo tuvo como objetivo entrenar y probar sistemáticamente las ANN para clasificar el rendimiento académico de los estudiantes. En esta etapa, se desarrollaron modelos predictivos utilizando los conjuntos de entrenamiento, validación cruzada y prueba. Las ANN fueron entrenadas y probadas siguiendo los pasos representados en la Fig. 2 mientras cambiaban los hiperparámetros enumerados en la Tabla 3. Los cambios sistemáticos en varios hiperparámetros (es decir, cinco valores de tasa de aprendizaje por nueve valores de impulso por tres funciones de activación) llevaron a 135 combinaciones para entrenar y probar ANN en cada grupo de rendimiento, lo que da como resultado 270 combinaciones. Durante cada época de entrenamiento, se generaron curvas de error de los conjuntos de entrenamiento y validación cruzada. Cuando la curva de error en el conjunto de validación cruzada comenzó a aumentar, fue una indicación para detener el entrenamiento para evitar el sobreajuste. Además, para cada combinación de hiperparámetros, se calcularon en el conjunto de pruebas las métricas de evaluación descritas en la sección 2.3.4. El modelo seleccionado en cada grupo de rendimiento fue el que poseía el conjunto de hiperparámetros que logró el mejor rendimiento en el conjunto de prueba.

3.1.6. Evaluación del modelo

La etapa de evaluación del modelo probó el modelo resultante para clasificar cada grupo de desempeño de dos maneras diferentes. Primero, cada modelo seleccionado se volvió a entrenar 30 veces (también durante 200 épocas) para generar la curva de error con límites de desviación estándar para los conjuntos de entrenamiento y validación cruzada. Es importante aclarar que los pesos de las ANN se inicializaron aleatoriamente para cada nueva ejecución de entrenamiento. Por tanto, se evitó la esperada mejora posterior de una formación anterior generando una nueva formación sin aprendizaje previo.

En segundo lugar, se desarrollaron varios otros algoritmos de aprendizaje automático (es decir, gran margen rápido, árbol de decisión, bosque aleatorio y árboles potenciados por gradiente) y técnicas estadísticas tradicionales (es decir, modelo lineal general y regresión logística) utilizando RapidMiner 9.8. Posteriormente, también se calcularon los valores de las métricas de evaluación descritas en el apartado 2.3.4 para estas metodologías predictivas adicionales. De esta manera, fue posible comparar la calidad general de la clasificación del rendimiento académico de los estudiantes proporcionada por las ANN frente a las demás metodologías predictivas.

3.2. La importancia relativa de los predictores del rendimiento académico en la educación superior

Se realizó un análisis de sensibilidad para responder a la cuarta pregunta de investigación planteada en este estudio. El análisis de sensibilidad se ha utilizado en investigaciones anteriores no solo como un método de selección de variables sino también para explicar un modelo (Kewley et al., 2000; Yeh & Cheng, 2010). Análisis de sensibilidad

Tabla 2

Niveles de desempeño para la sección de razonamiento cuantitativo de la prueba SABRE PRO.

Rendimiento nivel	Descriptor general	Descriptores específicos
Nivel 1 (Puntuación entre 0 y 125)	Un estudiante de este nivel. identifica información explícita de una sola fuente asociada a contextos cotidianos, que se presenta en tablas o gráficos de barras que contienen pocos datos o involucran como máximo dos variables.	Un estudiante de este nivel: Establece relaciones de similitud y orden a partir de la información proporcionada. Representa de diferentes maneras la información contenida en tablas y gráficos.
Nivel 2 (Puntuación entre 126 y 155)	Además de lo anterior, un estudiante de este nivel identifica e interpreta información explícita de varias fuentes, que se presenta en tablas y gráficos de barras, mientras utiliza procedimientos aritméticos simples a partir de la información proporcionada.	Además de lo descrito, un estudiante de este nivel: Identifica y extrae información explícita presentada en tablas y gráficos de barras. Representa información contenida en gráficos de barras en otros tipos de registro. Formula estrategias, valida procedimientos sencillos y resuelve problemas en contextos cotidianos relacionados con el uso del dinero, operaciones comerciales, etc., que requieren el uso de: - Una o dos operaciones, como suma, resta o multiplicación. - Propiedad distributiva de la multiplicación sobre la suma.
Nivel 3 (Puntuación entre 156 y 200)	Además de lo anterior, un estudiante de este nivel extrae información implícita contenida en representaciones inusuales asociadas a la misma situación y de una sola fuente de información, argumenta la validez de los procedimientos y resuelve problemas usando modelos que combinan pensamiento aritmético, algebraico y variacional.	Además de lo descrito, un estudiante de este nivel: Identifica y extrae información relevante, explícita o implícita presentada en gráficos inusuales, como gráficos de barras apiladas, diagramas circulares, etc. Identifica las diferencias entre las representaciones de datos asociadas con el mismo contexto. Pronostica los resultados, indicando un valor único o un posible intervalo, en función de las tendencias de los datos presentados. Propone estrategias y resuelve problemas utilizando cálculos de porcentajes, conversión de unidades estándar, promedios simples, nociones básicas de probabilidad o conteos que utilizan los principios de suma y multiplicación, en unos pocos pasos o cálculos.
Nivel 4 (Puntuación entre 201 y 300)	Además de lo anterior, un estudiante de este nivel identifica y utiliza información implícita contenida en representaciones inusuales de varias fuentes de información para entender un situación problema, argumenta la validez de los procedimientos, y los utiliza para resolver problemas, decidiendo cuál es el más adecuado.	Además de lo que fue descrito, un estudiante en este nivel: Reconoce el significado de expresiones aritméticas dadas en el contexto de resolver un problema. Establece y usa puntos de referencia en el plano, haciendo uso de nociones de paralelismo y rotaciones. Propone representaciones a partir de la manipulación

Tabla 2 (continuación)

Nivel de desempeño	Descriptor general	Descriptores específicos
		y transformación de datos relevantes en contextos con una o más fuentes de información. Propone estrategias y resuelve problemas, en contextos con información implícita, utilizando conversión de unidades no estándar, operaciones con decimales, el concepto de proporcionalidad y la regla de tres. Identifica y corrige errores en los procedimientos propuestos como solución a un problema. Resuelve problemas que requieren múltiples operaciones o aproximaciones como parte del proceso de solución. Valida y compara procedimientos de solución de un mismo problema y las soluciones obtenidas.

Fuente: Instituto Colombiano de Evaluación Educativa (ICFES).

también proporciona una medida de la importancia relativa de una variable de entrada al calcular cómo cambia la salida de la ANN de acuerdo con los cambios en esa entrada mientras que las entradas restantes permanecen fijas. Para comenzar el análisis de sensibilidad, cada variable de entrada se varió entre su valor mínimo y su valor máximo (rango entre 0 y 1 para las variables codificadas ficticias). Posteriormente, se normalizó la importancia relativa de cada variable de entrada, siendo 1 el valor de la variable más importante y las demás variables teniendo un valor de importancia medido con respecto a la más importante. A continuación, las variables de entrada se agruparon en las categorías definidas en la sección 3.1.2, calculándose la importancia de cada categoría sumando la importancia relativa de todas las variables dentro de esa categoría. Finalmente, se realizó una comparación entre los dos grupos de nivel de rendimiento.

4. Resultados

Los resultados de este estudio se dan de acuerdo con las preguntas de investigación. Se destacan los hallazgos derivados de las etapas de implementación del modelo y evaluación del modelo, dado que los hallazgos de las cuatro etapas anteriores son independientes en su descripción presentada anteriormente. En este apartado también se incluyen los resultados del análisis de los predictores del rendimiento académico de los estudiantes de educación superior.

4.1. Resultados de la etapa de implementación del modelo

La etapa de implementación del modelo tuvo como objetivo entrenar y probar sistemáticamente varias ANN para clasificar el rendimiento académico de los estudiantes. El Apéndice B incluye los resultados del entrenamiento y prueba de las ANN usando las 270 combinaciones de hiperparámetros. A continuación se describen los diferentes efectos encontrados en la etapa de implementación del modelo.

4.1.1. Efectos durante el entrenamiento

Se identificaron tres efectos durante el entrenamiento sistemático de las RNA. El primer efecto estuvo relacionado con la duración del entrenamiento. La duración del entrenamiento fue menor cuando el softmax se estableció como la función de transferencia de la capa de salida, independientemente de los valores de la tasa de aprendizaje y el impulso. Este hecho podría indicar que la función softmax converge más rápido hacia el error mínimo que las otras dos funciones de transferencia (sigmoides y sigmoides lineales). Sin embargo, un entrenamiento más rápido no garantiza necesariamente valores de error más bajos en la curva de error.

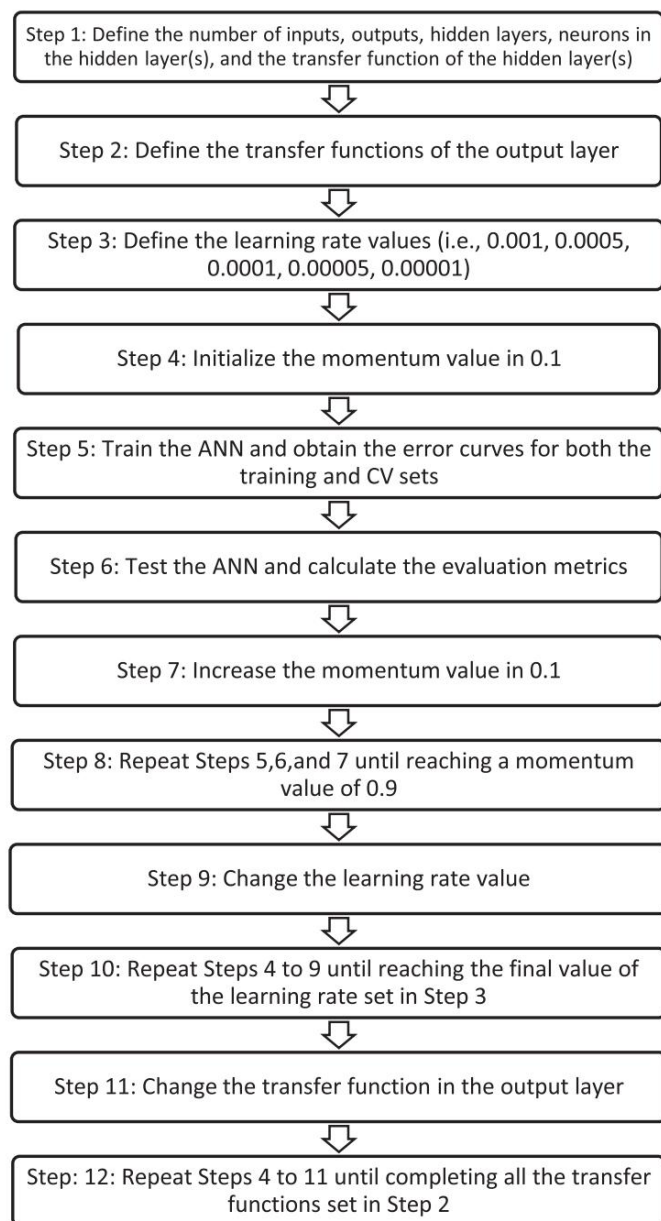


Fig. 2. Ajuste de los hiperparámetros de las ANN.

El segundo efecto estaba relacionado con el valor inicial de la curva de error. Este valor fue el más grande cuando se eligió el sigmoide lineal como la función de transferencia de la capa de salida con este efecto observado en los conjuntos de entrenamiento y validación cruzada. Por el contrario, cuando se definió sigmoide o softmax como la función de transferencia de la capa de salida, la curva de error comenzó desde un valor más bajo. Este mejor desempeño en la curva de error podría sugerir que el sigmoide o softmax es una opción más adecuada para las funciones de transferencia con respecto a la resolución de problemas de clasificación.

El tercer efecto estaba relacionado con el sobreajuste. Cuando se eligió el sigmoide lineal como la función de transferencia de la capa de salida, la curva de error para el conjunto de validación cruzada aumentó más rápidamente que en el caso de las otras dos funciones de transferencia. Tal comportamiento de la curva de error se observó independientemente de la tasa de aprendizaje y los valores de impulso. Cuando el sigmoide se estableció como la función de transferencia de la capa de salida, las curvas de error para los conjuntos de entrenamiento y validación cruzada fueron notablemente similares en las 200 épocas, lo que sugiere que no hubo sobreajuste en el modelo. En conjunto, estos hallazgos podrían sugerir que una función sigmoidea converge más efectivamente hacia el mínimo de la curva de error que la función sigmoidea.

otras dos funciones de transferencia.

4.1.2. Efectos durante la prueba

Los resultados del entrenamiento (Apéndice B) revelaron que los valores bajos de error durante el entrenamiento no necesariamente corresponden a mejores métricas de evaluación en las pruebas. Una explicación de este hallazgo podría ser una clasificación desequilibrada debido al sobreentrenamiento. En este contexto, el sobreentrenamiento puede entenderse como la falta de discriminación en el sistema predictivo debido a la inclusión de efectos de patrones aleatorios durante la clasificación.

Por lo tanto, solo una categoría (ya sea "perteneciente" o "no perteneciente") tuvo un valor extremadamente alto de casos correctamente clasificados.

En la prueba, el modelo final para el grupo de "alto rendimiento" clasificó correctamente al 82% de los estudiantes después de establecer los valores de los hiperparámetros de la siguiente manera: la tangente hiperbólica como la función de transferencia de la capa oculta, sigmoide como la función de transferencia de la capa de salida, una tasa de aprendizaje de .00005 y un impulso de .2. De manera similar, el modelo final para el grupo de "bajo rendimiento" clasificó correctamente al 71% de los estudiantes utilizando los siguientes valores de hiperparámetros: la tangente hiperbólica como función de transferencia de la capa oculta, sigmoide como función de transferencia de la capa de salida, un aprendizaje tasa de .0001, y un impulso de .4.

4.2. Resultados de la etapa de evaluación del modelo

La etapa de evaluación del modelo evaluó el modelo resultante para clasificar cada grupo de desempeño de dos maneras diferentes. [higos. 3 y 4](#) muestran la curva de error obtenida para cada grupo de prestaciones siguiendo el procedimiento descrito en el apartado 3.1.6. [higos. 3 y 4](#) ilustran que las curvas de error para los conjuntos de entrenamiento y validación cruzada fueron bastante similares después de 30 ejecuciones de entrenamiento, lo que también sugiere que no hubo sobreajuste en los modelos.

Estos hallazgos indican la consistencia en la clasificación proporcionada por las ANN. En otras palabras, se puede esperar que los resultados de la clasificación sean similares en varias ejecuciones de entrenamiento de las RNA.

[La Tabla 4](#) presenta los valores de las métricas de evaluación de los diferentes modelos predictivos para el grupo de "alto desempeño". La precisión es la más baja en el caso de las ANN. Sin embargo, los valores de precisión más altos podrían ser engañosos, ya que solo había 2260 estudiantes en el conjunto de prueba que pertenecían al grupo de "alto rendimiento" y 30 146 estudiantes que no (datos no balanceados). Aunque la precisión está por debajo del 60% en todos los modelos, las RNA detectan más falsos positivos, lo que hace que alcancen el valor de precisión más bajo. Por el contrario, el recuerdo y la puntuación F1 son los más altos en el caso de las ANN, lo que resulta en una diferencia considerable en el recuerdo a favor de las ANN. Estos resultados sugieren que las ANN logran un mejor desempeño ya que clasifican correctamente a la mayoría de los estudiantes que realmente pertenecen al grupo de "rendimiento alto" (mayor recuerdo) y también logran un mejor valor combinado entre la precisión y el recuerdo (mayor puntaje F1).

[La Tabla 5](#) presenta los valores de las métricas de evaluación de los diferentes modelos predictivos para el grupo de "bajo rendimiento". La precisión es la más baja en el caso de las ANN. Una vez más, las precisiones más altas podrían ser engañosas, ya que solo había 6580 estudiantes en el conjunto de pruebas que pertenecían al grupo de "bajo rendimiento" y 25 826 estudiantes que no (datos no balanceados). Aunque la precisión está por debajo del 60% en todos los modelos, las RNA detectan más falsos positivos, lo que hace que presenten el valor de precisión más bajo. En cambio, la puntuación de recuerdo y F1 es la más alta en el caso de las RNA, mostrando de nuevo una diferencia considerable en el valor de recuerdo a favor de las RNA. Estos resultados indican que las ANN muestran un mejor rendimiento, ya que clasifican correctamente a la mayoría de los estudiantes que realmente pertenecen al grupo de "bajo rendimiento" (mayor recuerdo) y también revelan un mejor valor combinado entre la precisión y el recuerdo (mayor puntaje F1).

4.3. Análisis de los predictores del rendimiento académico en la educación superior

[La Tabla 6](#) muestra la importancia relativa y normalizada de los

Tabla 3
Hiperparámetros de las ANNs.

Topología	Perceptrón multicapa (MLP)
Número de nodos de entrada	122
Número de nodos de salida	2
Número de capas ocultas	1
Número de neuronas en la capa oculta	50
Número de épocas para el entrenamiento	200
tipo de aprendizaje	En línea
Función de transferencia de la capa oculta	tangente hiperbólica
Función de transferencia de la capa de salida (x 3)	Sigmoide lineal, Sigmoide y Softmax
Valores de tasa de aprendizaje (x 5)	.001, .0005, .0001, .00005, .00001
Valores de impulso (x 9)	Pasando de .1 a .9 (pasos de .1)
Función de error	Error cuadrático medio
Algoritmo de optimización	Descenso de gradiente

predictores en el grupo de "alto rendimiento". Los resultados en cinco secciones de la prueba SABER 11 (matemáticas, química, biología, español, y física), el programa académico de los estudiantes y el ingreso familiar mensual son los predictores que más contribuyen a la clasificación en el grupo de "alto rendimiento". A continuación, los predictores se agruparon utilizando el categorías presentadas en la sección 3.1.2. La Fig. 5 proporciona información sobre el contribución predictiva de cada categoría. Los resultados indican que antes rendimiento académico (39,5%), NSE de los estudiantes (22,8%), universidad antecedentes (15,1%) y las características de la escuela secundaria (10,2%) son las categorías con mayor contribución a la clasificación de los estudiantes en el grupo de "alto rendimiento".

La Tabla 7 muestra la importancia relativa y normalizada de los predictores en el grupo de "bajo rendimiento". Los resultados en cuatro secciones de la prueba SABER 11 (matemáticas, química, biología y ciencias sociales) y la edad de los estudiantes son los predictores que más contribuyen a la clasificación en el grupo de "bajo rendimiento". Los predictores de la "baja grupo de desempeño" también se agruparon utilizando las categorías presentadas en apartado 3.1.2. La figura 6 proporciona información sobre la contribución predictiva de cada categoría. Los resultados sugieren que el rendimiento académico previo (28,4 %), NSE de los estudiantes (20,3 %), formación universitaria (10,3 %) y características de la escuela secundaria (10,2%) son también las categorías con la mayor contribución a la clasificación de los estudiantes en el grupo de "rendimiento bajo".

Una comparación entre las Figs. 5 y 6 revela las contribuciones diferenciales de los predictores del rendimiento académico en la educación superior. Los logros académicos previos, el SES de los estudiantes y los antecedentes universitarios brindan más información para la clasificación en el grupo de "alto rendimiento" en lugar de en el grupo de "bajo rendimiento". Por el contrario, la casa de los estudiantes características, cómo pagan los estudiantes las tasas de matrícula, el estado del hogar de los estudiantes,

y los antecedentes de los estudiantes tienen una mayor contribución predictiva para su clasificación en el grupo de "bajo rendimiento" que en el grupo de "alto rendimiento". Si bien las características de la escuela secundaria son igualmente importantes para la clasificación en ambos grupos de desempeño, el estado laboral contribuye muy poco a la clasificación de cualquiera.

5. Discusión

Había dos objetivos de este estudio: (1) probar un procedimiento sistemático para implementar ANN para modelar dos niveles de rendimiento diferentes grupos de la prueba SABER PRO en una cohorte de 162.030 estudiantes universitarios colombianos y (2) analizar la importancia relativa del rendimiento académico previo, nivel socioeconómico, características de la escuela secundaria, y el estado de trabajo al predecir cada grupo de nivel de rendimiento.

En cuanto a la primera pregunta de investigación, los efectos encontrados en el modelo La etapa de implementación se puede resumir de la siguiente manera. Primero, es posible argumentar que una menor duración de la formación no implica una menor clasificación valores de error dado que la convergencia hacia el mínimo en el curva de error depende del número de épocas y la función de transferencia en la capa de salida. Por lo tanto, cuando el objetivo es maximizar el número de casos clasificados correctamente pertenecientes a una categoría específica, una adecuada La opción para la función de transferencia en la capa de salida es la función sigmoidea. Esto se debe a que durante el entrenamiento, la función sigmoidea comienza con un error más bajo. valores y converge más eficientemente hacia el valor mínimo de la curva de error

Además, no es aconsejable establecer aleatoriamente los valores de los hiperparámetros en un modelo ANN. Una configuración aleatoria es problemática porque podría producir efectos indeseables en el entrenamiento de las RNA como un aumento del tiempo de formación o alcanzar un mínimo local en la curva de error Una opción más aconsejable sería variar sistemáticamente los hiperparámetros de las ANN bajo un entrenamiento y prueba controlados proceso para que los valores para maximizar la clasificación de interés puedan ser alcanzada adecuadamente. Como aporte metodológico, los pasos propuestos en este estudio para el ajuste fino de los hiperparámetros de las RNA (Fig. 2) se puede replicar fácilmente para analizar varios otros conjuntos de datos educativos.

En cuanto a la segunda pregunta de investigación, el presente estudio tiene demostró cómo obtener curvas de error con la desviación estándar límites del entrenamiento de ANNs de una manera simple. Aunque no existe una regla general para seleccionar el número de repeticiones, el Los hallazgos de este estudio sugieren que 30 carreras de entrenamiento, con 200 épocas cada una, proporcionaría suficiente información para graficar las curvas de error para el conjuntos de entrenamiento y validación cruzada. Estos gráficos son importantes ya que revelan que la clasificación proporcionada por los sistemas predictivos basados en ANNs es estable durante varias repeticiones de entrenamiento. Estos gráficos también hacen




Figura 3. Curvas de error para el grupo de "alto rendimiento" ($lr=0.00005$, $m=4.2$).

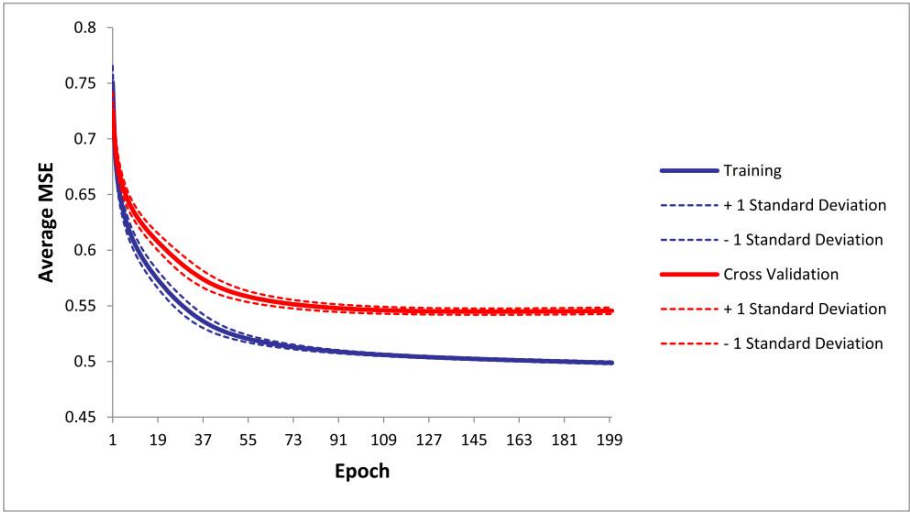


Figura 4. Curvas de error para el grupo de “bajo rendimiento” ($lr\frac{1}{4.0001}$, $m\frac{1}{4.4}$).

Tabla 4
Métricas de evaluación para el grupo de “alto rendimiento”.

	Modelo lineal generalizado	Regresión logística	Margen grande y rápido	Árbol de decisión	Bosque aleatorio	Árboles potenciados por gradiente ANN
Exactitud	93,5%	93,5%	93,4%	93,0%	93,2%	93,6%
Error de clasificación	6,5%	6,6%	6,6%	7,0%	6,8%	6,5%
Precisión	57,7%	57,5%	60,2%	49,5%	53,7%	60,7%
Recuerdo	22,6%	22,9%	16,8%	17,1%	14,7%	18,9%
Puntuación F1	0,33	0,33	0,26	0,25	0,23	0,29

Tabla 5
Métricas de evaluación para el grupo de “bajo rendimiento”.

	Modelo lineal generalizado	Regresión logística	Margen grande y rápido	Árbol de decisión	Bosque aleatorio	Árboles potenciados por gradiente ANN
Exactitud	84,2%	84,2%	84,1%	82,4%	82,4%	84,4%
Error de clasificación	15,8%	15,8%	15,9%	17,6%	17,6%	15,6%
Precisión	54,8%	54,8%	54,6%	47,7%	49,3%	58,3%
Recuerdo	36,0%	36,0%	35,7%	28,6%	44,7%	33,0%
Puntuación F1	0,43	0,43	0,43	0,36	0,47	0,42

posible verificar la convergencia de los modelos ANN hacia un mínimo sin sobreajuste.

En cuanto a la tercera pregunta de investigación, es posible argumentar que modelos predictivos basados en ANNs muestran buena calidad en comparación con varias otras metodologías predictivas. En particular, las ANN implementadas en este estudio exhibieron valores satisfactorios en las métricas de evaluación.

como la precisión, el recuerdo y la puntuación F1. La puntuación F1 equilibra la precisión y la recuperación. Por lo tanto, la puntuación de F1 obtenida implica una calificación satisfactoria equilibrio entre la precisión y el recuerdo del modelo predictivo. En conjunto, los resultados de este estudio muestran que los modelos predictivos basados en Las ANN son adecuadas para resolver problemas de clasificación con desbalance datos y tienen ventajas sobre los resultados obtenidos al implementar otras metodologías predictivas.

En cuanto a la cuarta pregunta de investigación, los hallazgos de este estudio resaltar varios puntos clave que se deben considerar cuando se predice la rendimiento académico en la educación superior. El primer punto es que antes El rendimiento académico es el predictor más importante del rendimiento académico. desempeño en las universidades. Si bien este estudio corrobora la evidencia previa sobre este tema, se encontró que el rendimiento académico previo proporciona más información para la clasificación de los de alto rendimiento. Pertenecer a un grupo de mayor rendimiento (nivel 4) implica mayor demandas cognitivas (p. ej., usar información implícita de varias fuentes de información para resolver un problema) en comparación con las habilidades requeridas para bajos niveles de rendimiento (nivel 1; por ejemplo, para identificar información explícita de una sola fuente). Si consideramos el rendimiento académico previo como un

"proxy cognitivo" en la evaluación a gran escala (Kuncel et al., 2005; Shaw et al., 2016), este hallazgo es parcialmente consistente con estudios previos que han encontrado una mayor contribución de las variables cognitivas básicas para la baja rendimiento académico (Kyndt et al., 2015; Musso et al., 2012, 2013)

Sin embargo, el rendimiento académico previo es un predictor superior para identificar ambos grupos de actuación.

El segundo punto es que el NSE de los estudiantes sí contribuye a la predicción de su desempeño académico en las universidades. Este estudio también sugiere la necesidad de considerar el nivel de medición de los indicadores SES (es decir, nivel individual, familiar o de área) ya que cada nivel proporciona un contribución a la clasificación del rendimiento académico de los estudiantes. El Los resultados de este estudio también indican que el SES de los estudiantes proporciona más información a la clasificación en el grupo de "alto rendimiento" que en el grupo de "bajo rendimiento". Tal resultado es consistente con anteriores investigación utilizando ANN (Musso et al., 2012, 2013), que también ha encontrado una mayor contribución de las variables socioeconómicas a la identificación de artistas de alto rendimiento.

El tercer punto es que las características de la escuela secundaria contribuyen igualmente a la clasificación del rendimiento académico de los estudiantes como alto o bajo. Aunque el peso predictivo de las características de la escuela secundaria podría ser confundido por otros predictores tales como estudios académicos previos rendimiento o SES de los estudiantes, se puede argumentar que las características de la escuela secundaria influyen en el rendimiento académico en las universidades (por ejemplo, Birch & Molinero, 2006; Negro et al., 2015; Pike & Saupé, 2002). Estos resultados están en acuerdo con investigaciones anteriores que utilizan ANN, que también encontraron un

Tabla 6
Pesos predictivos para el grupo de “alto rendimiento”.

Variable	Profético	normalizado
	peso	importancia
Puntaje de matemáticas de SABRE 11	0.1549	100%
Puntuación de química de SABRE 11	0.0741	47,8%
Puntaje de biología de SABRE 11	0.0420	27,2%
SABRE 11 partitura española	0.0411	26,6%
Programa académico (Matemáticas y Ciencias Naturales) ciencias)	0.0405	26,2%
Puntuación de física de SABRE 11	0.0402	26,0%
Ingreso familiar mensual	0.0249	16,1%
Puntaje de ciencias sociales de SABRE 11	0.0247	16,0%
Programa académico (Ingeniería, arquitectura, urbanismo y titulaciones afines)	0.0230	14,8%
Calendario académico de secundaria (B)	0.0201	13,0%
Beca (Si)	0.0189	12,2%
Educación de la madre (Desconocido)	0.0186	12,0%
Puntaje de filosofía SABER 11	0.0175	11,3%
Ocupación del padre (Desempleado)	0.0144	9,3%
Educación del padre (nivel de posgrado)	0.0139	9,0%
Tipo de universidad (Régimen especial)	0.0117	7,6%
Tipo de escuela secundaria (pública)	0.0108	6,9%
Tipo preparatoria (Privada)	0.0102	6,6%
Ocupación de la madre (Independiente)	0.0102	6,6%
Ocupación del padre (Trabajador no remunerado por familia) negocio)	0.0101	6,5%
Ocupación del padre (NA)	0.0097	6,2%
Programa académico (Agronomía, veterinaria, y grados relacionados)	0.0091	5,9%
Diploma académico de escuela secundaria (Desconocido)	0.0089	5,8%
Programa académico (Economía, administración, y contabilidad)	0.0089	5,7%
Tipo de universidad (Financiamiento público de los municipios) 0,0082		5,3%
Ocupación de la madre (Trabajadora doméstica) 0,0082 Número de personas a cargo	0,0078	5,3%
Ocupación de la madre (Trabajadora no remunerada por familia) negocio)	0,0077	5,1%
Ocupación de la madre (Trabajadora no remunerada por familia) negocio)	0,0077	5,0%
Tipo de universidad (Financiamiento público departamental) 0,0077		5,0%
Horario de secundaria (solo vespertino) 0,0075		4,9%
Semestre académico Horario de secundaria (día completo) 0,0072		4,7%
Programa académico (Educación)	0,0072	4,6%
Ocupación de la madre (Trabajadora en privado negocio)	0,0067	4,3%
Ocupación de la madre (Trabajadora en privado negocio)	0,0065	4,2%
Tipo de universidad (Financiación de corporación privada)	0,0065	4,2%
Educación de la madre (Licenciatura incompleto)	0,0064	4,1%
Ocupación de la madre (Otra actividad/ ocupación)	0,0062	4,0%
Tipo de universidad (Financiación de fundaciones privadas)	0,0059	3,8%
Educación de la madre (primaria incompleta)	0,0058	3,7%
Género femenino)	0,0057	3,7%
Ocupación de la madre (NA)	0,0056	3,6%
Diploma académico de escuela secundaria (Profesor capacitación)	0,0055	3,6%
Horas trabajadas semanalmente (Entre 11 y 20)	0,0055	3,6%
Recursos de los padres (No)	0,0055	3,5%
Tipo de universidad (Financiación pública nacional)	0,0054	3,5%
Estrato Hogar 6	0,0053	3,4%
Horas trabajadas semanalmente (Menos de 10)	0,0053	3,4%
Educación de la madre (Secundaria completa)	0,0053	3,4%
Hogar de la familia (No)	0,0051	3,3%
Ocupación de la madre (desempleada)	0,0051	3,3%
Estrato hogar 4 0,0049		3,1%
Ocupación de la madre (Empleada en el gobierno)	0,0045	2,9%
0,0045 Crédito educativo (Si) 0,0045		2,9%
Diploma académico de escuela secundaria (Técnico)	0,0045	2,9%
Ocupación del padre (Trabajador en empresa privada) 0,0044		2,9%
Ocupación del padre (Empleador) 0,0044		2,8%
Recursos propios (Si)	0,0043	2,8%
Composición de género de la escuela secundaria (solo para niñas)	0,0042	2,7%
Hogar estrato 0	0,0042	2,7%
Calendario académico de secundaria (F)	0,0041	2,7%
Programa académico (Social y humano) ciencias)	0,0040	2,6%
Ocupación del padre (autónomo)	0,0039	2,5%

Tabla 6 (continuación)

Variable	Profético	normalizado
	peso	importancia
Recursos propios (No)	0.0038	2,5%
Recursos de los padres (Si)	0.0038	2,5%
Educación de la madre (nivel de posgrado)	0.0038	2,4%
Composición de género de la escuela secundaria (solo niños)	0.0037	2,4%
Horario de la escuela secundaria (solo por la mañana)	0.0037	2,4%
Hogar estrato 2	0.0036	2,3%
Alojamiento permanente	0.0035	2,3%
Educación del padre (Licenciatura incompleto)	0.0035	2,3%
Horas trabajadas semanalmente (Más de 30)	0.0035	2,2%
Ocupación de la madre (Jubilada)	0.0035	2,2%
Educación del padre (Secundaria completa)	0.0034	2,2%
Diploma académico de escuela secundaria (Académico y Técnico)	0.0033	2,1%
Ocupación de la madre (Obrera)	0.0032	2,0%
Horas trabajadas semanalmente (Entre 21 y 30)	0.0031	2,0%
Ocupación madre (Trabajadora no remunerada por no negocio familiar)	0.0031	2,0%
Horas trabajadas semanalmente (0)	0.0031	2,0%
Educación de la madre (Técnico completado)	0.0030	1,9%
Género masculino)	0.0028	1,8%
Horario de la escuela secundaria (solo por la tarde)	0.0027	1,7%
Programa académico (Salud)	0.0026	1,7%
Educación del padre (Técnico completado)	0.0026	1,7%
PC en casa (No)	0.0024	1,5%
Hogar estrato 3	0.0023	1,5%
Hogar estrato 5	0.0023	1,5%
Crédito educativo (No)	0.0022	1,4%
Educación del padre (Sin educación)	0.0022	1,4%
Edad	0.0022	1,4%
Educación del padre (Secundaria incompleta)	0.0021	1,3%
Ocupación del padre (Retirado)	0.0020	1,3%
Calendario académico de secundaria (A)	0.0020	1,3%
Programa académico (Artes)	0.0019	1,2%
Ocupación del padre (Trabajador doméstico)	0.0019	1,2%
Alojamiento temporal (Para estudiar o cualquier otra razon)	0.0019	1,2%
Hogar estrato 1	0.0018	1,2%
Educación de la madre (Secundaria incompleta)	0.0018	1,1%
Educación de la madre (Licenciatura completa) 0,0017		1,1%
Ocupación del padre (Obrero) 0,0015		1,0%
Ocupación del padre (Trabajador no remunerado por no negocio familiar)	0,0015	0,9%
Horario de la escuela secundaria (solo fin de semana)	0.0014	0,9%
Educación de la madre (primaria completa)	0.0014	0,9%
Educación del padre (Técnico incompleto)	0.0014	0,9%
Educación de la madre (Técnico incompleto)	0.0014	0,9%
Ocupación de la madre (Empleador)	0.0013	0,8%
Internet en casa (Si)	0.0013	0,8%
Programa académico (No especificado)	0.0013	0,8%
PC en casa (Si)	0.0012	0,8%
Ocupación del padre (Empleado en el gobierno) 0,0012		0,8%
Ocupación del padre (Otra actividad/ocupación) 0,0011		0,7%
Educación del padre (Primaria completa) 0,0010		0,7%
Beca (No)	0,0010	0,7%
Educación del padre (primaria incompleta)	0.0010	0,6%
Horario de bachillerato (ordinario)	0.0010	0,6%
Educación del padre (Desconocido)	0.0010	0,6%
Diploma académico de escuela secundaria (académico)	0.0007	0,4%
Educación del padre (licenciatura completa)	0.0007	0,4%
Composición de género de la escuela secundaria (Coeducacional)	0.0005	0,4%
Educación de la madre (Sin educación)	0.0005	0,3%
Número de habitaciones en casa	0.0005	0,3%
Hogar de la familia (Si)	0.0005	0,3%
Internet en casa (No)	0.0004	0,3%

similar peso predictivo de los factores relacionados con la escuela a la clasificación de rendimiento académico como alto o bajo (Musso et al., 2020).

El cuarto punto es que la situación laboral no brinda mucha información para clasificar el desempeño académico de los estudiantes en la educación superior. Sin embargo, este resultado merece especial atención dado que el estado laboral se evaluó simplemente a través de una variable categórica




Figura 5. Categorías de predictores en el grupo de “alto rendimiento”.

(categorías basadas en las horas semanales trabajadas). En este sentido, pasado La investigación educativa (Wang et al., 2010; Yanbarisova, 2015) ha sugerido definir el estado laboral no solo como una categoría dicotómica sino también basado en una consideración de información adicional sobre por qué los estudiantes trabajo mientras asiste a la universidad y otras características de su trabajo.

El quinto punto es la necesidad de incluir información sobre los programas académicos de los estudiantes al analizar su rendimiento académico en las universidades, ya que los programas académicos de los estudiantes brindan información importante para su clasificación en diferentes grupos de actuación. Un hallazgo similar se ha dado en la literatura educativa (por ejemplo, De Clercq et al., 2013; Hansen y Mastekaasa, 2006). Una posible explicación para este hallazgo es que los diferentes programas académicos atraen a estudiantes cuyas habilidades y los intereses personales también son diversos. Además, el contenido de cada académico el programa podría haber afectado la preparación y el nivel de desempeño de los estudiantes en la prueba SABRE PRO. Por lo tanto, el poder predictivo de los seleccionados predictores del rendimiento académico pueden variar entre los diferentes disciplinas

5.1. Limitaciones

El presente estudio apoya el uso de ANN en la investigación educativa. y proporciona una mejor comprensión de algunos de los factores involucrados. Sin embargo, existen limitaciones en su alcance que deben ser reconocidas. En primer lugar, se encontró que los logros académicos previos contribuían más a la la clasificación del rendimiento académico de los estudiantes. Sin embargo, esto el predictor se puso en funcionamiento solo con los resultados de la prueba SABRE 11 ya que no se contaba con otra información sobre las calificaciones de los estudiantes de la escuela secundaria. disponible. Por lo tanto, la información relevante representada a través de un tradicional y un indicador ampliamente informado, como el promedio de calificaciones de la escuela secundaria (HSGPA) no se pudo incluir en este análisis. Además, todos los la información sobre las condiciones socioeconómicas de los estudiantes fue auto reportada por los estudiantes cuando se les administró el SABER PRO prueba, hecho que podría conducir a la medición inexacta de tal construcción compleja como SES. Finalmente, aunque el presente estudio utilizó un conjunto de validación cruzada para evitar el sobreajuste del modelo, más avanzado técnicas como la regularización y la deserción han sido reportadas en el literatura sobre aprendizaje automático (p. ej., Piotrowski y Napiorkowski, 2013; Srivastava et al., 2014). En particular, la implementación de estos técnicas en futuras investigaciones podría mejorar la calidad general de la modelos predictivos desarrollados.

5.2. Investigación futura

Futuras investigaciones sobre el uso de ANN para predecir el rendimiento académico de los estudiantes la actuación podría centrarse tanto en temas educativos como metodológicos. En cuanto a los temas educativos, los indicadores de rendimiento académico como ya que la tasa de retención o abandono podría explorarse más a fondo como resultados de sistemas predictivos basados en ANNs. Algunas investigaciones iniciales (Musso et al.,

Tabla 7
Pesos predictivos para el grupo de “bajo rendimiento”.

Variable	Profético peso	normalizado importancia
Puntaje de matemáticas de SABRE 11	0.0694	100%
Calificación SABRE 11 en química	0.0609	87,6%
Calificación SABRE 11 en biología	0.0443	63,8%
Calificación SABRE 11 en ciencias	0.0428	61,7%
sociales Edad Calificación SABRE 11 en español	0.0392	56,5%
Calificación SABRE 11 en física	0.0343	49,4%
Beca (No)	0.0208	29,9%
	0.0202	29,1%
Número de personas a cargo Beca (Si)	0.0188	27,1%
	0.0186	26,8%
Programa académico (Ingeniería, arquitectura, urbanismo y titulaciones afines)	0.0176	25,4%
Programa académico (Matemáticas y Ciencias Naturales) ciencias)	0.0168	24,2%
Internet en casa (Si)	0.0163	23,5%
Género femenino)	0.0162	23,3%
PC en casa (Si)	0.0161	23,2%
Tipo preparatoria (Privada)	0.0158	22,7%
Horario de la escuela secundaria (solo por la noche)	0.0153	22,0%
Tipo de escuela secundaria (pública)	0.0153	22,0%
Internet en casa (No)	0.0134	19,3%
Educación de la madre (Desconocido)	0.0133	19,2%
Programa académico (Educación)	0.0128	18,5%
PC en casa (No)	0.0118	17,0%
Puntaje de filosofía SABRE 11	0.0114	16,4%
Horas trabajadas semanalmente (Más de 30)	0.0113	16,3%
Diploma académico de escuela secundaria (Desconocido)	0.0112	16,2%
Ocupación de la madre (trabajadora no remunerada para la familia) negocio)	0.0109	15,7%
Préstamo educativo (Si)	0.0097	13,9%
Ingreso familiar mensual	0.0092	13,3%
Préstamo educativo (No)	0.0090	13,0%
Ocupación de la madre (Empleador)	0.0088	12,7%
Tipo de universidad (Financiación de corporación privada)	0.0083	12,0%
Ocupación del padre (Otra actividad/ocupación)	0.0083	11,9%
la madre (Trabajadora en negocio)	0.0082	11,9%
Recursos de los padres (Si)	0.0081	11,6%
Ocupación del padre (Trabajador no remunerado por no negocio familiar)	0.0080	11,5%
Ocupación de la madre (Obrera)	0.0080	11,5%
Programa académico (Social y humano) ciencias)	0.0079	11,4%
Recursos propios (No)	0.0079	11,3%
Recursos propios (Si)	0.0077	11,1%
Programa académico (Economía, administración, y contabilidad)	0.0077	11,1%
Horario de bachillerato (ordinario)	0.0076	11,0%
Ocupación de la madre (Independiente)	0.0075	10,8%
Género masculino)	0.0072	10,3%
Estrato Hogar 5	0.0071	10,2%
Horas trabajadas semanalmente (Entre 21 y 30)	0.0070	10,1%
Programa académico (Artes)	0.0068	9,9%
Ocupación de la madre (Empleada doméstica)	0.0068	9,8%
Recursos de los padres (No)	0.0067	9,6%
Ocupación de la madre (Otra actividad/ ocupación)	0.0065	9,4%
Educación de la madre (Licenciatura incompleto)	0.0061	8,8%
Ocupación de la madre (desempleada)	0.0061	8,8%
Tipo de universidad (Financiación de fundaciones privadas)	0.0059	8,5%
Número de cuartos en el hogar	0.0059	8,4%
Ocupación del padre (Empleador)	0.0058	8,3%
Horas trabajadas semanalmente (0)	0.0057	8,2%
Hogar de la familia (No)	0.0056	8,1%
Programa académico (Salud)	0.0055	7,9%
Ocupación de la madre (Empleada en el gobierno)	0.0054	7,7%
del padre (Trabajador doméstico)	0.0052	7,5%
Ocupación de la madre (Trabajador no remunerado por no negocio familiar)	0.0048	6,9%
Horas trabajadas semanalmente (Entre 11 y 20)	0.0048	6,9%
Educación del padre (nivel de posgrado)	0.0047	6,8%
Educación del padre (Desconocido)	0.0046	6,7%

(Continúa en la siguiente página)

Tabla 7 (continuación)

Variable	Profético peso	normalizado importancia
Programa académico (No especificado)	0.0046	6.7%
Diploma académico de bachillerato (Técnico)	0.0045	6.5%
Calendario académico de secundaria (A)	0.0045	6.4%
Educación del padre (Licenciatura incompleto)	0.0044	6.3%
Hogar de la familia (Si)	0.0044	6.3%
Hogar estrato 6	0.0043	6.3%
Educación de la madre (Técnico completado)	0.0043	6.2%
Hogar estrato 4	0.0043	6.2%
Ocupación del padre (Retirado)	0.0041	5.9%
Alojamiento temporal (Para estudiar o cualquier otra razón)	0.0041	5.9%
Calendario académico de secundaria (B)	0.0040	5.7%
Horario de la escuela secundaria (solo fin de semana)	0.0040	5.7%
Diploma académico de escuela secundaria (Académico y Técnico)	0.0039	5.7%
Educación de la madre (Secundaria incompleta)	0.0039	5.6%
Alojamiento permanente	0.0038	5.5%
Educación de la madre (Sin educación)	0.0037	5.4%
Ocupación del padre (Obrero)	0.0037	5.3%
Hogar estrato 3	0.0037	5.3%
Programa académico (Agronomía, veterinaria, y grados relacionados)	0.0035	5.0%
Educación del padre (Técnico incompleto)	0.0034	4.9%
Educación de la madre (Técnico incompleto)	0.0034	4.8%
Educación de la madre (Licenciatura completa) 0.0033 Estrato de origen 1	0.0033	4.7%
0.0029 Ocupación del padre (Trabaja por cuenta propia)	0.0029	4.2%
	0.0029	4.2%
Diploma académico de escuela secundaria (académico)	0.0029	4.1%
Educación de la madre (Secundaria completa)	0.0029	4.1%
Educación de la madre (nivel de posgrado)	0.0027	3.9%
Ocupación de la madre (NA)	0.0026	3.8%
Hogar estrato 2	0.0026	3.7%
Educación del padre (licenciatura completa)	0.0025	3.6%
Horario de secundaria (día completo)	0.0025	3.5%
Educación del padre (primaria completa)	0.0025	3.5%
Horario de la escuela secundaria (solo por la tarde)	0.0023	3.4%
Calendario académico de secundaria (F)	0.0023	3.3%
Horas trabajadas semanalmente (Menos de 10)	0.0022	3.1%
Educación de la madre (primaria incompleta)	0.0021	3.0%
Ocupación de la madre (Jubilada)	0.0019	2.7%
Educación de la madre (primaria completa)	0.0018	2.6%
Tipo de universidad (Financiamiento público departamental) 0.0016	0.0016	2.2%
Composición de género de la escuela secundaria (solo niños) 0.0015 Estrato de origen 0	0.0015	2.2%
Educación del padre (secundaria completa)	0.0015	2.1%
	0.0015	2.1%
Composición de género de la escuela secundaria (solo para niñas)	0.0014	2.0%
Tipo de universidad (Régimen especial)	0.0014	2.0%
Ocupación del padre (Empleado en el gobierno)	0.0013	1.8%
Ocupación del padre (desempleado)	0.0012	1.8%
Tipo de universidad (Financiación pública nacional)	0.0012	1.7%
Diploma académico de escuela secundaria (Profesor capacitación)	0.0012	1.7%
Ocupación del padre (Trabajador en empresa privada) 0.0011 Tipo de universidad (Financiamiento de los municipios públicos) 0.0010	0.0011	1.6%
Educación del padre (Sin educación) 0.0010 Composición de género de la escuela secundaria	0.0010	1.5%
	0.0007	1.1%
(Coeducacional)		
Educación del padre (Técnico completado)	0.0007	1.0%
Ocupación del padre (Trabajador no remunerado por familia) negocio)	0.0007	1.0%
Educación del padre (Secundaria incompleta)	0.0007	1.0%
Horario de la escuela secundaria (solo por la mañana)	0.0007	1.0%
Semestre académico	0.0005	0.8%
Ocupación del padre (NA)	0.0003	0.5%
Educación del padre (primaria incompleta)	0.0002	0.3%

2020) ha demostrado el valor de esta metodología en la predicción varios resultados académicos a lo largo de la trayectoria académica de un estudiante. En esta manera, las instituciones y los formuladores de políticas podrían hacer esfuerzos específicos para mejorar la calidad de los sistemas de educación superior y mejorar varios resultados educativos. Además, la naturaleza compleja de la relación entre SES y el rendimiento académico puede ser mejor




Figura 6. Categorías de predictores en el grupo de "bajo rendimiento".

entendido mediante el uso de enfoques no lineales como ANN, como se ha mostrado en este estudio; y más aplicaciones en diferentes poblaciones y deben explorarse las circunstancias adaptando la metodología seguida en este estudio para ser utilizado para la predicción del rendimiento académico en varios otros entornos educativos.

En cuanto a la metodología utilizada, sigue existiendo una clara necesidad de más heurísticas precisas y más generalizables cuando se usan ANN. En esto respecto, varios parámetros de las redes deben ser estudiados para mejorar entender sus funciones en los modelos. Por ejemplo, los números de las capas ocultas y las neuronas en cada capa podrían influir en su desempeño. Además, se podrían usar diferentes topologías de ANN para realizar tareas como la agrupación. Por lo tanto, topologías adicionales basadas en diferentes Se deben explorar los paradigmas de aprendizaje. Finalmente, la determinación de la los intervalos de confianza y los intervalos de predicción de las RNA también merecen consideración adicional (p. ej., De Veaux et al., 1998; He & Li, 2011).

Declaraciones sobre datos abiertos y ética

Los participantes fueron protegidos anonimizando su información personal en este estudio. Los datos se pueden obtener mediante el envío de correos electrónicos de solicitud al autor de correspondencia.

Declaración de competencia de intereses

Los autores declaran que no tienen competencia financiera conocida. intereses o relaciones personales que podrían haber parecido influir el trabajo reportado en este trabajo.

Expresiones de gratitud

Los autores desean agradecer al Instituto Colombiano de Evaluación Educativa (ICFES) por proporcionar los datos para este estudio. Esta investigación fue financiada en parte por el Departamento de Ciencias de Colombia, Tecnología e Innovación (COLCIENCIAS) bajo la Beca 756 de 2016.

Apéndice A. Datos complementarios

Los datos complementarios de este artículo se pueden encontrar en línea en <https://doi.org/10.1016/j.caeai.2021.100018>.

Referencias

Adekitan, AI y Salau, O. (2019). El impacto del desempeño de los estudiantes de ingeniería en los primeros tres años en su resultado de graduación utilizando minería de datos educativos. *Heliyon*, 5(2), Artículo e01250. <https://doi.org/10.1016/j.heliyon.2019.e01250>
Ahmad, F., Ismail, NH y Aziz, AA (2015). La predicción de los resultados académicos de los estudiantes. desempeño utilizando técnicas de minería de datos de clasificación. *Matemáticas Aplicadas Ciencias*, 9(129), 6415–6426. <https://doi.org/10.12988/ams.2015.53289>

Ahmad, Z. y Shahzadi, E. (2018). Predicción del rendimiento académico de los estudiantes mediante redes neuronales artificiales. *Boletín de Educación e Investigación*, 40(3), 157–164.

Al-barrak, MA y Al-razgan, M. (2016). Predecir el GPA final de los estudiantes utilizando árboles de decisión: un estudio de caso. *Revista internacional de tecnología de la información y la educación*, 6(7), 528–533.

Almarabeh, H. (2017). Análisis del rendimiento de los alumnos mediante el uso de diferentes clasificadores de minería de datos. *Revista internacional de educación moderna y ciencias de la computación*, 9 (8), 9–15. <https://doi.org/10.5815/ijmecs.2017.08.02>

Aluko, RO, Daniel, EI, Oshodi, OS, Aigbavboa, CO y Abisuga, AO (2018). Hacia una predicción fiable del rendimiento académico de estudiantes de arquitectura utilizando técnicas de minería de datos. *Revista de Ingeniería, Diseño y Tecnología*, 16(3), 385–397. <https://doi.org/10.1108/jedt-08-2017-0081> Álvarez, SA (2002). Una relación analítica exacta entre recuerdo, precisión y precisión de clasificación en la recuperación de información (Informe Técnico BCCS-02-01). <http://www.cs.bc.edu/~alvarez/APR/aprformula.pdf>.

Alyahyan, E. y Düs,tegor, D. (2020). Predicción del éxito académico en la educación superior: revisión de literatura y mejores prácticas. *Revista internacional de tecnología educativa en educación superior*, 17, 1–21. <https://doi.org/10.1186/s41239-020-0177-7> Anuradha, C. y Velmurugan, T. (2015). Un análisis comparativo sobre la evaluación de algoritmos de clasificación en la predicción del rendimiento de los estudiantes. *Revista india de ciencia y tecnología*, 8 (15), 1–12. <https://doi.org/10.17485/ijst/2015/v8i15/74555>

Asif, R., Merceron, A., Abbas, S. y Ghani, N. (2017). Analizar el rendimiento de los estudiantes de pregrado mediante la minería de datos educativos. *Informática y Educación*, 113, 177–194. <https://doi.org/10.1016/j.compedu.2017.05.007>

Asif, R., Merceron, A. y Pathan, MK (2015). Predicción del rendimiento académico de los estudiantes a nivel de grado: un estudio de caso. *Revista internacional de sistemas y aplicaciones inteligentes*, 7(1), 49–61. <https://doi.org/10.5815/ijisa.2015.01.05> Attoh-Okine, NO (1999). Análisis de la tasa de aprendizaje y el término de impulso en Algoritmo de red neuronal de retropropagación entrenado para predecir el rendimiento del pavimento. *Avances en software de ingeniería*, 30(4), 291–302. [https://doi.org/10.1016/S0965-9978\(98\)00071-4](https://doi.org/10.1016/S0965-9978(98)00071-4)

Beauchamp, G., Martineau, M. y Gagnon, A. (2016). Examinando el vínculo entre el estilo de apego adulto, el empleo y el rendimiento académico en el primer semestre de educación superior. *Psicología Social de la Educación: Revista Internacional*, 19(2), 367–384. <https://doi.org/10.1007/s11218-015-9329-3>

Birch, ER y Miller, PW (2006). Resultados de los estudiantes en la universidad de Australia: un enfoque de regresión por cuantiles. *Documentos económicos australianos*, 45(1), 1–17. <https://doi.org/10.1111/j.1467-8454.2006.00274.x>

Black, SE, Lincove, J., Cullinane, J. y Veron, R. (2015). ¿Puedes dejar la escuela secundaria? ¿detrás? *Revista de Economía de la Educación*, 46, 52–63. <https://doi.org/10.3386/w19842>

Bonsaksen, T. (2016). Predictores del rendimiento académico y del programa educativo satisfacción en estudiantes de terapia ocupacional. *Revista británica de terapia ocupacional*, 79(6), 361–367. <https://doi.org/10.1177/0308022615627174> Bulus, M. (2011). Orientaciones de meta, locus de control y rendimiento académico en futuros maestros: una perspectiva de diferencias individuales. *Ciencias de la educación: teoría y práctica*, 11(2), 540–546.

Cascallar, EC, Boekaerts, M. y Costigan, TE (2006). Evaluación en la evaluación de la autorregulación como proceso. *Revisión de psicología educativa*, 18 (3), 291–306. <https://doi.org/10.1007/s10648-006-9023-2>

Cascallar, E., Musso, MF, Kyndt, E. y Dochy, F. (2015). Modelado para la comprensión y para la predicción/clasificación del poder de las redes neuronales en la investigación. *Investigación de aprendizaje de primera línea*, 2(5), 67–81. <https://doi.org/10.14786/flr.v2i5.135> Chen, X., Zou, D., Cheng, G. y Xie, H. (2020). Detección de temas latentes y tendencias en tecnologías educativas durante cuatro décadas utilizando modelos de temas estructurales: una retrospectiva de todos los volúmenes de computadoras y educación. *Informática y Educación*, 151, 103855. <https://doi.org/10.1016/j.compedu.2020.103855> Chen, X., Zou, D. y Xie, H. (2020). Cincuenta años de la revista británica de educación tecnología: una perspectiva bibliométrica basada en el modelado de temas. *Revista británica de tecnología educativa*, 51 (3), 692–708. <https://doi.org/10.1111/bjjet.12907> Cliffordson, C. (2008). Predicción diferencial del éxito de los estudios en los programas académicos en el contexto sueco: la validez de las calificaciones y las pruebas como instrumentos de selección para la educación superior. *Evaluación educativa*, 13(1), 56–75.

De Clercq, M., Galand, B., Dupont, S. y Frenay, M. (2013). El rendimiento en estudiantes universitarios de primer año: un enfoque integrado y contextualizado. *Revista Europea de Psicología de la Educación*, 28(3), 641–662. <https://doi.org/10.1007/s10212-012-0133-6>

De Clercq, M., Galand, B. y Frenay, M. (2017). Transición de la escuela secundaria a la universidad: un enfoque centrado en la persona para el logro académico. *Revista Europea de Psicología de la Educación*, 32(1), 39–59. <https://doi.org/10.1007/s10212-016-0298-5> De Veaux, RD, Schumi, J., Schweinsberg, J. y Ungar, LH (1998). Intervalos de predicción para redes neuronales mediante regresión no lineal. *Tecnometría*, 40(4), 273–282. <https://doi.org/10.2307/1270528> Fausett, LV (1994). *Fundamentos de las redes neuronales*. Prentice Hall.

Campo, AP (2009). *Descubriendo estadísticas usando SPSS: (y sexo y drogas y rock 'n' roll)*. Publicaciones de salvía.

Garg, R. (2018). Predicción del desempeño de los estudiantes en diferentes regiones de Punjab utilizando técnicas de clasificación. *Revista internacional de investigación avanzada en informática*, 9 (1), 236–241. <https://doi.org/10.26483/ijarcs.v9i1.5234> Garson, GD (2014). *Modelos de redes neuronales*. Editores asociados estadísticos.

Gerken, JT y Volkwein, JF (2000, mayo). Características preuniversitarias y experiencias de primer año como predictores de resultados universitarios de 8 años. Cincinnati, OH: Documento presentado en la reunión anual de la Asociación para la Investigación Institucional.

Golino, H. y Gomes, C. (2014). Cuatro métodos de aprendizaje automático para predecir el rendimiento académico de estudiantes universitarios: un estudio comparativo. *Revista E-PSI*, 4, 68–101.

Hamoud, AK, Hashim, AS y Awadh, WA (2018). Predicción del rendimiento de los estudiantes en instituciones de educación superior mediante el análisis de árboles de decisión. *Revista internacional de multimedia interactiva e inteligencia artificial*, 5(2), 26–31. <https://doi.org/10.9781/ijimai.2018.02.004>

Hansen, MN y Mastekaasa, A. (2006). Orígenes sociales y rendimiento académico en la universidad. *Revista Sociológica Europea*, 22(3), 277–291. <https://doi.org/10.1093/esr/jci057>

Haykin, SS (2009). *Redes neuronales y máquinas de aprendizaje (Vol. 3)*. Upper Saddle River, Nueva Jersey, EE. UU.: Pearson.

Éi, S. y Li, J. (2011). Intervalos de confianza para redes neuronales y aplicaciones para modelar materiales de ingeniería. En CLP Hui (Ed.), *Redes neuronales artificiales : aplicación* (págs. 337–360). Shanghai, China: InTech.

Hwang, GJ, Xie, H., Wah, BW y Gasevic, D. (2020). Visión, desafíos, roles y temas de investigación de la Inteligencia Artificial en la Educación. *Informática y Educación: Inteligencia Artificial*, 1, 100001. <https://doi.org/10.1016/j.caeai.2020.100001> ICFES (Instituto Colombiano para la Evaluación de la Educación). (2021a). Acerca del examen SABRE 11. [Especificaciones de la prueba SABRE 11]. <http://www.icfes.gov.co/acerca-examen-saber-11>

ICFES (Instituto Colombiano para la Evaluación de la Educación). (2021a). Acerca del examen SABER PRO. [Especificaciones de la prueba SABRE PRO]. <http://www.icfes.gov.co/acerc-a-del-examen-saber-pro>

Juba, B. y Le, HS (2019). Precisión-recuperación frente a exactitud y el papel de grandes conjuntos de datos. *Actas de la Conferencia AAAI sobre Inteligencia Artificial*, 33(1), 4039–4048. <https://doi.org/10.1609/aaai.v33i01.33014039>

Kewley, R., Embrechts, M. y Breneman, C. (2000). Data strip mining para el diseño virtual de fármacos con redes neuronales. *Transacciones IEEE en redes neuronales*, 11(3), 668–679. <https://doi.org/10.1109/72.846738> Khalilzadeh, J. y Tasci, AD (2017). Gran tamaño de muestra, nivel de significación y tamaño del efecto: soluciones a los peligros del uso de big data para la investigación académica. *Gestión Turística*, 62, 89–96. <https://doi.org/10.1016/j.tourman.2017.03.026> Kingston, JA y Lyddy, F. (2013). Autoeficacia y capacidad de memoria a corto plazo como predictores del razonamiento proporcional. *Aprendizaje y diferencias individuales*, 26, 185–190. <https://doi.org/10.1016/j.lindif.2013.01.017>

Kuncel, NR, Crede, M., Thomas, LL, Klieger, DM, Seiler, SN y Woo, SE (2005). Un metanálisis de la Prueba de Admisión a la Facultad de Farmacia (PCAT) y los predictores de calificaciones del éxito de los estudiantes de farmacia. *Revista estadounidense de educación farmacéutica*, 69(3), 339–347. <https://doi.org/10.15688/aj690351>

Kuncel, NR y Hezlett, SA (2007). Las pruebas estandarizadas predicen los resultados de los estudiantes de posgrado. *éxito. Ciencia*, 315(5815), 1080–1081. <https://doi.org/10.1126/science.1136618>

Kyndt, E., Musso, M., Cascallar, EC y Dochy, F. (2015). predicción académica rendimiento: El papel de la cognición, la motivación y los enfoques de aprendizaje. Un análisis de redes neuronales V. Donche, S. De Maeyer, D. Gijbels y H. van den Bergh (Eds.). En *Desafíos metodológicos en la investigación sobre el aprendizaje de los estudiantes* (págs. 55–76). Garante.

Lau, ET, Sun, L. y Yang, Q. (2019). Modelado, predicción y clasificación del rendimiento académico de los estudiantes utilizando redes neuronales artificiales. *SN Ciencias Aplicadas*, 1, 982. <https://doi.org/10.1007/s42452-019-0884-7>

Lewandowsky, S. (2011). Capacidad de la memoria de trabajo y categorización: Individual diferencias y modelado. *Revista de Psicología Experimental: Aprendizaje, Memoria y Cognición*, 37(3), 720–738. <https://doi.org/10.1037/a0022639> Luft, CDB, Gomes, JS, Priori, D. y Takase, E. (2013). Uso de tareas cognitivas en línea para predecir el bajo rendimiento escolar en matemáticas. *Informática y Educación*, 67, 219–228. <https://doi.org/10.1016/j.compedu.2013.04.001>

McKenzie, K. y Schweitzer, R. (2001). ¿Quién tiene éxito en la universidad? Factores que predicen el rendimiento académico en estudiantes universitarios australianos de primer año. *Investigación y desarrollo de la educación superior*, 20(1), 21–33. <https://doi.org/10.1080/07924360120043621>

Mesari c, J. y Sebalj, D. (2016). Árboles de decisión para predecir el éxito académico de los estudiantes. *Revista de investigación operativa croata*, 7(2), 367–388. <https://doi.org/10.17535/corr.2016.0025>

Mohamed, MH y Waguih, HM (2017). Predicción temprana del éxito de los estudiantes utilizando una técnica de clasificación de minería de datos. *Revista Internacional de Ciencia e Investigación*, 6(10), 126–131.

Morris, A. (2011). Pruebas estandarizadas para estudiantes: prácticas actuales en los países de la OCDE y una revisión de la literatura. *Documentos de trabajo sobre educación de la OCDE*, 65, 1–51. <https://doi.org/10.1787/5kg3rp9qbnnr6-es>

Mueen, A., Zafar, B. y Manzoor, U. (2016). Modelización y predicción del rendimiento académico de los alumnos mediante técnicas de minería de datos. *Revista internacional de educación moderna y ciencias de la computación*, 11, 36–42. <https://doi.org/10.5815/ijmecs.2016.11.05> Musso, MF (2016). Comprender los fundamentos del rendimiento académico: la relación de procesos cognitivos básicos, factores de autorregulación y estrategias de aprendizaje con características de tareas en la evaluación y predicción del rendimiento académico (Publicación No. LIRIAS1941186) [Tesis doctoral, KU Leuven]. Repositorio digital de KU Leuven https://lmo.libis.be/primo-explore/search?vid=UkLirias&fromLogi n=true&sortBy=rank&lang=en_USC.

Musso, MF y Cascallar, CE (2009). *Sistemas predictivos mediante neural artificial redes: Una introducción a conceptos y aplicaciones en educación y ciencias sociales*.M. C. Richaud y JE Moreno (Eds.). En *Investigación en Ciencias del Comportamiento (Volumen I)* (págs. 433–459). CIIPME/CONICET.

Musso, M., Kyndt, E., Cascallar, E. y Dochy, F. (2012). predicción matemática rendimiento: Los efectos de los procesos cognitivos y los factores de autorregulación. *Internacional de Investigación en Educación*, 2012, 1–13. <https://doi.org/10.1155/2012/250719> Musso, MF, Kyndt, E., Cascallar, EC y Dochy, F. (2013). Predecir el rendimiento académico general e identificar la contribución diferencial de las variables participantes mediante redes neuronales artificiales. *Investigación de aprendizaje de primera línea*, 1(1), 42–71. <https://doi.org/10.14786/flr.v1i1.13>

- Musso, MF, Cascallar, EC, Bostani, N. y Crawford, M. (2020). Identificar predictores confiables de resultados educativos a través de modelos predictivos de aprendizaje automático. *Fronteras en Educación*, 5. <https://doi.org/10.3389/educ.2020.00104>. Artículo 104.
- Nimón, KF (2012). Supuestos estadísticos de análisis sustantivos a través del general modelo lineal: una mini revisión. *Fronteras en Psicología*, 3, 1–5. <https://doi.org/10.3389/psyg.2012.00322> _
- Osborne, J. y Waters, E. (2002). Cuatro suposiciones de regresión múltiple que los investigadores siempre deben probar. *Evaluación práctica, investigación y evaluación*, 8(2), 1–5. <https://doi.org/10.7275/r222-hv23> _
- P erez, PM, Costa, JLC, & Corbi, RG (2012). Un modelo explicativo del rendimiento académico basado en aptitudes, orientaciones a metas, autoconcepto y estrategias de aprendizaje. *Revista Española de Psicología*, 15(1), 48–60. https://doi.org/10.5209/rev_sjop.2012.v15.n1.37283 _ Pike, GR y Saupe, JL (2002). ¿Importa la escuela secundaria? Un análisis de tres métodos para predecir las calificaciones del primer año. *Investigación en Educación Superior*, 43, 187–207. <https://doi.org/10.1023/A:1014419724092> _ Piotrowski, AP y Napiorkowski, JJ (2013). Una comparación de métodos para evitar
- sobreajuste en el entrenamiento de redes neuronales en el caso del modelado de escorrentía de cuencas. *Revista de hidrología*, 476, 97–111. <https://doi.org/10.1016/j.jhydrol.2012.10.019> Putpuek, N., Rojanaprasert, N., Atcharyachanvanich, K. y Thamrongthanyawong, T. (2018). Estudio comparativo de modelos de predicción para el puntaje GPA final: un estudio de caso de la Universidad Rajabhat Rajanagarindra. *Actas de la 17.ª Conferencia internacional sobre informática y ciencias de la información IEEE/ACIS de 2018*, 1, 92–97. <https://doi.org/10.1109/ICIS.2018.8466475> _ Richardson, M., Abraham, C. y Bond, R. (2012). Correlatos psicológicos del rendimiento académico de estudiantes universitarios: una revisión sistemática y metanálisis.
- Boletín Psicológico, 138(2), 353–387. <https://doi.org/10.1037/a0026838> Rodríguez-Hernández, CF, Cascallar, E., & Kyndt, E. (2020). Situación socioeconómica y rendimiento académico en la educación superior: una revisión sistemática. *Revista de investigación educativa*, 29. <https://doi.org/10.1016/j.edurev.2019.100305>. Artículo 100305.
- Roll, I. y Wylie, R. (2016). Evolución y revolución de la inteligencia artificial en educación. *Revista Internacional de Inteligencia Artificial en Educación*, 26, 582–599. <https://doi.org/10.1007/s40593-016-0110-3>
- Sackett, PR, Kuncel, NR, Beatty, AS, Rigdon, JL, Shen, W. y Kiger, TB (2012). El papel del estatus socioeconómico en las relaciones de calificación SAT y en las decisiones de admisión a la universidad. *Ciencia psicológica*, 23(9), 1000–1007. <https://doi.org/10.1177/0956797612438732>
- Saito, T. y Rehmsmeier, M. (2015). El gráfico de recuperación de precisión es más informativo que el gráfico ROC cuando se evalúan clasificadores binarios en conjuntos de datos desequilibrados. *PloS One*, 10(3), Artículo e0118432. <https://doi.org/10.1371/journal.pone.0118432> Shaw, EJ, Marini, JP, Beard, J., Shmueli, D., Young, L. y Ng, H. (2016). Estudio de validez predictiva piloto SAT rediseñado: una primera mirada (Informe de investigación No. 2016-1). <https://www.collegeboard.org/>.
- Singh, W. y Kaur, P. (2016). Análisis comparativo de técnicas de clasificación para la predicción del rendimiento académico de estudiantes de ingeniería informática. *Revista internacional de investigación avanzada en informática*, 7(6), 31–36. <https://doi.org/10.26483/ijarcs.v7i6.2793>
- Sirin, S. (2005). Estado socioeconómico y rendimiento académico: una revisión metaanalítica de la investigación. *Revisión de Investigación Educativa*, 75(3), 417–453. <https://doi.org/10.3102/00346543075003417>
- Sivasakthi, M. (2017). Algoritmos de minería de datos basados en clasificación y predicción para predecir el rendimiento de programación introductoria de los estudiantes. *Actas de la Conferencia Internacional sobre Computación e Informática Inventivas (ICICI) de 2017*, 1, 346–350. <https://doi.org/10.1109/icici.2017.8365371>
- Somers, MJ y Casal, JC (2009). Uso de redes neuronales artificiales para modelar la no linealidad: el caso de la relación entre satisfacción laboral y desempeño laboral. *Métodos de investigación organizacional*, 12(3), 403–417. <https://doi.org/10.1177/1094428107309326>
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I. y Salakhutdinov, R. (2014). Abandono: una forma sencilla de evitar el sobreajuste de las redes neuronales. *The Journal of Machine Learning Research*, 15(56), 1929–1958.
- Steinmayr, R., Ziegler, M. y Träuble, B. (2010). ¿La inteligencia y la atención sostenida interactúan en la predicción del rendimiento académico? Aprendizaje y diferencias individuales, 20(1), 14–18. <https://doi.org/10.1016/j.lindif.2009.10.009>
- Tacq, J. (1997). Técnicas de análisis multivariante en la investigación en ciencias sociales. *Del problema al análisis*. Publicaciones de salvia.
- El Banco Mundial. (2012). Revisión de Políticas nacionales para la educación: Educación terciaria en Colombia 2012. Publicaciones de la OCDE.
- Triventi, M. (2014). ¿Trabajar durante la educación superior afecta el rendimiento académico de los estudiantes? ¿progresión? *Revista de Economía de la Educación*, 41(C), 1–13. <https://doi.org/10.1016/j.econedurev.2014.03.006> _ Van Ewijk, R. y Slegers, P. (2010). El efecto del estatus socioeconómico de los compañeros en el rendimiento estudiantil: un metanálisis. *Revista de investigación educativa*, 5(2), 134–150. <https://doi.org/10.2139/ssrn.1402645> _
- Wang, H., Kong, M., Shan, W. y Vong, SK (2010). Los efectos de hacer trabajos a tiempo parcial en el rendimiento académico de los estudiantes universitarios y la vida social en una sociedad china. *Revista de Educación y Trabajo*, 23(1), 79–94. <https://doi.org/10.1080/13639080903418402> Win, R. y Miller, PW (2005). Los efectos de los factores individuales y escolares en el rendimiento académico de los estudiantes universitarios. *The Australian Economic Review*, 38(1), 1–18. <https://doi.org/10.1111/j.1467-8462.2005.00349.x> Yanbarisova, DM (2015). Los efectos del empleo estudiantil en el rendimiento académico en las instituciones de educación superior de Tatarstán. *Educación y sociedad rusas*, 57(6), 459–482. <https://doi.org/10.1080/10609393.2015.1096138> Yassein, NA, Helali, RGM y Mohomad, SB (2017). Tecnología de la información e ingeniería de software que predicen el rendimiento académico de los estudiantes en KSA utilizando técnicas de minería de datos. *Revista de tecnología de la información e ingeniería de software*, 7(5), 1–5. <https://doi.org/10.4172/2165-7866.1000213> Yeh, IC y Cheng, WL (2010). Análisis de sensibilidad de primer y segundo orden de MLP.
- Neurocomputación, 73(10–12), 2225–2233. <https://doi.org/10.1016/j.neucom.2010.01.011> _ Yıldıız Aybek, HS y Okur, MR (2018). Predicción de logros con redes neuronales artificiales: el caso del sistema educativo abierto de la universidad Anadolu. *Revista internacional de herramientas de evaluación en educación*, 5(3), 474–490. <https://doi.org/10.21449/ijate.435507> _
- Zheng, JL, Saunders, KP, Shelley, II, Mack, C. y Whalen, DF (2002). Predictores del éxito académico para estudiantes de primer año de residencia. *Revista de Desarrollo de Estudiantes Universitarios*, 43(2), 267–283.